

国际科技智库动态简报（2026-07-05）

新增概览

新增条目：32

P0/P1重点：27

涉及机构：3

高频主题：AI治理，中国与上海相关，科技治理，数字经济，国防AI，科技创新

P0/P1重点

[P0] AI智能体让新手具备进攻性网络能力

机构：RAND

主题：AI治理，国防AI，数字经济，科技创新

链接：https://www.rand.org/pubs/research_reports/RRA3892-2.html

摘要：该报告比较AI智能体和人类在进攻性网络任务中的表现，结论是AI智能体已经降低网络攻击门槛，使非专业人员更容易完成侦察、漏洞利用和攻击链组织。对中国和上海网络安全治理的意义在于，AI安全议题需要同网络攻防、关键基础设施防护、企业红队测试和模型工具调用权限联动。

[P0] 出口管制与出口促进的AI治理权衡

机构：Institute for AI Policy and Strategy

主题：AI治理，中国与上海相关，科技治理

链接：<https://www.governance.ai/research-paper/export-controls-and-export-promotion>

摘要：该文讨论美国前沿 AI 政策中出口管制与出口促进之间的张力。出口管制试图限制高风险能力、算力和半导体设备向中国扩散，出口促进则强调通过算力基础设施、技术援助、云服务和贸易安排把美国 AI

嵌入关键国际市场。其研究价值在于把 AI 安全、产业竞争和地缘技术政策放在同一政策组合中观察，提示单纯限制或单纯扩散都会带来治理成本。对中国与上海相关研判而言，该条目可用于比较算力、模型、云服务和标准输出的政策边界。

[P0] 前沿AI监管：管理公共安全新兴风险

机构：Institute for AI Policy and Strategy

主题：AI治理，科技治理

链接：<https://www.governance.ai/research-paper/frontier-ai-regulation-managing-emerging-risks-to-public-safety>

摘要：该文是前沿 AI 监管框架的基础性文本，聚焦高度能力基础模型可能突然出现危险能力、部署后难以防止滥用、能力容易扩散等公共安全挑战。文章提出三类监管构件：一是形成前沿 AI 开发者安全要求的标准制定过程，二是通过注册和报告制度让监管者获得开发过程可见性，三是建立确保安全标准被执行的合规机制。其政策价值在于把行业自律、政府监督、许可制度、预部署风险评估、外部审查和发布后监测放在同一治理架构中，为后续前沿模型监管提供了早期制度蓝图。

[P0] 中国大语言模型格局的近期趋势

机构：Institute for AI Policy and Strategy

主题：AI治理，中国与上海相关

链接：<https://www.governance.ai/research-paper/recent-trends-chinas-llm-landscape>

摘要：该报告梳理中国大规模预训练模型的发展格局，以 26 个中国大模型样本为对象，描述其文本、图像和视频生成能力，并强调政府、产业和高校科研机构协同对模型项目推进的作用。报告同时关注中国关于技术民族主义、AI 治理和伦理的讨论。对涉华研判而言，该条目具有基础资料价值：它把中国大模型发展置于模型能力、组织协同和治理叙事三条线索中观察，可用于后续比较中国与欧美前沿模型生态、政策约束和产业组织方式。

[P0] AGI过渡期降低战略风险与促进稳定的Rideout策略

机构：RAND

主题：AI治理，中国与上海相关

链接：<https://www.rand.org/pubs/perspectives/PEA4347-1.html>

摘要：该观点报告提出AGI过渡期的风险缓释策略，强调在能力跃迁、战略不信任和大国竞争叠加时，通过减速、透明、危机沟通和核稳定安排降低误判风险。对上海前沿AI治理的启示在于，面向通用智能的产业布局需要同步配置风险阈值、国际沟通和公共部门技术评估能力。

[P0] 从图灵到明日：英国AI监管路径

机构：Institute for AI Policy and Strategy

主题：AI治理，科技治理

链接：<https://www.governance.ai/research-paper/from-turing-to-tomorrow-the-uks-approach-to-ai-regulation>

摘要：该文梳理英国 AI

监管路径，指出英国在欧盟严格法制化路径与美国较弱风险约束之间形成了相对独特的制度位置：强调促进创新，同时通过 AI 安全研究所和国际 AI

安全峰会提升前沿风险协调能力。文章主张英国下一阶段需要建立灵活、原则导向的监管机构，覆盖最先进 AI

开发、生物设计工具风险、AI 生成虚假信息、版权、歧视和 AI

智能体等议题。其价值在于提供一种以监管能力和制度协调为中心的 AI

治理样本，可用于比较欧盟、美国与英国路径。

[P0] 前沿AI安全论证模板：网络能力不足论证

机构：Institute for AI Policy and Strategy

主题：AI治理，数字经济

链接：<https://www.governance.ai/research-paper/safety-case-template-for-frontier-ai-a-cyber-inability-argument>

摘要：该文提供前沿 AI 安全论证模板，聚焦“模型不具备造成不可接受网络风险的能力”这一论证路径。文章把总体安全主张拆解为风险模型、代理任务、评估设置、评估结果和证据链，并用 Claims-Arguments-

Evidence 框架把隐含的安全判断转化为可审查结构。其核心意义在于把前沿模型安全从笼统承诺推进到可陈述、可核验、可质疑的论证体系。对 AI 治理而言，该材料可用于设计安全案例、第三方评估和高风险模型发布前审查。

[P0] 审议自主武器治理

机构：Institute for AI Policy and Strategy

主题：AI治理，国防AI

链接：<https://www.governance.ai/research-paper/deliberating-autonomous-weapons>

摘要：该文围绕 Stuart Russell 关于致命自主武器禁令的论述展开，认为在主要大国不愿放弃具有军事

重要性的替代性技术时，单纯禁令很难形成有效军控。文章提出以不扩散作为替代治理路径，重点防止先进且有效的自主武器能力扩散，同时通过安全保证降低相关国家放弃某些防御手段的成本。该材料对国防 AI

研究的价值在于，它把自主武器治理从伦理禁令转向战略稳定、技术扩散和大国安全承诺问题，适合用于观察 AI 军控可行性。

[P0] 布鲁塞尔效应与人工智能

机构：Institute for AI Policy and Strategy

主题：AI治理，科技治理

链接：<https://www.governance.ai/research-paper/brussels-effect-ai>

摘要：该报告讨论欧盟 AI 监管能否向全球扩散并形成“布鲁塞尔效应”。文章区分事实层面的扩散，即企业为了服务欧盟市场而在非欧盟市场调整产品；以及法律层面的扩散，即其他司法辖区借鉴欧盟规则。围绕拟议中的欧盟 AI

法案，作者判断欧盟部分监管制度可能同时产生 de facto 与 de jure 效应，尤其会影响拥有高风险

AI 系统的大型美国科技公司。其政策意义在于：如果欧盟率先操作化“可信、人本

AI”，其规则设计将具有全球治理外溢性。

[P1] AI生物设计工具可验证审计轨迹方案

机构：RAND

主题：AI治理，数字经济

链接：<https://www.rand.org/pubs/perspectives/PEA4613-1.html>

摘要：该报告提出面向AI生物设计工具的可验证日志制度，通过不可篡改审计轨迹记录用户、模型、工具调用和设计输出，以便在保护商业机密的同时支持生物安全追责。该机制对AI+生物制造、合成生物学平台监管和上海生命科学产业治理具有直接参考价值。

[P1] 习近平时代中国科技产业战略：压力下的生产体系

机构：RAND

主题：中国与上海相关，先进制造

链接：https://www.rand.org/pubs/research_reports/RRA4012-1.html

摘要：该报告分析习近平时代中国科技产业战略，认为中国在外部压力和内部增长约束下，通过产业政策、贸易、规划和国家动员体系推动韧性生产与技术自主。对上海而言，这类外部研判可用于观察美国智库如何理解中国先进制造、供应链安全和科技竞争政策。

[P1] 前沿AI安全框架的第三方合规审查

机构：Institute for AI Policy and Strategy

主题：AI治理

链接：<https://www.governance.ai/research-paper/third-party-compliance-reviews-for-frontier-ai-safety-frameworks>

摘要：该文讨论前沿 AI 企业安全框架如何接受第三方合规审查。文章关注审查主体独立性、信息来源、合规判断方法、外部披露范围、审查结果如何影响开发部署决策，以及审查时点安排。其判断意义在于指出企业自设安全框架不足以支撑公共信任，还需要可验证的外部审查机制；但第三方审查也会带来信息安全、成本和声誉风险，需要通过分层披露和行业成熟实践加以控制。

科技创新与AI治理

[P1] Center for Security and Emerging Technology | 五角大楼僵局凸显AI战争应用的关键时刻

[P2] Center for Security and Emerging Technology | 数据要素×三年行动计划

[P2] Center for Security and Emerging Technology | 加快科技金融体系建设支持高水平科技自立自强的政策措施

[P0] Institute for AI Policy and Strategy | 出口管制与出口促进的AI治理权衡

[P0] Institute for AI Policy and Strategy | 从图灵到明日：英国AI监管路径

[P0] Institute for AI Policy and Strategy | 前沿AI安全论证模板：网络能力不足论证

[P1] Institute for AI Policy and Strategy | 前沿AI安全框架的第三方合规审查

[P0] Institute for AI Policy and Strategy | 前沿AI监管：管理公共安全新兴风险

涉华/涉沪判断

[P2] Center for Security and Emerging Technology | 数据要素×三年行动计划 | <https://cset.georgetown.edu/publication/china-data-3-year-action-plan-2024-2026/>

[P2] Center for Security and Emerging Technology | 加快科技金融体系建设支持高水平科技自立自强的政策措施 | <https://cset.georgetown.edu/publication/china-tech-finance-measures/>

[P0] Institute for AI Policy and Strategy | 出口管制与出口促进的AI治理权衡 | <https://www.governance.ai/research-paper/export-controls-and-export-promotion>

[P0] Institute for AI Policy and Strategy | 中国大语言模型格局的近期趋势 | <https://www.governance.ai/research-paper/recent-trends-chinas-llm-landscape>

[P0] RAND | AGI过渡期降低战略风险与促进稳定的Rideout策略 | <https://www.rand.org/pubs/perspectives/PEA4347-1.html>

[P1] RAND | 习近平时代中国科技产业战略：压力下的生产体系 | https://www.rand.org/pubs/research_reports/RRA4012-1.html

[P2] RAND | 入侵之后：中国如何思考统治台湾问题 | https://www.rand.org/pubs/external_publications/EP71373.html

[P2] RAND | 中国全球卫生战略演变及其对美国的影响 | https://www.rand.org/pubs/external_publications/EP71376.html

新增索引

[P1] Institute for AI Policy and Strategy | 前沿AI模型数量趋势及2028年预测 | <https://www.governance.ai/research-paper/trends-in-frontier-ai-model-count-a-forecast-to-2028>

[P1] Institute for AI Policy and Strategy | 美国地方官员对AI影响与治理的看法 | <https://www.governance.ai/research-paper/local-us-officials-views-on-the-impacts-and-governance-of-ai-evidence-from-2022-and-2023-survey-waves>

[P1] Institute for AI Policy and Strategy | AI中的发声与访问：全球AI多数参与治理与能力建设 | <https://www.governance.ai/research-paper/voice-and-access-in-ai-global-ai-majority-participation-in-artificial-intelligence-development-and-governance>

[P1] Institute for AI Policy and Strategy | 前沿AI模型第三方研究的结构化访问 | <https://www.governance.ai/research-paper/structured-access-for-third-party-research-on-frontier-ai-models>

[P1] Institute for AI Policy and Strategy | STREAM化学生物：AI模型报告评估透明披露标准 | <https://www.governance.ai/research-paper/stream-chembio-a-standard-for-transparently-reporting-evaluations-in-ai-model-reports>

[P1] Institute for AI Policy and Strategy | 内部评估不足：通用目的AI第三方缺陷披露机制 | <https://www.governance.ai/research-paper/in-house-evaluation-is-not-enough-towards-robust-third-party-flaw-disclosure-for-general-purpose-ai>

[P1] Institute for AI Policy and Strategy | 前沿AI开发者的监管监督 | <https://www.governance.ai/research-paper/regulatory-supervision-of-frontier-ai-developers>

[P1] RAND | 供应链、能源与AI交汇：评估AI能源供应链脆弱性 | https://www.rand.org/pubs/research_reports/RRA4707-1.html

[P1] RAND | 青少年转向聊天机器人寻求心理健康帮助：需要安全规则 | <https://www.rand.org/pubs/commentary/2026/07/teens-are-turning-to-chatbots-for-mental-health-help.html>

[P1] RAND | 核酸合成筛查不对称性叠加：强化全球生物安全治理的政策路径 | https://www.rand.org/pubs/external_publications/EP71386.html

[P1] RAND | LLM智能体能否选择并调用生物工具：初步生物安全评估 | https://www.rand.org/pubs/external_publications/EP71387.html

org/pubs/research_reports/RRA4741-1.html

[P1] RAND | 超越政府监管工具箱：企业与社会组织缓释变革性AI风险 | https://www.rand.org/pubs/research_reports/RRA4522-1.html

org/pubs/research_reports/RRA4522-1.html

[P1] RAND | AI世界中人类情报为何更重要 | <https://www.rand.org/pubs/commentary/2026/06/why-human-intelligence-matters-more-in-an-ai-world.html>

[P1] RAND | 如果AI接管，我们会知道吗：Benjamin Boudreaux问答 | <https://www.rand.org/pubs/commentary/2026/06/will-we-know-if-ai-takes-over-qa-with-benjamin-boudreaux.html>

[P1] Center for Security and Emerging Technology | 五角大楼僵局凸显AI战争应用的关键时刻 | <https://cset.georgetown.edu/article/pentagon-standoff-is-a-decisive-moment-for-how-ai-will-be-used-in-war/>

[P2] RAND | 入侵之后：中国如何思考统治台湾问题 | https://www.rand.org/pubs/external_publications/EP71373.html

[P2] RAND | 中国全球卫生战略演变及其对美国的影响 | https://www.rand.org/pubs/external_publications/EP71376.html

[P2] RAND | 解放军海军维修管理方式：茶壶煮饺子的组织隐喻 | https://www.rand.org/pubs/research_reports/RRA3368-1.html

[P2] Center for Security and Emerging Technology | 数据要素×三年行动计划 | <https://cset.georgetown.edu/publication/china-data-3-year-action-plan-2024-2026/>

[P2] Center for Security and Emerging Technology | 加快科技金融体系建设支持高水平科技自立自强的政策措施 | <https://cset.georgetown.edu/publication/china-tech-finance-measures/>

后续推进

对P0/P1条目补充中文研判、页码级证据和可复用表述。