

戦略プロポーザル

コグニティブセキュリティー

～デジタル社会における自律的な意思決定の支援～

STRATEGIC PROPOSAL

Cognitive Security

- Supporting Self-reliant Decision-making in the Digital Society -

研究開発戦略センター（CRDS）は、国の科学技術イノベーション政策に関する調査、分析、提案を中立的な立場に立つて行う公的シンクタンクの一つで、文部科学省を主務省とする国立研究開発法人科学技術振興機構（JST）に属しています。

CRDSは、科学技術分野全体像の把握（俯瞰）、社会的期待の分析、国内外の動向調査や国際比較を踏まえて、さまざまな分野の専門家や政策立案者との対話を通じて、「戦略プロポーザル」を作成します。「戦略プロポーザル」は、今後国として重点的に取り組むべき研究開発の戦略や、科学技術イノベーション政策上の重要課題についての提案をまとめたものとして、政策立案者や関連研究者へ配布し、広く公表します。

公的な科学技術研究は、個々の研究領域の振興だけでなく、それらの統合によって社会的な期待に応えることが重要です。「戦略プロポーザル」が国の政策立案に活用され、科学技術イノベーションの実現や社会的な課題の解決に寄与することを期待しています。

さらに詳細は、下記ウェブサイトをご覧ください

<https://www.jst.go.jp/crds/>

エグゼクティブサマリー

本戦略プロポーザルの目的は、さまざまな情報が氾濫するデジタル社会において、情報サービスの利用者である人間の自律的な意思決定を支援し、悪意のある情報や偏った情報から人や社会を守ることである。これにより、デジタル化によってもたらされるさまざまな可能性や恩恵が広く享受される社会の実現に貢献することを目指す。

本戦略プロポーザルにおけるコグニティブセキュリティとは、「デジタル社会において、人間の脆弱性となりうる認知に、悪影響を及ぼす情報から人・社会を守ること」である。また、コグニティブセキュリティにおける自律的な意思決定とは、「悪意のある情報や偏った情報にだまされたり依存したりすることによる、本人にとって望まない結果をもたらすことのない意思決定」¹とここでは定義する。

近年、情報技術の進展に伴い社会のデジタル化が急速に進み、人工知能（AI）やSocial Networking Service（SNS）といった情報技術の登場によって、利便性は大きく向上した。一方で、AIが悪用されれば、真偽の判断が困難な情報が容易かつ大量に生成されることも可能となり、SNSを通じてそれらを広範囲にかつ瞬時に拡散できるような環境も整っている。さらに、SNS上ではフィルターバブル²やエコーチェンバー²と呼ばれる現象により、利用者が特定の偏った情報に囲まれる状況が加速している。このような状況が深刻化する現在のデジタル社会では、人間の認知の隙、すなわち「認知的脆弱性」を狙った巧妙なフィッシングメールやフェイクニュース、世論操作を意図してSNS上で拡散される情報などが脅威となり、個人や組織、さらには社会全体に悪影響を及ぼしている。こうした脅威の内容や規模によっては国家の安全保障を揺るがしかねない深刻な脅威ともなる。

このような脅威に対処するためには、情報システムをサイバー攻撃から守る従来のサイバーセキュリティのみでは不十分である。情報を受け取る人間の認知的脆弱性を、脅威から守り、自律的な意思決定を支援するコグニティブセキュリティの確立が不可欠である。本戦略プロポーザルでは、このようなコグニティブセキュリティに関する研究開発戦略を提案する。

人間の認知的脆弱性を突く情報（以降、「脅威情報」と呼ぶ）に対しては、これまでもさまざまな対策が講じられてきた。現在の中心的な対策は、事前に検証したフィッシングメールの発信者やフィッシングサイトのアドレス情報などに基づき、脅威情報のフィルタリングや無効化を行うことにより、脅威情報を利用者に到達させないための対策（脅威情報が利用者に到達する前の「事前対策」）である³。しかし、AIやSNSといった情報技術の進展により、こうした事前対策をすり抜けて利用者に到達する脅威情報が増加している。また、事前対策は既知の脅威情報を対象とするため、未知の脅威情報は防ぎきれず、対策が後追いになってしまう。このような現行対策の問題点を克服し、多様化・高度化する脅威情報に対応するために、次の目標に向けて、研究開発に取り組む。

- 1 一般に自律的な意思決定では、本人が望まない結果をもたらす意思決定もありうる。本戦略プロポーザルでは、悪意のある情報や偏った情報に対して、だまされるといった明確な不利益や利用者の価値観との乖離といった望まない結果をもたらすことのない意思決定を支援することを目指しており、本戦略プロポーザルにおける自律的な意思決定を上述のように定義した。
- 2 フィルターバブル、エコーチェンバーについては、「付録D 専門用語解説」を参照いただきたい。
- 3 事前対策の他に、利用者がフィッシングメールやフィッシングサイトにアクセスした時に警告する即時対策や、ファクトチェックやリテラシー教育なども実施されている。これらの手法は一定の効果を有するが、脅威情報に対して利用者が必ずしも適切な判断ができるとは限らず、脅威情報にだまされたり依存したりして、本人が望まない結果をもたらす可能性が残る。そのため、本戦略プロポーザルでは、事前対策を現在の中心的な対策とした。詳細は、「2.1.3 現行対策と問題点」を参照いただきたい。

- 情報サービスの利用者（人間）に到達してしまう脅威情報への対策を加えた、広範な対策⁴
- 将来出現しうる新たな脅威への予見的（プロアクティブ）な対策

目標に示した対策を実現するには、脅威情報を受け取って意思決定を行う人間が有する認知的脆弱性に関する知見を蓄積し、この知見に基づいて新たな対策を創出することが極めて有効である。その実現に向けて、次の二つの研究開発課題の推進を提案する。

【研究開発課題1】デジタル社会における人間の認知的脆弱性の体系化と原因説明、新たな脅威の予測

デジタル社会における人間の認知的脆弱性を、コグニティブセキュリティーの観点から体系化し、認知的脆弱性の原因説明、および新たな脅威の予測を行う。

【研究開発課題2】人間の認知的脆弱性の知見に基づく対策手法の創出

研究開発課題1で得られた知見を活用し、認知的脆弱性を突く脅威情報から利用者を守り、利用者の自律的な意思決定を支援するための対策手法を創出する研究開発を進める。

認知的脆弱性に関する知見に基づいて新たな対策を創出するためには、認知に関する研究分野と対策を創出する研究分野を分野横断的に連携させて推進する必要がある。そのために次の二つの推進方策を提案する。

【推進方策1】コグニティブセキュリティー研究コミュニティを通じた分野横断的な研究開発の推進

コグニティブセキュリティーの研究開発をけん引する研究者が主体となって、人間の認知に関する研究分野と対策を創出する情報技術などの研究分野が分野横断的に連携する「コグニティブセキュリティー研究コミュニティ」を構築し、研究コミュニティを通じて研究開発を推進する。

【推進方策2】ファンディングプログラムによる研究開発の加速

推進方策1により、研究者が主体となって、分野横断的な連携を推進することと並行して、現在顕在化しているフィッシングやSNS上の偽・誤情報などの脅威への対応を急ぐために、問題解決型の目標を設定し、ファンディングプログラムによって研究開発を加速する。

コグニティブセキュリティーの研究開発を推進することにより、人間の認知的脆弱性につながる原因を説明し、その知見に基づき、既知の脅威だけでなく未知の脅威に対する対策手法を創出する。この対策手法を社会実装することにより、利用者の自律的な意思決定を支援することが可能となり、個人、組織、さらには社会全体に悪影響を及ぼすさまざまな問題への対策に寄与することが期待できる。

本戦略プロポーザルで提案するコグニティブセキュリティーが対象とする人間の認知的脆弱性は、文化、価値観、社会規範などにより異なる場合があるため、他国で得られた研究成果をそのままわが国に全て適用できるとは限らない。わが国固有の社会的・文化的特性を踏まえ、主体的に研究開発を推進することが不可欠である。

4 広範な対策とは、現在の中心的な対策である事前対策のみならず、脅威情報が利用者に到達した時点の「即時対策」、および到達した後の「事後対策」を加えた対策とする。

Executive Summary

The purpose of this strategic proposal is to support users of information services in making self-reliant decisions and to protect individuals and society against malicious or biased information in digital society. Consequently, it will contribute to making a future where the diverse benefits of digitalization can be fully realized.

In this strategic proposal, “Cognitive Security” is defined as protecting individuals and society from information that negatively impacts human cognition, which can function as a vulnerability in digital society. From the perspective of Cognitive Security, we define Self-reliant Decision-making as “decision-making that does not lead to outcomes that individual does not intend, as a result of being deceived by or becoming dependent on malicious or biased information.”

In recent years, rapid digitalization—driven by the technologies such as Artificial Intelligence (AI) and Social Networking Services (SNS)—has significantly improved a convenience. At the same time, the misuse of AI has made it possible to easily generate vast amounts of information that is difficult to distinguish between the real and the fake, and the current digital environment enables such information to spread instantly and extensively via SNS. Furthermore, phenomena such as “filter bubbles” and “echo chambers” on SNS are accelerating the tendency for users to be surrounded by specific, biased information. In today’s digital society, sophisticated phishing emails, fake news, and other information intending opinion manipulation target “cognitive vulnerability” and affect individuals, organizations, and society. In some cases, these have become serious threats that could undermine national security.

To address these threats, “Cybersecurity”, which protects information systems from cyberattacks, is not sufficient. It is necessary to establish “Cognitive Security” to protect humans from information that exploits cognitive vulnerabilities and to support self-reliant decision-making. This strategic proposal proposes R&D tasks and promotion strategies for Cognitive Security.

Various countermeasures have been taken against the threat, such as phishing, fake news, and opinion manipulation (hereinafter referred to as “threat information”). The current primarily approach is “pre-arrival countermeasures,” in which threat information is verified and learned in advance, and known threats are then filtered out or invalidated before they reach users. However, as information technology evolves, an increasing amount of threat information is bypassing these countermeasures. Moreover, since pre-arrival countermeasures target known threats, they are unable to fully prevent unknown threats.

To overcome these limitations and respond to diversifying and sophisticated threats, we need to achieve the following goals:

- To create comprehensive countermeasures⁵ for threat information that reaches the user of information services, and

⁵ Comprehensive countermeasures refer to a multi-layered countermeasures that includes not only “pre-arrival countermeasures” but also “real-time countermeasures” at the point of contact and “post-pre-arrival countermeasures” after threat information reach the user.

- To create countermeasures to prevent emerging future threats.

To achieve these goals, it is extremely effective to create new countermeasures that incorporate insights into the cognitive vulnerability who receive threat information and make decisions. This strategic proposal proposes the following two R&D tasks:

[R&D Task 1] Systematization and identifying the mechanism of human cognitive vulnerabilities in a digital society, and prediction of new threats

This foundational R&D task aims to systematize human cognitive vulnerabilities, identify the mechanism, and predict new threats.

[R&D Task 2] Creation of countermeasures based on insights into human cognitive vulnerabilities

This R&D task focuses on creating practical methods to protect users from information that exploits cognitive vulnerabilities and to support self-reliant decision-making, utilizing the insights from R&D Task 1.

To create new countermeasures based on these insights, it is necessary to promote cross-disciplinary collaboration between cognitive research and security technology. This strategic proposal proposes the following two promotion strategies:

[Strategy 1] Promoting Interdisciplinary R&D through the “Cognitive Security Research Community”

To promote R&D in Cognitive Security, leading researchers establish the Interdisciplinary “Cognitive Security Research Community”. This community facilitates interdisciplinary collaboration by integrating fields focused on human cognition with information technology sectors dedicated to developing countermeasures. Through this community, we will continue R&D for Cognitive Security.

[Strategy 2] Acceleration of R&D through Funding Programs

In parallel with Strategy 1, we will establish mission-oriented funding programs to accelerate R&D toward specific problem, such as phishing, fake news, and public opinion manipulation on social media.

By advancing R&D in Cognitive Security, we will be able to support the self-reliant decision-making of users in a digital society. Consequently, it is expected to contribute to countermeasures against various issues that negatively impact individuals, organizations, and society.

Since the human cognitive vulnerabilities addressed in Cognitive Security can vary based on culture, values, and social norms, research results from other countries may not always be directly applicable to Japan. It is necessary to proactively promote R&D that accounts for Japan’s unique social and cultural characteristics.

目次

1	研究開発の内容	1
2	研究開発を実施する意義	3
2.1	現状認識および問題点	3
2.2	社会・経済的効果	9
2.3	科学技術上の効果	10
3	具体的な研究開発課題	11
3.1	【研究開発課題1】デジタル社会における人間の認知的脆弱性の体系化と原因解明、新たな脅威の予測	12
3.2	【研究開発課題2】人間の認知的脆弱性の知見に基づく対策手法の創出	14
4	研究開発の推進方法および時間軸	16
	【推進方策1】コグニティブセキュリティー研究コミュニティを通じた分野横断的な研究開発の推進	17
	【推進方策2】ファンディングプログラムによる研究開発の加速	18
	【時間軸】	19
付録A	検討の経緯	21
A-1	科学技術未来戦略ワークショップ	21
A-2	専門家へのインタビュー	22
付録B	国内外の状況	24
B-1	国内外の研究プログラム・政策の状況	24
B-2	論文数の推移	25
付録C	現行対策の事例	28
付録D	専門用語解説	30
付録E	参考文献	32

1 | 研究開発の内容

本戦略プロポーザルでは、さまざまな情報が氾濫するデジタル社会において、情報サービスの利用者である人間の自律的な意思決定を支援し、悪意のある情報や偏った情報から人や社会を守るコグニティブセキュリティの研究開発戦略を提案する。

具体的には、図1に示すように、AIやSNSなどの情報技術の進展により深刻化している脅威に対して、現在の中心的な対策である「脅威情報が利用者（人間）に到達する前の対策（事前対策）」のみならず、「情報サービスの利用者に到達してしまう脅威情報への対策を加えた、広範な対策」を目指すものである。




図1 研究開発の全体像

利用者に到達してしまう脅威情報への対策には、脅威情報を受け取り意思決定する際の人間の認知的脆弱性に関する知見を獲得し、その知見に基づく利用者側に着目した対策手法の創出が求められる。その実現のため、次の二つの研究開発課題を提案する。

【研究開発課題1】デジタル社会における人間の認知的脆弱性の体系化と原因解明、新たな脅威の予測

デジタル社会における人間の認知的脆弱性を、コグニティブセキュリティの観点からコグニティブセキュリティのための認知マップ⁶（以降、「コグニティブセキュリティ認知マップ」と呼ぶ）として体系化する。こ

6 脅威とひもづく認知的脆弱性、および対策手法との関係を整理したもの。利用者の意思決定はさまざまな認知的脆弱性の要因・要素が関係する。脅威に対して、脅威とひもづく認知的脆弱性を特定・分析して対策手法を創出したり、まだ狙われていない認知的脆弱性を特定・分析し新たな脅威を予測したりすることに活用する。詳細は、「3.1 具体的な研究課題例コグニティブセキュリティ認知マップの構築」を参照いただきたい。

のコグニティブセキュリティ認知マップを基礎として、認知的脆弱性の原因解明、および新たな脅威の予測を行い、現在顕在化している脅威への対策に加えて、将来出現しうる新たな脅威に対する予見的（プロアクティブ）な対策を可能とする基盤的な研究開発を進める。

具体的な研究開発課題例を以下に示す（詳細は3.1に記載）。

- コグニティブセキュリティ認知マップの構築
- 認知的脆弱性の原因解明と新たな脅威の予測
- 認知的脆弱性をシミュレーションできる認知モデルの構築

【研究開発課題2】人間の認知的脆弱性の知見に基づく対策手法の創出

研究開発課題1で得られた知見を活用し、人間の認知的脆弱性を突く脅威情報から利用者を守り、利用者の自律的な意思決定を支援するための対策手法を創出する研究開発を進める。

具体的な研究開発課題例を以下に示す（詳細は3.2に記載）。

- 個々人の認知的脆弱性に応じてパーソナライズされた対策手法の創出
- 能動的なインタラクションによるなりすましへの対策手法の創出
- ナラティブ（物語）⁷を使う情報工作への対策手法の創出

これらの研究開発課題を推進するには、人間の認知に関わる研究分野と対策の創出に関わる研究分野を分野横断的に連携する方策が重要である。本戦略プロポーザルでは、次の二つの方策を提案する。

【推進方策1】コグニティブセキュリティ研究コミュニティを通じた分野横断的な研究開発の推進

コグニティブセキュリティの研究開発をけん引する研究者が主体となって、研究開発の目指す姿を描きその方向性を発信・共有し、分野横断的な議論を進め、関連する分野から、研究者のさらなる参画を促す。これらの活動を進め、人間の認知に関する研究分野と対策を創出する情報技術などの研究分野が分野横断的に連携する「コグニティブセキュリティ研究コミュニティ」を構築し、研究コミュニティを通じて研究開発を継続的に推進する。

【推進方策2】ファンディングプログラムによる研究開発の加速

推進方策1により、コグニティブセキュリティ研究コミュニティを構築するには、目指す姿の議論・共有や、関連する分野からの研究者のさらなる参画、運営体制の整備を含め、時間を要することが予想される。一方で、フィッシングやSNS上の偽・誤情報などによる脅威は拡大している。推進方策1と並行して、これらの脅威への対応を急ぐために、問題解決型の目標を設定し、ファンディングプログラムによって研究開発を加速する。

7 ナラティブ（物語）については、「付録D 専門用語解説」を参照いただきたい。

2 | 研究開発を実施する意義

2.1 現状認識および問題点

以下では、まず、コグニティブセキュリティーが含まれるセキュリティー・トラスト分野における研究開発の動向を俯瞰し、コグニティブセキュリティーの位置づけを述べる。その後、現在起きている問題、現行対策と問題点、関連する研究開発の状況について述べる。


2.1.1 セキュリティー・トラスト分野における研究開発の俯瞰とコグニティブセキュリティー

図2は、セキュリティー・トラスト分野の研究開発を時系列および構造の観点から俯瞰したものである⁸。図2(1)の俯瞰図(時系列)では、インフラ、プラットフォーム、サービスについて、台頭した情報サービス・制度、サイバー攻撃事案、およびセキュリティー技術をプロットしている。本分野の研究開発は、社会への広がり観点から、大きく二つの潮流がある。

潮流1は、情報システムを構成する「デバイス、システム、情報」を対象として、情報システムをサイバー攻撃から守るセキュリティー、および利用者が情報システムを安心・信頼して利用するためのトラストを構築する研究開発の潮流である。潮流2は、「人、社会」を対象として、フィッシングやフェイクニュースといった、人間の認知の隙を狙った脅威から人や社会を守るセキュリティー、および社会における信頼基盤を構築するトラストのための研究開発の潮流である。近年、AIやSNSなどの情報技術の進展に伴い、フィッシングやフェイクニュースなど人や社会に悪影響を及ぼす脅威が拡大しており、情報システムを対象とした「潮流1」とともに、人や社会を対象とした「潮流2」の研究開発が極めて重要となっている。

図2(2)の俯瞰図(構造図)は、本分野の研究開発領域の構造を示したものである。横軸を「セキュリティー」と「トラスト」に分け、縦軸をセキュリティー・トラストの対象となる「デバイス、システム、情報」と「人・社会」、および基礎となる「基盤」として整理している。コグニティブセキュリティーは、研究開発領域「人・社会とセキュリティー」の中の研究開発テーマである。

8 詳細は、参考文献2)を参照いただきたい。



(1) 時系列 (2) 構造図
図2 セキュリティ・トラスト分野における研究開発の俯瞰図

表1は、研究開発領域「人・社会とセキュリティ」における、コグニティブセキュリティの位置づけを示したものである（表1には、参考として潮流1についても記載している）。人・社会とセキュリティでは、個人や組織、社会に関わる問題を対象として、コグニティブセキュリティの他に、ユーザブルセキュリティ⁹、およびサイバーセキュリティの中でも社会に関わる問題を対象とする重要インフラ・サプライチェーンのセキュリティ¹⁰を研究開発テーマとして位置づけている。人間の認知的脆弱性を狙い、個人、組織、社会・国家に影響を及ぼしうる脅威は年々拡大しており、人間の認知を守るコグニティブセキュリティの研究開発の取り組みが不可欠である。

表1 「人・社会とセキュリティ」とコグニティブセキュリティ

分類	個人に影響を及ぼしうる問題	組織に影響を及ぼしうる問題	社会・国家に影響を及ぼしうる問題
	人・社会とセキュリティ（潮流2）		
コグニティブセキュリティ （人間の認知を守る）	・フィッシング詐欺 ・SNSを使った詐欺 ・ダークパターンによる利用者の誘導 ・SNS上のデマによる健康被害、買占め	・企業を狙ったフィッシング詐欺・不正送金 ・フェイクニュースによる企業ブランド毀損・風評被害	・SNSを使う世論操作 ・SNSを通じた社会的分断 ・SNSを通じた偏った意見・価値観の形成 ・フェイクニュースによる株価変動・経済被害
ユーザブルセキュリティ （セキュリティの使い方を間違わないようにする、利便性を高める）	・パスワード管理不備 ・家庭用IoT機器のセキュリティ設定の間違い ・情報サービスのプライバシーポリシーの間違った理解	・企業のアカウント管理ポリシーの運用不備 ・従業員のセキュリティ規定の遵守不備 ・インシデント対応の手順不備 ・開発者による法規制やプライバシーポリシーの間違った理解とシステム不具合	・セキュリティ認証製品の普及 ・セキュリティ教育の推進 ・高齢者、発展途上国などの多様なユーザーを対象としたセキュリティ意識の向上
サイバーセキュリティ （情報システムを守る）	・個人端末のマルウェア感染・不正侵入による情報漏えい・金銭被害	・企業・自治体システムのマルウェア感染・不正侵入・DDoS攻撃による情報漏えい・業務停止・金銭被害	・重要インフラ（医療、電力、水道、ガスなど）やサプライチェーンへのサイバー攻撃による金銭被害・重要な業務停止

情報・システム・デバイスのセキュリティ（潮流1）

9 ユーザブルセキュリティについては、「付録D 専門用語解説」を参照いただきたい。
10 重要インフラ・サプライチェーンのセキュリティについては、「付録D 専門用語解説」を参照いただきたい。

2.1.2 現在起きている問題

図3に、現在起きている主な問題を、横軸を脅威情報の種類、縦軸を影響が及ぶ対象として整理した。これらの問題による影響は、個人、組織にとどまらず、社会、国家にまで拡大している。主に以下のような問題がある。

・個人・組織に影響を及ぼしうる問題

個人や組織を狙ったフィッシング被害は年々増加している。その報告件数は2024年に約171万件となり2023年の約120万件と比較するとおよそ1.4倍に増加している¹¹。また、インターネットバンキングに係る不正送金の被害額は2024年に約86億円となり2023年と比較すると微減ながら、2022年の約15億円と比較するとおよそ5.7倍に増加している¹²。その手口は、SMS（Short Messaging Service）を使った「スミッシング（Smishing）」や音声案内を使った「ボイシング（Voishing）」などへと巧妙化している。AIの悪用も急増しておりフィッシングメールの約8割にAIが利用されているとの報告もある¹³。また、新型コロナウイルス感染症（COVID-19）では、さまざまなデマがまん延した¹⁴。ウェブサイトでは、ダークパターン¹⁵も広がっている。米国連邦取引委員会（Federal Trade Commission：FTC）、および国際消費者保護ネットワーク（International Consumer Protection and Enforcement Network：ICPEN）が2024年に公表した報告書¹⁶は、サブスクリプションサービスを提供するウェブサイトやアプリケーションの約76%に何かしらのダークパターンが含まれていたことを示した。

- 11 フィッシング対策協議会 技術・制度検討ワーキンググループ「第1章 フィッシングの動向」『フィッシングレポート2025』, https://www.antiphishing.jp/report/phishing_report_2025.pdf (2025年11月1日アクセス)
- 12 警察庁サイバー警察局『令和6年におけるサイバー空間をめぐる脅威の情勢等について』(2025年3月) https://www.npa.go.jp/publications/statistics/cybersecurity/data/R6/R06_cyber_jousei.pdf (2025年11月1日アクセス)
- 13 独立行政法人情報処理推進機構「2.1.4(2)(c) AIを用いた認知領域への攻撃」『情報セキュリティ白書2025』
- 14 Dr Greg Nyilasy, “Fake News in the Age of COVID-19,” Faculty of Business and Economics, University of Melbourne, <https://fbe.unimelb.edu.au/newsroom/fake-news-in-the-age-of-covid-19#:~:text=GOOD AND BAD INTENTIONS,spread their opinion as fact> (2026年2月1日アクセス)
- 15 ダークパターンについては、「付録D 専門用語解説」を参照いただきたい。
- 16 Federal Trade Commission, “FTC, ICPEN, GPEN Announce Results of Review of Use of Dark Patterns Affecting Subscription Services, Privacy,” <https://www.ftc.gov/news-events/news/press-releases/2024/07/ftc-icpen-gpen-announce-results-review-use-dark-patterns-affecting-subscription-services-privacy> (2025年2月1日アクセス)




図3 現在起きている問題の例

・社会・国家に影響を及ぼしうる問題

SNS上の偽・誤情報の話題は、健康、政治、紛争、災害、気候変動など多岐にわたる。「令和6年能登半島地震」では、虚偽の救助要請が拡散され救助活動を阻害する事態が生じた¹⁷。また、生成AIを使ったフェイクニュースは、真偽を判断することがますます難しくなっている。米国国防総省近くで爆発があったとするフェイクニュースによって、株価が一時下落する騒動になったなど、経済にも影響を及ぼしている¹⁸。さらに、SNS上ではフィルターバブルやエコーチェンバー現象により、社会の分断が加速しているとの懸念がある。2020年の米国大統領選挙においては、リベラル系と保守系の利用者の間で顕著な分断が観察され、また、COVID-19においては、反ワクチン派とワクチン推進派の対立がSNS上で先鋭化した¹⁹。加えて、SNS上でのナラティブ（物語）を使う意図的な世論操作は、安全保障上の重大な課題となっている。各国の選挙への他国の関与が疑われる情報工作や偽情報の流布が相次いで報告²⁰されており、民主的かつ公正な意思決定に影響を及ぼしている。

このように、情報技術の高度化によりさまざまな問題が起こっており、その影響は年々拡大している。

2.1.3 現行対策と問題点

図4に現行対策とその限界、および研究開発の目標を示す。図4では、対策を「脅威情報への直接的対策」と「脅威情報への間接的対策」に分け、さらに、脅威情報への直接的対策については、脅威情報が利用者に

- 17 NHK NEWS WEB「「不謹慎で迷惑」能登半島地震で相次いだ偽救助要請 実態は？」
<https://news.web.nhk/newsweb/na/na-k10014383261000>（2025年11月1日アクセス）
- 18 総務省「デジタル時代における放送制度の在り方に関する検討会（第19回）NHK説明資料」
https://www.soumu.go.jp/main_content/000884978.pdf（2025年11月1日アクセス）
- 19 総務省プラットフォームサービスに関する研究会「資料1 エコーチェンバーとフィルターバブル：プラットフォームが促進するフィードバックループ（東京工業大学環境・社会理工学院笹原和俊准教授）」第44回 配布資料
https://www.soumu.go.jp/main_content/000880080.pdf（2025年11月1日アクセス）
- 20 独立行政法人情報処理推進機構「2.2.3 2024年度の注目事象」『情報セキュリティ白書2025』
https://www.ipa.go.jp/publish/wp-security/j5u9nn0000004wk0-att/ISWP2025_ALL.pdf（2025年11月1日アクセス）

到達するタイミングにより、事前対策、即時対策、事後対策の三種類に分類した。脅威情報への間接的対策は、脅威情報が利用者に到達するタイミングによらない対策であるため、時系列による整理は行わなかった。また、現行対策の限界を、脅威情報に対して意思決定する「利用者からの視点（赤字）」と、対策が可能な「脅威情報からの視点（青字）」で整理した。対策手法（例）には、既の実施されている対策、および研究開発が進められている対策の例を示した²¹。

ここで、本戦略プロポーザルで用いる「問題」、「脅威」、「脅威情報」を以下の通り定義する。

【問題、脅威、脅威情報の定義】

問題： 個人・組織、社会・国家に悪影響を及ぼしうる事象（例：フィッシング詐欺、世論操作）

脅威： 問題を引き起こす手口（例：メールによるフィッシング、SNSへの詐欺投稿）

脅威情報： 脅威を構成する個々の情報（例：個別のフィッシングメール、SNSへの個別の投稿）

この定義では、例えば、フィッシング詐欺の場合、「問題」はフィッシング詐欺、「脅威」はメールフィッシングといった手口、「脅威情報」は利用者に送られる個々のフィッシングメール、がそれぞれ該当する。



図4 現行対策と限界、研究開発の目標

次に、図4に示した現行対策の限界、および問題点と研究開発の目標について説明する。

現行対策の限界

・脅威情報への直接的対策の限界

脅威情報への直接的対策では、事前にフィッシングメールの発信者やフィッシングサイトのアドレス情報を登録したリストや、フィッシングメールの文面を学習したAIモデルに基づく、フィッシングメールのフィルタリングやフィッシングサイトの無効化などの事前対策が実施されている。また、このようなリストやAIモデルに基づき、利用者がフィッシングメールやフィッシングサイトにアクセスした際に警告を行う即時対策も実施されている。

21 対策手法の事例については、「付録C 現行対策の事例」を参照いただきたい。

事前対策では、リストやAIモデルに含まれていない未知の脅威情報は、事前対策をすり抜けて利用者に到達してしまい、利用者が脅威情報を適切に判断できるとは限らず、本人が望まない結果をもたらす可能性が残る。即時対策では、既知の脅威情報に対しては警告が行われるが、利用者が脅威情報を適切に判断できるとは限らず、本人が望まない結果をもたらす可能性が残る。未知の脅威情報に対しては警告も行われないため、利用者が脅威情報を適切に判断することがさらに難しく、本人が望まない結果をもたらす可能性が高まる。また、ファクトチェックは、個々の脅威情報の真偽を検証し公開する取り組みとして有益である一方、膨大な脅威情報の全てをチェックすることは難しい。このため、ファクトチェックでも、利用者が脅威情報を適切に判断できるとは限らず、本人が望まない結果をもたらす可能性が残る。

つまり、既知・未知のいずれの脅威情報も利用者に到達してしまう限り、利用者が適切に脅威情報を判断できるとは限らず、本人が望まない結果をもたらす可能性が残る。

・脅威情報への間接的対策の限界

リテラシー教育は、インターネットやSNSの仕組みやリスクなどに関する基礎的な知識を習得できる。また、プレバンキングは、ゲームやクイズ、動画視聴などを通じて、フィッシングやSNS上の偽・誤情報などの脅威に対する抵抗力を高めることが期待できる。しかし、現在の間接的対策だけでは、利用者が受け取った脅威情報を適切に判断できるとは限らず、本人が望まない結果をもたらす可能性が残る。

現行対策の問題点と研究開発の目標

上述した現行対策の限界をまとめると、利用者からの視点（赤字）では、事前にリストなどに登録されている既知の脅威情報に対しては事前対策によって対策可能だが、事前対策をすり抜けて利用者に到達してしまう脅威情報に対しては、利用者が適切に判断できるとは限らず、本人が望まない結果をもたらす可能性が残る。同様に、事前対策をすり抜けて利用者に到達してしまう脅威情報に対しては、即時対策や事後対策によっても、利用者が適切に判断できるとは限らず、本人が望まない結果をもたらす可能性が残る。つまり、「脅威情報が利用者（人間）に到達する前の対策（事前対策）」のみならず、「情報サービスの利用者に到達してしまう脅威情報への対策を加えた、広範な対策」ができていないという問題点がある。

脅威情報の視点（青字）では、事前対策、即時対策、事後対策が対応可能な範囲は、事前にリストなどに登録されている既知の脅威情報に限られるため、未知の脅威情報は防ぎきれず、対策が後追いになってしまう。つまり、「将来出現しうる新たな脅威への予見的（プロアクティブ）な対策」ができていないという問題点がある。

情報技術の進展により、AIを悪用すれば巧妙な脅威情報を容易かつ大量に作成でき、さらにそれをSNSを通じて広範囲にかつ瞬時に拡散することが可能となった。そのため、利用者に到達する脅威情報は巧妙で膨大なものとなっており、事前対策では十分に対策できない脅威情報が増加している。このような状況において、現行対策の問題点を解決し、自律的な意思決定を支援するためには、次の目標に向けて、研究開発に取り組む必要がある。

【研究開発の目標1】 情報サービスの利用者（人間）に到達してしまう脅威情報への対策を加えた、広範な対策

【研究開発の目標2】 将来出現しうる新たな脅威への予見的（プロアクティブ）な対策

2.1.4 関連する研究開発の状況

研究開発の目標に示した対策を創出するためには、利用者である人間が情報を受け取り意思決定する際に生じる認知的脆弱性を分析・解明し、その知見に基づいて対策手法を創出することが必要となる。以下では、人間の認知的脆弱性に関する研究開発と、対策手法の研究開発の状況を説明する。

人間の認知的脆弱性に関する研究開発の状況

人間の認知に関する研究は、認知科学や心理学、行動経済学などにおいて長い歴史を持ち、多くの知見が蓄積されている。例えば、人間の認知は直感的な「システム1」と熟慮的な「システム2」からなると仮定した二重過程理論という人の情報処理の枠組みや、人間の意思決定に影響するさまざまな認知バイアス²²などの研究成果が知見として蓄積されている。しかし、これらの知見を、AIやSNSなどの情報技術が進展したデジタル社会にそのまま適用できるかについては、十分に検証されていない¹⁾。例えば、AIにより生成された巧妙なフェイクメディアや、SNSに投稿される膨大な量の情報、さらにフィルターバブルやエコーチェンバーによる利用者が受け取る情報の偏りなど、デジタル社会特有の情報環境が認知バイアスなどの認知的脆弱性にどのように作用し、利用者の意思決定にどのような影響を及ぼすかを再検証する必要がある。この検証のためには、AIやSNSを模した複雑なデジタル環境の構築や、デジタル環境における利用者を対象とした評価手法などの知見も必要となり、認知に関する研究者が単独で取り組むにはハードルが高いことが指摘されている¹⁾。

対策手法の研究開発の状況

対策手法の研究開発では、セキュリティ技術やAI技術を活用して、フィッシングメールのフィルタリングや、フィッシングサイトの検出精度の向上、フェイクメディアの検出、SNS上での情報拡散の分析などの研究開発が活発に行われている。しかし、人間の認知的脆弱性に関する知見に基づく対策手法の研究事例は少数にとどまっている²³。

2.2 社会・経済的効果

本戦略プロポーザルの推進を通じて、以下に示すような社会・経済的効果が期待できる。

・フィッシング対策

フィッシングによる被害件数・被害額は年々拡大している（2.1.2を参照）。現行の即時対策であるフィッシングサイトの警告は、事前に検証したフィッシングサイトのアドレス情報などにに基づき、利用者に対して一律に表示される。また、リテラシー教育は、幅広い利用者を対象として実施されている。このため、個々の利用者の認知的脆弱性（だまされやすさや、情報環境の理解度など）を十分に考慮できていない。個々の利用者の認知的脆弱性に応じてパーソナライズされた対策手法（利用者のだまされやすさに応じた警告表示や、情報環境に関する理解度に応じたリテラシー教育など）を創出することにより、フィッシング詐欺への対策の効果を高め、被害件数や被害額の削減に寄与できる（対策手法の詳細は、「3.2 具体的な研究課題例 個々人の認知的脆弱性に応じてパーソナライズされた対策手法の創出」を参照）。

・SNS上の偽・誤情報対策

SNS上の偽・誤情報による脅威は、個人や組織だけでなく、社会や国家にまで拡大している（2.1.2を参照）。SNS上の投稿に含まれる表現が利用者の拡散行動にどのように作用するのかを分析し、投稿の拡散行動を再考することを促す対策手法を創出する。これにより、SNS上の詐欺・デマにつながる偽・誤情報やフェイクニュースなどの拡散を抑制し、安心・安全な社会の実現に寄与できる（対策手法の詳細は、「3.2 具体的な研究課題例 個々人の認知的脆弱性に応じてパーソナライズされた対策手法の創出」を参照）。

22 無意識のうちに生じる人間の思考の偏り。「付録D 専門用語解説」も参照いただきたい。

23 「付録B 国内外の状況 B-1 国内外の研究プログラム・政策の状況 研究プログラム」を参照いただきたい。

・ダークパターン対策

個人が利用するウェブサービスやアプリケーションではダークパターンも広がっている（2.1.2を参照）。だまされやすいダークパターンを事前に検出したり、利用者がアクセスした際に警告したりする対策手法を創出することにより、利用者がダークパターンにだまされてサービスに申し込むような事例を削減することに寄与できる。

・世論操作対策

選挙時などにおける他国からの意図的な世論操作も頻繁に確認され問題となっている（2.1.2を参照）。SNSを通じた世論操作を意図した投稿の拡散状況を分析し、発信者や目的の予測、利用者や社会への影響を評価する技術を構築する。これにより、選挙時の世論誘導や社会の分断を狙った情報工作に対して、公正な選挙に基づく民主主義や国家の安全保障を維持することに寄与できる（対策手法の詳細は、「3.2 具体的な研究課題例 ナラティブ（物語）を使う情報工作への対策手法の創出」を参照）。

2.3 科学技術上の効果

本戦略プロポーザルの推進を通じて、次に示す科学技術上の効果が期待できる。

・デジタル社会における認知に関する学術基盤の確立

AIやSNSなどの情報技術が進化したデジタル社会において、AIにより生成された巧妙なフェイクメディアや、SNSに投稿される膨大な量の情報、さらにフィルターバブルやエコーチェンバーにより利用者が受け取る情報の偏りなどのデジタル社会特有の情報環境における、認知的脆弱性が体系化され、利用者の自律的な意思決定に影響を及ぼす原因の解明が進められる。これにより、デジタル環境特有の人間の認知的脆弱性と意思決定に関する知見を蓄積することができ、デジタル社会における認知に関する学術基盤の確立に寄与できる。

・認知と情報の融合による学際的な新しい研究開発領域の創出

セキュリティの研究分野では、人間の認知的脆弱性に関する知見をセキュリティのための対策技術に融合することで、人の認知を守ることを目指す新しい研究開発領域が創出できる。これにより、フィッシングや偽・誤情報といった、人間の認知の隙を狙った脅威への対策技術を構築できる。

また、人間の認知的脆弱性に関する知見を、エージェント型AI（AIエージェントとも呼ぶ）や自律型ロボットに適用することにより、例えば、エージェント型AIが利用者の認知の隙を突いてだましたり、プライバシー侵害となる情報を得たりするようなインタラクションを抑制できる。これは、利用者から信頼されるエージェント型AIや自律型ロボットの実現につながり、エージェント型AIや自律型ロボットに対するトラストの研究開発にも寄与できる。さらに、このような研究開発を進めることで、将来、人間の認知に関する研究と情報技術の研究が融合したより広い「認知×情報」の研究開発領域に発展することも期待できる。

3 | 具体的な研究開発課題

2.1.3 で述べた研究開発の目標に向けて、本戦略プロポーザルは、情報を受け取る人間の認知的脆弱性の知見を対策に融合させ、広範かつ将来の脅威にも予見的（プロアクティブ）に対策できる新たな対策手法の創出を目指す。そのために、図5に示す二つの研究開発課題の取り組みをわが国で推進することを提案する。

【研究開発課題1】デジタル社会における人間の認知的脆弱性の体系化と原因解明、新たな脅威の予測

デジタル社会における人間の認知的脆弱性を、コグニティブセキュリティの観点から体系化し、認知的脆弱性の原因解明、および新たな脅威の予測を行う。

【研究開発課題2】人間の認知的脆弱性の知見に基づく対策手法の創出

研究開発課題1で得られた知見を活用し、人間の認知的脆弱性を突く脅威情報から利用者を守り、利用者の自律的な意思決定を支援するための対策手法を創出する研究開発を進める。




図5 研究開発課題の全体像

本戦略プロポーザルでは、認知的脆弱性をコグニティブセキュリティの観点から体系的に整理した「コグニティブセキュリティ認知マップ」を研究開発課題1で構築し、これを基礎として二つの研究開発課題を連携させて取り組むアプローチを取る。以下では、目標1と目標2に向けた研究開発課題の取り組み概要と、二つの研究開発課題の取り組み間のフィードバックについて説明する。

・研究開発の目標1に向けた取り組み概要

研究開発課題1で、現在の脅威、認知的脆弱性、および既存の対策手法の関係を体系的に可視化したコグニティブセキュリティ認知マップを構築する。この認知マップを使い、対策すべき脅威とひもづく認知的脆弱性と既存の対策手法を特定・分析し、認知的脆弱性の原因を解明する。さらに、研究開発課題2で、その知見に基づき、情報を受け取る利用者の意思決定を支援する対策手法を創出する。

・研究開発の目標2に向けた取り組み概要

研究開発課題1で、コグニティブセキュリティ認知マップを使い、まだ狙われていない認知的脆弱性を特定・分析し、将来の新たな脅威を予測する。さらに、研究開発課題2で、その知見に基づき、将来の新たな脅威への予見的（プロアクティブ）な対策手法を創出する。

・二つの研究開発課題間のフィードバック

二つの研究開発課題間では、フィードバックを繰り返すことにより、次のように、研究開発が進展することが期待できる。例えば、研究開発課題2の対策手法の評価で得られた問題点を研究開発課題1にフィードバックすることにより、研究開発課題1では、この問題点の分析を行い新たな知見を蓄積したり、将来の新たな

脅威を予測したりすることが期待できる。さらに、その知見を、研究開発課題1から研究開発課題2にフィードバックすることにより、研究開発課題2では、対策手法の改良や新たな脅威への対策手法を創出できる。

以下では研究開発課題1と研究開発課題2の具体的な内容について説明する。

3.1【研究開発課題1】デジタル社会における人間の認知的脆弱性の体系化と原因解明、新たな脅威の予測

研究開発課題1では、デジタル社会における人間の認知的脆弱性を、コグニティブセキュリティの観点から「コグニティブセキュリティ認知マップ」として体系化する。この認知マップを基礎として、認知的脆弱性の原因解明、および新たな脅威の予測を行い、現在顕在化している脅威への対策に加えて、将来出現しうる新たな脅威に対する予見的（プロアクティブ）な対策を可能とする基盤的な研究開発を進める。

研究開発課題1の具体的な研究課題例を示す。

具体的な研究課題例

・コグニティブセキュリティ認知マップの構築

コグニティブセキュリティにおける自律的な意思決定に関わる人間の認知的脆弱性には、さまざまな要因・要素が関係している。そのうちの一つである人間の認知バイアスの数は100以上ともいわれている^{24, 25}。例えば、フィッシングでは、ある商品の希少性が高い状況だとその商品の主観的な価値が増すという希少性バイアスなどが影響する可能性がある。SNS上の偽・誤情報では、自分の信念を裏付ける情報を探し求めそれ以外を見ない確認バイアスが影響する可能性がある。認知バイアス以外にも、感情（感謝、期待、怒りなど）、パーソナリティ特性（開放性、誠実性、外向性、協調性、神経症傾向、誠実性）、外部環境（社会・文化的環境、人間関係、作業環境など）などが意思決定に影響する可能性がある。

このように、利用者の意思決定はさまざまな認知的脆弱性の要因・要素が関係する。脅威への対策手法を創出するためには、脅威とひもづく認知的脆弱性を特定・分析するために、まず、脅威と認知的脆弱性、対策手法との関係を体系的に整理し、コグニティブセキュリティ認知マップを構築することが有用である(図6)。

コグニティブセキュリティ認知マップは、フィッシングなどの特定の脅威が、どのような認知的脆弱性に作用するのか、それに対してどのような対策手法が存在するのかを可視化することができ、対策が必要な認知的脆弱性や、まだ狙われていない認知的脆弱性を特定することに活用できる。さらに、脅威に関わる複数の要因・要素を多角的に分析することにも活用できる。それ以外にも、認知に関する研究者と情報分野の研究者の共通言語となり、分野横断的な研究開発の推進にも役立つ。研究開発の社会的価値創出（対策手法の社会実装）に向けても、個別の研究の対象を可視化し、研究を社会実装に向けて集積することにも活用できる。

本研究課題例に関連する研究として、フィッシングを対象として脅威と心理的テクニック、心理的要因、対策手法を整理した研究³⁾が行われている。このような研究事例を参考に、脅威と認知的脆弱性、対策手法の関係性を整理していくことにより、コグニティブセキュリティ認知マップの構築に取り組む。

24 WIKIMEDIA COMMONS, “COGNITIVE BIAS CODEX,”
https://commons.wikimedia.org/wiki/File:Cognitive_bias_codex_en.svg (2025年11月1日アクセス)

25 池田まさみ（十文字学園女子大学）他「錯思コレクション100」
https://www.jumonji-u.ac.jp/sscs/ikeda/cognitive_bias/cate_s/ (2025年11月1日アクセス)




図6 コグニティブセキュリティ認知マップの概要

・認知的脆弱性の原因解明と新たな脅威の予測

AIにより生成された巧妙なフェイクメディアや、SNSに投稿される膨大な量の情報、さらにフィルターバブルやエコーチェンバーによる利用者が受け取る情報の偏りなど、デジタル社会特有の情報環境が認知バイアスなどの認知的脆弱性にどのように作用し、利用者の意思決定にどのような影響を及ぼすかを再検証する。具体的には、コグニティブセキュリティ認知マップをもとに、脅威とひもづく認知的脆弱性を特定・分析し、意思決定に関わる原因を解明する。また、コグニティブセキュリティ認知マップの中で、まだ狙われていない認知的脆弱性を分析し、将来、起こりうる可能性がある新たな脅威を予測する。認知バイアスには、個人の意思決定に影響するもののほかに、同調バイアスなど集団意思決定に影響するものも存在する。集団への対策手法を創出するために、集団となった場合の認知的脆弱性を特定・分析し、集団の意思決定に関わる原因を解明する。

さらに、利用者の認知的脆弱性に応じた適応的な対策を実現するために、認知的脆弱性をモデル化・数値化して情報技術で利用できる形式とすることが有用である。例えば、個々の利用者のだまされやすさにつながる要因を数値として表すことができれば、個々の利用者のだまされやすさに応じてパーソナライズされた警告を表示する対策手法などの実現が可能となる。

本研究課題例に関連する研究として、SNS上の情報拡散を分析した研究が多数行われている⁴⁾。また、SNSへの投稿に含まれる感情表現の度合いと投稿を受け取った利用者の拡散行動との関係性を分析した研究⁵⁾や、利用者に投稿に含まれる感情表現に対する気付きを促すことにより拡散行動を抑制する研究⁶⁾が行われている。このような研究事例を参考に、SNSへの投稿に含まれる感情表現などが、認知的脆弱性にどのように作用し拡散行動につながるのかといった分析を進めることにより、SNS上の偽・誤情報の拡散における認知的脆弱性の原因解明に取り組む。

・認知的脆弱性をシミュレーションできる認知モデルの構築

コグニティブセキュリティーの研究開発では、人間を対象とした実験・評価を行う際、侵襲性²⁶や不可逆性²⁷といったリスクが伴う可能性がある。例えば、陰謀論をテーマとした実験の後に、参加者の一部がその内容を実験後も信じ続けてしまう事例がある⁷⁾。新たな対策手法の探索や評価のためには、初期段階の実験で人間の認知的脆弱性をシミュレーションできる認知モデルを構築することが有用である。

本研究課題例に関連する研究として、脳情報科学分野では、人間の脳計測データから脳のプロセスをAIモデルとして構築する脳シミュレーションの研究が行われている^{8), 9)}。また、AIの分野では、大規模言語モデル(LLM)に年齢、教育レベル、政治的立場などの属性を設定して、仮想的な参加者として利用する研究が行われている¹⁰⁾。このような研究事例を参考に、さまざまな人の脳計測データを収集してAIモデルに学習させることにより、個々人の認知的脆弱性をシミュレーションできる認知モデルの構築に取り組む。

3.2【研究開発課題2】人間の認知的脆弱性の知見に基づく対策手法の創出

研究開発課題1で得られた知見を活用し、人間の認知的脆弱性を突く情報から利用者を守り、利用者の自律的な意思決定を支援するための対策手法を創出する研究開発を進める。

研究開発課題2の具体的な研究課題例を示す。

具体的な研究課題例

・個々人の認知的脆弱性に応じてパーソナライズされた対策手法の創出

利用者の認知的脆弱性の違いに着目し、パーソナライズされた警告やリテラシー教育による対策手法を創出する。例えば、フィッシングにだまされやすい人や偽・誤情報を信じやすい人の認知的脆弱性に応じてパーソナライズされた適応型の警告手法や、個々人の情報環境の理解度に基づいてパーソナライズされたりテラシー教育を創出する。

本研究課題例に関連する研究として、利用者の認知的脆弱性の違いを脳計測データからモデル化する研究^{8), 9)}が行われている。このような研究事例を参考に、だまされやすい人に共通する認知的脆弱性にパーソナライズされた対策手法を創出する。また、SNSへの投稿に含まれる感情表現に応じて情報拡散の再考を促す警告画面を表示する対策手法の研究^{5), 6)}が行われている。投稿内容と利用者の認知的脆弱性(感情的な行動になりやすいなど)に応じてパーソナライズされた警告を表示する対策手法の創出に取り組む。

・能動的なインタラクションによるなりすましへの対策手法の創出

AIによるなりすましの脅威に対して、利用者にAIとのインタラクションを促し、なりすましの判断を支援する対策手法を創出する。生成AIによる映像や音声は真偽の判断が難しく、偽ビデオ会議で役員になりすました攻撃者にだまされる事例¹³⁾もある。一度のインタラクションから得た情報だけでなく、相手への信頼の度合いに応じて複数回のインタラクションを促し、複数の情報から判断することを支援する対策手法を創出する。

本研究課題例に関連する研究として、エージェント型AIに対する利用者の信頼(過信/不信)の度合いに応じて、利用者に信頼の較正を促す研究²⁸⁾が行われている。このような研究事例を参考に、相手に対する信

26 研究目的で行われる、穿刺、切開、薬物投与、放射線照射、心的外傷に触れる質問等によって、研究対象者の身体又は精神に傷害又は負担が生じることをいう¹¹⁾。

27 実験参加者が経験した心理的・物理的な変化が、実験終了後も回復しない可能性。

28 科学技術振興機構(JST)戦略的創造研究推進事業 チーム型研究(CREST)「納得感のある人間-AI協調意思決定を目指す信頼インタラクションデザインの基盤構築と社会浸透」<https://ymdsij-lab.com/tid-crest/> (2025年11月1日アクセス)

頼の度合いに応じてインタラクションを促し、複数の情報から、相手が本人かなりすましかを判断することを支援する対策手法の創出に取り組む。

・ナラティブ（物語）を使う情報工作への対策手法の創出

単独の情報だけでなく、ストーリー性を持つ複数の情報「ナラティブ」による情報工作への対策手法を創出する。偽・誤情報の積み重ねによってナラティブを構築して世論を操作する事例^{29, 30}が増えている。SNS上の大量の投稿を時系列的に分析し、背後にあるナラティブの構造を分析、発信者や目的を予測し、利用者や社会に及ぼす影響を可視化・分析する技術を確立する。

本研究課題例に関連する研究として、SNS上の情報拡散を分析した研究が多数行われている¹²⁾。また、SNS上の偽・誤情報の拡散を、集団への対策により効率的に抑制する研究が行われている¹³⁾。このような研究事例を参考に、ナラティブを使う情報工作への対策手法の創出に取り組む。

研究開発課題2の取り組みでは、巧妙化する脅威（手口）や多様な情報環境に対応した、実効性の高い対策手法を創出し社会実装することが望まれる。そのために、以下の三つの点を考慮して研究開発に取り組む。

・実際の脅威シナリオ・認知的脆弱性に即した対策

フィッシング詐欺の脅威（手口）には、単独のフィッシングメールによる単純なものから、複数のフィッシングメールにより段階的にだます複雑なものまである。また、利用者の意思決定に影響する認知的脆弱性には、認知バイアスや感情、外部環境などの複数の要因・要素が関係する場合もありうる。対策手法の創出では、実際の脅威シナリオや認知的脆弱性に関わる複数の要因・要素を考慮する。

・アジャイルな研究開発・実証実験による社会受容性の向上

対策手法の創出では、実際の脅威シナリオや認知的脆弱性に関わる複数の要因・要素を考慮することが求められる。アジャイルな研究開発・実証実験により、考慮する脅威シナリオや認知的脆弱性の要因・要素を徐々に拡大し、実証実験の結果を研究開発にフィードバックしながら進めることで、社会受容性の高い対策手法を実現する。

・多様な社会実装を見据えた研究開発

対策手法の創出では、社会実装の形態を想定して研究開発を行うことが重要である。ブラウザーやアプリケーションなどのシステム、リテラシー教育などの教育プログラム、行政機関や関連団体による対策指針やガイドラインなど、幅広い社会実装の形態を想定して対策手法の研究開発を行う。

29 独立行政法人情報処理推進機構「2.2.2（2）偽・誤情報利用による安全保障上の脅威の拡大」『情報セキュリティ白書2025』

30 独立行政法人情報処理推進機構「2.2.3 2024年度の注目事象」『情報セキュリティ白書2025』

4 | 研究開発の推進方法および時間軸

3章に示した研究開発課題の取り組みを推進するためには、認知的脆弱性に関する研究と、対策を創出する研究とを分野横断的に連携して推進することが重要である。本戦略プロポーザルの実施にあたって求められる推進体制は、分野横断的な連携体制である「コグニティブセキュリティ研究コミュニティ」を確立し、研究コミュニティを通じて継続的な研究開発が可能となる体制である（図7）。そのためには、次の二つの推進上の課題に取り組む必要がある。

推進上の課題1：分野横断的な連携による研究開発の推進

コグニティブセキュリティの研究開発は、セキュリティやAI、認知科学、心理学、脳神経科学、行動経済学、計算社会科学などを含む学際的な領域である。しかし、現状では、本研究開発をけん引している、セキュリティやAI、認知科学、心理学分野の研究者による連携にとどまっている。関連する研究分野から、研究者のさらなる参画を促し、分野横断的な連携体制を構築し研究開発を推進する必要がある。

推進上の課題2：研究倫理に関する課題、研究データ共有への対応

人間の認知を対象とするコグニティブセキュリティの研究開発には、実験・評価での侵襲性や不可逆性のリスク、研究成果の公開による悪用の懸念など、本研究開発特有の倫理的な課題がある。また、認知的脆弱性の知見を対策手法の創出に活用するためには、研究開発で得られた認知的脆弱性に関する知見を蓄積・共有することが必要である。さらに、研究開発を社会的価値につなげるためには、現実の脅威情報に即した対策手法を創出することが求められる。

これらの二つの推進上の課題を解決するために、本戦略プロポーザルでは次の二つの推進方を提案する。




図7 推進体制の目指す姿

【推進方策1】コグニティブセキュリティー研究コミュニティを通じた分野横断的な研究開発の推進

コグニティブセキュリティーの研究開発をけん引する研究者が主体となって、研究開発の目指す姿を描き、関連する学会やシンポジウムなどで発信し方向性を共有し、分野横断的な議論を進め、関連する分野から、研究者のさらなる参画を促す。これらの活動を進め、人間の認知に関する研究分野と対策を創出する情報技術などの研究分野が分野横断的に連携する「コグニティブセキュリティー研究コミュニティ」を構築し、研究コミュニティを通じて、分野横断的な研究開発を継続的に推進する。

そのために、以下の三つの取り組みを行う。

・研究開発の目指す姿の共有を通じた分野横断的な連携の推進

本研究開発をけん引する研究者が主体となって分野横断的な議論を開始し、研究開発の目指す姿を描き、関連する学会やシンポジウムなどで発信し方向性を共有することにより、分野横断的な連携を進める。具体的には、研究者の交流や目指す姿の議論ができるシンポジウムや学会のセッションの企画などを行い、関連する分野の研究者が参入しやすい議論の場を創出し、分野横断的な議論を推進する。例えば、議論の場として、国立研究開発法人科学技術振興機構 研究開発戦略センター（JST CRDS）が主催しているトラスト連続シンポジウム^{31, 14)}を利用する、あるいはトラスト連続シンポジウム同様に分野横断的な議論を促進するシンポジウムをコグニティブセキュリティーを中心として開催することが考えられる。また、関連する学会では、コグニティブセキュリティーをテーマとした企画セッション³²が開催されており、このような学会を通じて研究者の交流や分野横断的な議論を推進することが考えられる。

これらの取り組みを進め、関連する分野からの研究者のさらなる参画を促し、コグニティブセキュリティー研究コミュニティの構築につなげる。分野横断的な議論は、推進方策2におけるファンディングプログラムへの課題提案に向け、研究課題の特定や研究体制を構築することにも寄与する。

・コグニティブセキュリティー特有の研究倫理指針の策定

人間の認知的脆弱性を対象とするコグニティブセキュリティーの研究開発には、本研究開発特有の倫理的な課題がある。例えば、実験・評価での侵襲性や不可逆性のリスク、プライバシー保護、表現の自由や知る権利を含めた法制度との整合、公開した研究成果が悪用される懸念、対策手法の社会受容のための取り組み（サイエンスコミュニケーションやシチズンサイエンスなど）などが挙げられる。

研究開発を推進するために、倫理的な課題に対する研究倫理指針、および具体的なガイドラインの策定に取り組む。これらの策定に向けた議論は、情報技術分野で経験があるELSI/RRI³³の研究者の参画が不可欠

31 トラスト連続シンポジウムは、分野横断の議論や知見の共有を目的として実施しており、コグニティブセキュリティーに関わるテーマも取り上げられている。

32 コンピュータセキュリティシンポジウム2023「認知バイアスと「コグニティブセキュリティー」」
<https://www.iwsec.org/css/2023/program.html#1A3>（2025年11月1日アクセス）
 コンピュータセキュリティシンポジウム2025「414 パネルディスカッション：関連WSから見たトラストの景観」
<https://www.iwsec.org/css/2025/index.html>（2026年2月2日アクセス）
 2025年電子情報通信学会全国大会「[AI-4] LLMとコグニティブセキュリティーによる安全な社会の構築」
<https://pub.conf.it.atlas.jp/ja/event/general2025/session/271A01-03>（2025年11月1日アクセス）
 2025年度人工知能学会全国大会（第39回）「OS-26 AIが生み出す偽・誤情報との付き合い方を考える」
<https://www.ai-gakkai.or.jp/jsai2025/os/>（2025年11月1日アクセス）
 日本認知科学会第42回大会「OS1-4：ローカルエコチェーンのステアリングに向けた認知研究の社会実装」
<https://www.jcss.gr.jp/meetings/jcss2025/>（2025年11月1日アクセス）

33 ELSI（Ethical, Legal and Social Issues：倫理的・法的・社会的課題）、RRI（Responsible Research and Innovation：責任ある研究・イノベーション）

である。関連する取り組み事例³⁴も参考にして議論を進めることが望ましい。

・研究データ共有基盤の設計・運用指針の策定

分野横断的な連携を加速し、研究開発を社会的価値につなげるために、以下の二種類のデータベースを含む研究データ共有基盤の設計・運用指針の策定に取り組む。

- 認知データベース： 認知的脆弱性の知見を対策手法の創出に活用するために、認知的脆弱性に関する知見を蓄積・共有するデータベース。
- 脅威情報データベース： 現実の脅威情報に即した対策手法を創出するために、現実の情報環境から収集した脅威情報（フィッシングメールやSNS上の情報など）を蓄積・共有するデータベース。

研究データ共有基盤の構築に向けて、以下の点を考慮して設計・運用指針を策定する。

- 認知的脆弱性に関する用語や分類の統一： 異なる分野の研究者が相互に認知データベースを活用することができるよう、用語や分類の仕様を定義・統一する。
- データ形式の統一： 認知的脆弱性に関する知見を対策手法の創出に活用できるよう、研究データ共有基盤に蓄積する認知的脆弱性の知見に関する評価条件や評価結果などデータ仕様を定義・統一する。
- システム要件・運用要件： 研究データ共有基盤への不正アクセスや個人情報の漏えい、プラバシー侵害を防止するための技術的要件や、利用規約などの運用要件を策定する。
- 継続的な運用体制： 研究データ共有基盤を継続的に運用するための運用体制の指針を策定する。

具体的な研究データ共有基盤の構築に向けては、情報技術分野の研究者の参画が不可欠である。関連する取り組み事例^{35, 36}とも連携して推進することが望ましい。

【推進方策2】ファンディングプログラムによる研究開発の加速

推進方策1により、コグニティブセキュリティー研究コミュニティを構築するには、目指す姿の議論・共有や、関連する分野からの研究者のさらなる参画、運営体制の構築などのために、時間を要することが予想される。一方で、フィッシングやSNS上の偽・誤情報などによる脅威は拡大している。推進方策1と並行して、これらの脅威への対応を急ぐために、問題解決型の目標を設定し、ファンディングプログラムによって研究開発を加速することが有効である。ファンディングプログラムでは、チーム型の研究開発により分野横断的な連携も推進することが望ましい。

そのためには、以下に示す点を考慮したプログラム設計が必要である。

・広い公募スコープの設定

推進方策1の初期段階では、本研究開発に取り組む研究者の数が少なく、ファンディングプログラムに必要となる十分な数の研究課題提案が集まらない可能性がある。このため、セキュリティー、AI、認知科学、心理学、脳神経科学、行動経済学、計算社会科学、ELSI/RRRIなどの幅広い研究分野の研究者が課題提案できるよう、コグニティブセキュリティーだけでなく、密接に関連するトラスト¹⁵⁾を加えた広い公募スコープとすることが望ましい。また、認知に関する研究開発を推進するために、研究開発課題1に示したコグニティブセキュリティー認知マップの構築や人間の認知的脆弱性の原因解明が公募スコープであることを明示する。

34 脳情報を活用し知覚情報等を推定する AI 技術の活用ガイドライン作成委員会「脳情報を活用し知覚情報等を推定する AI 技術の開発・活用ガイドライン（2024年1月）」

<https://cinet.jp/japanese/wp-content/uploads/sites/2/2024/06/脳情報を活用し知覚情報等を推定するAI技術の活用ガイドラインv1.pdf>（2025年11月1日アクセス）

35 国立情報学研究所オープンサイエンス基盤研究センター「NII研究データ基盤（NII Research Data Cloud：NII RDC）」
<https://rcos.nii.ac.jp/service/>（2026年2月1日アクセス）

36 日本心理学会第89回大会では心理学の研究成果を実践につなげるための大規模なデータベースを含む大規模研究の推進が議論されている。坂田省吾 他「[SS-052] 心理科学研究所構想の推進」日本心理学会第89回大会、
<https://pub.conf.atlas.jp/ja/event/jpa2025/presentation/SS52-01>（2025年11月1日アクセス）

・チーム型の研究開発

人間の認知的脆弱性に関する知見の獲得から対策手法の創出までの研究開発を一貫して行うために、チーム型のファンディングプログラムであることが望ましい。これにより、分野横断的な連携の加速も期待できる。

・研究倫理ガイドラインの策定、研究データ共有基盤の評価

推進方策1の取り組みと連携し、研究倫理指針の策定と研究データ共有基盤の設計・運用指針の策定に加えて、より具体的な研究倫理ガイドラインの策定、および研究データ共有基盤の構築に向けて取り組むことが望ましい。研究倫理ガイドラインの策定に向けて、研究倫理上の課題を特定・検討して、より具体的なガイドラインとしてまとめる研究課題を設定する。また、研究データ共有基盤に向けて、設計・運用指針を整理し、設計・運用指針で定めた要件を評価するためのシステムを構築し、ファンディングプログラムの中で活用・評価する研究課題を設定する。

【時間軸】

本戦略プロポーザルの実施に求められる推進体制は、分野横断的な連携体制となるコグニティブセキュリティ研究コミュニティを確立し、研究コミュニティを通じて、研究開発を継続的に推進し、社会的価値創出を継続することができる体制である。この確立に向けて、図8に示す時間軸に沿って、三つのステップで推進する。

ステップ1：研究開発の目指す姿の共有を通じた分野横断的な連携の推進

本ステップは、研究開発をけん引する研究者が主体となって、分野横断的な議論を開始し、研究開発の目指す姿を描きその方向性を発信・共有し、分野横断的な連携を進めるステップである。本ステップを通じて、関連する分野から、研究者のさらなる参画を促し、ステップ3のコグニティブセキュリティ研究コミュニティの構築につなげる。また、ステップ2のファンディングプログラムへの課題提案に向け、研究者が事前に研究課題や研究体制を議論する役割も有する。

ステップ2：ファンディングプログラムによる研究開発の加速

本ステップは、ファンディングプログラムによって研究開発を加速するステップである。現在顕在化しているフィッシングやSNS上の偽・誤情報などの脅威への対応を急ぐために、問題解決型の目標として設定し、ファンディングプログラムによって研究開発を加速する。本ステップは、チーム型のファンディングプログラムによる研究開発を通じて、分野横断的な連携を進め、ステップ3のコグニティブセキュリティ研究コミュニティの構築を加速する役割も有する。

ステップ3：コグニティブセキュリティ研究コミュニティを通じた継続的な研究開発

本ステップは、ステップ1やステップ2に参画した研究者が主体となり、コグニティブセキュリティを対象とした「コグニティブセキュリティ研究コミュニティ」を構築するステップである。研究コミュニティでの活動を通じて、分野横断的な研究開発を継続的にを行い、社会的価値創出を継続する。




図8 推進の時間軸

付録A 検討の経緯

国立研究開発法人科学技術振興機構 研究開発戦略センター（JST CRDS）では、2024年度の戦略スコープ策定委員会において、戦略プロポーザルを作成すべきテーマの候補として、本テーマを選定し、検討チームを発足させた。本検討チームは2024年9月から活動を開始し、2025年12月まで検討を進めてきた。

その間、専門家へのインタビューや、ワークショップを実施し、本テーマの研究開発状況の把握や研究開発課題・方向性の議論を進めてきた。以下に、その概要を示す。

A-1 科学技術未来戦略ワークショップ³⁷

1. 概要

日程：2025年5月16日（金）9:00～12:00

場所：Zoomによるオンライン開催

主催：国立研究開発法人科学技術振興機構（JST）研究開発戦略センター（CRDS）

2. 開催趣旨

現在、フィッシング詐欺やSNS上の偽・誤情報によるデマ、世論操作など、さまざまな情報に関わる問題が人や社会に大きな影響を及ぼしている。これらの問題の背景には、AIやSNSなどの情報技術の発展も関係しており、AIによりだます手段が巧妙化し情報を受け取った人間がだまされていることに気付くことが難しくなっている。また、SNSにより情報の量が膨大となり人間が全ての情報を収集・理解・吟味することが難しくなっている。これらには、情報を受け取る人間の認知が関係しており、人間の認知特性が脆弱性となっている。そのため、問題を解決するためには、フィッシングメールのフィルタリングやフェイク画像の検知などの技術的な対策や制度的な対策に加えて、脆弱性となっている人間の認知特性の理解に基づいたより根本的な対策が必要である。さらに、現在の脅威に対する対策だけでなく、将来の脅威に対してもプロアクティブに対策することが重要である。

「コグニティブセキュリティ」のための研究開発戦略の提案に向け、科学技術未来戦略ワークショップを開催し、人間の認知特性の理解と、それに基づく対策技術を創出するための重要な研究開発課題や推進方策の具体化に向けた論点について議論した。本ワークショップでは、フィッシングや偽情報などの悪意がある情報だけでなく、デマなどの必ずしも悪意があるとは限らない情報を対象とした研究開発戦略の提案を検討しており、ワークショップにおいても情報と認知に関わる問題を幅広く議論した。

3. プログラム（敬称略）

- (1) 開催挨拶（9:00～9:05） 木村康則（CRDS 上席フェロー）
- (2) 提言骨子と論点の説明（9:05～9:15） 福井章人（CRDS フェロー）
- (3) 話題提供（9:15～10:33） 各発表13分

デジタル社会の脅威 / 対策と今後の取り組み

- ・セキュリティの観点から：秋山満昭 NTT社会情報研究所 上席特別研究員
- ・偽・誤情報の観点から：鈴木悠 NICTサイバーセキュリティ研究所 専門研究員

37 詳細は、参考文献1）を参照いただきたい。

- ・アテンションエコノミーの観点から：土方嘉徳 兵庫県立大学 大学院情報科学研究科 教授
人間の認知特性の理解の現状と今後の取り組み
- ・認知科学・心理学の観点から：田中優子 名古屋工業大学 大学院工学研究科・基礎類 教授
- ・脳情報科学の観点から：西田知史 NICT 未来ICT研究所 脳情報通信融合研究センター 主任研究員

対策のシステムデザインと社会受容性の現状と今後の取り組み

- ・対策のシステムデザインと社会受容性：小野哲雄 京都橘大学 工学部情報工学科 教授
- 休憩（10:33～10:40）

(4) 総合討論（10:40～12:00）司会：福井章人（CRDS フェロー）

ディスカッサント

- ・青木孝文 東北大学 理事・副学長
- ・後藤厚宏 情報セキュリティ大学院大学 教授/JST CRDS 特任フェロー
- ・植田一博 東京大学 大学院総合文化研究科 教授
- ・標葉隆馬 慶應義塾大学 大学院メディアデザイン研究科 准教授
- ・福島俊一 CRDS フェロー

聴講参加者（上記参加者以外）

- ・文部科学省 1名
- ・総務省 1名
- ・国立研究開発法人情報通信研究機構（NICT） 5名
- ・国立研究開発法人新エネルギー・産業技術総合開発機構（NEDO） 1名
- ・独立行政法人情報処理推進機構（IPA） 1名
- ・国立研究開発法人科学技術振興機構 社会技術研究開発センター（RISTEX）研究プログラム「情報社会における社会的側面からのトラスト形成（デジタルソーシャルトラスト）」研究者 7名
- ・国立研究開発法人科学技術振興機構（JST） 20名

合計 36名

A-2 専門家へのインタビュー

インタビュー・意見交換を実施した専門家

（敬称略、五十音順、所属・役職は実施時点）

青木 孝文	東北大学 理事・副学長
秋山 満昭	NTT 社会情報研究所 上席特別研究員
安藤 未希	株式会社インフォハント 代表取締役
稲葉 緑	情報セキュリティ大学院大学情報セキュリティ研究科 教授
井上 大介	国立研究開発法人情報通信研究機構サイバーセキュリティ研究所 所長
植田 一博	東京大学大学院総合文化研究科 教授
大澤 淳	独立行政法人情報処理推進機構セキュリティセンター企画室サイバー情勢研究室 室長
小川 隆一	独立行政法人情報処理推進機構セキュリティセンター企画室
小野 哲雄	京都橘大学工学部 情報工学科 教授
加藤 雅彦	フィッシング対策協議会 技術・制度検討ワーキンググループ

唐沢 勇輔	フィッシング対策協議会 技術・制度検討ワーキンググループ
川原 圭博	東京大学大学院工学系研究科 教授
桐生 正幸	東洋大学社会学部社会心理学科 教授
小高 照正	一般財団法人日本サイバー犯罪対策センター 業務統括マネージャー
後藤 厚宏	情報セキュリティ大学院大学 教授
齋木 潤	京都大学大学院人間・環境学研究科共生人間学専攻 教授
櫻澤 健一	一般財団法人日本サイバー犯罪対策センター 業務執行理事
澤井 努	広島大学大学院人間社会科学研究科 特定教授
Katie Seaborn	東京科学大学工学院 准教授
標葉 隆馬	大阪大学社会技術共創研究センター 准教授
澁谷 遊野	東京大学大学院情報学環・学際情報学府 准教授
鈴木 悠	国立研究開発法人情報通信研究機構サイバーセキュリティ研究所 専門研究員
高橋 達二	東京電機大学大学院先端科学技術研究科/理工学部理工学科情報システムデザイン学系 教授
田中 優子	名古屋工業大学大学院工学研究科・基礎類 教授
鳥海 不二夫	東京大学大学院工学系研究科 教授
長迫 智子	独立行政法人情報処理推進機構セキュリティセンター企画室サイバー情勢研究室 研究員
中島 尚樹	独立行政法人情報処理推進機構セキュリティセンター普及啓発・振興部相談・支援グループグループリーダー
成瀬 康	国立研究開発法人情報通信研究機構未来ICT研究所脳情報通信融合研究センター 脳機能解析研究室 室長
西垣 正勝	静岡大学創造科学技術大学院 教授
西田 知史	国立研究開発法人情報通信研究機構未来ICT研究所脳情報通信融合研究センター 主任研究員
信原 幸弘	東京大学大学院・総合文化研究科 教授
土方 嘉徳	兵庫県立大学大学院情報科学研究科 教授
平塚 伸世	フィッシング対策協議会 技術・制度検討ワーキンググループ
福住 伸一	特定国立研究開発法人理化学研究所革新知能統合研究センター 副チームリーダー
古田 大輔	日本ファクトチェックセンター 編集長
本田 秀仁	追手門大学大学院心理学研究科 教授
三輪 和久	名古屋大学大学院情報学研究科心理・認知科学専攻 教授
村山 太一	横浜国立大学大学院環境情報研究院 助教授
森田 純哉	静岡大学学術院情報学領域情報学部 教授
渡邊 泰司	一般財団法人日本サイバー犯罪対策センター 業務統括部長

付録B 国内外の状況

B-1 国内外の研究プログラム・政策の状況

表B-1-1に、日本、米国、欧州における関連する研究プログラムと政策の主要な動向をまとめた。

各国の研究プログラムでは、コグニティブセキュリティに関わる研究開発は各国で推進されているが、人間の認知に関する研究分野と連携したテーマはまだ少数である。また、政策では、国により違いがあるが、日本や欧州は、偽・誤情報などの情報流通に関わる問題に対して政策面からも積極的に取り組んでいることがうかがえる。

以下では、表B-1-1に示した研究プログラムと政策の動向について概要を説明する。

研究プログラム

<日本>

フェイクメディアを対象とした研究開発が、科学技術振興機構（JST）戦略的創造研究推進事業 チーム型研究（CREST）「インフォデミックを克服するソーシャル情報基盤技術」や、内閣府 経済安全保障重要技術育成プログラム（K Program）「SYNTHETIQ X：フェイク情報拡散の防御と予防を実現する研究基盤」において実施されている。また、SNS上の偽・誤情報を対象とした研究開発が、K Program「偽情報分析に係る技術の開発」や総務省「インターネット上の偽・誤情報等への対策技術の開発・実証事業」において実施されている。トラストを対象とした研究プログラムが、JST 社会技術研究開発センター（RISTEX）研究プログラム「情報社会における社会的側面からのトラスト形成（デジタルソーシャルトラスト）」による実施されている。人間の認知的脆弱性に関する知見に基づく対策の研究テーマはまだ少数である。

<米国>

過去から国防高等研究計画局（Defense Advanced Research Projects Agency：DARPA）がフェイク画像・動画対策やフィッシングなどのソーシャルエンジニアリング対策の研究プログラムを推進している。国家安全保障の観点からコグニティブセキュリティの研究開発が積極的に進められている。

<欧州>

Horizon Europeにおいて、SNS上の偽・誤情報対策のための情報拡散における個人行動や敵対的行動の予測、偽情報に対するAIソリューション、SNSを使うナラティブへの対処、意思決定のための可視化など、主に一般市民を対象とした幅広いプロジェクトが推進されている。

政策

<日本>

「情報流通プラットフォーム対処法」や「デジタル空間における情報流通の健全性確保の在り方に関する検討会」など、総務省を中心として、SNS上の情報流通に関わる問題への対策が進められている。また、「国家安全保障戦略」（2022年12月閣議決定）において「偽情報等の拡散を含め、認知領域における情報戦への対応能力を強化する」ことが記載され、認知領域における対策の強化が求められている。

<米国>

米カリフォルニア州が消費者プライバシー権利法（California Privacy Rights Act：CPRA）（2020年成立）によりダークパターンを禁止している。

<欧州>

EUデジタルサービス法（DSA：Digital Service Act）（2024年2月成立）でプラットフォーム事業者に違法コンテンツへの対処などを義務付けており、偽・誤情報への対策を進めている。

表 B-1-1 コグニティブセキュリティー関連の研究プログラム・政策

国・地域	研究プログラム・政策事例
日本	<研究プログラム> - 文部科学省 2020 年戦略目標「信頼される AI」を受けた JST CREST「信頼される AI システムを支える基盤技術」研究領域の「インフォデミックを克服するソーシャル情報基盤技術」における、多様なモダリティによる高度な FakeMedia 生成技術・検出・防御・無毒化技術、インフォデミックを緩和し多様な意思決定を支援する情報技術の研究開発（2020 年度～） - 経済安全保障重要技術育成プログラム（K Program）「人工知能（AI）が浸透するデータ駆動型の経済社会に必要な AI セキュリティ技術の確立」における、JST「SYNTHETIQ X：フェイク情報拡散の防御と予防を実現する研究基盤」（2024 年度～） - 経済安全保障重要技術育成プログラム（K Program）「偽情報分析に係る技術の開発」における、NEDO「偽情報の検知・評価・システム化に関する研究開発」（2024 年～） - JST 社会技術研究開発センター（RISTEX）の「情報社会における社会的側面からのトラスト形成（デジタルソーシャルトラスト）」（2023 年～） - 総務省「インターネット上の偽・誤情報等への対策技術の開発・実証事業」（2024 年～） <政策> 「情報流通プラットフォーム対処法」（2024 年 5 月成立） - 総務省「デジタル空間における情報流通の健全性確保の在り方に関する検討会」（2023 年 11 月～）、「デジタル空間における情報流通の諸課題への対処に関する検討会」（2024 年 10 月～） - 国民を詐欺から守るための総合対策とりまとめ（犯罪対策閣僚会議）（2024 年 6 月） - 国家安全保障戦略（2022 年 12 月閣議決定）において「偽情報等の拡散を含め、認知領域における情報戦への対応能力を強化」
米国	<研究プログラム> - DARPA（Defense Advanced Research Projects Agency）の SemaFor（Semantic Forensics）において画像・動画の改ざんやフェイクの検知、Active Social Engineering Defense（ASED）においてソーシャルエンジニアリングの検知・防御、Influence Campaign Awareness and Sensemaking（INCAS）において情報拡散による社会への影響の認知と対策。 - IARPA（Intelligence Advanced Research Projects Activity）ReSCIND（Reimagining Security with Cyberpsychology-Informed Network Defenses）プロジェクトにおいて、攻撃者の手口や認知に着目した対策の研究。 <政策> - 米カリフォルニア州の消費者プライバシー権利法（California Privacy Rights Act: CPRA）（2020 年成立）でダークパターンを禁止。
欧州	<研究プログラム> - Horizon Europe において、SNS の情報拡散における個人行動や、敵対的行動の予測、偽情報に対する AI ソリューション、SNS でのナラティブへの対処、意思決定などを対象とした複数のプロジェクトを推進。 - URIBMD project, “The I in Misinformation: Understanding the Role of Individual Behavior in Social Media Information Diffusion”¹⁶⁾（ソーシャルメディアの情報拡散における個人行動の役割の理解）（2024 年～） - ERINIA project, “Evaluating the Robustness of Non-Credible Text Identification by Anticipating Adversarial Actions”¹⁷⁾（敵対的行動を予測することによる非信頼性テキスト識別の堅牢性の評価）（2022 年～） - AI4TRUST project, “AI-based technologies for trustworthy solutions against disinformation”¹⁸⁾（偽情報に対する信頼できるソリューションのための AI ベース技術）（2023 年～） - SMIDGE project, “Social Media narratives: addressing extremism in middle age”¹⁹⁾（ソーシャルメディアの物語：ミドル世代の過激主義への対処）（2023 年～） - SYMBIOTIK project, “Context-aware adaptive visualizations for critical decision making”²⁰⁾（重要な意思決定のためのコンテキスト認識型適応型可視化）（2022 年～） <政策> - EU デジタルサービス法（DSA：Digital Service Act）（2024 年 2 月成立）でプラットフォームに違法コンテンツへの対処などを義務付け。

B-2 論文数の推移

図 B-2-1 に、コグニティブセキュリティーに関する論文数の推移を示した（検索条件は表 B-2-1 を参照）。論文数は、年々増加しており、この分野の研究開発が活発であることを示している。国別では、米国、英国、インド、中国、オーストラリアの順となっており、欧米が中心であるものの、インドや中国の発表も増加してい

ることがうかがえる。表B-2-2、および表B-2-3に示すように、著者所属組織や研究者の順位では、欧州、米国、オーストラリアの組織や研究者が上位を占めており、これまで、欧米やオーストラリアを中心に研究が行われてきたことがうかがえる。

付録B 国内外の状況




表 B-2-1 検索条件

項目	条件
データソース	Scopus 2024 年 12 月末データ
検索キーワード	Phishing、Misinformation、Disinformation、Dark pattern、Conspiracy
出版年	2000 年～2024 年
対象分野	Scopus27 分野：学際分野、人文科学、コンピュータ科学、決定科学、経済学・計量経済学・財政、工学、数学、神経科学、心理学、社会科学
検索対象	タイトル、抄録、検索語、著者キーワード
検索言語	英語
文献種別	Article、会議録、Letter、研究ノート、総説

表 B-2-2 論文数（整数カウント） 著者所属機関

組織名	論文数	国
University of Amsterdam	91	オランダ
University of Western Australia	73	オーストラリア
Carnegie Mellon University	68	米国
Vrije Universiteit Amsterdam	62	オランダ
University of Kent	61	英国
Indiana University	60	米国
University of Washington	59	米国
University of Michigan	59	米国
University of Illinois	57	米国
University College London	57	英国

表 B-2-3 論文数（整数カウント） 研究者

研究者	論文数	組織名	国
Lewandowsky Stephan	45	University of Bristol	英国
Ecker Ullrich K. H.	45	University of Western Australia	オーストラリア
Douglas Karen M.	38	University of Kent	英国
Van Prooijen Jan-Willem	36	Vrije Universiteit Amsterdam	オランダ
Rand David G.	33	Sloan School of Management	米国
van der Linden Sander	32	ケンブリッジ大学	米国
Loftus Elizabeth F.	30	University of California	米国
Hameleers Michael	30	University of Amsterdam	オランダ
Pennycook Gordon	29	Cornell University	米国
Otgaar Henry	25	Maastricht University	オランダ

付録C 現行対策の事例

表 C-1 に、対策手法の分類と現行対策の例・概要を示す。現行対策の例・概要には、既に実施されている対策、および研究開発が進められている対策が含まれる。

表 C-1 対策手法の分類と現行対策の概要

対策手法の分類		現行対策の例・概要
脅威情報への直接的対策	事前対策	- フィッシングメールのフィルタリング： プラットフォーム事業者などによるメールフィルタリング³⁸。 - フィッシングサイトの無効化： ウェブサイトを調査・分析して検出したフィッシングサイトを無効化³⁹。 - 既知の脅威情報を学習した機械学習（Machine Learning：ML）や大規模言語モデル（Large Language Model：LLM）を用いたフィッシングサイトの検出を効率化する研究開発⁴⁰。 - フェイクメディアを検知・無害化する研究開発⁴¹。 - SNS への投稿の拡散を分析する研究開発⁴²。
	即時対策	- フィッシングメールやフィッシングサイトの警告表示： 事前に分析・検証したフィッシングメールの発信者やフィッシングサイトのアドレス情報などに基づき、利用者がフィッシングメールやフィッシングサイトにアクセスした際に警告を表示⁴³。 - コンテンツの作成者・発信者、情報の改ざん有無の表示： 誰が作成・発信したのかを第三者機関が確認し、改ざん不可能な形で付与し、利用者に提示⁴⁴。 - 利用者が受け取ったメールがフィッシングメールである可能性を生成 AI により自然言語で説明する研究開発⁴⁵。

付録C 現行対策の事例

38 Google Cloud Japan Team「Gmailの迷惑メールフィルタを理解する（2022年6月3日）」
<https://workspace.google.com/blog/ja/identity-and-security/an-overview-of-gmails-spam-filters>（2025年11月1日アクセス）

39 日本サイバー犯罪対策センター（JC3）「サイバー空間の脅威の特定・軽減・無効化に向けた活動」
<https://www.jc3.or.jp/about/>（2025年11月1日アクセス）

40 阿曾村一郎 他「機械学習とAI エージェントを組み合わせたハイブリッド型フィッシングサイト検出システムの開発と評価」『コンピュータセキュリティシンポジウム2025 予稿集』
<https://easycongress.com/css2025/registration/mypage/proceedings/IPSJCSS-2025221.pdf>（2025年11月1日アクセス）

41 CREST FakeMedia「インフォデミックを克服するソーシャル情報基盤技術」JST 戦略的創造研究推進事業（CREST）研究領域「信頼されるAIシステム」
<https://research.nii.ac.jp/~iechizen/crest/index.html>（2025年11月1日アクセス）

42 総務省プラットフォームサービスに関する研究会「資料1 エコーチェンバーとフィルターバブル：プラットフォームが促進するフィードバックループ（東京工業大学環境・社会理工学院笹原和俊准教授）」第44回 配布資料（2025年11月1日アクセス）

43 Google, “Making the world’s information safely accessible.” Google Safe Browsing,
<https://safebrowsing.google.com/>（2025年11月1日アクセス）

44 Originator Profile「Originator Profile 技術について」
<https://originator-profile.org/ja-JP/overview/>（2025年11月1日アクセス）

45 Yizhu Wang, et al., “Can You Walk Me Through It? Explainable SMS Phishing Detection using LLM-based Agents,” in *SOUPS '25: Proceedings of the Twenty-First USENIX Conference on Usable Privacy and Security*,
<https://www.usenix.org/conference/soups2025/presentation/wang>（2025年11月1日アクセス）

	事後対策	• ファクトチェック：ファクトチェック団体などが、SNSなどに投稿された情報の真偽を検証し公開⁴⁶（ファクトチェックは、利用者がチェック結果を見るタイミングにより、事前対策、即時対策、事後対策となる）。 • コミュニティーノート：SNSの利用者が投稿に対して補足情報や異なる視点による情報を自発的に記述し、他の利用者がその投稿の信頼性や妥当性を評価⁴⁷。
脅威情報への間接的対策	脅威情報が利用者に到達するタイミングによらない対策	• リテラシー教育：学校現場などで、インターネットやSNSの仕組み、リスクなどに関する知識を教育⁴⁸。 • 能動的なプレバンキング：ゲームやクイズの形式で提供される。フィッシングやSNS上の偽・誤情報などの脅威に対する抵抗力を高める^{14), 49, 50} • 受動的なプレバンキング：短い形式（テキスト、グラフィックス、ビデオ）で提供され、脅威に抵抗するための知識を身に付ける¹⁴⁾。

46 日本ファクトチェックセンター, <https://www.factcheckcenter.jp/>（2025年11月1日アクセス）

47 X, “Community Notes,” <https://communitynotes.x.com/guide/en/about/introduction>（2026年2月1日アクセス）

48 株式会社インフォハント「学校現場でのメディア情報リテラシー教育の実践」総務省デジタル空間における情報流通の健全性確保の在り方に関する検討会（第18回）資料18-2-3, https://www.soumu.go.jp/main_content/000945574.pdf（2025年11月1日アクセス）

49 Google「フィッシングクイズ」<https://phishingquiz.withgoogle.com/?hl=ja>（2026年2月1日アクセス）

50 CLASSROOM ADVENTURE「体験型メディアリテラシープログラム“レイのブログ”」総務省デジタル空間における情報流通の健全性確保の在り方に関する検討会（第18回）資料18-2-4, https://www.soumu.go.jp/main_content/000945584.pdf（2025年11月1日アクセス）

付録D 専門用語解説

用語	説明
認知バイアス	人間の意思決定に影響を与える心理的な傾向や偏り。人間は、自分の願望や経験、思い込み、周囲の環境によって、無意識のうちに合理的ではない行動、偏った判断をすることがある ⁵¹ 。
二重過程理論	人間には二つの情報処理様式（以下ではシステム1とシステム2と呼ぶ）があると仮定する情報処理の理論。システム1は、直観的、自動的、速い、努力を要さない、進化的に古い、という特徴がある。システム2は、熟慮的、制約的、遅い、努力を要する、進化的に新しい、という特徴がある ²¹⁾ 。
アテンションエコノミー	興味や関心、注目（＝アテンション）をひくような情報によって、クリックを促し、より多くの広告を見てもらったり、サービスを使ってもらったりしようとするインターネット上のしくみ（＝経済モデル） ⁵¹ 。
フィルターバブル	SNSなどの情報サービスでは、過去の検索・閲覧履歴に基づいて、自分の好みに近い有益そうな情報が優先的に表示される。その結果、自分色の泡の中に閉じ込められているかのように、自分が見たいとされる情報しか見えなくなってしまう状態 ⁵¹ 。
エコーチェンバー	ソーシャルメディアを利用する際、自分と似た興味関心を持つユーザーをフォローする結果、意見をSNSで発信すると自分と似た意見が返ってくるという状況を、閉じた小部屋で音が反響する物理現象にたとえたもの ²²⁾ 。
フィッシング	送信者を詐称したメールやSMSを送り、貼り付けたリンクをクリックさせて偽のホームページなどに誘導することで、クレジットカード番号やアカウント情報（ユーザーID、パスワードなど）などの情報を盗み出す手口 ⁵² 。
偽・誤情報	偽情報（ディスインフォメーション）：個人、組織、国などに危害を与えるため、意図的・意識的に作られたウソ（虚偽）の情報（例：意図的に作られた悪意があるプロパガンダ・世論操作）。 誤情報（ミスインフォメーション）：危害を引き起こす意図で作成されたものではなく、勘違い・誤解により拡散した間違い情報（例：デマ）。 悪意ある情報（マルインフォメーション）：情報自体は正しいが、誰か（何か）を攻撃したり誤解させたりする狙いのある情報（例：リーク、ハラスメント、リベンジポルト） ^{51, 21)} 。
ダークパターン	ユーザーが無意識のうちに自身に不利な行動を取るよう誘導するデザイン ²⁾ 。
ナラティブ（物語）	コグニティブセキュリティーにおける「ナラティブ（物語）」とは、個々の情報を一貫性のあるストーリーとして提示することで、受け手の信念や感情に働きかけ、特定の目的を達成するための意図的な情報の体系。
ファクトチェック	社会に広がっている情報・ニュースや言説が事実に基づいているかどうかを調べ、そのプロセスを記事化して、正確な情報を人々と共有する取り組み ⁵³ 。

付録D 専門用語解説

51 総務省「知っておきたい16のキーワード」ICT活用リテラシー向上プロジェクト ネット&SNSよりよくつかって未来をつくろう、
<https://www.soumu.go.jp/ict-mirai/keyword/>（2026年1月27日アクセス）

52 総務省「フィッシング詐欺とは？」国民のためのサイバーセキュリティサイト、
https://www.soumu.go.jp/main_sosiki/cybersecurity/kokumin/basic/risk/04/（2026年1月27日アクセス）

53 ファクトチェック・イニシアチブ「ファクトチェックとは」<https://fj.info/introduction>（2026年1月27日アクセス）

ユーザブルセキュリティ	ユーザブルセキュリティは、情報サービスを利用するユーザーや開発者・運用者などの人を中心にしてセキュリティやプライバシーの問題解決に取り組む研究分野。この分野では、ユーザーが情報サービスを利用したり、開発・運用したりするさまざまなシーンにおいて、認識（perception）・行動（behavior）を観測してユーザーを理解することで、ユーザーがより適切な認識や意思決定（decision-making）を行いやすいセキュリティ・プライバシー技術の確立を目指している ⁵⁴ 。
重要インフラ・サプライチェーンのセキュリティ	重要インフラのセキュリティ： 医療、電力、水道、ガスなどの重要インフラへのサイバー攻撃に対するセキュリティ。 サプライチェーンのセキュリティ： 企業の製品開発のための製品サプライチェーンや、オープンソースソフトウェア（Open Source Software：OSS）などのソフトウェア流通のためのソフトウェアサプライチェーンへのサイバー攻撃に対するセキュリティ ⁵⁵ 。

- 54 詳細は、[参考文献 2] 科学技術振興機構研究開発戦略センター「研究開発の俯瞰報告書 システム・情報科学技術分野」(2025年12月) <https://www.jst.go.jp/crds/report/CRDS-FR-S.html> (2026年2月2日アクセス) S3.04 人・社会とセキュリティを参照いただきたい。
- 55 参考文献2) 科学技術振興機構研究開発戦略センター「研究開発の俯瞰報告書 システム・情報科学技術分野」(2025年12月) <https://www.jst.go.jp/crds/report/CRDS-FR-S.html> (2026年2月2日アクセス) S3 セキュリティ・トラスト 区分総論を参照いただきたい。

付録E 参考文献

- 1) 科学技術振興機構研究開発戦略センター「科学技術未来戦略ワークショップ報告書 コグニティブセキュリティ」(CRDS-FY2025-WR-04)(2025年9月)
<https://www.jst.go.jp/crds/report/CRDS-FY2025-WR-04.html> (2025年11月1日アクセス)
- 2) 科学技術振興機構研究開発戦略センター「研究開発の俯瞰報告書 システム・情報科学技術分野」(2025年12月) <https://www.jst.go.jp/crds/report/CRDS-FR-S.html> (2026年2月2日アクセス)
- 3) T. T. Longtchi, R. M. Rodriguez, L. Al-Shawaf, A. Atyabi and S. Xu, “Internet-Based Social Engineering Psychology, Attacks, and Defenses : A Survey,” *Proceedings of the IEEE*, vol. 112, no. 3, 210-246., <https://doi.org/10.1109/JPROC.2024.3379855>.
- 4) Kunihiro Miyazaki and et al. “Aggressive behaviour of anti-vaxxers and their toxic replies in English and Japanese,” *Humanit Soc Sci Commun* 9, 229.,
<https://doi.org/10.1057/s41599-022-01245-x>.
- 5) 鈴木、稲葉,「Disinformationの共有を減らすための情動調節戦略を用いたデジタルナッジ」, 第55回SPT研究会(2024)
- 6) Jack Jamieson, Toru Hara, and Mitsuaki Akiyama, “Flagging Emotional Manipulation : Impacts of Manipulative Content Warnings on Sharing Intentions and Perceptions of Health-Related Social Media Posts,” *Proceedings of the Extended Abstracts of the CHI Conference on Human Factors in Computing Systems*, no. 281, 1-9.,
<https://doi.org/10.1145/3706599.3719948>.
- 7) Yuwei Chuai, Haoye Tian, Nicolas Pröllochs, and Gabriele Lenzini, “Did the Roll-Out of Community Notes Reduce En-gagement With Misinformation on X/Twitter?” *Proceedings of the ACM on Human-Computer Interaction*, vol. 8, no. 428, 1-52.,
<https://doi.org/10.1145/3686967>.
- 8) Satoshi Nishida, et al., “Brain-Mediated Transfer Learning of Convolutional Neural Networks,” *Proceedings of the AAAI Conference on Artificial Intelligence*, 34, 5281–5288.
- 9) Kiichi Kawahata, et al., “Decoding Individual Differences in Mental Information from Human Brain Response Predicted by Convolutional Neural Networks,” bioRxiv.,
<https://doi.org/10.1101/2022.05.16.492029>.
- 10) Weicheng Ma, et al., “Simulated Misinformation Susceptibility (SMISTS) : Enhancing Misinformation Research with Large Language Model Simulations,” *Findings of the Association for Computational Linguistics : ACL 2024*, 2774–2788.,
<https://doi.org/10.18653/v1/2024.findings-acl.162>.
- 11) 文部科学省, 厚生労働省, 経済産業省,「人を対象とする生命科学・医学系研究に関する倫理指針」2021年3月23日,
https://www.mext.go.jp/lifescience/bioethics/files/pdf/n2373_01.pdf, (2025年9月1日アクセス) .
- 12) Joseph B. Bak-Coleman, et al. “Combining interventions to reduce the spread of viral misinformation,” *Nat Hum Behav* 6, 1372–1380.,
<https://doi.org/10.1038/s41562-022-01388-6>.
- 13) Satoshi Furutani, et, al. “Suppressing the Endogenous Negative Influence Through Node

- Intervention in Social Networks,” *IEEE Access*, vol. 13, 9290-9302.,
<https://doi.org/10.1109/ACCESS.2024.3523036>.
- 14) 科学技術振興機構研究開発戦略センター「連続シンポジウム報告書 さまざまな分野に広がるトラスト研究、総合知による取り組みへ（１）～フェイク問題、医療AI、安全保障とトラスト～」(CRDS-FY2024-SY-01) (2025年3月)
<https://www.jst.go.jp/crds/report/CRDS-FY2024-SY-01.html> (2025年11月1日アクセス)
 - 15) 科学技術振興機構研究開発戦略センター『戦略プロポーザル：デジタル社会における新たなトラスト形成』(2022年9月)
<https://www.jst.go.jp/crds/report/CRDS-FY2022-SP-03.html> (2025年11月1日アクセス)
 - 16) URIBMD project, “The I in Misinformation : Understanding the Role of Individual Behavior in Social Media Information Diffusion,” Horizon EUROPE,
<https://doi.org/10.3030/101111447>.
 - 17) ERINIA project, “Evaluating the Robustness of Non-Credible Text Identification by Anticipating Adversarial Actions,” Horizon EUROPE, <https://doi.org/10.3030/101060930>.
 - 18) AI4TRUST project, “AI-based-technologies for trustworthy solutions against disinformation,” Horizon EUROPE, <https://doi.org/10.3030/101070190>.
 - 19) SMIDGE project, “Social Media narratives : addressing extremism in middle age,” Horizon EUROPE, <https://doi.org/10.3030/101095290>.
 - 20) SYMBIOTIK project, “Context-aware adaptive visualizations for critical decision making,” Horizon EUROPE, <https://doi.org/10.3030/101071147>.
 - 21) 科学技術振興機構研究開発戦略センター「俯瞰ワークショップ報告書 コグニティブセキュリティ研究動向」(CRDS-FY2023-WR-04) (2023年1月)
<https://www.jst.go.jp/crds/report/CRDS-FY2023-WR-04.html> (2025年11月1日アクセス)
 - 22) 笹原 和俊『フェイクニュースを科学するー拡散するデマ、陰謀論、プロパガンダのしくみ』(東京：化学同人, 2018) .

作成メンバー

総括責任者	木村 康則	上席フェロー	CRDS システム・情報科学技術ユニット
リーダー	福井 章人	フェロー	CRDS システム・情報科学技術ユニット
サブリーダー	尾崎 翔	フェロー	CRDS システム・情報科学技術ユニット
メンバー	青木 孝	フェロー	CRDS システム・情報科学技術ユニット
	小崎 成治	フェロー	CRDS システム・情報科学技術ユニット
	高島 洋典	フェロー	CRDS システム・情報科学技術ユニット
	福島 俊一	フェロー	CRDS システム・情報科学技術ユニット
	阪口 幸駿	フェロー	CRDS 企画運営室横断・融合グループ

戦略プロポーザル

CRDS-FY2025-SP-06

コグニティブセキュリティ

～デジタル社会における自律的な意思決定の支援～

STRATEGIC PROPOSAL

Cognitive Security

- Supporting Self-reliant Decision-making in the Digital Society -

令和 8 年 3 月 March 2026

ISBN 978-4-86829-046-9

国立研究開発法人科学技術振興機構 研究開発戦略センター

Center for Research and Development Strategy, Japan Science and Technology Agency

〒102-0076 東京都千代田区五番町 7 K's 五番町

電話 03-5214-7481

E-mail crds@jst.go.jp

<https://www.jst.go.jp/crds/>

本書は著作権法等によって著作権が保護された著作物です。

著作権法で認められた場合を除き、本書の全部又は一部を許可無く複製・複製することを禁じます。

引用を行う際は、必ず出典を記述願います。

なお、本報告書の参考文献としてインターネット上の情報が掲載されている場合、当該情報はURLに併記された日付または本報告書の発行年月の1ヶ月前に入手しているものです。

上記以降の情報の更新は行わないものとします。

This publication is protected by copyright law and international treaties.

No part of this publication may be copied or reproduced in any form or by any means without permission of JST, except to the extent permitted by applicable law.

Any quotations must be appropriately acknowledged.

If you wish to copy, reproduce, display or otherwise use this publication, please contact crds@jst.go.jp.

Please note that all web references in this report were last checked on the date given in the link or one month prior to publication.

CRDS is not responsible for any changes in content thereafter.

FOR THE FUTURE OF
SCIENCE AND
SOCIETY



CRDS

<https://www.jst.go.jp/crds/>

