

정책연구 2019-13

인공지능 기술 전망과 혁신정책 방향(2차년도)

- 안전하고 윤리적인 인공지능 R&D 및 활용을 위한
제도 개선 방안을 중심으로 -

A Prospective Analysis of Artificial Intelligence(AI)
Technology and Innovation Policies

이제영 · 김단비 · 양희태

연구진

연구책임자

이제영 | 과학기술정책연구원 부연구위원

연구참여자

김단비 | 과학기술정책연구원 연구원

외부연구진

양희태 | 한동대학교 경영경제학부 교수

정책연구 2019-13

인공지능 기술 전망과 혁신정책 방향(2차년도)

2019년 12월 24일 인쇄

2019년 12월 30일 발행

發行人 | 조항희

發行處 | 과학기술정책연구원

세종특별자치시 시청대로 370

세종국책연구단지 과학·인프라동 5-7F

Tel: 044)287-2000 Fax: 044)287-2068

登 録 | 2003년 9월 8일 제2015-000014호

組版 및 印刷 | 미래미디어

Tel: 02)815-0407 Fax: 02)822-1269

ISBN 978-89-6112-609-0 93300

| 목 차 |

요 약	i
-----------	---

제1장 서 론: 연구의 목적	1
-----------------------	---

제1절 연구 배경	1
1. 인공지능 시대의 개화	1
2. 인공지능의 안전성과 윤리 이슈 대두	3
제2절 연구 목적 및 프레임워크	4

제2장 인공지능 안전성 및 윤리의 개념	6
-----------------------------	---

제1절 인공지능 안전성(AI Safety)	6
1. 인공지능 안전성의 개념 및 중요성	6
2. 인공지능 안전성 침해 사례	10
제2절 인공지능 윤리	12
1. 인공지능 윤리(AI Ethics)의 개념 및 중요성	12
2. 인공지능 윤리 침해 사례	16
제3절 인공지능 안전성 및 윤리의 개념적 범위	19

제3장 기업 및 학계/연구계 대응 동향	20
-----------------------------	----

제1절 글로벌 기업 대응 동향	21
1. 인공지능 윤리 전문가 채용	21
2. 인공지능 개발자가 지켜야 할 원칙 수립	24
3. 인공지능의 사회적 영향 연구 및 감시 전담부서 설치	28
4. 인공지능 감사(Algorithm Auditing) 실시	31
5. 인공지능 윤리교육 실시	32
6. 인공지능을 활용한 사회적 공익 프로젝트 운영	33

7. 협회 구성 또는 외부 시민 단체와 공동 대응	35
제2절 학계/연구계 대응 동향	36
1. 인공지능 윤리지침, 표준규정 및 가이드라인 제시	36
2. 인공지능 윤리 프로젝트 운영	43
3. 인공지능 윤리교육 강화 및 방법론 연구	45
제3절 시사점	47

제4장 주요국 정부 대응 동향 50

제1절 주요국 정부 대응 동향	50
1. 미국	50
2. EU	64
3. 일본	72
4. 중국	78
5. OECD AI 권고안	85
6. 시사점	89
제2절 국내 기업·정부·학계 대응 동향	90
1. 기업 대응 동향	90
2. 학계 대응 동향	100
3. 정부 대응 동향	108
제3절 기업 및 학계/연구계, 주요국 정부 대응 동향 종합	122

제5장 정책제언 124

제1절 법제도 개선 방안	124
1. 법제도적 이슈 정리	124
2. 법제도 개선 우선순위 도출	135
3. 법제도 개선 방안	139
제2절 결론 및 시사점	161
1. 인공지능 안전·윤리 R&D의 방향	161

2. 인공지능 윤리 확보를 위한 R&D 방향	164
3. 인공지능 안전성 확보를 위한 R&D 방향	167
4. 데이터 이슈를 고려한 인공지능 정책방향	168

참고문헌	171
-------------------	------------

부 록	185
------------------	------------

Summary	189
----------------------	------------

Contents	191
-----------------------	------------

| 표 목 차 |

〈표 2-1〉 1차년도 인공지능 활용사례 별 안전성 관련 소비자 pain point	8
〈표 2-2〉 인공지능 통제 방법	9
〈표 2-3〉 행위의 윤리성 판단에 대한 이론들	13
〈표 2-4〉 아이작 아시모프의 로봇 3원칙	14
〈표 2-5〉 인공지능의 윤리적 학습 관련 연구 사례	15
〈표 3-1〉 Google AI 권고사항	25
〈표 3-2〉 Microsoft AI 개발원칙	26
〈표 3-3〉 카카오의 윤리 현장 전문	27
〈표 3-4〉 구글의 'AI for Social Good' 수행 과제	33
〈표 3-5〉 인텔의 'AI for Social Good' 수행 과제	34
〈표 3-6〉 아실로마 23대 인공지능 원칙	37
〈표 3-7〉 캠브리지대 실존적 위기센터(CSER)의 인공지능 위협 대비 권고안	40
〈표 3-8〉 일본 인공지능 윤리지침 주요내용	42
〈표 3-9〉 인공지능 윤리와 거버넌스의 세부 프로젝트 내용	44
〈표 4-1〉 DARPA의 AI Next Campaign의 주요 내용	60
〈표 4-2〉 조직의 참여 수준과 AI 시스템에 대한 평가 관련 역할	70
〈표 4-3〉 일본 인공지능 연구개발 가이드라인 주요 내용	73
〈표 4-4〉 중국 차세대 인공지능 발전계획 6대 보장조치	80
〈표 4-5〉 윤리문제 측면에서 알고리즘과 관련된 주요 논의 주제	91
〈표 4-6〉 카카오의 윤리 현장 전문	92
〈표 4-7〉 네이버의 프라이버시 관련 보고서	95
〈표 4-8〉 2019 인공지능 윤리+교육 포럼 공동선언문	99
〈표 4-9〉 고등과학원 초하제 연구프로그램 워크숍 (2017.11. ~ 2019. 8.)	101
〈표 4-10〉 HK+인공지능인문학 세부영역	104
〈표 4-11〉 HK+인공지능인문학 예상 성과	104
〈표 4-12〉 개별 산업별 윤리 이슈	107

〈표 4-13〉 윤리 대응 프레임워크 (예시: 제조)	107
〈표 4-14〉 2007 로봇윤리헌장 초안	109
〈표 4-15〉 지능형 로봇 개발 및 보급 촉진법 중 로봇윤리헌장 관련 내용 ...	109
〈표 4-16〉 로봇 윤리 가이드라인(안)의 3대 기본가치와 5대 실천원칙	111
〈표 4-17〉 ‘로봇기본법’의 주요 내용	111
〈표 4-18〉 지능정보사회 윤리헌장	112
〈표 4-19〉 지능정보사회 윤리가이드라인의 적용 대상 및 범위	113
〈표 4-20〉 지능정보사회 윤리가이드라인의 공통원칙	114
〈표 4-21〉 지능정보사회 윤리가이드라인의 적용대상별 세부지침	114
〈표 4-22〉 “[목표4]지능정보화시대 이용자 보호 체계 정립”의 전략 및 과제	117
〈표 4-23〉 “[목표4]지능정보화시대 이용자 보호 체계 정립” 추진 일정	118
〈표 4-24〉 사이버 위협 유형별 대응 방향	119
〈표 5-1〉 자율주행 단계별 구분	150
〈표 5-2〉 인공지능 윤리 확보를 위한 R&D 방향	167

| 그 림 목 차 |

[그림 1-1] 연구 프레임워크	5
[그림 2-1] 인공지능의 구성기술	6
[그림 2-2] 인공지능 로봇 오작동(상) 및 우버 사고(하) 사례	10
[그림 2-3] 콤파스의 인종차별(좌)와 안면인식 카메라의 오류(우) 사례	11
[그림 2-4] 전세계 군사용 로봇 시장 규모(좌) 및 용도별 드론 시장 규모(우) ·	16
[그림 2-5] 예멘 공군기지(좌)와 베네수엘라 대통령(우) 드론 테러 사례	17
[그림 2-6] 인공지능을 이용한 딥페이크 사례	17
[그림 2-7] 진찰 과정에서의 이미지 조작 사례(좌)와 실제 조작한 이미지(우) ·	18
[그림 2-8] 인공지능 안전성과 인공지능 윤리의 개념적 범위	19
[그림 4-1] 미국 국가 AI R&D 전략계획 (' 16.10)	56
[그림 4-2] 인공지능의 3가지 물결	59
[그림 4-3] 설명 가능한 인공지능의 목표	61
[그림 4-4] 적대적 공격의 예시	62
[그림 4-5] 적대적 공격의 가능성이 있는 오염된 정지 교통표지판	63
[그림 4-6] 신뢰성 있는 AI의 7가지 요건	69
[그림 4-7] VUNO-MED BoneAge(2018)	97
[그림 4-8] 심심이 대화 중 혐오표현 사례	98
[그림 4-9] 인공지능 안전성 및 윤리성 측면의 대응동향 종합	122
[그림 4-10] 정책 및 기술적 차원의 대응동향 종합	123
[그림 5-1] 인공지능 법제도 개선 시급성 평가	136
[그림 5-2] 인공지능 법제도 개선 용이성 평가	137
[그림 5-3] 인공지능 법제도 개선 파급성 평가	138
[그림 5-4] 인공지능 법제도 개선 평가 종합	139

| 요약 |

제1장 서론: 연구의 목적

1. 연구 필요성 및 목적

□ 연구 배경


- 인공지능은 2010년대 들어 재부흥기를 맞이하며 기업을 넘어 국가간 경쟁도 치열해지고 있으나 안전성(safety)과 윤리(ethics) 관련 이슈도 본격적으로 대두
 - 자율주행차, 로보어드바이저, 로봇, 지능형 개인비서 기기 테스트 또는 실사용 중의 오작동으로 금전적 또는 인명 피해 발생
 - 가짜 뉴스, 자율살상무기 개발 움직임 등에 따라 산업계와 연구계, 학계에 인공지능 윤리에 대한 관심 고조

□ 연구의 목적 및 주요 질문

- 인공지능이 다양한 제품과 서비스로 상용화되어 인간의 삶에 획기적인 도움을 줄 수 있도록 미리 안전성 및 윤리 관련 이슈들을 검토해보고 실효성 높은 대안을 제시하고자 하는 것이 본 연구의 목적
 - 첫째, 인공지능의 안전성과 윤리는 어떻게 구조화될 수 있는가?
 - 인공지능의 안전성과 윤리에 대해 통용되는 정의는 무엇인가?
 - 연구개발(R&D)과 이후 제품/서비스 활용 측면에서 어떤 안전성 및 윤리 이슈들이 발생하고 있는가?
 - 둘째, 인공지능의 안전성과 윤리에 대해 이해관계자들은 어떻게 대응하고 있는가?
 - 주요국들은 인공지능의 안전성과 윤리 이슈를 어떤 관점으로 바라보고 접근하고 있으며, 국가별 차이점이 존재하는가?

- 글로벌 기업들은 인공지능의 안전한 연구개발 및 상용화 후 오작동에 대한 적절한 대처와 인공지능 윤리 실현을 위해 어떤 활동들을 펼치고 있는가?
- 셋째, 우리나라의 관련 법제도 현황과 구체적인 개선 방안은 무엇인가?
- 안전하고 윤리적인 인공지능 연구개발 및 활용 차원에서 어떤 법제도들이 개선 또는 신설되어야 하는가?

[그림 1] 연구 프레임워크



제2장 인공지능 안전성 및 윤리의 개념

1. 인공지능 안전성(AI Safety)

□ 인공지능 안전성의 개념 및 중요성

- 본 연구에서 인공지능 안전성(AI Safety)은 “인공지능의 기술·구조적 한계 및 특징으로 인해 발생할 수 있는 의도치 않은 각종 위험들에 대비하는 개념 및 분야”로 조작적 정의
- 인공지능은 인간의 지능을 모사하기 위해 다양한 SW와 HW 기술들이 융합되어

구현되는 복합체이기 때문에, 필연적으로 개발과정 상의 오류와 상용화 이후 기능적 오작동의 위험성을 내포

- 1차년도 연구에서 수행했던 핵심 응용분야 별 인공지능 활용 시나리오 분석에서도 10개 활용사례(use cases)에서 모두 인공지능 안전성과 관련된 소비자들의 pain point가 도출

〈표 1〉 1차년도 인공지능 활용사례 별 안전성 관련 소비자 pain point

활용 사례		안전성 관련 소비자 pain point
스마트홈	음성 정보 검색	- 사람을 부르는 소리, TV 소리 등을 질의/요청으로 인식
	기기 제어	- 사람을 부르는 소리, TV 소리 등을 질의/요청으로 인식 - 질의/요청사항 오독에 의한 동작 오류
자율주행차	일반 차량 주행	- 물체/환경 인식 오류에 따른 사고 발생 위험 - 돌발 상황에 맞게 유연한 운전이 어려움 - 사고 원인 및 책임 규명의 한계
	대중교통 주행	- 탑승을 완료하지 않았는데 출발 - 물체/환경 인식 오류에 따른 사고 발생 위험 - 돌발 상황에 맞게 유연한 운전이 어려움 - 사고 원인 및 책임 규명의 한계
핀테크	로보 어드바이저	- 기존 포트폴리오와의 장단점 분석의 어려움(손실 발생 가능성)
	P2P 대출	- 대출 조건에 대한 상세 설명 부재로 유·불리 판단 불가 - 대출금 지급 지연
디지털 헬스케어	진단 보조	- 의학적 정확성 검증 불가 - 인종 등 샘플 데이터 차이에 의한 권고안 오류
	웨어러블 건강관리	- 추천 코칭 정보에 대한 근거 설명 부족
상거래	온라인 쇼핑	- 추가 할인적용 등 최종 가격 및 최적 결제 수단 파악의 어려움
	무인 오프라인 매장	- 결제 오류 발생

□ 인공지능 안전성 침해 사례

- 인공지능 알고리즘 오류 및 관련 제품 및 서비스의 오작동에 의한 사건·사고는 끊임없이 발생
 - 2013년 12월 우리나라의 한택투자증권은 차익거래 자동매매시스템의 알고리즘에 오류가 발생해 2분 만에 450억원의 손실을 입었고 결국 1년 후 파산
 - 2016년 러시아에서 시험 중이던 자율 로봇이 연구실에서 나와 거리를 활보하

- 고 같은 해 미국의 한 쇼핑몰에 배치된 보안 로봇이 어린 아이를 공격
- 2018년 3월에는 미국 애리조나에서 무단횡단하던 보행자가 시험 운행 중인 우버(Uber)의 자율주행차에 치어 사망
 - 미국 플로리다 주 법무부가 사용하는 리걸 테크(legal tech) 서비스인 콤파스 (COMPAS)는 흑인과 백인의 재범 발생 확률이 비슷함에도 불구하고 흑인을 백인보다 훨씬 위험하다고 평가

2. 인공지능 윤리(AI Ethics)

□ 인공지능 윤리의 개념 및 중요성

- 본 연구에서는 인공지능 윤리(AI Ethics)를 “인공지능 관련 이해관계자들이 준수해야 할 보편적 사회 규범 및 관련 기술”로 조작적 정의
- 나쁜 의도를 가진 개발자 또는 관련 제품 및 서비스 판매자, 이용자가 인공지능을 악용하는 행위는 인공지능 윤리의 가치를 위반

□ 인공지능 윤리 침해 사례

- 인공지능을 비윤리적으로 활용하는 대표적인 경우는 대량의 인명 피해가 예상되는 자율살상 무기 개발
- 2025년 기준으로 인공지능을 탑재한 군사용 로봇과 드론 시장 규모는 민간 시장 규모를 압도할 것으로 예상
- 2019년 1월 예멘의 한 공군기지에서 개최된 정부군 행사에 후티(Houthi) 반군의 드론이 폭파해 정부군 6명이 사망하고 관료 12명이 부상하는 사고 발생
- 의도적으로 가짜 이미지나 영상, 뉴스, 음성을 생성해 배포하는 행위도 만연
- 딥페이크(deepfake)라고 불리는 이러한 편집물들은 개인의 평판을 훼손시키고 사회적 구성원 간의 신뢰를 저하

[그림 2] 예멘 공군기지 드론 테러(좌) 및 딥페이크(우) 사례



- 이스라엘의 벤구리온(Ben-Gurion) 대학교 연구진은 딥러닝을 이용해 의료 영상을 조작한 실험 결과를 2019년 4월 논문으로 발표

3. 인공지능 안전성 및 윤리의 개념적 범위

- 기술적 오류 또는 관련 이해관계자의 고의가 아닌 실수로 인해 생긴 사건·사고에 대비하는 영역을 ‘인공지능 안전성’으로, 인공지능 개발자 및 사용자가 특정 목적 및 의도를 가지고 악용하는 경우에 대응하는 분야를 ‘인공지능 윤리’로 규정하고 대응 방안을 수립

[그림 3] 인공지능 안전성과 인공지능 윤리의 개념적 범위



제3장 기업 및 학계/연구계 대응 동향

1. 글로벌 기업 대응 동향

□ 인공지능 윤리 전문가 채용

- KPMG는 인공지능과 관련하여 가장 유망한 5대 직업으로 인공지능 아키텍트, 인공지능 제품 매니저, 데이터 과학자, 인공지능 소프트웨어 엔지니어와 함께 인공지능 윤리전문가를 선정
- 세일즈포스닷컴(Salesforce.com)은 인공지능 윤리 전문가들을 지속적으로 확보하고 임원급에 해당하는 직책을 신규로 만들어 주요 의사결정에 참여
- 우버(Uber)는 2018년 7월 최고준법윤리책임자(Chief Compliance and Ethics Officer)라는 직책을 만들고 미국 법무부(US Department of Justice)에서 차관보로 근무했던 스콧 스쿨스(Scott Schools)를 임명

□ 인공지능 개발자가 지켜야 할 원칙 수립

- 2018년 6월 국방부와 의 무인드론 업그레이드 프로젝트(Project Maven)에 대한 추가 계약을 윤리적 이유로 포기하면서 구글의 CEO인 순다 피차이는 공식 블로그에 구글의 인공지능 원칙(AI at Google : Our Principle)을 발표
- 마이크로소프트도 2018년 3월 신뢰할 수 있는 인공지능 개발을 위해 개발자가 설계 단계부터 준수해야 하는 여섯 가지 개발 원칙을 제시
- IBM은 2014년부터 디자이너와 개발자에게 실무적인 가이드라인을 제공하기 위해 「인공지능을 위한 일상의 윤리(Everyday Ethics for AI)」 책자를 발간
- 카카오는 국내 업계 최초로 2018년 1월 개발자들이 알고리즘 설계 시 준수해야 할 인공지능에 관한 윤리규범을 제정·발표

□ 인공지능의 사회적 영향 연구 및 감시 전담부서 설치

- 구글 딥마인드는 2017년 10월 인공지능 개발 과정에서 연구자가 올바른 윤리적 선택을 하고 인공지능이 사회를 위해 활용되도록 도움을 주는 것을 목적으로 전담부서(DeepMind Ethics & Society Unit)를 설립
- 2018년 4월 미국 의회의 청문회 직후 페이스북은 공정한 알고리즘 설계와 모두에게 이로운 서비스를 제공하기 위한 인공지능 윤리팀 가동
- 마이크로소프트는 인공지능의 책임있는 개발과 윤리적 활용과 관련된 의사결정을 위해 2017년 7월 임원으로 구성된 ‘엔지니어링 및 연구에서의 인공지능 윤리 위원회’ 신설

□ 인공지능 감사(Algorithm Auditing) 실시

- IBM은 알고리즘의 의사결정이 편향성이 있는지를 실시간 파악할 수 있는 기술적 툴킷인 ‘Fairness 360’을 개발 중
- 구글은 ‘AI for Social Good’ 프로젝트의 일환으로 머신러닝 기반의 편향성 측정 도구 ‘What-If’ Tool을 개발
- 마이크로소프트는 알고리즘 편향성을 적발하는 툴을, 페이스북은 인공지능 훈련 데이터가 공정한지 판단하는 Fairness Flow라는 소프트웨어를 개발 중

□ 인공지능 윤리 교육 및 훈련과정 개설

- 구글은 기계학습의 공정성 확보와 관련된 콘텐츠를 별도 웹사이트(ml-fairness.com)를 통해 제공 중
- 마이크로소프트는 인공지능 전문가 교육 과정(Microsoft Professional Program in AI)내에 윤리 교육을 강화

2. 학계/연구계 대응 동향

□ 인공지능 윤리지침, 표준규정 및 가이드라인 제시

- 미래의 삶 연구소는 2017년 미국 캘리포니아 주 아실로마에서 합의된 인공지능 원칙(i.e., Asilomar AI Principles)을 발표하며 향후 인공지능을 우리의 삶을 개선하는데 활용하기 위해 고려해야 할 윤리 원칙들을 제시
- 실존적 위기센터와 세계 유수의 7개 연구기관이 공동으로 작성한 “인공지능의 해악적 사용: 예측, 예방, 완화” 보고서는 인공지능의 고의적 악용이 가져올 보안 위협에 주목하고 이를 예방·완화하기 위한 방안들을 제시

<표 2> 캠브리지대 실존적 위기센터(CSER)의 인공지능 위협 대비 권고안

권고안	주요 내용
사이버 보안 공동체에서 배우기	- 인공지능을 이용한 공격과 사이버 보안의 교차점에 위치한 문제를 해결하려면 적색팀(red team)을 구성하여 실제 어떤 공격을 받을 수 있는지 검증을 진행 - 인공지능의 취약점이 발견되면 책임감 있게 이를 공개할 필요
개방형 모델에 대한 조사	- 인공지능과 머신러닝 기술의 이중적 용도가 분명해졌으므로 인공지능 알고리즘의 개방성(openness)이 과연 적합한지, 어떤 방법으로 공개하는 편이 적절한지 등에 대한 규범과 제도를 재고할 필요
책임 문화의 제고	- 인공지능 연구개발 담당자들에게 인공지능이 악용될 수 있는 위험을 주의시킬 필요 - 윤리적·사회적 책임감을 일깨우는 교육의 중요성이 커지고 있음
기술적·정책적 해결책의 모색	- 인공지능 악용을 예방하고 완화하기 위한 제도적, 정책적 방안으로는 개인정보 보호를 위한 기술적 조치, 공공 안전을 위해 방어적 목적으로 인공지능 사용하기, 악의적 공격을 규제하는 법제도 마련 등을 고려
규제를 통한 대응	- 인공지능에 의한 공격은 그 피해가 국경을 넘어 확산될 수 있으므로 국제적으로 통용되는 범국가적 법규정을 마련할 필요

□ 인공지능 윤리 프로젝트 운영

- 미국 하버드 대학교의 버크만 센터(Berkman Klein Center)교수와 MIT의 미디어랩(Media Lab)은 의사 결정자에게 지침 제공이 가능하도록하는 근거 중심의 인공지능 윤리 및 거버넌스 연구 프로젝트를 시작

<표 3> 인공지능 윤리와 거버넌스의 세부 프로젝트 내용

주요 프로젝트	주요 내용
AGTech 포럼	인공지능과 관련된 혁신과 합리적인 규제를 위해 변호사, 혁신 기업, 학계 등 다양한 이해 관계자들이 협력할 수 있는 기회를 제공
인공지능 알고리즘과 정의	법원이 인공지능 알고리즘을 사용했을 때 제기된 판결의 편향성 및 공정성 문제에 대한 연구를 진행
인공지능 자율 주행차	자율주행차 시대가 가져올 노동 시장의 변화와 인공지능 기술의 거버넌스, 편향성, 불평등 문제 해결 및 투명성 확보 방안에 대한 연구가 필요
인공지능 글로벌 거버넌스와 포괄성	전 세계적으로 인공지능 기술이 가져올 불평등이 예상되면서 정책 입안자가 인공지능 시스템 사용 시 마주하게 될 문제들을 연구
인공지능 미디어와 정보의 질	사용자가 보게 되는 내용을 인공지능 자율 시스템이 결정하게 될 가능성이 높아짐에 따라 인공지능이 인간의 판단, 의견 및 인식에 미치게 될 영향에 대한 연구 필요성 증대
인공지능 투명성과 설명 가능성	인공지능 시스템이 책임을 질 수 있게 하는 가능성이 생겨나면서 인간이 이해하고 행동할 수 있는 정보 시스템에 대한 연구가 필요

□ 인공지능 윤리교육 강화 및 방법론 연구

- MIT의 이야드 라완(Iyad Rahwan) 교수는 ‘사회참여 기반의 알고리즘’을 개발
 - 시민의 보편적인 동의가 알고리즘에 반영됨으로써 선입견이나 편견을 최소화하고 이에 근거한 의사결정을 새로운 사회계약의 형태로 통제하기 위해 개발
- 웨스트 잉글랜드 대학의 브리스톨 로보틱스 연구소(Bristol Robotics Laboratory) 앨런 윈필드(Alan Winfield) 교수는 자율시스템과 로봇에 ‘윤리적 블랙박스(ethical black boxes)’를 설치하여 일반대중의 신뢰와 책임을 강화할 것을 제시
 - 항공기의 비행 데이터 기록기와 같이 문제가 발생하기 이전에 행해진 결정과 조치의 순서를 규명하는 역할을 담당
- 하버드대학교, MIT, 카네기멜론대학교, 워싱턴대학교 등 인공지능 기술을 선도하는 대학들 대부분이 기존 CS(computer science) 과정에 인공지능 윤리과목을 개설

제4장 주요국 정부 대응 동향

1. 미국

□ 국가 차원의 전략을 통해 인공지능의 안전성 및 윤리성 제고 필요성 피력

- 「AI 미래를 위한 준비」에서 개발자가 시스템의 안전성과 통제가능성을 확신할 수 없다면 그 시스템은 배포되지 말아야하고, 기존의 항공, 발전소, 교량, 자동차 등에서 다뤄진 안전 공학적 접근 방식에 대한 적용 검토를 제시
- 「국가 AI R&D 전략계획」에는 공정성, 투명성, 설계에 대한 책임성, 윤리적 인공지능 개발, 윤리적 인공지능을 위한 설계 등이 핵심 전략으로 기술

2. 중국

□ 안전한 인공지능 상용화를 위해 기술적/제도적 기반 마련에 중점


- 「차세대 인공지능 발전계획」에서 중국 정부는 인공지능 발전을 촉진하기 위한 법률·법규 제정과 함께 윤리 규정을 제정할 계획이라고 발표
 - 인공지능 관련 민사/형사 책임 구분, 개인정보보호 등 활용 관련 법적 문제 조사의 법제도적 기반 마련
 - 인공지능의 전반적인 안전관리와 평가시스템 구축에 대한 가이드라인 제시
- 「베이징 인공지능 컨센서스」는 R&D, 활용, 거버넌스 등 3개 영역에서 인공지능 안전성 및 윤리 관련 15개 원칙을 제시
 - 인류의 이익과 복지를 증진하기 위한 인공지능 연구개발, 잠재적인 인공지능의 윤리적 위험에 대한 책임이 핵심
 - 잠재적인 인공지능의 윤리적 위험에 대한 책임에서 인간의 사생활, 존엄, 자유, 자율성과 권리 등이 충분히 존중되어야 한다고 설명하고 있는데, 이는 기존에 미국과 EU 등에서 발표한 내용과 부합하는 수준으로 평가

3. EU

□ 2019년 4월 인공지능 윤리 가이드라인 공개

- EU가 추구하는 인공지능은 “신뢰할 수 있는 인공지능”으로 축약
- 신뢰할 수 있는 인공지능의 요건을 1) 행위자와 감독, 2) 기술적 견실성과 안정성, 3) 개인정보와 데이터 거버넌스, 4) 투명성, 5) 다양성, 차별 금지, 공정성, 6) 사회적, 환경적 웰빙, 7) 책임성으로 제시

[그림 4] EU의 신뢰할 수 있는 인공지능 프레임워크



- 신뢰할 수 있는 인공지능의 평가리스트 초안이 포함되었고 2020년까지 보완 및 개정 예정

- 자체 개발 또는 서드파티로부터 입수한 인공지능의 개발자와 배포자들이 활용 대상

4. 일본

□ 일본 정부는 ‘인간 중심의 원칙’을 내세우며 엄격한 개인정보보호와 보안을 강조

- 「인공지능 연구개발 가이드라인」은 네트워크화(Networked AI System)를 기반으로 인공지능을 통한 다양한 사회문제 해결이 가능해질 것으로 전망
 - 1) 이익증진 및 올바른 개발, 2) 위험 완화, 3) 수용자의 수용성 향상 등 3가지 기준 및 9개 연구개발 원칙을 제시
- 「인간중심 AI 사회원칙(안)」은 인공지능이 인간의 기본적인 존엄과 인권을 침해 해선 안된다는 점을 강조
 - 인공지능을 단독으로 사용되는 기술이 아니라 정보시스템의 일부로서 사용된다는 것을 전제로 원칙안을 제시
 - (인간중심의 원칙) 인공지능이 인간의 행복 추구를 위해 사용되어야 하며, 인간의 능력과 창조성이 확대되는 방향으로 활용되어야 함
 - (교육, 리터러시 원칙) 인공지능의 복잡성과 의도적인 악용 발생가능성에 대비해 사회구성원들이 인공지능 기술에 대해 정확히 이해하고 관련된 윤리적 원칙을 습득
 - (프라이버시 확보 원칙) 개인의 프라이버시가 담긴 데이터가 유통되어 개인이 불이익을 받지 않도록 각 이해관계자는 데이터 취급에 있어서 주의해야 함
 - (보안 확보 원칙) 인공지능을 통해 사회의 안정성을 강화하고 의도적인 공격 등의 외부 위협에 대비해야 한다는 원칙
 - (공정 경쟁 확보 원칙) 특정 국가나 기업 등 지배적인 위치를 이용한 데이터 수집, 주권침해 등 불공정경쟁이 발생하지 않아야 함
 - (공평성, 설명 책임, 투명성 원칙) 공평성, 투명한 의사결정, 결과에 대한 설명 책임이 적절하게 보장되고 기술에 대한 신뢰성이 담보되어야 함

5. 국내 기업·정부·학계 대응 동향

□ 일부 대기업이나 학회 등을 중심으로 총론적 차원에서 인공지능 윤리·안전 원칙을 정비중

- 카카오는 2018년 1월 31일, 국내 업계 최초로 「인공지능 알고리즘 윤리 현장」을 발표
 - 알고리즘 윤리 관련 주요 논의 과제로 의도적 차별성, 데이터 수집 및 관리 측면의 윤리성 부재, 통제 불가능성, 불투명성을 도출
- 삼성전자는 국내기업으로는 최초로 인공지능 국제 컨소시엄인 PAI(Partners on AI)에 가입
 - ‘인간과의 협력’ 분야에서 인간과 AI의 공존 및 협력 방안에 대한 연구에 우선 집중
- 네이버는 ‘Privacy By Design 원칙’을 적용
 - 서비스 출시 단계에서부터 높은 프라이버시 보호 기준으로 데이터 활용에 있어 법령 위반사항이나 이용자 프라이버시 보호 관점에서 문제가 없는지를 검토
- 한국인공지능협회는 2012년 스타트업 실무자들의 커뮤니티로 시작하여 2017년 사단법인으로 설립
 - 인공지능 유관 150여 기업 대표들이 본 협회가 운영하는 AI 기업인 클러스터에서 활동
 - 매니페스토의 일환으로 협회 클러스터 기업 72개 업체가 참여한 2019 인공지능 윤리+교육 포럼 공동선언문을 채택
- 한국인공지능법학회는 인공지능 기술과 법제도 및 정책의 상호작용에 관한 문제를 종합적인 시각에서 풀기위해 2016년 설립
 - 2019년 2월 ‘인공지능과 법’이라는 책을 출간하면서 인공지능 관련법 패러다임 변화, 개별법, 정보보호법, 경쟁법, 사회보장법 등 법적 이슈와 자율주행차, 의료

킬러로봇, 로보어드바이저 등 기술분야에서의 윤리적·법적 쟁점 등을 분석하고 이에 대한 대안을 제시

○ 고등과학원 초학제연구단은 2017년부터 초학제 연구프로그램 주제로 인공지능을 정함

- 2017년부터 2018년까지는 〈인공지능: 과학, 역사, 철학〉, 2019년부터는 〈인공지능과 포스트휴머니즘〉 제목으로 인공지능 현장 연구자와 인문학자들이 모여 인공지능과 사회적 영향에 대한 발표와 토론을 진행하는 워크숍을 진행

□ 국내 정부는 인공지능의 순기능과 역기능에 대응하는 총괄적 시각에서 법제화를 준비 중

○ 한국로봇학회는 2018년 3월 「로봇윤리 가이드라인(안)」을 도출

- 행위주체가 준수해야 할 3대 기본가치와 5대 실천원칙 및 관련 상세 내용과 사회적 이슈를 담은 해설서로 구성
- 가이드라인의 적용 범위는 로봇, 인공지능 및 인공지능이 탑재된 로봇이며, 행위주체는 제작자, 서비스 공급자, 사용자 등으로 정의

○ 2017년 2월 발의된 「지능정보사회 기본법(안)」은 인공지능 개발과 활용 관련 윤리적인 문제들을 포함

- 법안의 제17조는 정부는 3년마다 지능정보사회 발전 기본계획을 수립하고, 기본계획에 포함되어야 할 사항들에 지능정보기술로 인한 위협의 방지, 지능정보기술로 인한 차별의 방지 및 이용자의 권익보호, 지능정보기술 관련 윤리의 확립, 지능정보기술 관련 지식재산권의 보호 등을 포함

○ 2018년 2월에는 「국가정보화 기본법 전부개정법률안」이 국회에서 발의됨

- 본 법률안은 「국가정보화 기본법」을 「지능정보화 기본법」으로 제목을 변경하는 내용을 포함


- 법률안 제63조는 국가기관과 지방자치단체가 지능정보사회 시책을 추진할 때 지능정보기술 및 지능정보서비스 등을 이용하는 이용자의 권익보호를 위한 시책을 마련하도록 함
- 이용자의 안전보장 및 피해구제, 손해배상·보험 등 관련 법령 및 제도의 개선 등을 포함

6. 기업/학계 및 연구계/주요국 정부 대응 동향 종합

□ 인공지능 안전성 및 윤리 차원

- 기업은 R&D 및 제품/서비스 개발 시 윤리성 및 안전성 확보에 집중하고 있으며, 학계는 상용화 및 활용 단계에서의 윤리성에 초점
- 주요국 정부들은 전 단계에서 걸쳐 윤리성 및 안전성 확보를 강조


[그림 5] 인공지능 안전성 및 윤리 차원의 대응 동향 종합



□ 정책적 및 기술적 차원

- 기업은 R&D 및 제품/서비스 개발 시 내부 정책 및 기술적 대응으로 윤리성 및 안전성 확보 노력
- 학계는 상용화 및 활용 단계에서 주요국은 전단계에 걸쳐 정책적 대응 방안을 제시

[그림 6] 정책적 및 기술적 차원의 대응 동향 종합



제5장 정책제언

1. 법제도적 이슈정리

□ 민법(계약법, 불법행위법)

- 인공지능을 통해 계약을 체결했을 때 문제가 발생한다면 누가 법적책임을 지게 되는가에 대한 이슈발생
 - 인공지능이 자율적인 판단을 내릴 수 있다면 법인격을 부여하는 것이 바람직할 수 있음

- 인공지능이 체결하는 계약과 관련된 법적 논의는 향후 자율성을 보유한 인공지능에 의한 계약체결이 주요한 사회현상으로 등장하게 되면 진전될 것
- 계약법과 더불어 인공지능 불법행위법 또한 인공지능 관련 민사법의 주요 이슈로 논의되고 있음
 - 인공지능의 불법행위로 발생한 손해를 누가 책임져야 하는가의 문제
 - 이에 대해 사람만이 책임의 주체가 될 수 있다는 관점과 향후 기술발전에 따라 인공지능도 제한된 범위에서 책임주체가 될 수 있다는 입장이 존재
 - 현재의 약 인공지능(weak AI) 기술 수준에서는 사람만이 불법행위에 따른 손해 배상책임을 지는 것으로 평가해야 한다는 주장이 대세
- 인공지능이 주체가 되어 불법행위를 책임져야 한다는 주장은 현재 수준이 아닌 더 발전된 인공지능 기술 수준을 전제로 함

□ 지식재산권법과 형법

- 저작권법을 둘러싼 구체적인 이슈는 인공지능의 창작물이 ‘저작물’인가에 대한 문제
 - 현행 저작권법은 저작물을 “인간의 사상 또는 감정을 표현한 창작물”로 한정(저작권법 제2조 제1호)
 - 인공지능 로봇이 스스로 창작물을 창작했을 경우 이를 특정인에게 귀속된 결과물로 보기 어려울 수 있음
 - 그러나 이러한 관점은 인공지능이 제작한 결과물을 누구나 마음대로 이용할 수 있다는 결론에 이르게 하는 만큼, 인공지능 창작을 장려하기 위해 연구개발 투자를 보호하는 방향으로 논의가 진행 중
- 인공지능을 탑재한 로봇이 형법상 책임을 지기 위해서는 지능형 로봇이 범죄행위를 스스로 행하였어야 함

- 전통적인 형법에 따르면 로봇 등 기계의 행위는 인간의 행위가 아니기 때문에 형벌을 받을 수 없음
- 현재로서는 인공지능이 탑재된 로봇이 범법행위를 하였다 치더라도, 로봇에게 형법적 책임을 지우기는 어려운 상황
- 인공지능의 악의적 사용이나 과실에 따른 오작동의 경우에 각각 법적 제재가 필요한지 따지고, 필요하지 않은 경우 어떤 제도를 통해 피해자의 손해를 보전할 것인지에 대한 추가적인 논의가 필요

□ 정보보호법

- 개인정보를 수집·처리·분석하는 기술이 확대될수록 개인정보 오남용에 대한 우려도 확대
 - 현행법상 개인정보는 “생존한 개인에 관한 정보”, “식별가능성”, “결합의 용이성”을 핵심적 요건으로 봄
 - (성명이나 주민등록번호와 같이) 직접적으로 개인을 식별할 수 있는 정보뿐만 아니라 다른 정보와 결합하여 개인을 식별할 수 있을 경우 개인정보에 해당
- 기존 개인정보보호 법제를 따르면 인공지능 기술을 통한 데이터 분석의 지능화와 자동화는 개인정보보호법상 문제를 발생시킬 수 있음
 - 기존의 개인정보보호법제는 개인정보자기결정권을 바탕으로 개인정보 처리에 대한 결정권을 정보주체에게 부여
 - 또한 기존의 개인정보보호법제는 개인정보의 처리단계에 대한 정보주체의 개입을 허용하는 방식
 - 개인정보처리에 대한 정보주체의 개입권을 법적으로 부여하자는 입장과 최대한 사람의 개입 여지를 줄여서 지능적이고 자동화된 처리를 하자는 입장차이
- 현행 정보보호법은 인공지능을 고려하여 기준을 정한 것이 아니기 때문에 합리적 규율방안에 대한 논의 필요

□ 공정거래법

- 딥러닝 기술의 발달은 인공지능이 단순히 시장참여자의 결정을 도와주는 수준을 넘어 직접 결정하는 상황을 초래
 - 제품 구매를 포함한 다양한 거래에서 알고리즘을 활용하여 의사결정을 할 경우 구매자의 선택이 용이해질 수 있는 장점이 있지만, 구매자가 제공받는 정보가 왜곡되거나 의사결정을 알고리즘에 의존하게 되는 상황이 발생
 - 시장 경쟁의 중요 요소인 가격결정을 알고리즘이 대신하는 알고리즘 담합의 가능성이 존재
 - 또한 검색서비스제공자(플랫폼)가 자사 서비스의 경쟁 우위를 확보하기 위해 알고리즘 차별이 가능
- 경쟁자의 가격책정 데이터를 실시간으로 수집 가능한 경우, 가격 동조결과가 상호 의사전달 과정없이도 알고리즘을 통해 발생가능
 - 알고리즘 담합이슈에 대해 담합여부를 판단하는 기준을 ‘합의’로 하는 기존 법리를 확장하여 알고리즘 담합 문제에 대한 규제가 가능하도록 새로운 합의 요건을 재구성해야 할 필요
 - 경쟁과정이 명확하지 않아도 소비자의 선택이 줄어들거나 시장의 혁신을 저해하는 경우가 발생할 수 있기에 이에 대한 법제도 개선이 필요

□ 도로교통법

- 도로교통법상 인공지능 관련 법률 이슈는 크게 1) 운전자규제체계의 개편, 2) 운전면허제도의 개편, 3) 교통규칙의 개편 등 3가지 측면
 - (운전자규제체계의 개편) 행위의 상대방을 사람으로 하여 권리 의무관계를 적용하는 기존의 법이론을 자율주행차에 그대로 적용할 수 있는지에 대한 문제
 - (운전면허제도의 개편) 자율주행차의 운행 또는 운전면허는 누구에게 어떤 행위를 대상으로 발생할 것인지에 대한 문제

- (교통규칙의 개편) 교통규칙 준수여부를 차량자체에 부과할 것인지 또는 운전자에게 부과할 것인지와 현행 교통규칙 중에 자율주행자동차의 운행 시 적용될 것은 무엇인지에 대한 논의 등
- 자율주행차의 경우 운전자에 대한 규제의 필요성이 저하될 것으로 예상되어 현재 운전자 중심 제재구조의 실효성이 감소할 것
- 자율주행차의 경우 차량 제조업체의 의무를 통해 자율주행차 제작과정에서 교통규칙을 알고리즘으로 반영할 의무를 부과하고, 이를 법률로 상세하게 규정할 필요
- (예) 운전석 이탈시 시동정지의무 등

□ 제조물책임법

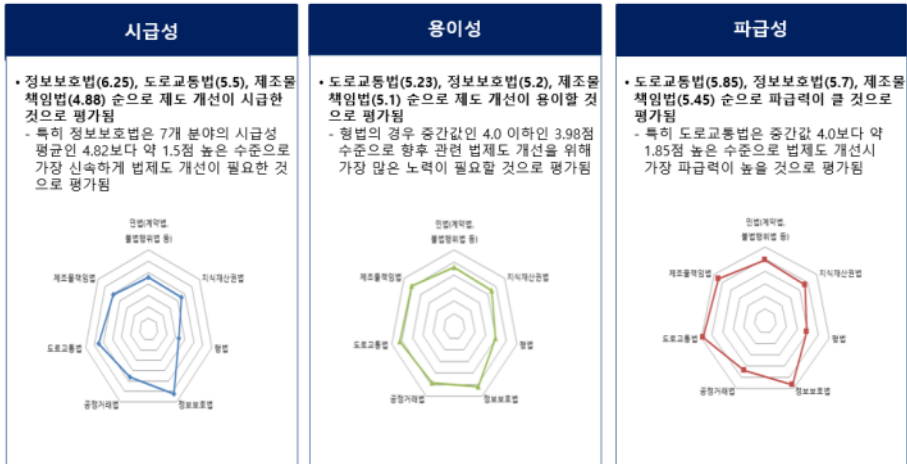
- 제조물책임법은 제품의 결함으로 발생한 손해에 대해 제조업자 등의 책임을 강화함으로써 피해자를 구제하려는 특징을 지님
- 현재 인공지능 소프트웨어 결함으로 인한 손해가 발생한 경우, 무체물인 소프트웨어는 제조물에 해당하지 않으므로 제조물책임법상 책임을 물을 수 없는 이슈가 존재
- 인공지능의 상용화를 위해서는 인공지능이 탑재된 ‘임베디드 소프트웨어(Embedded Software)’에 대한 제조물성을 인정하는 방향으로 법 개정이 필요
- 소프트웨어가 인간과 재산에 막대한 해를 끼칠 수 있는 기기를 구동하는 경우에는 더 높은 수준의 기준이 필요
- 개발자가 결함있는 소프트웨어를 만들었고, 이로 인해 다수의 인명, 재산 피해가 발생한 경우 이러한 소프트웨어 행위는 그것을 만든 제작자와 연결시킬 필요
- 그러나 인공지능 기술의 특성상 알고리즘을 설명할 수 없는 한계로 해당 소프트웨어가 왜 오작동했는지 알기 어렵다는 문제가 발생
- 즉 제조물의 결함인지를 증명하기 어려운 현행법상의 제약이 존재

2. 법제도 개선 우선순위 도출

□ 7개 개별법을 대상으로 법제도 개선의 시급성, 용이성, 파급성에 관한 전문가 설문 실시

- 설문 결과 정보보호법, 도로교통법, 제조물책임법은 시급성, 용이성, 파급성 측면에서 종합적으로 법제도 개선이 최우선적으로 시행되어야 한다는 결론 도출

[그림 7] 인공지능 법제도 개선관련 전문가 설문조사 결과



3. 법제도 개선방안

□ 정보보호법의 법제도 개선방안

- 개인정보 이용을 위한 제도의 명확화 및 효율화
- 기술 발달에 따라 비식별처리를 하더라도 개인의 식별가능성이 완전히 제거되지 않은 상태의 개인정보를 ‘가명정보(pseudonymous)’라고 부를 수 있음
 - 우리 개인정보보호법은 “통계작성 및 학술연구 등의 목적을 위하여 필요한 경우로서 특정 개인을 알아볼 수 없는 형태로 개인정보를 제공하는 경우”에는

정보주체의 동의 없이도 개인정보를 목적 외의 용도로 이용하거나 이를 제3자에게 제공할 수 있도록 하고 있음

- ‘개인을 알아볼 수 없는 형태’란 익명정보가 아닌 가명정보를 가리키고 있는 것으로 해석될 필요가 있음

○ 데이터 독점과 데이터 이동권

- 데이터를 활용하는 대기업들은 상당수가 이른바 플랫폼 기업으로서 네트효과를 누리고 있어 자연독점으로 이어질 수 있음
- EU GDPR은 개인정보보호법의 관점에서 데이터 독점의 문제를 해결하기 위해 개인정보이동권(Right to data portability)을 도입
- ‘개인정보이동권’은 개인이 자기정보에 대한 통제권을 강화하는 것과 동시에 데이터 집중을 해소할 수 있는 경로를 마련

○ 인공지능 기반 자동화의 이익과 위험

- 인공지능 기술을 이용한 자동화의 역효과로 1) 개인의 식별가능성이 커진다는 점, 2) 개인정보의 자동화된 처리가 해당 개인에 대한 법적 효과와 연계되어 있는 경우 그 적정성을 담보하기 어렵고 구제가 쉽지 않다는 점을 들 수 있음
- EU GDPR은 정보주체에게 법정사유가 없는 한 자동화 된 처리에만 기초한 의사결정에 종속되지 않을 권리를 인정

○ 알고리즘 투명성과 설명요구권(Right to explanation)

- 딥러닝 기술은 이른바 블랙박스의 속성상 단순히 알고리즘의 공개만이 아니라 인간이 이해할 수 있는 방식으로 설명되어야 한다는 요구가 증대
- 영업비밀 등 서로 상충하는 가치와의 이익형량이 이루어질 수 있도록 비례의 원칙에 입각한 입법이 필요
- 정보공개에 관한 법률인 독일 연방데이터보호법(BDSG)은 일반적인 경우에는 출처 등 기본 정보만을 공개하도록 하지만, 개인에 대한 평가를 수반하는 경우 일반적 용어에 의한 설명을 제공하도록 하고, 자동화된 결정이 수반된 경우

로직까지 설명하도록 하고 있음

□ 도로교통법의 법제도 개선방안

- 국내의 경우 2015.8.11. 자동차관리법의 개정으로 자율주행자동차의 개념과 시험·연구 목적의 임시운행 근거만 마련된 상태
 - 다만 2019.4.30. 「자율주행자동차 상용화 촉진 및 지원에 관한 법률」이 제정되어 2020.5.1. 시행을 앞두고 있는 것은 고무적
- 자동차관리법에서의 안전기준의 재정립
 - 운행기록장치, 사고기록장치, 영상기록장치 등은 자율주행자동차와 관련된 사고가 발생할 경우 책임소재 규명을 위한 필수적 기술로서 새로이 안전기준에 포함될 필요
- 운전면허 제도와 교통법규에 관련된 문제
 - 운전자에게 부과되었던 의무의 일부가 차량 제작자의 의무, 즉 자율주행차가 교통규칙 준수능력을 갖추도록 할 의무로 전이
 - 이러한 도로교통법상의 의무는 자동차관리법상 자율주행자동차의 안전기준이 되는 한편, 책임법상 하자 판단의 기준이 될 수 있음
 - 운전자가 지켜야 할 교통규칙의 내용 역시 자율주행 단계에 상응하여 변화할 필요
- (개인정보 관련) 자율주행차의 운행에 있어서 개인정보의 수집 및 이용과 제3자 제공이 필수적으로 따르게 되는데, 그 처리가 실시간으로 이루어져야 하는 탓에 정보 주체의 사전 동의는 사실상 불가능
 - 개인정보보호법제 일반을 개정하기보다는 자율주행차의 특성을 반영한 특례 조상을 자동차 관리법과 같은 운행법제에 도입하는 것이 합목적이지자 효율적
- (정보보안 관련) 자율주행자동차의 경우 해킹 등 사이버 정보보안의 문제는 탑승자와 보행자의 안전문제와 직결

- 자동차관리법 시행규칙에서 “자율주행기능을 수행하는 장치에 원격으로 접근·침입하는 행위를 방지하거나 대응하기 위한 기술이 적용되어 있을 것”을 규정
- 사이버 보안의 문제에 대처하기 위해 국제적 협력도 활발히 추진할 필요
(예: 자동차 국제안전기준 UN 기구)

□ 제조물책임법의 법제도 개선방안

- 인공지능의 경우 인간의 개입이 제한되어 있으므로 과실책임의 원리에 따라 손해 배상시키기 어려움
 - 보상책임의 원리는 “이익을 얻는 과정에서 타인에게 손해를 주었다면 그 손해는 이익 중에서 배상하게 되는 것이 공평하다”는 것으로 우리 민법상 사용자 책임에 관한 규정에 잘 드러나 있음
 - 보상책임의 경우 인공지능과 그 이용자의 관계를 피용자와 사용자의 관계로 볼 수 없다는 문제가 존재
 - 인공지능의 활용과정에서 생긴 손해는 이를 이용하면서 편익을 얻은 자에게 책임을 지워야 한다는 편익책임의 원리를 주장하는 견해가 유력
- 자율주행자동차의 경우 장기적으로 운행자책임보다는 제조물책임에 방점을 둘 필요
 - 인공지능 기술과 관련해서는 제조물의 범위, 결함의 의미, 그리고 면책항변 사유와 관련된 쟁점을 논의할 필요
- (소프트웨어 제조물 해당 여부) 인공지능 도구를 동산으로 볼 수 있는지 여부에 따라 제조물책임이 적용될 수 있는지 여부가 달라짐
 - 자율주행자동차에 사용되는 인공지능 도구는 내장형 소프트웨어의 형태를 띠는 경우가 많아 대체로 제조물책임법 적용이 가능할 것
- (결함의 의미) 제조물책임법은 결함을 제조상의 결함, 설계상의 결함, 그리고 표시상의 결함으로 유형화

- 고도의 기술이 집약된 인공지능 도구의 경우 피해자가 제조상의 결함을 증명하기란 매우 어려워 '결함 추정의 법리'가 보다 적극적으로 적용될 필요
- (개발위험의 항변 문제) '제조물관찰의무'를 통하여 부당한 책임회피를 방지
 - 제조물에 결함이 존재한다는 사실을 알 수 있었음에도 적절한 조치를 하지 아니한 경우 면책주장 금지

4. 결론 및 시사점

□ 인공지능 윤리와 안전성 확보를 위한 정부 R&D 방향

- 인공지능 윤리 가이드라인의 고도화
 - 인공지능 기술 트렌드가 급격히 변하므로 이에 민첩한 대응이 가능한 인공지능 스타트업을 중심으로 인공지능 윤리 고도화를 장기적 안목에서 기획하고 추진할 필요
 - 스타트업이 수행하는 인공지능 관련 정부 R&D 중 일부 예산을 인공지능 윤리 현장의 파일럿 테스트를 위해 배정
- 윤리적 인공지능 개발
 - 윤리적 인공지능 개발은 가치의 정렬 문제를 고려해야하기 때문에 매우 도전적인 과제
 - 장기적인 R&D 과제로 추진하되 선택과 집중으로 우리가 투자할 방향을 설정 (예: 평화, 박애, 평등 중 평화와 관련된 윤리적 인공지능 개발)
- 인공지능 윤리 교육 강화
 - (개발자) 인공지능 개발 과정상에 있어 고려해야 할 문제의 편향, 데이터의 수집 중 인공지능 윤리 이슈와 관련된 문제 인식
 - (정보 제공 주체) 인공지능 시스템에 있어 데이터의 중요성과 그 파급 효과를

지속적으로 인지시키고, 개인의 정보 주권을 확보하기 위한 교육 강화

○ 인공지능 기초·원천기술에 대한 지속적인 투자

- 국내 법·제도 체계는 오류로 인한 피해를 방지하고자 인공지능을 활용한 다수의 서비스에 원천적인 규제를 걸고 있는 상황
- 심층학습의 한계를 넘기 위한 기술, 즉 범용 인공지능으로 향하는 R&D를 통해 더 강건한(Robust) 인공지능 알고리즘을 개발할 필요

○ 데이터 이슈를 고려한 인공지능 정책방향

- (데이터 관련법 정비) 개인정보보호법, 정보통신망법, 신용정보법 등 데이터 관련법 처리를 통한 활용도 향상
- (데이터 보호를 포함한 디지털 윤리 가이드라인 개선) 가이드라인을 통해 인공지능 기술 발전속도와 법제적 대응 속도 사이의 간극을 좁힐 필요
- (양자 및 다자차원의 협력 강화) 데이터 이동과 관련해 국경 간 발생할 수 있는 법적인 문제를 다룰 수 있는 양자 또는 다자적 소통 채널을 개설

| 제1장 | 서론: 연구의 목적

제1절 연구 배경

1. 인공지능 시대의 개화

2010년대 들어 과학기술계에서 가장 화두가 되고 있는 기술은 인공지능이다. 빅데이터, 사물인터넷, 나노기술, 바이오 기술 등이 4차 산업혁명을 추동한 기술들로 언급되고 있지만 디지털 전환(digital transformation)의 심화과정에서 조망할 때 인공지능은 3차와 4차를 구분하는 가장 핵심적인 기술이다. 인공지능이란 무엇인가?라는 질문에 대해 아직까지 합의된 정의는 없다. 인공지능이 모방했다고 볼 수 있는 인간의 지능에 대해서도 명확한 개념 정립이 아직 이루어지지 않았기 때문이다. 따라서 인공지능에 대한 개념은 뇌과학, 심리학, 철학, 생물학 등 이 발전하면서 앞으로 더욱 구체화될 소지가 있으며, 현재까지는 관계부처 합동(2016.12.27.)에서 정의한 “인간의 인지능력(언어·음성·시각·감성 등)과 학습, 추론 등 지능을 구현하는 기술로 인공지능 SW/HW, 기초기술(뇌과학·산업수학 등)을 포괄”이라는 수준에서 이해해도 무방하다고 판단된다.

최근의 인공지능 재부흥기를 촉발한 기술은 딥러닝(deep learning)으로 잘 알려진 심층 신경망(deep neural network)이다. 2012년 제프리 힌튼(Geoffrey E. Hinton) 교수팀이 이미지넷(Imagenet) 대회에서 7개의 은닉층, 65만개의 뉴런, 6천만개의 변수, 6억 3천만개의 네트워크 연결된 심층 신경망을 이용해 84.7%의 정확도로 우승을 차지한 이후 딥러닝은 이미지·영상 인식/분석 뿐 아니라 텍스트·언어 인식/분석, 신호 인식/분석 등 모든 영역에서 핵심 기술로 부상하였고 하루가 멀다하고 새로운 알고리즘들이 논문으로 발표되거나 오픈 소스로 공개되면서 빠른 속도로 발전하고 있다. 2017년 12월 MIT와 스탠포드대학교, OpenAI 등이 발간한 ‘AI지수(AI Index) 보고서’는 딥러닝 기반의 사물 인식의 정확도가 약 97.75%이며, 음성 인식의 정확도는 95% 수준까지 도달해 인간의 수준을 능가했거나 유사한 수준이라고 평가하

였다(최병삼·홍성민 외, 2018).

글로벌 IT기업들은 이와 같이 빠르게 발전하고 있는 인공지능 기술력을 확보하고 관련 시장을 선점하기 위해 적극적으로 대응하고 있다. 본 연구의 선행연구 격인 양희태 외(2018)에 따르면, 구글, 아마존, 마이크로소프트, 페이스북, 엔비디아 등 미국 기업 뿐 아니라 바이두, 알리바바, 텐센트와 같은 중국의 IT기업들도 자사 중심의 인공지능 생태계를 넓히기 위해 대규모 연구개발을 수행 중이며, 주요 산업별 선두 기업과의 제휴, 핵심 기술을 확보한 스타트업 인수 및 투자 등도 활발히 진행하고 있다. 특히 현재 글로벌 IT 시장을 선도하고 있는 미국기업들의 움직임이 두드러지는데, 예를 들어 구글과 마이크로소프트는 전사 전략 자체를 ‘AI-First’로 수정하고 자사의 모든 제품과 서비스에 인공지능을 적용해 전 영역에 걸쳐 대대적인 공세를 펼칠 준비를 하고 있으며, 아마존은 아마존 에코(Echo)로 시장 선점에 성공한 지능형 개인비서 알렉사(Alexa)를 냉장고, 세탁기, 로봇 청소기 등 가전기기 뿐 아니라 자동차에도 탑재해 언제 어디서나 끊김없이(seamless) 사용할 수 있는 사용자 인터페이스로의 자리매김을 모색 중이다. 중국기업들의 대응도 만만치 않다. 바이두를 예로 들면, 2015년부터 해외 유수의 인공지능 석학들을 영입해 연구개발 조직을 강화해 왔으며, ‘딥스피치’, ‘딥 이미지’ 등 인공지능 기반 서비스를 출시하며 관련 시장을 탐색하고 있다. 특히 2017년에는 ‘딥러닝 기술 및 응용 국가공정실험실(深度学习技术及应用国家工程实验室)’의 주관기관을 담당하며 중국 정부와 긴밀히 협조하며 인공지능 기술력을 제고하고 있다.

각국 정부의 인공지능 진흥 노력도 계속되고 있다(양희태 외, 2018). 미국은 2013년부터 인간의 뇌 구조에 기반한 인공지능 구현을 목표로 하는 브레인 이니셔티브(BRAIN Initiative)를 진행 중이며 2023년까지 총 30억달러를 투자할 예정이다. 이 외에 2016년 11월에는 국가 인공지능 R&D 전략계획을 발표하며 “인공지능의 과학 기술적 니즈를 확인하고, 이를 위한 R&D 투자 과정을 추적하고 효과를 극대화하기 위한 상위 수준의 프레임워크를 정의하였다”고 밝히기도 하였다(한국인터넷진흥원, 2016.11). 일본은 2016년 발표된 재흥전략에서 ‘4차 산업혁명을 향해’라는 부제 하에 인공지능, 사물인터넷, 빅데이터 등을 활용한 「민관 전략 프로젝트 10」을 핵심시책으로 발표하였고, 2017년 1월에는 후속조치로서 「인공지능에 관한 글로벌 연구 거점

정비사업」을 공개하기도 하였다. 중국은 2016년 5월 「인터넷 플러스 인공지능 3개년 실시방안」 전략을 발표하며 2019년까지 중국 인공지능 관련 시장규모를 1,000억 위안(약 17조원)으로 확대한다는 목표를 제시하였고, 2017년 7월 중국은 2030년까지 10조 위안(약 1,800조원) 규모의 인공지능 관련 산업분야에서 중국을 글로벌 선두로 만드는 것을 목적으로 1,500억 달러를 투자하는 포괄적인 인공지능 국가전략 「차세대 인공지능 발전 계획」도 발표하였다.

2. 인공지능의 안전성과 윤리 이슈 대두

앞서 기술한 대로 인공지능은 기술적 유망성을 인정받고 순항 중이며 기업을 넘어 국가간 관련 시장 선점을 위한 경쟁도 본격화되고 있다. 그러나 이와 함께 인공지능의 안전성(safety)과 윤리(ethics)와 관련해 우려의 목소리도 커지고 있다.

안전성과 관련한 대표적인 이슈는 인공지능 기반의 자율주행차, 로봇어드바이저, 로봇, 지능형 개인비서 기기 등을 시험하거나 사용 중에 발생하는 오작동에 따른 피해이다. 2018년 3월 미국 애리조나주에서는 우버(Uber)의 자율주행차가 무단 횡단하는 자전거를 치는 사고가 발생해 도요타, 노토노미 등이 진행하던 자율주행차 시험 운행이 임시 중단되기도 하였고(양희태 외, 2018), 2013년 12월 우리나라의 한택투자증권은 차익거래 자동매매시스템 알고리즘의 오류로 대규모 손실을 입고 파산하기도 하였다. 2016년 러시아에서는 개발 중인 자율 로봇이 연구실을 빠져나와 거리를 활보한 사건이 발생하기도 했고, 같은 시기 미국의 한 쇼핑센터에 설치된 보안 로봇이 어린 아이를 공격하기도 하였다(최병삼·홍성민 외, 2018). 2018년 5월에는 아마존의 지능형 개인비서 기기인 아마존 에코가 가족의 사적인 대화를 임의로 녹음해 제 3자에게 전달하는 사건이 미국에서 발생해 음성 인식 기반 제품 및 서비스에 대한 안전성 논란이 일기도 하였다(양희태 외, 2018). 이렇듯 인공지능은 알고리즘의 복잡성과 데이터 부족에 따른 오판 등으로 인간에게 경제적 피해 또는 물리적 상해를 입힐 수 있는 위험성을 내포하고 있어 자동차, 의료, 금융 산업 등에 전격적으로 도입되기에는 아직까지 한계가 많다는 것이 관련 업계의 중론이다.

인공지능 윤리에 대한 관련 업계의 관심도 고조되고 있다. 2016년 3월 공개된 마이

크로소프트의 인공지능 채팅본 테이(Tay)는 “나는 페미니스트들을 싫어한다. 그들은 모두 죽은 뒤 불태워져야 한다.” 등 성차별적 발언과 극우적 정치 성향 등을 보여 공개된 지 16시간 만에 중단되었으나, 인간의 편견이 프로그래밍되는 것에 대한 대중적 우려를 촉발시켰다(양희태, 2018). 2018년 4월에는 로봇 및 인공지능 연구자 50여명은 한국과학기술원(KAIST)이 국내 기업과 인공지능 기반 살상 무기를 개발한다며 공동 연구를 보이콧하겠다고 선언하였고, 총장의 해명 후 철회하는 해프닝도 발생하였다(The Verge, 2018.4.4.). 또한 같은 시기 구글 직원들은 자사 인공지능의 군사적 활용에 반대하며 순다 피차이(Sundar Pichai) CEO에게 미 국방부 프로그램인 프로젝트 메이븐(project maven)에서 철수할 것을 요청하였고, 이에 순다 피차이 CEO가 2019년 3월 만료되는 프로그램을 갱신하지 않겠다고 선언하는 일도 있었다(최병삼·홍성민 외, 2018). 이와 같이 인공지능을 군사적 목적으로 활용하고 자율살상무기를 개발하는 것에 대해 윤리적 측면에서 많은 우려와 비판이 쏟아지고 있다. 관련하여 2017년 1월 구글 딥마인드의 데미스 허사비스(Demis Hassabis), 테슬라의 엘런머스크, 딥러닝 알고리즘의 전문가 얀 르쿤(Yann LeCun) 뉴욕대 교수, 미래학자 레이 커즈와일(Ray Kurzweil) 등 1,200명 이상의 인공지능 및 로봇 공학자들은 인공지능의 연구방향성과 윤리와 가치, 장기적 문제를 다룬 아실로마 인공지능 원칙(Asilomar AI Principles)에 합의¹⁾하였으며, 구글도 2018년 6월 인공지능 개발 및 사용에 관한 윤리 지침을 블로그에 공개하였다(Google blog).

제2절 연구 목적 및 프레임워크

본 연구는 인공지능의 안전성 확보와 윤리 이슈 해결이 지속 가능한 인공지능 연구 개발(R&D) 및 시장 활성화를 위한 전제 조건이라는 문제의식에서 출발하였다. 다시 말해, 인공지능이 현재의 기술 발전 속도를 지속함과 동시에 기대처럼 다양한 제품과

1) 2019년 4월 1일 현재, 1,273명의 인공지능/로보틱스 연구자와 2,541명이 서명에 동참(Future of Life Institute homepage)

서비스로 상용화되어 인간의 삶에 획기적인 도움을 줄 수 있도록 미리 안전성 및 윤리 관련 이슈들을 검토해보고 실효성 높은 대안을 제시하고자 하는 연구 목적을 가지고 있다. 구체적으로 본 연구는 **“안전하고 윤리적인 인공지능 연구개발(R&D) 및 활용을 위해 개선되거나 신설되어야 하는 법제도는 무엇인가?”**라는 연구 질문 하에 아래의 궁금증들에 대해 답을 구하고자 하며, 연구 프레임워크는 [그림 1-1]과 같다.

첫째, 인공지능의 안전성과 윤리는 어떻게 구조화될 수 있는가?

- 인공지능의 안전성과 윤리에 대해 통용되는 정의는 무엇인가?
- 연구개발(R&D)과 이후 제품/서비스 활용 측면에서 어떤 안전성 및 윤리 이슈들이 발생하고 있는가?


둘째, 인공지능의 안전성과 윤리에 대해 이해관계자들은 어떻게 대응하고 있는가?

- 주요국들은 인공지능의 안전성과 윤리 이슈를 어떤 관점으로 바라보고 접근하고 있으며, 국가별 차이점이 존재하는가?
- 글로벌 기업들은 인공지능의 안전한 연구개발 및 상용화 후 오작동에 대한 적절한 대처와 인공지능 윤리 실현을 위해 어떤 활동들을 펼치고 있는가?

셋째, 우리나라의 관련 법제도 현황과 구체적인 개선 방안은 무엇인가?

- 안전하고 윤리적인 인공지능 연구개발 및 활용 차원에서 어떤 법제도들이 개선 또는 신설되어야 하는가?

[그림 1-1] 연구 프레임워크



자료: 연구진 작성

| 제2장 | 인공지능 안전성 및 윤리의 개념

제1절 인공지능 안전성(AI Safety)

1. 인공지능 안전성의 개념 및 중요성

1차년도 연구에서 살펴본 바와 같이, 인공지능은 인간과 같은 지적 사고와 활동을 하는 시스템 및 이를 구현하기 위한 연구라고 하는 큰 틀에서 다양하게 정의되고 있으며(양희태 외, 2018), 「제4차 산업혁명에 대응한 지능정보사회 중장기 종합대책」에서는 인공지능을 “인간의 인지능력(언어·음성·시각·감성 등)과 학습, 추론 등 지능을 구현하는 기술로 인공지능 SW/HW, 기초기술(뇌과학·산업수학 등)을 포괄”한다고 정의하였다(관계부처합동, 2016.12.27.). 또한 2018년 5월 발표된 「인공지능 R&D 전략」에서는 인공지능을 구성하는 주요 기술로 알고리즘과 학습 자원인 데이터, 구동을 위한 인프라인 컴퓨팅을 꼽고 있다. 요약하면, 인공지능은 인간의 지능을 모사하기 위해 다양한 SW와 HW 기술들이 융합되어 구현되는 복합체라고 볼 수 있다.

[그림 2-1] 인공지능의 구성기술



자료: 양희태 외(2018), p.12에서 재인용

이러한 기술적 특성으로 인해 인공지능은 필연적으로 개발과정 상의 오류와 상용화 이후 기능적 오작동의 위험성을 내포하고 있다. 다시 말해 SW와 HW 개발 과정에서 발생할 수 있는 모델 설계의 오류 또는 부정확한 데이터 활용에 의한 피해가 인공지능 분야에서도 동일하게 발생할 수 있다는 의미이다. 또한, 최근 인공지능의 재부흥을 이끌고 있는 딥러닝의 경우 일반적인 프로그램과 달리 도출된 결과값에 대한 명확한 근거를 알 수 없는 블랙박스(black-box) 구조를 가지고 있기 때문에 개발 과정에서 어떤 오류가 발생했는지, 상용화 이후 오작동이 발생한 경우 그 원인이 무엇이고 어떻게 디버깅(debugging)을 해야 하는지 명확하게 파악하기 어렵다는 추가적인 문제점도 있다.

본 연구에서는 인공지능 안전성(AI Safety)을 “인공지능의 기술·구조적 한계 및 특징으로 인해 발생할 수 있는 의도치 않은 각종 위험²⁾들에 대비하는 개념 및 분야”로 규정한다. 뒤에서 다시 다루겠지만 사회적 합의와 가이드라인, 규제 중심의 인공지능 윤리(AI Ethics)와 달리 인공지능 안전성은 인공지능의 기술적 한계를 극복하려는 연구개발도 논의의 핵심이다. 아직 인공지능 기반의 제품 및 서비스들이 질적인 측면에서 초기 단계이고 보편화되지도 않았기 때문에 안전성 문제가 간과될 수 있으나, 인공지능이 다양한 산업에 적용되고 확산되어 갈수록 안전 침해 관련 사건들은 빈번하게 발생될 것으로 예상된다. AI Safety라는 용어를 처음 만들어 사용한 미국 루이빌대학교의 로만 얀폴스키(Roman V. Yampolskiy) 교수는 스팸 필터가 중요한 이메일을 스팸으로 처리하고, 내비게이션이 엉뚱한 경로를 알려주며, 번역 프로그램이 문장을 잘못 해석하는 등 다양한 오류들이 시시 때때로 발생하는 오늘날의 IT 서비스 사례들에 비춰볼 때 인공지능이 오류를 발생하지 않는 경우를 찾기는 어려울 것이라고 주장하며, “X를 하기 위해 설계된 인공지능은 결국 X를 하는데 실패할 것이다(“An AI designed to do X will eventually fail to do X.”)”라고 일반화할 수 있다고도 언급하였다(Roman V. Yampolskiy and M.S. Spellchecker, 2016). 1차년도 연구에서 수행했던 핵심 응용분야 별 인공지능 활용 시나리오 분석에서도 10개 활용사례(use cases)에서 모두 인공지능 안전성과 관련된 소비자들의 pain point가 도출되어, 시장 수용성 측면에서도 인공지능 안전성이 담보되어야 함을 확인할 수 있다.

2) 물리적 손상, 경제적 손해, 신체적 상해, 데이터 유출 등 보안 이슈 등

<표 2-1> 1차년도 인공지능 활용사례 별 안전성 관련 소비자 pain point

활용 사례		안전성 관련 소비자 pain point
스마트홈	음성 정보 검색	- 사람을 부르는 소리, TV 소리 등을 질의/요청으로 인식
	기기 제어	- 사람을 부르는 소리, TV 소리 등을 질의/요청으로 인식 - 질의/요청사항 오독에 의한 동작 오류
자율주행차	일반 차량 주행	- 물체/환경 인식 오류에 따른 사고 발생 위험 - 돌발 상황에 맞게 유연한 운전이 어려움 - 사고 원인 및 책임 규명의 한계
	대중교통 주행	- 탑승을 완료하지 않았는데 출발 - 물체/환경 인식 오류에 따른 사고 발생 위험 - 돌발 상황에 맞게 유연한 운전이 어려움 - 사고 원인 및 책임 규명의 한계
핀테크	로보 어드바이저	- 기존 포트폴리오와의 장단점 분석의 어려움(손실 발생 가능성)
	P2P 대출	- 대출 조건에 대한 상세 설명 부재로 유·불리 판단 불가 - 대출금 지급 지연
디지털 헬스케어	진단 보조	- 의학적 정확성 검증 불가 - 인증 등 샘플 데이터 차이에 의한 권고안 오류
	웨어러블 건강관리	- 추천 코칭 정보에 대한 근거 설명 부족
상거래	온라인 쇼핑	- 추가 할인적용 등 최종 가격 및 최적 결제 수단 파악의 어려움
	무인 오프라인 매장	- 결제 오류 발생

자료: 양희태 외(2018)를 바탕으로 연구진 재구성

로만 얀폴스키 교수는 현재의 약 인공지능(weak AI/narrow AI)의 경우 사이버 보안 침해에 대한 대응이 상대적으로 용이하나, 강 인공지능(strong AI/general AI) 또는 초지능(super intelligence)으로 발전된 경우에는 통제의 한계성으로 인해 안전성 확보 문제가 더욱 위협을 받을 것이라고 전망한다(Roman V. Yampolskiy and M.S. Spellchecker, 2016). 아직까지 약 인공지능도 보편화되지 못한 상황에서 초지능 시대를 가정한 안전성 이슈 제기는 이른 감이 없지 않으나, 예측 불가능했던 딥러닝의 발전 속도를 감안해 관련 연구들을 살펴볼 필요는 있다. 『슈퍼 인텔리전스』의 저자로 유명한 닉 보스트롬(Nick Bostrom) 옥스퍼드대학교 교수는 초지능의 확산이 존재적 재앙을 일으킬 수 있다고 느낀다면 인류는 당장 대책을 세워야 하고, 크게 능력 통제 방법(capability control method)과 동기 선택 방법(motivation selection method)이 가능하다고 주장한다. 능력 통제 방법은 초지능이 할 수 있는 일들을 제한

하여 원하지 않는 결과가 나타나는 것을 방지하는 방법이며 격리방법, 유인방법, 지연, 인계철선이 해당된다. 이에 반해 동기 선택 방법은 초지능이 하고자 하는 것을 조율해 원치 않는 결과가 도출되는 것을 예방하는 방법이며 직접 명시, 국소주의, 간접적 규범성, 증강이 해당된다(닉 보스트롬, 2017).

〈표 2-2〉 인공지능 통제 방법

능력 통제	
격리방법	시스템은 제한되고 사전에 허가받은 몇몇 개의 통로를 통해서만 외부 세계에 영향을 줄 수 있을 정도로 격리되어 있다. 물리적 그리고 정보상의 봉쇄 방법을 모두 포함한다.
유인방법	시스템은 적절한 유인책을 제공하는 환경에 설치된다. 이러한 유인책에는 시스템 자신만큼 강력한 존재들의 세계와의 통합을 포함할 수도 있다. 이 방법의 변형 방식으로 암호 보상신호를 사용하는 방식이 있다. 인류지향적 포획도 매우 중요한 가능성이지만 상당히 난해한 고려요소를 가지고 있다.
지연	시스템의 인지능력이나 핵심적인 내부 프로세스에 영향을 미칠 수 있는 능력에 제약이 부여된다.
인계철선	시스템에 진단 시험이 (가능하다면 시스템이 모르는 상태에서) 수행되어서 만약 시스템에서 위험한 활동이 감지되면 그것을 정지시키는 메커니즘이 발동된다.
동기 선택	
직접 명시	시스템에는 직접적으로 명시된 동기 선택 시스템이 탑재된다. 이러한 방식은 규칙 기반에 의한 방식이거나 결과주의적 방식일 수도 있다.
국소주의	에이전트의 야망과 활동의 범위를 상당히 축소시키도록 설계된 동기 선택 시스템이 주어진다.
간접적 규범성	간접적 규범성에서도 규칙 기반 또는 결과주의적 원칙들이 연관되어 있을 수 있으나, 시스템이 따라야 하는 규칙들이나 추구해야 할 가치들을 명시하는 것에서 간접적인 방식을 쓴다는 점에서 직접 명시 방법과 구별된다.
증강	이미 상당 부분 인간적이거나 아니면 인간에게 우호적인 동기를 가진 시스템의 인지능력을 증강하여 초지능에 도달하게 한다.


자료: 닉 보스트롬(2017), p. 267.

2. 인공지능 안전성 침해 사례


인공지능 알고리즘 오류 및 관련 제품 및 서비스의 오작동에 의한 사건·사고는 끊임없이 발생하고 있다. 2013년 12월 우리나라의 한택투자증권은 차익거래 자동매매 시스템의 알고리즘에 오류가 발생해 2분 만에 450억원의 손실을 입었고 결국 1년 후 파산하고 말았다(중앙일보, 2016.3.15.). 2016년에는 러시아에서 시험 중이던 자율 로봇이 연구실에서 나와 거리를 활보한 사례도 있었고, 같은 해 미국의 한 쇼핑몰에 배치된 보안 로봇이 어린 아이를 공격해 상해를 입히기도 하였다(ZDNet, 2016.7.13.). 2018년 3월에는 미국 애리조나에서 우버의 시험 운행 중이던 자율주행차가 무단 횡단하던 보행자를 치어 사망에 이르는 사고도 발생했다. 미 연방교통안전위원회(National Transportation Safety Board)의 조사 결과, 사고 차량의 자율주행센서가 보행자를 사건 발생 6초 전에 인식했으나 물건, 차량, 자전거 등으로 판단해 비상 브레이크 시스템이 작동하지 않았던 것으로 밝혀졌다(최병삼·홍성민 외, 2018). 사고 발생 후 도요타, 누토노미 등 다른 자동차 회사들도 자율주행 시험 운행을 일시 중단하였고, 우버는 7개월이 지난 11월에서야 펜실베이니아 주에서 시험운행을 재개하였다.

[그림 2-2] 인공지능 로봇 오작동(상) 및 우버 사고(하) 사례

〈러시아 시험용 로봇 탈출 및 미국 보안로봇의 어린이 공격 사례〉




〈우버 사고 현장 및 차량〉



자료: 로봇신문사(2016.6.16.)(좌상), 로봇신문사(2016.7.13.)(우상), New york times(2018.3.19.)(좌하), Bloomberg(2018.5.24.)(우하)에서 재인용

인공지능 알고리즘의 오류와 관련 제품/서비스의 오작동은 보유 자산의 물리적 손상, 신체적 상해, 경제적 손실, 개인정보 유출과 같은 개인 차원의 안전성 침해를 넘어, 사회적 불안정성을 심화시킬 소지도 있다. 2016년 3월 마이크로소프트가 공개한 채팅 봇인 테이(Tay)는 “나는 페미니스트를 싫어한다. 그들은 모두 죽은 뒤 불태워져야 한다.”라는 성차별적 발언을 해 16시간 만에 서비스가 중단되었고(양희태, 2018), 같은 해 5월 비영리 언론인 프로파블리카(ProPublica)는 미국 플로리다 주의 경우 흑인과 백인의 재범 발생 확률이 비슷함에도 불구하고 법무부가 사용하는 인공지능 기반 리걸 테크(legal tech) 서비스인 콤파스(COMPAS)가 흑인을 백인보다 훨씬 위험하다고 평가하는 오류를 범하고 있다고 보도하기도 하였다(ProPublica, 2016.5.23.). 아마존은 2014년부터 인공지능 기반의 채용 시스템을 개발했는데 이력서에 “여성(women)”이라는 단어가 들어있는 경우 감점을 하여 성차별 논란에 휩싸였다. 해당 시스템이 10년간 제출받은 이력서를 기반으로 학습을 하였고, 기술직의 경우 남성 지원자가 많아 남성성에 대한 우월적 편견을 가지게 된 것이 원인으로 알려졌다(Medium, 2018.12.11.). 2018년 11월에는 무단횡단하는 사람들을 단속하기 위해 중국 저장성 Ningbo시에 설치된 안면인식 카메라가 세계 최대 에어컨 제조사인 거리전기(Gree·格力)의 CEO인 등밍주(董明珠)를 무단횡단자로 대형 전광판에 공개하는 사고가 발생했다. 안면인식 카메라가 지나다니는 버스 광고판에 붙은 등밍주 회장의 사진을 보행자로 잘못 인식한 것이 원인이었는데(Medium, 2018.12.11.), 이러한 종류의 오류는 언제든지 범죄자로 취급받을 수 있다는 일반 시민들의 불안감을 가중시킬 수 있다.

[그림 2-3] 콤파스의 인종차별(좌)와 안면인식 카메라의 오류(우) 사례



자료: ProPublica(2016.5.23.); Medium(2018.12.11.)

제2절 인공지능 윤리

1. 인공지능 윤리(AI Ethics)의 개념 및 중요성

윤리(倫理)는 인간이 사회적 일원으로서 지켜야 하는 행동 규범이며 공동체 구성원 전체가 공유하는 도리로 살아가면서 지켜야 할 집단적인 이치를 의미한다(한희원, 2018). 흔히 도덕과 윤리를 혼용해서 사용하기도 하지만 윤리는 개개인의 주관적 가치인 도덕보다 보편적인 행위 기준이 되며, 따라서 일반 사회 규범의 성격을 띠고 있다. 다만 윤리적 가치라는 것은 시기와 장소에 따라 변화하는 가변성이 있고 윤리적 행위에 대해서도 명확한 기준을 제시하기 어려운 경우가 많다. 대표적인 예가 트롤리(trolley) 딜레마이다. 브레이크가 고장 난 채로 달려오는 열차로 인해 여러 명의 인부가 죽게 된 상황에서 선로 전환기를 당기면 다른 선로에 있는 한 명만 죽게 되는 경우, 선로 전환기를 당기는 것이 보다 윤리적인 행위인지는 명확치 않다. 매일 고통스러워하는 불치병 환자에게 인락사를 허용하는 문제나, 최근 우리나라에서 조건부로 허용된 낙태에 대해서도 태아의 생명권 논리 등 다양한 윤리적 이슈들이 제기된다. 이렇게 의견이 갈리는 윤리적 행위의 기준에 대해 학계에서는 3가지 이론으로 접근한다(한희원, 2018). 첫 번째는 목적론적 윤리론 또는 결과적 도덕성의 원리라고도 불리는 ‘결과주의’이다. 수단과 방법에 상관없이 결과적으로 최대의 행복을 가져오는 행위를 정의롭다고 보는 윤리론이다. 따라서 결과주의에 따르면, 앞서 예로 든 트롤리 딜레마 사례에서 선로 전환기를 당겨 한 명을 희생시키는 것이 윤리적인 행위가 된다. 두 번째 학설은 어떤 행동의 윤리성이나 도덕성, 정당함은 결과에 상관없이 행위 그 자체로 명백하다고 보는 ‘행위주의’이다. 따라서 결과가 아무리 좋다고 해도 일반적이고 보편적인 도덕 법칙에 어긋나는 행위가 이루어졌다면 이는 윤리적인 행위라고 볼 수 없다. 따라서 행위주의에 따르면 트롤리 딜레마 사례에서 선로 작동기를 당겨 한명을 희생시킬 경우 이는 무고한 사람을 죽인 살인 행위에 지나지 않는다. 마지막으로 결과주의나 행위주의와 달리 행위자의 덕성을 기준으로 행위의 도덕성을 판단하는 ‘덕윤리’가 있다. 구체적인 상황과 맥락, 인간관계를 고려해 윤리성을 판단하고 이성 못지않게 감

성을 중요시 여긴다. 최근에는 언급한 3가지 전통적인 이론을 보완하기 위한 새로운 이론들도 등장하고 있다.

〈표 2-3〉 행위의 윤리성 판단에 대한 이론들

구분	내용
결과주의	수단과 방법을 불문하고 결과적으로 최대의 행복을 가져오는 행위라면 옳고 정당하다고 보는 윤리론이며, “최대 다수의 최대 행복(the greatest happiness for the greatest number)”이라는 공리주의적 정의론에 근거
행위주의	어떤 행동의 도덕성 및 정당성은 행위 그 자체로 이미 명백하기 때문에 결과가 아닌 의무동기가 중요
덕윤리	행위자의 품성에 따라 도덕적 행동이 결정되며 구체적인 상황과 맥락 및 인간관계를 고려해 윤리성을 판단하여 평소 공동체 생활에서의 미덕을 중시하는 삶을 강조
예치의 윤리	의무윤리와 덕윤리가 상호 보완하는 가운데 도덕적 상상력과 창의성을 수용하면서도 규칙에 기반한 의무 윤리가 갖는 현실성도 차용
한스 요나스(Hans Jonas)의 책임윤리	현대과학기술 기반의 행위들은 그 규모와 대상, 결과가 너무 새롭기 때문에 기존의 전통 윤리학의 틀에서 파악될 수 없으므로, 미래학, 두려움, 겸손, 검소함, 절제와 같은 새로운 가치가 필요

자료: 한희원(2018), 이유탉(2005)를 토대로 연구진 재구성

이렇듯 인간의 윤리적 행위에 대해서도 기준이 모호한 상황에서 인공지능 윤리가 최근 화두가 되는 이유는 무엇일까. 또한 학자들 뿐 아니라 인공지능 기반의 제품과 서비스를 개발하고 있는 글로벌 기업의 CEO들까지 이 문제에 대해 관심을 가지고 윤리적 인공지능 개발을 강조하는 이유는 무엇일까. 핵심은 기존 공학 윤리와 인공지능 윤리의 차이에서 기인한다(김효은, 2019). 공학 윤리는 이익과 윤리간의 딜레마 해결에 관심을 가진다. 다시 말해, 안전성이나 공정성 등을 준수할수록 비용이 증가하는 상황에서 생산성과 이익도 증가시키는 방안에 대한 답을 내는데 목적이 있다. 그런데 인공지능 윤리는 공학 윤리와 반대로 윤리적인 문제가 해결되어야 생산성과 이익이 확보되는 방향성을 가진다. 만약 편향적인 알고리즘 개발이 만연하고 범죄 목적의 인공지능 제품 및 서비스가 확산될 경우, 이는 엄청난 사회적 비용을 초래할 것이고 인공지능 기술 뿐 아니라 관련 산업계의 지속 가능성은 불투명해질 것이다. 따라서 인공

지능 윤리는 연구개발(R&D)과 상용화(commercialization)가 어느정도 진전된 이후 고민해야 할 후속적 이슈가 아닌, 인공지능 연구개발 및 상용화의 활성화와 지속 가능성을 위해 선제적으로 대응해야 할 이슈이다.

본 연구에서는 인공지능 윤리(AI Ethics)의 범위를 “인공지능 관련 이해관계자들이 준수해야 할 보편적 사회 규범 및 관련 기술”로 규정한다. 앞서 살펴본 인공지능 안전 성과의 가장 큰 차이점은 “의도성” 여부이다. 다시 말해, 나쁜 의도를 가진 개발자 또는 관련 제품 및 서비스 판매자, 이용자가 인공지능을 악용하는 행위는 인공지능 윤리의 가치에 어긋난다고 볼 수 있다. 따라서 이해관계자간의 합의와 가이드라인, 더 나아가 법제도적 규제를 통해 비윤리적인 인공지능에 의한 사회적 혼란을 방지할 수 있다. 그런데 인간이 아닌 스스로 사고하는 강 인공지능이 악행을 저지르는 경우도 상정해 볼 수 있다. 이러한 경우에 대해서는 호모 사피엔스에만 적용되던 윤리적 기준을 준용하기도 모호한 측면이 있고, 특히 법제도적으로는 별다른 준비가 되어 있지 못한 것이 현실이다. 미국의 작가인 아이작 아시모프(Isaac Asimov)가 1942년 발표한 소설인 ‘Runaround’에서 제시한 로봇 3원칙(Three Laws of Robotics)을 강인공지능에 대한 원칙의 기원으로 보기도 하나, 사회적 합의를 통해 도출되거나 검증되지 않았고, 실제 적용하기에도 구체성이 부족하다는 비판이 많다.

<표 2-4> 아이작 아시모프의 로봇 3원칙

구분	내용
제 1원칙	로봇은 인간에게 해를 끼쳐서는 안 되고 위험에 처한 인간을 무시해서도 안 된다. (A robot may not injure a human being or, through inaction, allow a human being to come to harm.)
제 2원칙	로봇은 제1원칙에 위배되지 않는 한, 인간으로부터 받은 명령에 복종해야 한다. (A robot must obey the orders given it by human beings except where such orders would conflict with the First Law.)
제 3원칙	로봇은 제1원칙과 제2원칙에 위배되지 않는 한, 스스로를 보호해야 한다. (A robot must protect its own existence as long as such protection does not conflict with the First or Second Laws.)

자료: Wikipedia, Three Laws of Robotics를 참고해 연구진 재구성 (https://en.wikipedia.org/wiki/Three_Laws_of_Robotics)

최근 인공지능에게 윤리를 학습시키기 위한 기술적 방안들에 대해서도 개념적 논의가 이루어지고 있다. 먼저 하향식 방법은 보편적인 도덕 원리를 인공지능에게 입력하고 이후 추론하도록 하는 방식이다(한희원, 2018). 구체적인 윤리이론을 택하고 이를 구현하는 알고리즘과 서브시스템을 설계하는 방식으로 이루어지는데, 학습 능력이 뛰어난 인공지능이 인간보다 더 윤리적인 도덕 행위자가 될 수 있다는 전망도 존재한다. 그러나 앞서 살펴본 바와 같이 윤리적 행위에 대한 기준이 모호한 경우가 많기 때문에, 기초적인 윤리 외에 복잡한 상황에 적용할 수 있는 절대적인 윤리 기준을 입력하기에는 한계가 많다. 참고로, 동아대학교의 김종욱 교수팀은 10세 어린이 수준의 윤리적 판단이 가능한 인공지능을 개발하는 과제를 수행 중이다(김효은, 2019). 하향식 방법과 반대로 상향식 방법은 인공지능이 윤리적으로 칭찬받을 행동을 한 경우에 보상을 받는 환경을 구축하는데 초점을 두고 있다. 다시 말해, 인간이 성장하는 과정에서 윤리성을 배우는 것처럼 인공지능 알고리즘이 경험을 통해 윤리적 행동의 기준을 습득하도록 하는 방식이다. 그러나 하향식 역시 상향식과 마찬가지로 보편적인 윤리 기준 학습에 대한 한계가 있으며, 윤리를 학습해나가는 과정에서 시행착오를 거쳐야 하는 위험성도 존재한다(한희원, 2018). 실제 현장에서는 하향식과 상향식을 병행하는 혼합형 방식의 활용이 검토되고 있다.

〈표 2-5〉 인공지능의 윤리적 학습 관련 연구 사례

구분	내용
하향식	셀머 브링스요드(Selmer Bringsjord)는 공리주의적 규칙을 사용해 결과에 대한 적합성 증명까지 제시하는 소프트웨어 추론 기술을 개발 중
상향식	마이클 앤더슨(Michael Anderson)과 수잔 앤더슨(Susan Anderson) 부부는 사례 분석을 통해 규칙 또는 의무들이 상충할 시 어떤 선택을 해야 하는지 결정하는 메드에덱스(MedEthEx) 프로그램을 개발. 예를 들어, 의료 시술 시 두 가지 이상의 선택지가 제시되었을 때 과거 사례를 참고해 결정.
혼합식	빈센트 비겔(Vencent Wiegel) 교수가 개발한 소포랩(SophoLab)은 실제 사회와 같은 복잡한 네트워크에서 여러 행위자들이 어떤 상호작용을 하고 어떤 판단을 내릴지 시뮬레이션


자료: 김효은(2019)을 참고해서 연구진 재구성

2. 인공지능 윤리 침해 사례


인공지능을 비윤리적으로 활용하는 대표적인 경우는 대량의 인명 피해가 예상되는 자율살상 무기 개발이다(최병삼·홍성민 외, 2018). 이봉진·김유혁(2018)에 의하면 인공지능 기반의 무기 개발은 비용 대비 효과가 높다고 알려져 있는데, 예를 들어 F-35 전투기 개발에는 1억달러 이상이 소요되나 유사한 업무를 1달러 정도의 작은 드론을 통해서도 수행할 수 있다는 식이다. 이에 2025년 기준으로 인공지능을 탑재한 군사용 로봇과 드론 시장 규모는 민간 시장 규모를 압도할 것으로 예상되고 있다.

[그림 2-4] 전세계 군사용 로봇 시장 규모(좌) 및 용도별 드론 시장 규모(우)

전세계 군사용 로봇 시장 규모 추이



2016년 대비 2020년 용도별 드론 시장 규모



자료: 이봉진·김유혁(2018), p. 1.

여전히 세계 곳곳에서 전쟁이 일어나는 가운데 인공지능을 무기 개발에 활용하는 것 자체를 비윤리적이라고 단정 짓기에는 무리가 있다. 또한 이미 미국, 러시아 등 군사 대국들은 인공지능 기반의 미사일, 함정, 탱크 등을 실전 배치하고 있어 전면적인 반대 역시 쉽지 않은 상황이다. 다만, 자율살상 무기가 무고한 민간인들을 무분별하게 학살하거나 테러리스트들에 의해 악의적으로 이용될 경우에 대해서는 확실한 대책이 요구된다. 이미 드론에 대한 테러 사례는 심심치 않게 나타나고 있는데, 가장 최근에는 2019년 1월 예멘의 한 공군기지에서 개최된 정부군 행사에 후티(Houthi) 반군의 드론이 폭파해 정부군 6명이 사망하고 관료 12명이 부상을 당한 사례가 있다(The Guardian,

2019.1.10.). 그 이전인 2018년 8월에는 니콜라스 마두로 베네수엘라 대통령의 군 창설 연설 도중에 드론 테러가 발생해 7명의 부상자가 발생하기도 하였다(The Verge, 2018.8.17.).

[그림 2-5] 예멘 공군기지(좌)와 베네수엘라 대통령(우) 드론 테러 사례



자료: (좌) The Guardian(2019.1.10.); (우) The Verge(2018.8.17.)

또 다른 대표적인 인공지능의 악용 사례는 의도적으로 가짜 이미지나 영상, 뉴스, 음성을 생성해 배포하는 행위를 들 수 있다. 딥페이크(deepfake)라고 불리는 이러한 편집물들은 개인의 평판을 훼손시키고 사회적 구성원 간의 신뢰를 떨어뜨리는 등 부작용이 만만치 않다. 이미 국내외적으로 유명 연예인들의 얼굴이 음란물과 합성돼 인터넷에 무작위로 유포되고 있어 디지털 성범죄에 따른 우려의 목소리가 높아지고 있다. 미국의 온라인 매체인 버즈피드(BuzzFeed)는 조던 필레(Jordan Peele) 감독과 오바마 전 대통령이 트럼프 대통령을 비난하는 영상을 FakeApp을 통해 간단하게 만들어 딥페이크의 위험성을 경고하기도 하였다.


[그림 2-6] 인공지능을 이용한 딥페이크 사례



자료: 연합뉴스(2019.6.13.); BuzzFeed(2018.4.18.)

마지막으로 인공지능을 데이터 조작, 해킹 등 사이버 공격에 사용하는 경우가 있다. 이스라엘의 벤구리온(Ben-Gurion) 대학교 연구진은 딥러닝³⁾을 이용해 의료 영상을 조작한 실험 결과를 2019년 4월 논문으로 발표하였다(Mirsky, Yisroel, et al., 2019). 우선 연구진은 실험 대상인 병원의 허가 하에 외부에서 인터넷을 통해 3D CT 의료 영상 이미지들을 해킹했고, 임의로 폐암 이미지를 삽입하거나 반대로 폐암 이미지의 일부를 지우는 방식으로 원본 이미지들을 조작하였다. 그리고 3명의 방사선과 의사들에게 진의여부를 물어보았는데, 폐암 이미지가 삽입된 가짜 이미지의 99%를 암환자의 이미지로 판단했고 폐암 이미지를 지운 가짜 이미지의 94%를 건강한 사람의 의료 영상으로 착각하는 결과가 도출되었다. 본 실험은 현재의 보안 수준에서 해커들이 인공지능을 범죄에 악용할 수 있는 가능성이 매우 높다는 것을 보여준 사례이며, 악성코드 개발, 데이터 조작 등에 대한 대비책 마련이 시급함을 알 수 있다.

[그림 2-7] 진찰 과정에서의 이미지 조작 사례(좌)와 실제 조작한 이미지(우)



자료: Mirsky, Yisroel, et al.(2019), p. 2, p. 11.


3) 이미지 생성자와 구별자가 서로 대답하면서 서로 성능을 개선시키는 GAN(Generative Adversarial Network) 알고리즘을 이용

제3절 인공지능 안전성 및 윤리의 개념적 범위

앞서 언급한대로 본 연구에서는 인공지능 안전성을 “인공지능의 기술·구조적 한계 및 특징으로 인해 발생할 수 있는 의도치 않은 각종 위험들에 대비하는 개념 및 분야”로 정의하고, 인공지능 윤리는 “인공지능 관련 이해관계자들이 준수해야 할 보편적 사회 규범 및 관련 기술”로 구분하였다. 다시 말해 기술적 오류 또는 관련 이해관계자의 고의가 아닌 실수로 인해 생긴 사건·사고에 대비하는 영역을 ‘인공지능 안전성’으로, 인공지능 개발자 및 사용자가 특정 목적 및 의도를 가지고 악용하는 경우에 대응하는 분야를 ‘인공지능 윤리’로 규정하고 대응 방안을 수립하고자 한다.

인공지능 안전성과 인공지능 윤리 관련 이슈들은 관련 제품 및 서비스가 상용화되기 이전 단계와 이후 단계 모두에서 발생할 수 있다. 또한 이슈 해결을 위한 방안은 관련 기술 개발(예. 사이버 보안)과 진흥/규제 정책으로 구분해 모색해 볼 수 있다. 따라서 앞으로 전개될 연구 내용들에서는 이러한 관점을 견지하며 인공지능 기업과 학계, 주요국 정부의 대응 동향을 살펴보고, 상대적으로 어떤 분야에 중점을 두고 있는지 관련 시사점을 도출하고자 한다. 또한, 최종적인 법제도 개선안도 인공지능 안전성과 인공지능 윤리로 구분해 관련 기술력 향상 및 사회적 안전성 제고 측면에서 제시하고자 한다.

[그림 2-8] 인공지능 안전성과 인공지능 윤리의 개념적 범위



자료: 연구진 작성

| 제3장 | 기업 및 학계/연구계 대응 동향

심층학습(Deep Learning) 기술을 바탕으로 하는 인공지능은 4차 산업혁명을 견인하는 핵심동력으로 그 가치를 인정받으면서 급격히 발전하고 있다. 특히 연구자들이 최신 연구결과를 서로 공유하는 오픈 사이언스(Open Science) 구조의 확산은 인공지능의 기술 발전을 더욱 가속화시키고 있다. 향후 범용 인공지능, 사람 수준의 인공지능 등 인공지능의 궁극적 목표를 달성함에 있어서 낙관론도 펼쳐지고 있으나 한편으로는 이에 대한 경계를 표하는 움직임도 증가하고 있다. 인공지능 연구자들은 범용 인공지능 개발이 우리의 삶을 더 편하고 안전하게 할 수도 있지만 이로 인해 발생할 수 있는 잠재적 위험에 대한 경고의 목소리도 높이고 있다. 즉 인공지능이 직접 산업에 적용되기 위해서는 아직 많은 숙제를 안고 있으며 그 중에서도 인공지능의 안전성(safety)과 투명성(transparency)에 대한 보장이 우선되어야 한다는 것을 강조하고 있다. 만약 안전성과 투명성이 보장되지 않는다면 이것이 새로운 인공지능 기술의 등장으로 해결될 수 있는 것인지, 아니면 윤리 및 법·제도 연구를 통해 사회적 합의를 이끌어 낼 것인지에 대한 논의가 필요할 것이다. 관련해서 글로벌 기업 및 학계에서도 인공지능의 안전성과 투명성 확보와 연관된 연구를 활발히 진행 중이다. 이는 기업이 명백히 인공지능의 산업적 활용을 염두하고 있기 때문이며, 현 시점에서는 인공지능의 기술적인 완성도도 중요하지만 실제 적용할 수 있는 가능성을 높이는 방향 설정이 중요하다. 이에 본 장에서는 인공지능의 안전성과 투명성을 확보하기 위한 글로벌 기업 및 학계의 대응 동향을 살펴보고자 한다.

제1절 글로벌 기업 대응 동향⁴⁾

1. 인공지능 윤리 전문가 채용

KPMG는 인공지능과 관련하여 가장 유망한 5대 직업으로 인공지능 아키텍트, 인공지능 제품 매니저, 데이터 과학자, 인공지능 소프트웨어 엔지니어와 함께 인공지능 윤리전문가를 선정했다(KPMG, 2019.1). 실제로 테크 기업 내부에서 인공지능 윤리 전문가에 대한 수요가 증가하고 있다. 최근 실리콘밸리에 근무하는 디지털 기술개발자들이 자신들이 개발한 디지털 기술이 군사, 반이민 정책 등을 집행하는 정부부처에서 반인권적인 수단으로 사용하는데 대한 반대 시위가 늘어나는 등 윤리적 요구가 높아지고 있기 때문이다. 종업원들의 디지털 기술의 윤리적 사용에 대한 요구가 높은 기업은 구글, 아마존, 세일즈포스닷컴⁵⁾ 등인데, 이러한 기업들은 관련 문제를 제대로 해결하지 못할 경우 우수한 인재를 확보하지 못할 수 있다는 위기위식을 가지고 있다.

세일즈포스닷컴(Salesforce.com)은 인공지능 윤리 전문가들을 지속적으로 확보하고, 임원급에 해당하는 직책을 신규로 만들어 주요 의사결정에 참여하게 만들었다. 일례로 2018년 8월 인공지능의 윤리적 구현을 지도하기 위한 책임자로 캐시 백스터(Kathy Baxter)를 고용했다(Wall Street Journal, 2019.1.29.). 캐시 백스터는 구글, 이베이, 오리클 등에서 사용자 경험(user experience)을 담당해 왔으며, 인공지능 윤리 담당자로서 고객, 과학자들을 조율하고, 모범 사례(best practice)를 세계경제포럼 등에 전파하는 역할을 하고 있다. 또한 개발자들이 다양한 의견과 경험을 고려하여 개발을 진행하는지, 학습데이터가 차별을 유도하지 않는지 등을 체화하도록 인공지능 교육 과정을 개발하여 제공하고 있다. 또한 2019년 1월에는 인공지능 윤리와 관련된 임원급 직책(Chief Ethical and Humane Use Officer)을 만들고 이베이 설립자인 피에르 오미디아르(Pierre Omidyar)가 설립한 사회적 책임 투자 회사인 오미디아르

4) 본 주제에 대해서는 소프트웨어정책연구소 조원영 선임연구원의 자문을 받아 작성하였으며, 2. 인공지능 개발자가 지켜야할 원칙 수립, 3. 인공지능의 사회적 영향 연구 및 감시 전담부서 설치, 6. 인공지능을 활용한 사회적 공익 프로젝트 운영은 조원영(2019.4.)을 포괄적으로 인용

5) 세일즈포스닷컴은 미국 세관 및 국경 보안청(US Custom and Border Protection)과 계약을 맺어 미국의 반이민정책을 지원한다는 이유로 직원들의 극심한 반대에 부딪힌 바 있음.

네트워크의 부회장을 지낸 파울라 골드만(Paula Goldman)을 선임했다(Business Insider, 2018.12.16.). 파울라 골드만의 주요 임무는 윤리적인 방법으로 기술을 사용하여 시장을 창출하는 전략을 수립하는 것이다. 그녀는 “우리는 사회에 더 큰 책임을 갖고 있으며, 고객의 성공뿐만 아니라 사회에 긍정적인 변화와 인류애에 도움이 되는 기술을 개발하겠다.”라고 발표했다.

우버(Uber)는 고객에 대한 범죄, 운전자의 난폭 운전뿐만 아니라 알고리즘 가격(surge pricing)을 이용한 담합 행위, 규제 당국을 속이기 위한 불법 소프트웨어(Grey Ball) 활용 등의 비윤리적 문제가 불거지며 논란이 되고 있다(매일경제, 2017.12.17.). 이에 우버는 2018년 7월 최고준법윤리책임자(Chief Compliance and Ethics Officer)라는 직책을 만들고 미국 법무부(US Department of Justice)에서 차관보로 근무했던 스콧 스쿨스(Scott Schools)를 임명했다(Business Insider, 2018.7.10.). 우버에는 현재 법무팀의 책임자(Chief Legal Officer)로 토니 웨스트(Tony West)가 근무하고 있는데, 스콧 스쿨스는 토니 웨스트와 함께 규제당국과의 소통과 조율 등의 역할을 주로 할 것으로 보인다.

기업 및 시장조사분석 기관인 CBInsight에 따르면, 시가총액 최상위권 테크기업을 지칭하는 GAFA(Google, Amazon, Facebook and Apple)에서도 인공지능 윤리 및 사회적 책임을 담당하는 전문가 채용을 늘리고 있다(CBInsight, 2018.9.11.). 기계학습 윤리를 위한 조사 분석가(Investigations Analyst for Machine Learning Ethics)에 대한 채용 공고를 냈던 구글은 특히 보안에 대한 문제가 발생하고 있는 구글의 스마트홈 분야의 경우 기술 전문가(Director of Software Engineering) 뿐만 아니라 프라이버시와 보안분야의 정책 커뮤니케이션 관리자(Policy Communications Manager)도 모집 공고를 낸 바 있다. 아마존 역시 알렉사를 필두로 한 스마트홈 분야의 보안 문제를 해결하기 위한 책임자를 모집하였다. 아마존이 모집했던 프라이버시 및 고객 신뢰 책임자(Director of Privacy and Customer Trust)는 아마존의 신제품 개발 연구소인 Lab126에서 알렉사 등 스마트홈 기기의 디자인 단계부터 최종 소비까지 전단계에 걸친 프라이버시 및 고객 신뢰 문제를 담당한다. 캠브리지 어널리티카로의 고객 데이터 불법 유출과 미국 대선에서 러시아의 개입

채널로 활용되어 여전히 몸살을 앓고 있는 페이스북은 새로운 서비스에서 야기될 프라이버시 문제를 평가하고 가이드라인을 제공하는 역할을 담당하는 개인정보보호 정책 담당자(Privacy Policy Director)를 모집했다. 또한 개인정보보호 관련 입법 시 정책 입안자들과 좀 더 원활한 소통과 의견을 개진하기 위해 개인정보보호 입법 책임자(Director of Privacy Policy Legislation)를 모집하기도 했다. 또한 정치적 중립성 유지와 편파적인 정치 개입을 예방하기 위한 전문가 모집도 이뤄지고 있다. 페이스북은 최근 정치적 선전 플랫폼으로 널리 활용되는 왓츠앱(WhatsApp)⁶⁾에 선거 정책 프로그램 관리자(Policy Program manager for Election)를 채용한 바 있으며, 전 세계에서 치러지는 선거 시 왓츠앱에 발생하는 문제에 유연하기 대처하는 것이 주요 역할이다. 정치적 콘텐츠를 소비하는 주요 채널로 부상한 구글의 유튜브 역시 공공정책 및 정부관계 책임자(Director of Public Policy and Government Relations at YouTube)를 채용했다. 역할은 테러, 아동안전, 잘못된 정치적 뉴스와 같은 콘텐츠를 차단하는 등 유튜브의 정치적 중립을 위한 책임성을 강화하는 것이다. CEO인 팀 쿡(Tim Cook)의 발언⁷⁾ 등 개인정보보호를 선도하는 기업으로 어필하고 있는 애플은 유럽의 GDPR에서부터 캘리포니아의 새로운 소비자 개인정보보호법까지 전세계의 개인정보에 관한 규정을 애플의 제품이 준수하는지를 감시하고 전략을 집행하는 개인정보 책임자(Director of Privacy Compliance)를 모집한 바 있다.

인공지능 윤리 전문가를 채용하기를 원하지만 책임자를 찾지 못하는 경우도 많다. 99달러로 일반인들의 유전자를 분석해주는 기업 23andMe 역시 최근 최고윤리책임자(Chief Ethics Officer) 채용을 시도했으나 책임자를 찾지 못한 상황이다. 대표이사를 맡고 있는 앤 워치츠키(Anne Wojcicki)는 “여러 후보들과 면접을 진행했지만 학계에서 머물며 연구에 집중하겠다고 모두 자리를 고사했다. 일단 특정 인물에게 이 직책을 맡기는 것보다는 경영진들이 모두 윤리적인 판단을 할 수 있는 능력(skillset)을 갖추기로 했다.”고 언급하기도 했다(New York Times, 2018.10.21.).

6) 2014년 페이스북이 인수

7) “사생활은 인권이고 시민의 자유입니다. 언론의 자유와 사생활은 우리를 위해 있습니다.”, “우리도 다른 기업들처럼 고객의 데이터를 팔아 수익을 창출할 수 있습니다. 하지만 우리는 단호히 거부합니다.” 등의 발언을 함

2. 인공지능 개발자가 지켜야 할 원칙 수립

인공지능이 잘못 개발 및 활용되어 사회적 문제를 만드는 것을 예방하기 위해서 인공지능 개발에 대한 윤리적 가이드라인을 만들어 개발자들에게 이를 준수하도록하는 기업들도 늘어나고 있다.

2018년 6월 국방부와의 무인드론 업그레이드 프로젝트(Project Maven)에 대한 추가 계약을 윤리적 이유로 포기하면서 구글의 CEO인 순다 피차이는 공식 블로그에 구글의 인공지능 원칙(AI at Google : Our Principle)을 발표했다(Google Blog). 순다 피차이는 이 글에서 “인공지능과 같은 강력한 기술은 앞으로 사회에 큰 영향을 미칠 것이며, 선두주자로서 구글은 큰 책임감을 느낀다”며 구글의 7가지 인공지능 원칙을 발표했다. 첫째, 구글은 서비스가 제공되는 국가의 문화, 사회 및 법적 규범을 지키면서 정확하고 품질이 높으며 사회적으로 유익한 인공지능 서비스(Be Socially Beneficial)를 제공할 것이다. 둘째, 구글은 국적, 인종, 민족, 성별, 소득, 능력 및 정치적, 종교적 신념, 성적 취향과 같은 민감한 특성과 관련된 부당한 영향과 불공정한 편견을 만들거나 강화하지 않는다(Avoid Creating or Reinforcing Unfair Bias), 셋째, 위험을 야기하는 의도치 않은 결과를 피하기 위해 강력한 안전 및 보안 관행을 개발 및 적용하며, 인공지능을 적절하고 신중하고 설계하고, 모범 사례에 따라 개발하며, 제한된 환경에서 테스트하고 배포 후에도 지속적으로 모니터링 한다(Be Built and Tested for Safety). 넷째, 인간에게 적절한 통제를 받으며 피드백과 설명을 하는 책임감 있는 인공지능을 개발한다(Be Accountable to People). 다섯째, 인공지능 기술의 개발 및 활용에 있어서 개인정보보호원칙을 철저히 준수하며, 사용자에게 올바른 정보를 제공하고 동의 절차를 명확히 하고, 개인정보 보호장치가 마련된 아키텍처를 장려해 데이터 사용에 대한 투명성과 사용자의 통제권한을 제공한다(Incorporating Privacy Design Principles). 여섯째, 인공지능을 활용하여 생물학, 화학, 의학, 환경과학과 같은 영역에서 과학 연구 및 지식의 새로운 지평을 여는데 활용한다(Uphold High Standard of Scientific Excellence), 일곱째, 인공지능 기술을 배포할 때, △솔루션이 유해한 사용과 얼마나 밀접하게 연관되어 있는지 용도를 파악하고, △독창적이고 일반적으로 사용 가능한 기술을 제공하는지 고려하며, △기술

의 사용이 의미 있는 영향을 미치는지 등을 고려할 뿐만 아니라 △전반적이고 중대한 위해의 위험이 있거나 △인명피해를 야기하는 기술을 개발하거나, △국제적으로 보편적인 규범을 위반하는 감시 정보를 수집하거나, △국제법과 인권을 침해하는데 구글의 기술을 사용하지 않는다.⁸⁾

이에 더하여 구글은 인공지능의 사회적 책임을 다하기 위해 인공지능 개발 및 활용에 지켜야 할 일반권고사항(General Recommendation Practice for AI)을 마련했다(Google AI 권고사항 홈페이지). 구글이 제시한 권고사항은 다음과 같이 여섯 가지 원칙으로 구성되어 있다.

〈표 3-1〉 Google AI 권고사항

첫째, 다양한 사용자를 테스트에 참여시켜 사용자가 인공지능을 어떻게 경험하고 의사 결정에 영향을 받는지를 파악하고 이들의 의견을 반영하여 인간 중심의 설계를 구현한다.

둘째, 사용자 설문, 시스템 성능 점검, 장기적인 이력 추적 등을 수행하고 이를 토대로 평가 시스템을 구축한다.

셋째, 개인정보보호를 침해하거나 편견의 원인이 되는 데이터가 있는지 확인하고 데이터 누락은 없는지, 무작위 표본 추출이 되었는지 등도 확인하는 등 원시 데이터(raw data)를 항상 점검한다.

넷째, 훈련 데이터(training data)에 의해 모델의 용도가 제한됨을 명심하고 무리하게 다른 용도로 확장하지 않는다.

다섯째, 인공지능이 의도한 대로 작동하는지 요소별 테스트, 요소별 상호작용 확인을 위한 통합 테스트, 사용자 테스트를 상시 수행한다.

여섯째, 시스템이 실제 환경에서 제대로 작동하는지 배포 후에도 관찰한다.

자료: 조원영(2019.4.), p.27 내용을 발췌하여 작성

8) 하지만 구글은 발표 직후 국방부의 100억 달러 규모 클라우드 사업입찰에 참여하여 인공지능 원칙을 위반했고, 이에 대한 비난이 거세지자 2018년 10월 입찰 포기를 선언(MIT Technology Review, 2018.10.21.)

2018년 3월 마이크로소프트도 신뢰할 수 있는 인공지능 개발을 위해 개발자가 설계 단계부터 준수해야 하는 여섯 가지 개발 원칙을 제시했다(Microsoft 홈페이지)

<표 3-2> Microsoft AI 개발원칙

첫째, 가능한 다양한 배경을 가진 인공지능 개발자가 함께 인공지능 개발에 참여하도록 하고 공정성을 평가하고 문제를 적발하는 기술을 개발함으로써 인공지능에 편견이 개입될 여지를 제거한다.

둘째, 양질의 훈련 데이터를 활용하고 광범위한 테스트 과정을 거치며 지속적으로 성능을 감시함으로써 예상할 수 있는 모든 환경 요인을 최대한 반영한다.

셋째, 개인정보보호법을 준수하고 개인정보 비식별 기술을 활용할 뿐만 아니라 데이터 수집, 분석, 활용 등 쏘단계를 투명하게 관리한다.

넷째, 장애인 등 소수 집단을 차별하거나 배제할만한 장벽이 있는지 확인하고 이들에게 기회를 부여한다.

다섯째, 인공지능이 왜 그런 결과를 도출했는지 설명하여 사용자를 납득시킬 수 있어야 하며 오류, 의도치 않은 결과 등이 나올 경우 원인을 명확히 파악한다.

여섯째, 인공지능 시스템의 운영 방식을 결정하고 결과에 대해 책임을 지기 위해서 내부 검토 위원회(Internal Review Board)를 운영한다.

자료: 조원영(2019.4.), p.27 내용을 발췌하여 작성

IBM은 2014년부터 디자이너와 개발자에게 실무적인 가이드라인을 제공하기 위해 「인공지능을 위한 일상의 윤리(Everyday Ethics for AI)」책자를 발간해왔으며 그 동안 총 다섯 차례의 개정을 거쳤다(IBM, 2018.9.). 서문에는 개발자들의 기술 중심적 사고(tech-centric focus)를 지양하고 윤리 및 인간 중심적(ethical and human-centric) 인공지능 개발의 필요성을 역설했다. 본문에는 5대 분야의 윤리원칙(Five Areas of Ethical Focus)을 제시하였다. 첫째, 인공지능 설계자와 개발자들은 인공지능의 설계, 개발, 의사결정 프로세스뿐만 아니라 그 결과에 대해서도 책임을 져야 한다는 책임성(accountability)의 원리를 제시했다. 둘째, 인공지능은 사용자 그룹이 갖고 있는 규범 및 가치체계와 일치(value alignment)하도록 설계되어야 함을

제시했다. 셋째, 인공지능의 의사결정 프로세스는 인간에게 쉽게 인지되고, 감시가능하며 이해가능 하도록 설계(explainability)되어야 하고, 넷째, 인공지능은 편견을 최소화하고 대부분을 포괄할 수 있도록 공정하게 설계(fairness)되어야 함을 강조했다. 마지막으로 다섯째는 인공지능은 사용자의 데이터를 보호하고 사용자들이 데이터에 대한 접근권과 사용권을 보호하도록 설계(User Data Right)되어야 한다고 언급했다. IBM은 인공지능 데이터와 알고리즘의 편향을 해결할 수 있는 방법의 일환으로 인공지능 공정성 360 오픈소스 도구를 공개했는데, 70가지 이상의 공정성 측정지표를 제공하며 편향을 줄일 수 있는 10가지 최신 기술을 공유하고 있다(IBM Research Trusted AI 홈페이지). 국내의 경우 2018년 1월 카카오가 국내 기업 중 최초로 인공지능 개발자들이 알고리즘 설계 시 준수해야 할 사항을 명문화한 인공지능에 관한 윤리규범을 제정·발표했다(국민권익위원회, 2019.1.). “인공지능을 인류의 편익과 행복을 추구하는데 활용한다”는 원칙 하에 “차별에 대한 경계, 학습 데이터 관리, 알고리즘 독립성, 알고리즘에 대한 설명 의무” 등의 내용을 담았다. 카카오의 윤리 현장 전문은 다음과 같다.

〈표 3-3〉 카카오의 윤리 현장 전문

원칙	내용
1. 카카오 알고리즘의 기본 원칙	카카오는 알고리즘과 관련된 모든 노력을 우리 사회 윤리 안에서 다하며, 이를 통해 인류의 편익과 행복을 추구한다.
2. 차별에 대한 경계	알고리즘 결과에서 의도적인 사회적 차별이 일어나지 않도록 경계한다.
3. 학습 데이터 운영	알고리즘에 입력되는 학습 데이터를 사회 윤리에 근거하여 수집·분석·활용한다.
4. 알고리즘의 독립성	알고리즘이 누군가에 의해 자의적으로 훼손되거나 영향받는 일이 없도록 엄정하게 관리한다.
5. 알고리즘에 대한 설명	이용자와의 신뢰 관계를 위해 기업 경쟁력을 훼손하지 않는 범위 내에서 알고리즘에 대해 성실하게 설명한다.

자료: 국민권익위원회(2019.1.), p.11

이와 같이 카카오의 윤리헌장은 최근 국내외에서 활발히 논의되고 있는 사회적 차별 금지, 데이터 윤리, 알고리즘의 독립성 및 설명 의무 등에 대한 원칙을 포함하고 있다. 즉 알고리즘 기술이 인간의 도덕적 가치와 윤리 관점에 부합되어야 하고 궁극적으로는 인간의 삶의 효용성을 높일 수 있어야 한다는 점을 강조하고 있다. 무엇보다 카카오 윤리헌장은 민간 기업 차원에서의 인공지능 윤리 기준을 공표했다는 점에 큰 의의가 있다. 지난 2017년 ‘지능정보사회 윤리 가이드라인’ 등과 같이 정부 차원의 관련 규범 수립 노력은 있었으나 민간 부문에서부터의 주도적인 가이드라인 설정 노력은 없었던 만큼, 카카오 윤리헌장은 다가오는 인공지능 시대에 국내 상황에 적합한 규제 주체, 범위, 성격에 대한 논의를 시작할 수 있는 계기를 제공했다는 점에서 주목할 만하다.

3. 인공지능의 사회적 영향 연구 및 감시 전담부서 설치

기업들은 인공지능 기술의 사회적 영향을 연구하고 인공지능에 의해 유발된 사회적 부작용 감시하는 전담부서를 설치하기 시작했다. 2017년 10월 구글 답마인드는 윤리 및 사회 전담부서(DeepMind Ethics & Society Unit)를 설립했다(DeepMind 블로그). 답마인드 윤리 및 사회 전담부서(DeepMind Ethics & Society Unit)는 인공지능이 사회전반에 미치는 광범위한 영향에 대해 연구와 조사를 진행하고 이를 바탕으로 인공지능 개발자에게 올바른 가이드라인을 제공하는 것을 목표로 한다고 밝혔다. 이와 관련하여 전담부서는 사회에 이익을 제공하는 연구, 근거 기반 연구, 투명하며 개방된 연구, 다학제 간 연구, 협업과 포용을 지향하는 연구 등 인공지능 개발 관련 5대 원칙을 도출하고 이를 개발자에게 공개했다. 또한, 옥스퍼드대 닉 보스트롬 교수, 케임브리지대 다이앤 코일 교수, 맥킨지 글로벌 연구소 제임스 매니카 소장, 컬럼비아대 제프리 삭스 교수 등 세계적인 공학자, 사회학자, 경제학자 등을 자문위원으로 임명하여 인공지능 사회적 영향과 관련된 공동연구를 수행하고 있다(조원영, 2019.4.).

2018년 4월 미국 의회의 청문회 직후 포브스(Forbes)지는 페이스북 내에 공정한 알고리즘 설계와 모두에게 이로운 서비스를 제공하기 위한 인공지능 윤리팀이 만들어졌다고 보도된 바 있다. 페이스북의 과학자 이자벨 클로우만(Isabel Kloumann)이 이

끄는 팀은 인공지능 훈련데이터의 공정성 여부를 판단하는 소프트웨어(Fairness Flow)를 개발 중에 있으며(Forbes, 2018.5.3.), 2018년 10월에는 미국 중간선거와 브라질 대선 기간에 맞춰 가짜 뉴스를 적발하고 이의 확산을 막는 전담부서(War Room)를 설치하기도 했다(The Guardian, 2018.10.19.). 기존에 페이스북은 빅데이터, 인공지능 기술을 악용하여 이용자의 정치적 성향을 정확히 프로파일링한 후 광고 매출을 늘리기 위해 가짜 뉴스 및 정치 광고 배포에 활용한다는 비난을 받아왔다(조원영, 2019.4.). 이와 관련하여 2018년 4월 미국 의회에서 관련 청문회가 열렸고, 페이스북은 연방수사국(FBI)과 증권거래위원회(SEC), 연방거래위원회(FTC), 연방법원(DOJ) 등으로부터 조사를 받았다. 페이스북이 사회적 부작용을 감시하는 것을 목적으로 신설한 부서에는 약 20여명의 인력이 배치되었으며, 이들은 타부서 소속의 300여명의 인력과 협력하여 허위 정보를 적발하는 업무를 수행하고 있다.

구글은 2018년 6월 발표한 구글의 인공지능 원칙(AI at Google : Our Principle)을 보완하기 위한 조치로 2019년 3월 26일 인공지능 윤리에 관한 외부자문위원회(Advanced Technology External Advisory Council for AI Ethics, ATEAC)를 설립하고 8명의 자문위원을 임명했다. 위원회는 원칙을 구현하는데 도움이 되는 내부 통제 구조 및 프로세스를 보완하고, 인공지능 개발과 관련된 복잡한 윤리적 문제에 대한 의사결정을 하는 기능을 수행할 계획이다(Google blog, 2019.3.26.). 자문위원으로는 드론회사인 트럼불(Trumbull)의 대표를 맡고 있는 다이안 기븐스(Dyan Gibbens), 반이민 정책, 성소수자에게 불리한 정책 등을 제안해 온 우파 싱크탱크인 헤리티지 재단(Heritage Foundation)의 대표를 맡고 있는 케이 콜스 제임스(Kay Coles james) 등이 포함되었다. 하지만 가디언 등의 언론은 “인공지능 윤리위원회의 구성에서도 역시 현실 세계에의 불평등이 고스란히 반영되었다”며 비판했고(The Guardian, 2019.3.29.), 구글 직원들 역시 케이 콜스 제임스 회장, 드론을 무기로 개발하는 다이안 기븐스 대표 등을 제외하라고 촉구했다(연합인포맥스, 2019.4.2.). 자문위원에 포함되었던 카네기멜론대의 알레산드로 아퀴스티(Alessandro Acquisti) 교수는 자문위원 구성에 불만을 갖고 참여하지 않겠다고 선언하기도 했다. 결국 구글은 현재의 상황에서 자문위원회가 제 기능을 수행하기 어렵다고 판단하여 4월 4일 해

산을 결정했다.

하지만 블룸버그는 2019년 4월 6일 이번에 해산한 외부자문위원회의 역할은 그리 중요하지 않았으며, 사실은 구글 내부 임원으로 구성된 선진 기술 검토위원회(Advanced Technology Review Council)가 작년에 이미 비밀리에 구성되어, 그동안 인공지능 윤리, 구글의 사회적 책임 문제 등을 검토하는 등 진정한 힘을 발휘하고 있다고 보도했다(Bloomberg, 2019.4.6.). 공식적인 입장은 아니지만 내부 소식통에 따르면 위원회에는 CEO인 순다 피차이와 구글 공동 설립자인 래리 페이지(Larry Page) 및 이들의 핵심 측근들이 포함되어 있다. 구글이 범용 얼굴 인식 기술을 도입하지 않기로 한 결정도 선진 기술 검토위원회에서 이뤄진 것으로 알려졌다.

마이크로소프트는 인공지능의 책임있는 개발과 윤리적 활용과 관련된 의사결정을 위해 2017년 7월 임원으로 구성된 ‘엔지니어링 및 연구에서의 인공지능 윤리위원회(AI and Ethics in Engineering & Research Committee, AETHER)’를 신설했다. 마이크로소프트 연구소(Microsoft Research Labs)의 소장이자 AETHER의 위원인 에릭 호르비츠(Eric Horvitz)는 “인공지능 개발 프로젝트가 시작되기 전에 위원회에서 인공지능의 잘못된 활용 가능성과 같은 잠재적인 문제를 찾아낸다”고 언급했다(Business Insider, 2017.7.12.). 또한 호르비츠는 2018년 4월 카네기멜론대에서 열린 ‘K&L Gates Conference on Ethics and AI’에서 “AETHER의 결정을 통해 얼굴인식이나 예측 등 인공지능을 활용한 서비스가 비윤리적으로 활용될 가능성이 있을 경우, 기능을 제거하거나 판매를 거부함으로써 마이크로소프트는 기꺼이 매출 감소를 감수하고 있다”고 언급한 바 있으며(GeekWire, 2018.4.9.), 앞서 언급한 마이크로소프트가 정부에게 얼굴 인식 기술에 명확한 규제를 만들라는 요구도 AETHER에서 이뤄진 것으로 보인다.

독일의 기업용 소프트웨어기업 SAP은 2018년 9월 인공지능윤리자문위원회(External AI Ethics Advisory Panel)를 구성했다(SAP, 2018.9.18.). 5명의 산학연 전문가로 구성된 위원회는 SAP의 인공지능 엔진인 SAP Leonardo Machine Learning이 무결성과 신뢰성을 유지하는 것을 목표로 하며, 개인정보보호와 사회적 문제를 해결하기 위한 다양한 방안을 마련하도록 지원하는 역할을 수행한다.

4. 인공지능 감사(Algorithm Auditing) 실시

인공지능이 사용자, 주주, 이해관계자 및 시민사회에 미치는 영향이 커짐에 따라 기업이 회계장부를 공개하고 감사를 받듯이, 인공지능 개발 회사도 책임 있는 인공지능 개발을 위해 기술을 공개하고 감사(Auditing)를 받아야 한다는 주장이 커지고 있다. 이를 위해서는 우선 인공지능의 개발과 사용에 있어서 국가의 명확한 규제체계가 마련되어 기술을 평가할 수 있어야 하며, 그 이전에 기업이 스스로 인공지능의 개발 및 활용 과정에 있어서 사회적 편익과 비용에 대한 정보를 체계적이고 통일된 방법론을 활용하여 정확하게 계량화하여 공개해야 한다. 이와 관련하여 2016년 미국 백악관 대통령실(Executive Office of the President)에서 발간한 <빅데이터 : 알고리즘 시스템, 기회와 시민권에 관한 보고서(Big Data : A Report on Algorithmic Systems, Opportunity, and Civil Right)>에서는 회계감사제도와 마찬가지로 알고리즘 역시 감사(Audit)제도를 마련하기 위해서 학술 연구 및 산업에서의 개발을 장려해야 한다고 주장했다(White House Executive Office of the President, 2016.5.). 한편 액센추어(Accenture), KPMG 등의 IT 컨설팅 업체들도 미국 연방정부에게 인공지능의 사회적 책임과 신뢰를 위해 규제를 강화할 것을 촉구하고 있다. 2019년 3월 액센추어는 책임 있고 설명 가능한 인공지능(Responsible and Explainable AI)을 위한 정부의 규제체계를 제안했다(Accenture, 2018; Wall Street Journal, 2019.3.20.).

인공지능 감사를 수행하기 위해서는 우선 인공지능이 미치는 영향을 객관적이고 정확하게 측정하고 평가할 수 있는 체계를 마련하고 이를 주주 및 이해관계자에게 보고하는 프로세스가 마련되어야 한다. 마이크로소프트는 인공지능이 소비자를 포함한 이해관계자(Stakeholder)의 인권에 미치는 영향을 측정하는 방법론(Human Rights Impact Assessment, HRIA)을 마련하고 이에 기반 하여 이해관계자에게 HRIA 성과를 공개하는 보고서(Human Rights Annual Report)를 2018년부터 발행하고 있다(Microsoft, 2018). 아직 인공지능 알고리즘 감사를 수행하는 기업은 많지 않지만 액센추어, 딜로이트(Deloitte) 등은 알고리즘 감사 컨설팅 작업을 수행하고 있다(Harvard Business Review, 2018.11.28.). 또한 대량수학 살상무기(Weapons of

Math Destruction)의 저자인 캐시 오닐(Cathy O'Neil)은 ORANA(O'Neil Risk Consulting and Algorithmic Auditing)라는 알고리즘 감사 전문기업을 설립하고 지멘스(Siemens) 등의 다국적 기업을 대상으로 알고리즘의 내부 감사 시스템을 개발하는데 도움을 주고 있다(Wired, 2018.5.9.).

또한 인공지능의 편향성과 공정성을 제대로 감시하기 위해서는 계량적·기술적 분석 툴이 필요하다. 주요 테크 기업들은 알고리즘의 편향성, 공정성 등을 측정하고 알고리즘의 어떤 부분이 문제가 되는지를 추적·적발하는 시스템을 개발 중에 있다. IBM은 알고리즘의 의사결정이 편향성이 있는지를 실시간 파악할 수 있는 기술적 툴킷인 'Fairness 360'을 개발하고 있다(BBC, 2018.9.19.). 구글은 인공지능을 사회적으로 긍정적으로 활용하는 'AI for Social Good' 프로젝트의 일환으로 머신러닝 기반의 편향성 측정 도구인 'What-If' Tool을 개발하고 있다. 페이스북의 경우 앞서 언급했다시피 과학자 이자벨 클로우만(Isabel Kloumann)이 이끄는 팀에서는 인공지능 훈련데이터가 공정한지를 판단하는 소프트웨어(Fairness Flow)를 개발 중에 있다(Forbes, 2018.5.3.). 마이크로소프트도 알고리즘 편향성을 적발하는 툴을 개발 중인 것으로 알려져 있다(MIT Technology Review, 2018.5.25.).

5. 인공지능 윤리교육 실시

기업 내부에서의 교육 자료 및 훈련 과정 개발도 활발히 이뤄지고 있다. 구글은 기계학습의 공정성 확보를 위한 웹사이트(ml-fairness.com)를 개설하여 콘텐츠를 제공하고 있다(Computerworld UK, 2018.11.9.). 또한 구글의 머신러닝 교육프로그램(Machine Learning Crash Course, MLCC) 내에 60분 분량의 인공지능 공정성에 관한 자기학습 과정을 신설했으며(Google Blog, 2018.10.18.), 클라우드 사업부에서는 기술 윤리학자인 셰넌 발러(Shannon Vallor)를 고용하여 자체적으로 인공지능 우수사례에 대한 내부 교육 프로그램을 마련하여 운영하고 있다(Computerworld UK, 2018.11.9.).

마이크로소프트는 인공지능 개발 역량을 향상시키고자 하는 사내 개발자를 대상으로 온라인 교육 프로그램(Massive Online Open Coursework, MOOC)인 마이크로소프트 인공지능 전문가 과정(Microsoft Professional Program in AI)을 제공하고

있다(Microsoft academy 홈페이지). 총 9개의 기본 과정과 1개의 최종 과제로 구성되어 있는데 기본 과정 중에는 ‘데이터와 분석에서 윤리와 법(Ethics and Law in Data and Analytics)’이 포함되어 인공지능과 데이터를 활용함에 있어서 윤리적 책임을 고려하는 방안을 교육하고 있다. 2018년 4월부터 마이크로소프트는 이 교육 프로그램을 누구나 수강할 수 있도록 외부에 공개하였다.

6. 인공지능을 활용한 사회적 공익 프로젝트 운영

기업들은 인공지능 기술의 활용을 통해 전지구적인 난제를 해결하고 사회를 변화시킴으로써 인공지능의 사회적 책임을 수행하는 프로젝트도 운영하고 있다. 구글은 인공지능을 활용하여 인류가 직면한 도전 과제를 해결하고 인류의 삶을 의미 있게 개선하기 위한 ‘AI for Social Good’ 사업을 수행 중이다(Google AI For Social Good 홈페이지). ‘AI for Social Good’ 사업은 세계 각국의 다수의 시민 단체로부터 인공지능을 활용하여 사회복지를 개선하는 아이디어를 수집하고 채택된 사업에 자금을 투입하여 사업을 공동으로 수행하는 방식이다(조원영, 2019.4.).

〈표 3-4〉 구글의 ‘AI for Social Good’ 수행 과제

과제명	과제내용	진행현황
Quickly and Accurately Forecasting Floods	홍수 발생을 사전에 감지하고 구글 지도에 표시하여 인근 주민들에게 알리는 경고 시스템을 구축	인도에 적용
Predicting Risk for Cardiac Events	망막 이미지를 사용하여 심장마비 같은 심혈관 위험 요인을 예측하는 기술을 개발	연구 진행 중
Analyzing ML Models with the What-If Tool	공정성 등 인공지능 모델의 기준을 사전에 설정하고 이를 충족했는지 시각화 도구로 결과를 제공하는 개발자 도구 개발	What-If Tool 1.0 버전 공개
Mapping Global Fishing Activity	글로벌 조업 활동을 실시간으로 구글 지도에 보여주는 플랫폼을 개발하여 불법 조업 적발 및 해양 서식지 보호	아라비아해에서 심야 조업하는 어선 감시
Fighting California Wildfires	구글 텐서플로우(Tensor Flow)와 센서를 이용하여 풍속, 풍향, 습도, 온도 등 산불에 영향을 미치는 요소를 측정, 산불을 예방	센서(Smart Wildfire Sensor) 개발 중
Helping Farmers Identify Diseased Plants	아프리카에서 5억 명 이상에게 식량으로 쓰이는 카사바(cassava)가 취약한 질병과 해충을 인공지능으로 진단	탄자니아에 진단용 앱 보급

자료: 조원영(2019.4.), p.29

인텔은 인공지능을 활용하여 식량 문제, 동식물 멸종 등의 전지구적 문제와 아동 착취, 온라인상 괴롭힘 등의 사회 문제, 암 연구와 유전체 연구 등 인류의 건강한 삶 추구하고 같이 사회에 긍정적인 영향을 미치는 사업을 선정하여 수행하고 있다(Intel AI For Social Good 홈페이지).

<표 3-5> 인텔의 ‘AI for Social Good’ 수행 과제

분야	원칙	내용	
전지구적 문제 해결	Fighting Illegal Poaching	멸종위기에 처한 야생 동물을 보호하기 위한 인공지능 카메라 개발	인공지능 칩(모비디우스) 개발('18.6.)
	Iceberg Classifier Challenge	선박과 빙산을 분류하여 선박이 안전한 해양운항을 가능케 지원하는 경진대회 지원	경진대회 종료('18.1.)
	Autonomous Greenhouse Challenge	온실에서의 작물 생산 자동화를 통한 스마트 농업 기술 축적	심층강화학습을 오이경작에 적용
	Noninvasive Arctic Research	드론 등을 이용하여 안전하고 자연친화적인 북극곰 연구	진행 중
	Great Wall of China Restoration	드론 등을 이용하여 만리장성의 3D 모델 및 벽의 손상을 인공지능으로 확인하고 수리자금을 내려 복원 및 보호	진행 중
사회 문제 해결	Hack Harassment	온라인에서 발생하는 욕설, 괴롭힘, 차별, 인권 침해 등의 문제를 해결	종료
	Fight Online Child Exploitation	이미지 인식 기술 등을 활용하여 온라인 아동 성매매를 적발 및 근절	비영리단체 쏜(Thorn)과 협력
	Assisting the World Bank	세계은행의 빈곤 퇴치 사업을 지원하기 위해 지역별 이미지를 분석하여 빈곤 수준을 파악	세계은행 개발 데이터 그룹과 시범 연구 종료('16.8.)
	Detecting Water Contamination	인공지능 기술을 이용하여 빈곤국가에 만연한 물 속의 해로운 박테리아를 탐지	시제품 개발단계
건강한 삶 추구	Cervical Cancer Screening	이미지 인식기술을 이용하여 자궁경부암 유형을 식별하고 효과가 없는 치료를 막는 것을 지원	진단 알고리즘 개발 경진대회 종료('17.8.)
	Genomics Research	딥러닝 기술을 이용하여 단백질 서열 태그에 대한 새로운 통찰력을 얻는 연구 수행	SGI와 공동연구 중
	Brain Imaging Analysis	뇌 활동을 관찰하여 인간의 사고를 해독하고 정신 질환에 대한 치료법을 향상	프린스턴대와 공동 연구 중
	Classifying Osteoarthritis	의사가 골관절염을 잘 해독할 수 있도록 인공지능 기반의 MRI 분류 시스템을 구축	개발 완료

자료: 조원영(2019.4). p.30

7. 협회 구성 또는 외부 시민 단체와 공동 대응

사회 문제 해결에 전문성을 보유한 외부의 시민단체와 공동으로 문제를 해결하는 경우도 많다. 미얀마에서 버마족의 로HING야족간에 갈등을 야기하고 유혈사태를 방관했다는 비난을 받은 페이스북은 버마어를 해독할 수 있는 직원을 채용하고 미얀마의 시민단체와 손을 잡았다(Data and Society Research Institute, 2018, p.19). 또한 페이스북은 뮌헨 공대와 함께 인공지능 윤리 연구소(Institute for Artificial Intelligence)를 설립했다. 페이스북에서 5년간 750만 달러의 초기 기금을 지원받아 설립된 이 연구소는 신기술에 대한 윤리적 연구 분야를 발전시키는 데 도움이 되며 인공지능의 사용에 영향을 미치는 근본적인 문제를 탐구할 예정이다(Facebook Newsroom, 2019.1.20.).

2015년 10월 테슬라의 CEO인 엘론 머스크(Elon Musk), Y 컴비네이터의 의장인 샘 알트만(Sam Altman), 링크드인의 설립자 레이드 호프먼, 페이스북의 공동 창업자 피터 틸(Peter Thiel) 등이 약 10억 달러의 지원을 통해 설립한 ‘오픈AI(OpenAI)’는 인공지능 연구 결과와 특허를 대중에게 공개함으로써 자유로운 협업을 통해 인류에게 이익을 주는 것을 목표로 수립되었다. 현재 안전한 범용 인공지능 기술을 개발하고 구현하기 위한 방법을 찾는 다수의 연구를 수행하는 것으로 알려져 있다.

지난 2016년 9월 28일에는 아마존, 페이스북, 구글, 딥마인드, IBM이 모여 ‘인공지능에 대한 파트너십(Partnership on AI)’을 설립했다. 홈페이지에는 학계, 연구자, 시민 단체, AI 기술을 구축하고 이용하는 회사 및 인공지능의 영향을 더 잘 이해하기 위해 노력하는 다른 단체 등이 참여하는 다자간 이해관계자 조직으로서, 인공지능 기술에 대한 모범 사례를 연구하고 대중의 인공지능에 대한 이해를 증진하며 인공지능 및 사람과 사회에 미치는 영향에 대한 토론과 참여를 위한 개방된 플랫폼 역할을 하기 위해 설립되었다고 명시하였다. 2017년 1월에 애플이 참여하였고, 현재는 50개 이상의 조직이 참여하고 있다(Partnership on AI 홈페이지).

애플, 마이크로소프트, IBM, 인텔 등 40여개의 정보기술 기업이 모여 만든 산업단체인 정보기술산업협회(Information Technology Industry Council)에서도 인공지능 윤리 관련 정책에 대한 로비 및 영향력을 행사하고 있다. 정보기술산업협회는

회원의 사업에 영향을 미치는 정책 문제에 대한 업계의 공감대를 형성하고 이를 정책에 반영하는 이익 집단이다.⁹⁾ 2017년 10월 24일 이 단체는 ‘인공지능 정책 원칙(AI Policy Principles)’을 발표했는데, 이 보고서에는 기업은 인공지능의 개발과 활용에 책임감을 갖고, △안전하고 통제 가능한 인공지능 개발, △대표성 있는 데이터 활용, △해석 가능한 시스템, △인공지능의 자율성에 대한 책임 등을 천명하였다(Information Technology Industry Council, 2017.10.24.). 또한 이 보고서에서는 정부에 인공지능 생태계의 조성을 위해 투자하고, 유연한 규제 환경을 조성하며, 사이버 보안, 개인정보보호, 국제 표준 및 우수 사례 발굴 등에 힘써달라는 주문을 포함시켰다. 또한 2019년 4월에 발표될 유럽연합의 인공지능 윤리 가이드라인에 대해서도 환영한다는 입장을 밝히기도 했다(Information Technology Industry Council, 2019.4.9.).

제2절 학계/연구계 대응 동향

1. 인공지능 윤리지침, 표준규정 및 가이드라인 제시

미래 범용 인공지능의 출현에 대비해 기업 외에도 학계를 중심으로 비영리단체들 역시 활발히 움직임을 보이고 있다. 영국 옥스퍼드 대학교 미래의 삶 연구소(Future of Life Institute)는 현재 제한된 용도로만 사용되는 인공지능이 향후 우리 생활 전반에 관여하게 될 경우 보다 높은 수준의 안전성 확보가 중요하다는 것을 강조한다(4차 산업혁명위원회, 2018.10.). 특히 기술 발전에 따라 인공지능이 인간의 능력을 넘어서는 ‘범용적 인공지능’(general AI)으로 진화되면서 발생될 수 있는 위험에 대비해 나가야 함을 주장한다. 미래 삶 연구소는 인공지능으로 인한 일자리의 변화, 범용 인공지능의 출현에 따른 윤리적 논의 등 인공지능의 사회적 파급효과에 대한 연구를 진행 중이며, 인공지능이 가져올 수 있는 가능성 높은 위험 시나리오를 두 가지로 제시

9) Wikipedia, Information Technology Industry Council 참고 (https://en.wikipedia.org/wiki/Information_Technology_Industry_Council, 2020.1.11. 접속)

하고 있다. 첫 번째는 인공지능이 군사용 무기를 운용하도록 설계된 경우처럼 인간에게 치명적 작업을 하도록 프로그래밍 된 경우다. 인공지능 기술이 발전하면서 자율성 수준이 높아지면 인간의 통제 수준을 넘어 전쟁 등 위험 발생 가능성도 함께 높아질 수 있는 것이다. 두 번째는 인공지능이 추구하는 목표가 인간의 가치기준과 일치하지 않는 경우다. 인공지능이 자신의 시스템에 입력된 목표 추구를 위해 인간 사회의 가치와 규범을 위반할 가능성이 있다면 해당 인공지능은 목적 달성을 위해 파괴적 방법을 활용할 가능성도 동시에 존재한다. 미래의 삶 연구소는 2017년 미국 캘리포니아 주 아실로마에서 합의된 인공지능 원칙(i.e., Asilomar AI Principles)을 발표하며 향후 인공지능을 우리의 삶을 개선하는데 활용하기 위해 고려해야 할 윤리 원칙들을 제시하였다(Future of Life Institute 홈페이지). 전체 23가지 원칙 가운데 최근 산업계에서 활발히 고려되고 있는 인공지능 윤리 이슈는 다음과 같다.

〈표 3-6〉 아실로마 23대 인공지능 원칙

분야	원칙	내용
연구 문제	연구목표	인공지능 연구의 목표는 방향성이 없는 지능이 아니라 유익한 지능(beneficial AI)을 개발하는 것이다.
	연구비 지원	인공지능에 대한 투자는 컴퓨터과학, 법과 윤리, 경제, 사회적 난제를 포함해 유익한 활동에 관련된 기금이 포함되어야 한다.
	과학정책 연계	인공지능 연구자와 정책 입안자들 간에 건강하고 건설적인 교류가 있어야 한다.
	연구문화	인공지능 연구자와 개발자는 협력과 상호 신뢰를 기반으로 투명한 문화가 형성되어야 한다.
	경쟁회피	인공지능 시스템 개발 조직들은 안전기준에 미달하는 것을 방지하기 위해 적극 협력해야 한다.
윤리와 가치	안전	인공지능 시스템은 운영 과정에서 안전성과 보안성이 보장되어야 한다.
	실패의 투명성	인공지능 시스템이 해를 입히는 경우 그 원인을 확인할 수 있어야 한다.
	사법적 투명성	자동화된 시스템의 사법적 결정 참여에 대해 인간으로 구성된 감사 기관의 만족스러운 설명이 제공되어야 한다.
	책임	진보된 인공지능 시스템의 설계자 및 개발자들은 인공지능 시스템의 사용, 오용, 활용과 관련한 도덕적 함의의 이해관계자이며, 이를 만들어나갈 책임과 기회가 있다.
	가치연계	고도로 자율적인 인공지능 시스템은 운영 과정 상에서 그 목표와 행위가 인간의 가치와 일치되도록 설계되어야 한다.
	인간의 가치	인공지능 시스템은 인간의 존엄성, 권리, 자유 및 문화 다양성과 양립될 수 있도록 설계되고 운영되어야 한다.

분야	원칙	내용
윤리와 가치	개인 프라이버시	인공지능 시스템이 데이터를 분석하고 활용할 수 있는 권한을 부여 받으면, 인간들 역시 자신이 생성한 데이터를 접근, 관리 및 제어 할 수 있는 권리가 있어야 한다.
	자유와 프라이버시	인공지능을 개인 데이터에 활용할 시 사람들의 실질적인 또는 지각된 자유가 부당하게 침해되어서는 안 된다.
	공유된 이익	인공지능은 최대한 많은 사람들에게 이익을 주고 권한을 위임해야 한다.
	공유된 번영	인공지능으로 인해 발생한 경제적 번영은 모든 인류에게 이익이 되도록 널리 공유되어야 한다.
	인간의 제어	인간은 인간이 선택한 목표를 달성하기 위해 인공지능 시스템에 의사결정을 위임할지 여부와 그 방식을 선택해야 한다.
	비(非)파괴	고도화된 인공지능 시스템에 대한 통제력은 사회와 시민들이 만들어온 절차들을 파괴하지 않고 존중하고 개선시켜야 한다.
	인공지능 무기경쟁	자동화된 무기와 관련한 군비 경쟁은 피해야 한다.
장기적 문제	역량에 대한 주의	미래의 인공지능의 능력에 대한 합의가 이루어지지 않았기 때문에 한계치에 대한 강한 가정은 피해야 한다.
	중요성	진보된 인공지능은 지구상의 생명체 역사에 중대한 변화를 가져올 수 있기 때문에 적절한 방법과 자원을 통해 관리되고 계획되어야 한다.
	위험	인공지능 시스템으로 인해 발생할 수 있는 치명적이고 실존적인 위험에 대비하는 계획 수립 및 완화 노력이 필요하다.
	재귀적 자체 개선	스스로 개선하고 복제할 수 있도록 설계되어 질적/양적으로 빠르게 확장될 수 있는 인공지능 시스템은 엄격한 안전 및 제어 조치를 받아야 한다.
	공공선	초지능은 한 국가나 조직이 아니라 광범위하게 공유된 윤리적 이념에 따라 모든 인류의 이익을 위해 개발되어야 한다.

자료: 최병삼·홍성민 외(2018), p.42 재인용

아실로마 원칙 제정의 배경에는 ‘인공지능을 인류에 이롭게 활용한다’라는 대전제가 깔려있다. 아실로마 원칙을 제안한 미래의 삶 연구소는 MIT의 물리학과 막스 테그마크 교수가 주도적으로 설립하였는데, 그는 자신의 저서인 “라이프 3.0”에서 범용 인공지능의 출현으로 인한 다양한 시나리오를 제시하였고 인공지능 연구개발에 있어 방향성이 매우 중요하다고 밝힌바가 있다. 또한 미래의 삶 연구소는 범용 인공지능에 대한 논의를 이어가며 2019년 1월에는 “Beneficial AGI 2019” 학회를 주관하기도 하였다(Future of Life Institute 홈페이지).

인공지능을 인류에 이롭게 활용해야 한다는 대전제 아래 최고의 연구자들이 인공지능 기술을 공개·공유하는 OpenAI도 비영리단체의 대표적 예이다. 테슬라 창업자인 엘론 머스크와 창업 투자회사인 와이 컴비네이터의 샘 알트만이 출자하여 만든 비영

리단체 OpenAI는 아실로마 원칙의 대전제를 실현하고 있는 연구기관이다. 세계 최정상급 인공지능 연구자들이 참여하고 있는 OpenAI는 먼저 최신 인공지능을 공유·공개하여 누구나 인공지능을 이롭게 활용하는 생태계를 만들고 있다. 특히 기업이나 국가가 최신 인공지능 기술을 독점하여 악의적으로 활용하는 것을 방지하는데 큰 역할을 할 것이라 전망된다. 물론 많은 정보가 공개되어 악의적인 활용이 더 활발해 질 수도 있다는 우려도 있으나, OpenAI가 추진하고 있는 연구과제는 대부분 인공지능의 신뢰성과 안전성을 확보하기 위함에 있기 때문에 현 시점에서는 긍정적인 역할이 큰 것으로 판단된다.

2012년 설립된 영국 캠브리지대학교의 실존적 위기센터(CSER)에서도 최근 다양한 분야의 전문가들과 함께 인공지능 오용이 가져올 위험성에 대한 연구를 진행 중이다(CSER 홈페이지). 실존적 위기센터와 세계 유수의 7개 연구기관이 공동으로 작성한 ‘인공지능의 해악적 사용: 예측, 예방, 완화’ 보고서는 인공지능의 고의적 악용이 가져올 보안 위협에 주목하고 인공지능 위협의 특성 및 변화 양상, 그리고 이를 예방·완화하기 위한 방안들을 제시하고 있다(Brundage et al. 2018). 이 보고서에서는 인공지능의 악의적인 활용으로 인해 발생할 수 있는 미래를 시나리오 기법으로 제시하여 인공지능의 잠재적인 위험성에 대해 경고하고 있다. 또한 인공지능의 악의적인 활용에 대한 대비책을 권고하고, 특히 미래 인공지능 기술에 주요한 영향력을 미치는 정책입안자와 연구 개발자의 인식 제고와 긴밀한 협업을 강조한다.

본 보고서에 따르면 인공지능 기술의 발전은 공격 행위자, 공격 속도, 공격 대상을 확대시키고 있으며 인공지능의 익명성과 환경적 제약의 소멸로 인해 무분별한 공격 위험성을 증대시킬 수 있다. 또한 인공지능 기반 시스템의 취약점을 노린 공격(ex. 알고리즘 오류를 유발시켜 교통 시스템을 마비시킨다거나 대량의 허위사실을 유포하는 등) 가능성은 높아지고 있지만 온라인이라는 익명의 공간에서 행위자를 찾아 책임을 물을 수 있는 작업은 반대로 점점 더 어려워지고 있다. 보고서는 또한 인공지능에 의한 보안 위협 시나리오를 크게 3가지로 구분하고 있다(한국정보화진흥원, 2018.8.3.). 디지털 보안(digital security)은 인공지능을 구현하는 알고리즘 코드의 취약점을 파악한 후 시스템 블랙박스 모델 추출, 선택적 공격대상을 추출 후 우선순위

지정 등을 통해 인공지능 시스템의 보안을 위협한다. 또한 인공지능 기술이 적용된 물리적 대상에 대한 공격 수단이 이를 방어할 수 있는 기술 발전의 속도보다 빠르게 진화하고 있으므로 이러한 물리적 보안(physical security)에 대한 정책적 개입의 중요성을 강조한다. 마지막으로 정치적 보안(political security)을 위해 소셜 미디어에서의 봇(bot)을 이용한 선동 행위(ex. 가짜 뉴스의 대량 유포·게시 또는 특정 정치인의 영상·발언 내용을 조작) 가능성에 대한 인공지능 기술의 위험성과 이에 대한 경각심을 주문한다. 보고서는 인공지능이 가져올 수 있는 이러한 오용 위험성에 대비하기 위해 다양한 이해관계자 간의 활발한 논의가 필요함을 강조하며, 인공지능의 위협에 대응하기 위해 다음과 같은 권고안들을 제안하고 있다.

<표 3-7> 캠프리지대 실존적 위기센터(CSER)의 인공지능 위협 대비 권고안

권고안	주요 내용
사이버 보안 공동체에서 배우기	- 인공지능을 이용한 공격과 사이버 보안의 교차점에 위치한 문제를 해결하려면 적색팀(red team)을 구성하여 실제 어떤 공격을 받을 수 있는지 검증을 진행 - 인공지능의 취약점이 발견되면 책임감 있게 이를 공개할 필요
개방형 모델에 대한 조사	- 인공지능과 머신러닝 기술의 이중적 용도가 분명해졌으므로 인공지능 알고리즘의 개방성(openness)이 과연 적합한지, 어떤 방법으로 공개하는 편이 적절한지에 대한 규범과 제도를 재고할 필요
책임 문화의 제고	- 인공지능 연구개발 담당자들에게 인공지능이 악용될 수 있는 위험을 주의시킬 필요 - 윤리적·사회적 책임감을 일깨우는 교육의 중요성이 커지고 있음
기술적·정책적 해결책의 모색	- 인공지능 악용을 예방하고 완화하기 위한 제도적, 정책적 방안으로는 개인정보 보호를 위한 기술적 조치, 공공 안전을 위해 방어적 목적으로 인공지능 사용하기, 악의적 공격을 규제하는 법제도 마련 등을 고려
규제를 통한 대응	- 인공지능에 의한 공격은 그 피해가 국경을 넘어 확산될 수 있으므로 국제적으로 통용되는 범국가적 법규정을 마련할 필요

자료: 4차산업혁명위원회(2018.10.), pp.57-58

미국에서는 인공지능 연구 중에 발생할 수 있는 위험을 방지하기 위해 구체적이고 명확한 표준 규정을 갖추려는 움직임이 일어나고 있다. 한 예로 미국의 윤리학자 제이크 멧칼프를 포함한 연구기관의 연구원들은 ‘퍼베이드(Pervade)’라는 단체를 공동으

로 조직하였다(Bloter, 2017.9.20.). 퍼베이드는 향후 4년간 대학과 기업 모두가 사용할 수 있는 빅데이터 연구를 위한 명확한 윤리적 프로세스를 구성하는데 미국 국립과학재단으로부터 300만 달러를 지원받았다. 비슷한 맥락에서 벨기에 브뤼셀의 싱크탱크 ‘리스본 카운슬(Lisbon Council)’은 알고리즘에 기반된 차별을 종식시키고 더 똑똑하고 좋은 세상을 만들기 위한 인공지능 시민윤리 내용을 담은 ‘AI윤리 보고서’를 발간함으로써 정부, 시민, 개발자의 행위 원칙을 선도적으로 제안하고자 하였다(Hofheinz, 2018).

영국표준연구소(BSI: British Standards Institute) 역시 로봇의 윤리 문제를 다룬 공식 가이드라인을 발표했다(로봇신문, 2016.9.20.). 웨스트 잉글랜드 대학의 로봇과 학자 알런 윈필드(Alan Winfield)는 영국표준연구소가 발표한 가이드라인이 인공지능과 로봇 개발에 윤리적인 가치를 반영하기 위한 첫걸음이라고 평가했다. BSI의 가이드라인은 먼저 포괄적인 로봇 윤리원칙을 제시하고 있다. “로봇은 인명 살상을 1차적인 목표로 개발되어서는 안된다”고 명시했다. 또한 “로봇이 아니라 인간이 책임을 져야한다”고 명시하면서 로봇의 행동이 일차적으로 인간의 책임임을 명확히 했다.

영국 표준연구소의 가이드라인 역시 로봇 개발자들이 투명성을 지향해야 함을 제안하고 있지만 로봇 과학자들이 실제로 이를 준수하는게 매우 까다롭다고 지적하고 있다. 앨런 윈필드 교수가 “AI, 특히 딥러닝의 경우 의사결정을 하게 된 이유를 아는게 불가능하다”고 말한 것처럼 딥러닝은 수백만번의 학습을 통해 특정 작업을 하는 방법을 학습하지만 인간은 이를 예측하기 힘들고 이해하기도 어렵다. 가이드라인은 또한 로봇이 문화적 다양성 등을 이해하지 못해 특정 집단을 옹호하는 성차별주의나 인종차별주의자가 될 가능성도 있다고 경고했다. 앨런 윈필드 교수는 “딥러닝 시스템은 그야말로 방대한 양의 데이터를 활용해 학습을 하지만 문제는 데이터 자체가 왜곡되어 있다”고 비판했다. 미래에 인공지능 기술이 의료 분야에 적극 활용될 수는 있으나 데이터 문제로 소수민족이나 여자를 진단하는 데는 어려움을 겪을 수 있고 지적하였다. 비슷한 예로 기존에 얼굴인식 시스템이나 음성인식 소프트웨어가 흑인이나 여성을 인식에 있어서 정확도가 떨어진다는 사실은 이미 알려진 바 있다. 이러한 점을 근거로 노엘 샤키 교수는 “로봇에 일종의 블랙박스 필요하다”고 주장한다. 가이드라

인은 또한 “로봇에 대한 과잉의존”도 경계하고 있다. 자동화 시스템에 장시간 익숙해 지다 보면 로봇에대한 의존성이 높아져서 인간이 게을러질 수 있다는 것이다. 로봇에 대한 과다 의존이 사람을 어리석게 만들 수 있다고 우려했다.

일본은 인공지능학회를 중심으로 2017년 2월 ‘인공지능 윤리지침’을 제정함으로써 사회 전반적인 큰 틀에서 인공지능에 대한 합의를 이루고 향후 더 깊은 논의를 위한 기틀을 마련하였다(일본 인공지능학회 윤리연구회 홈페이지). 해당 윤리지침은 먼저 인공지능 연구를 ‘인간과 같은 지성을 가지고 자율적으로 학습하고 행동하는 인공지능 실현을 목표로 하는 것’으로 정의한다(일본 인공지능학회 윤리지침). 인공지능은 산업, 의료, 교육, 문화 등 다양한 영역에 침투하면서 인간의 삶을 풍요롭게 할 것으로 기대되고 있으나 동시에 기술에 대한 악용 또는 남용으로 사회 공동의 이익을 침해할 우려도 있다. 이에 일본의 인공지능 윤리지침은 인공지능을 연구, 설계, 개발, 운영, 교육하는 연구자들의 사회에 대한 열린 자세와 양심과 양식에 따른 윤리적 행동을 강조하고 있다. 인공지능 윤리지침은 학회 회원의 윤리적인 가치판단의 기초가 되는 가이드라인을 다음과 같이 제공하고 있다.

〈표 3-8〉 일본 인공지능 윤리지침 주요내용

지침	주요 내용
인류에의 공헌	- 인류의 평화, 안전, 복지, 공공의 이익에 공헌하고 기초적 인권과 존엄을 지키고 문화의 다양성을 존중함 - 인공지능을 설계, 개발, 운영할 때 전문가로서 인류의 안전에의 위협을 배제하려고 노력
법규제의 준수	- 전문가로서 연구개발에 관련된 법규제, 지적재산, 다른 사람과의 계약이나 합의를 존중 - 다른 사람과의 정보나 재산을 침해하거나 손실시키는 위해를 가해서는 안되며, 직접적·간접적으로 다른 사람에게 위해를 가하려는 의도를 가진 인공지능을 이용하지 않음
다른 사람의 프라이버시 존중	- 인공지능의 이용 및 개발에서 다른 사람의 프라이버시를 존중 - 관련 규제에 따라 개인정보를 적정하게 취급할 의무를 가짐
공정성	- 인공지능의 개발과 이용에서 항상 공정성을 유지 - 인공지능이 인간사회에 불공평이나 격차를 가져올 가능성이 있다는 것을 인식하고, 개발에 있어서 차별하지 않도록 유의 - 인류가 공평, 평등하게 인공지능을 이용할 수 있도록 노력

지침	주요 내용
안전성	- 전문가로서 인공지능의 안전성 및 그 제어에 있어서 책임을 인식 - 인공지능의 개발과 이용에서 항상 안전성과 제어가능성, 필요로 하는 기밀성에 대하여 유의 - 인공지능을 이용하는 사람에게 적절하게 정보제공과 주의환기를 하도록 노력
성실한 행동	- 인공지능이 사회에 미칠 영향이 크다는 점을 인식하고 사회에 성실하게 신뢰받도록 행동 - 전문가로서 허위나 불명료한 주장을 삼가고, 연구개발을 한 인공지능의 기술적 한계나 문제점을 과학적으로 진솔하게 설명
사회에 대한 책임	- 연구개발을 한 인공지능이 미칠 결과를 검증하고, 잠재적인 위험성에 대하여 사회에 경고할 의무 - 의도에 반하여 연구개발이 다른 사람에게 위해를 끼칠 용도로 이용될 가능성이 있다는 점을 인식하고 악용되는 것을 방지하는 조치를 강구하도록 노력할 필요 - 인공지능이 악용되는 것을 발견한 사람이나 고발한 사람이 불이익을 받지 않도록 노력
사회와의 대화와 자기계발	- 사회에 다양한 목소리가 있다는 것을 이해하고, 사회로부터 진솔하게 배우고, 이해에 깊이를 더하고, 사회와 부단한 대화를 통하여 전문가로서 인간사회의 평화와 행복에 공헌
인공지능에 대한 윤리준수 요청	- 인공지능이 사회의 구성원 또는 그에 준하는 것이 되기 위해서는 위에서 정한 인공지능 학회 회원과 동등하게 윤리지침을 준수하여야 함

자료: 일본 인공지능학회(2017.2.28.)을 바탕으로 재구성

일본 인공지능학회 윤리지침의 특징은 연구자가 갖춰야 할 윤리성을 인공지능도 준수해야 한다고 강조한 것이다. 이미 기업 경영이나 의사의 치료 행위 등을 보조하는 AI가 등장한 상황이고 추후 인공지능이 만든 인공지능도 등장할 것으로 예상되면서, 법률상 책임 주체로서의 '인격'을 인공지능에게도 부여해야 한다는 의견이 적극적으로 수용되었다(연합뉴스, 2017.3.1.).

2. 인공지능 윤리 프로젝트 운영

인공지능 활용에 앞서 윤리적 지침과 규제가 필요하다는 목소리가 높아지고 있는 가운데 국내외 학계를 중심으로 관련된 논의가 활발해지고 있다. 미국 하버드대의 버크만 센터(Berkman Klein Center)와 MIT대 미디어랩(Media Lab)은 의사 결정자에게 지침을 제공하는 근거 중심의 인공지능 윤리 및 거버넌스 연구 프로젝트를 시작하였다(4차산업혁명위원회, 2018.10). 해당 프로젝트의 목표는 연구자들의 네트워크

구축을 기반으로 산업계, 학계, 시민사회 및 정부와의 관계를 강화해 나감으로써 공공 재로서의 인공지능 활용을 위한 윤리와 거버넌스를 확립해 나가는 것이다. 특히 하버드 대학교와 MIT가 공동으로 진행 중인 인공지능 윤리와 거버넌스(Ethics and Governance of AI)는 크게 (1)자율성과 국가, (2)자율성 및 플랫폼, (3)대학의 역할 세 가지 영역에 초점을 두고 있다. 자율성과 국가는 인공지능 기술의 소비자이자 규제자인 정부의 역할을 강조하고 인공지능이 현재 어떻게 인간의 자율성과 적절한 절차 및 정의에 대한 생각을 바꾸고 있는지에 주목한다. 자율성 및 플랫폼은 인공지능이 소셜 미디어 활동에 미칠 영향과 이로 인해 새롭게 구성될 민주적 규범에 주목한다. 마지막으로 대학의 역할 부문에서는 인공지능이 가져올 자동화 시대에 인간의 자율성 확보를 위해 대학이 할 수 있는 교육과 공동체 구축 방법을 연구한다. 이와 같은 인공지능 윤리 연구 방향을 바탕으로 하버드대와 MIT는 인공지능 윤리와 거버넌스를 구체화하기 위해 다음과 같은 세부 프로젝트를 추진 중이다.

<표 3-9> 인공지능 윤리와 거버넌스의 세부 프로젝트 내용

주요 프로젝트	주요 내용
AGTech 포럼	인공지능과 관련된 혁신과 합리적인 규제를 위해 변호사, 혁신 기업, 학계 등 다양한 이해 관계자들이 협력할 수 있는 기회를 제공
인공지능 알고리즘과 정의	법원이 인공지능 알고리즘을 사용했을 때 제기된 판결의 편향성 및 공정성 문제에 대한 연구를 진행
인공지능 자율 주행차	자율주행차 시대가 가져올 노동 시장의 변화와 인공지능 기술의 거버넌스, 편향성, 불평등 문제 해결 및 투명성 확보 방안에 대한 연구가 필요
인공지능 글로벌 거버넌스와 포괄성	전 세계적으로 인공지능 기술이 가져올 불평등이 예상되면서 정책 입안자가 인공지능 시스템 사용 시 마주하게 될 문제들을 연구
인공지능 미디어와 정보의 질	사용자가 보게 되는 내용을 인공지능 자율 시스템이 결정하게 될 가능성이 높아짐에 따라 인공지능이 인간의 판단, 의견 및 인식에 미치게 될 영향에 대한 연구 필요성 증대
인공지능 투명성과 설명 가능성	인공지능 시스템이 책임을 질 수 있게 하는 가능성이 생겨나면서 인간이 이해하고 행동할 수 있는 정보 시스템에 대한 연구가 필요

자료: Berkman Klein Center 홈페이지

프린스턴 대학의 경우 ‘인공지능과 윤리를 위한 대화(Princeton Dialogues on AI and Ethics)’ 프로젝트를 통해 인공지능 시스템 개발로 인해 야기될 수 있는 윤리적 문제에 대한 연구를 진행 중이다(Princeton University 홈페이지). 해당 프로젝트에서는 여러 가상 사례연구를 개발하고 인공지능 사용과 관련해 발생 가능한 상황에 대한 윤리적 문제를 공론화하는데 그 목적이 있다. 사례연구로는 “자동화된 건강관리 앱(Automated Healthcare App)”, “동적 사운드 식별 문제(Dynamic Sound Identification)”, “학교 문제 해결을 위한 개인정보의 사용(Optimizing Schools)”, “법 집행 챗봇(Law Enforcement Chatbos)”가 제시된 바 있다.

3. 인공지능 윤리교육 강화 및 방법론 연구

사회적 합의에 기반한 인공지능 윤리 지침 마련을 위해 미국 MIT의 이야드 라완(Iyad Rahwan) 교수는 ‘사회참여 기반의 알고리즘’을 개발하였다(이원태, 2016). ‘society-in-the-loop’라는 특성을 지닌 사회참여 기반 알고리즘은 ‘시민의 보편적 동의’가 반영되어 편견과 선입견을 최소화함으로써 알고리즘 기반의 의사결정을 새로운 사회계약의 형태로 통제하기 위해 개발되었다(이원태, 2016). 라완 교수는 시민들이 중요하게 생각하는 우선순위와 가치를 인공지능이 학습하여 사회가 지니고있는 정의와 도덕에 근거하여 판단하게 만들 수 있다고 주장하였다(NewsPeppermint, 2016.7.4.). 그는 시민들이 인공지능 시스템에 윤리적인 질문들을 반복적으로 던지고 그 시스템의 응답을 관찰함으로써 이를 검증할 수 있다고 주장한다. 일반 대중들이 인공지능을 받아들이게 만드는 방법으로 크게 두 가지가 언급되는데 첫 번째 방법은 인공지능을 이용해 인간 판사의 능력을 확장시키고 판단을 돕도록 만드는 인간참여(human-in-the-Loop) 방식이다. 이는 그러나 한편으로 인간이 자신의 잘못된 판단을 믿고 컴퓨터의 제안을 무시하게 되는 위험도 존재한다. 따라서 기계가 전체 시스템을 운영하도록 하고 인간은 사회적 효용을 높일 수 있는 중요한 정보만 제공하는 역할에 집중하는 방법을 찾는 것이 중요하다. 두 번째는 사회참여(society-in-the-Loop) 방식으로 대중이 인공지능을 직접 훈련시키도록 만드는 것이다. 인공지능이 개별 시민의 다양한 가치를 공평하게 대변한다고 신뢰할 수 있게 된다면 사람들의 지지를 받

는 대리인 자격의 역할을 수행할 수 있게 된다. 여기서 중요한 것은 일반인들이 해당 인공지능의 가치체계와 행동을 확인하고 검증할 수 있는 방법이 있어야 한다는 것이다. 한 예로 SNS 콘텐츠 추천 알고리즘 윤리와 관련해서 2018년 4월 미국 USC 안넨버그(Annenberg) 커뮤니케이션 연구소는 소셜 플랫폼 상의 콘텐츠 제공자와 이용자 사이의 중개 윤리(ethics of moderation)의 중요성 및 이를 기술적으로 구현하기 위한 방법론 및 정책 대안을 제시한 바 있다(Bengani, 2018.4.).

영국에서도 인공지능 기술의 투명성, 안전성, 신뢰성을 강조하는 인공지능 윤리 연구가 활발하다. 영국 바스 대학(Bath University)의 개발자 팀은 “설계자들은 로봇을 단순 관찰하는 것만으로는 로봇의 행동을 파악하는데 어려움을 겪고 있다”는 내용의 논문을 발표한 바 있다(로봇신문, 2017.8.7.). 이에 바스 대학의 연구원들은 ‘로봇 투명성(robot transparency)’의 개념을 윤리적 요구 사항으로 지지하고 있다. 로봇 투명성은 로봇의 사용자가 로봇의 기능과 의도를 쉽게 파악하는 것을 의미한다. 예를 들어 자율주행차가 보행자에게 상해를 입히는 상황이 발생했을 경우 자동차의 결정과정 대한 기록을 살펴보고 오류를 코드화할 수 있어야 한다는 것이다. 웨스트 잉글랜드 대학 브리스톨 로봇연구소(Bristol Robotics Laboratory)의 로봇 과학자 앨런 윈필드(Alan Winfield) 교수는 로봇과 자율 시스템에 ‘윤리적 블랙박스’ 설치를 통해 신뢰성과 책임성을 강화하는 방안을 제시한다(로봇신문, 2017.8.7.). 구체적으로 윤리적 블랙박스의 역할은 항공기의 비행 데이터 기록기처럼 문제 발생 이전에 행해진 결정과 조치의 순서를 밝히는 것이 될 수 있다(로봇신문, 2017.8.7.). 윈필드 교수는 인공지능 윤리 원칙으로 특히 투명성, 설명성 등을 강조한다(The Science Monitor, 2018.8.18.). 윈필드 교수는 “사고 조사에서 투명성은 조사 과정에서 왜 사고가 일어났는지 알아야 한다는 것이다. 항공기의 블랙박스처럼 이를 윤리적 블랙박스(ethical blackbox)라고 한다. 설명성(explainability)은 사용자 입장에서 필요한 부분이다. 왜 로봇이 특정한 행동, 발언을 했는지에 대한 이유를 물었을 때 자연어로 대답을 하는 것을 의미한다”고 설명한다.

인공지능을 전공하는 학생들에게 인공지능의 개발능력과 함께 윤리적인 역량도 강화하려는 대학의 움직임이 포착된다(New York Times, 2018.11.2.). 워싱턴대학교

(University of Washington)에서 이 대학 교수이자 구글 연구팀을 이끌고 있는 다니엘 그로스먼(Daniel Grossman) 교수가 ‘지능기계와 윤리(Intelligence Machinery, Identity and Ethics)’라는 과목을 개설했다. 그로스먼 교수는 “학생들이 향후 10~20년간 항상 맞닥뜨리는 윤리적 문제를 슬기롭게 해결하는 능력을 개발하는 것이 수업의 목표”라고 언급했다. 별도의 인공지능 학부 학위를 신설한 최초의 대학인 카네기멜론대의 경우 철학과 교수인 데이비드 댁크스(David Danks) 교수가 “인공지능, 사회, 그리고 인간(AI, Society and Humanity)”이라는 과목을 개설했다. 하버드대, MIT 등 인공지능 기술을 선도하는 대학에서도 모두 기존 CS(computer science) 과정에 인공지능 윤리과목을 포함하기로 결정했다(MIT AI Ethics Reading Group, 2018.11.7.). 개발자, 경영자 등을 대상으로 한 인공지능 윤리 교육도 강화되는 추세다. IEEE는 2018년 10월 ‘디자인에서의 인공지능과 윤리(AI and Ethics in Design)’라는 온라인 직업 교육 과정을 신설하였다(IEEE Educational Activities 홈페이지).

제3절 시사점

본 장에서는 인공지능의 안전성 및 윤리와 관련해 글로벌 기업 및 학계의 대응 동향을 살펴보았다. 글로벌 주요 기업과 학계 모두 인공지능 기술의 의도치 않은 오류로 인해 발생 가능한 위험에 대비하고 인공지능 알고리즘을 구현하는 개발자 및 사용자의 기술 악용을 방지하기 위해 자체적으로 또는 다른 파트너들과 협업하여 관련 이슈를 해결해 나가는 모습을 보이고 있다.

주요 기업들은 인공지능 윤리 전문가를 채용함으로써 개인정보보호 및 프라이버시와 같은 보안 문제는 물론 기술개발 과정에서 발생될 수 있는 사회적 문제를 적극적으로 해결하고자 하고 있다. 산업 전반에서 인공지능 윤리 전문가에 대한 수요가 늘고 있다는 사실은 인공지능 기술 개발 뿐만 아니라 기업의 사회적 책임에 대한 의식도 높아지고 있다는 것을 의미한다. 인공지능 개발자가 지켜야 할 원칙을 수립하고 관련

된 윤리 교육을 실시하는 것은 기업의 인공지능 윤리 문제에 대한 보다 적극적인 대응 방안으로 이해될 수 있다. 본문에서 언급된 구글의 7가지 인공지능 원칙이나 마이크로소프트가 강조한 6가지 개발원칙, IBM의 인공지능 가이드라인 등은 모두 개발자가 기술 중심적 사고에서 벗어나 인간 및 윤리가 중심이 되는 개발 방향을 강조한다. 이는 인공지능 관련 제품 및 서비스가 상용화되기 이전인 개발 단계에서부터 기술 윤리성을 고려해야 함을 의미한다. 인공지능의 사회적 영향을 연구하거나 인공지능에 의해 발생한 사회적 피해를 감시하는 전담부서를 설치하는 것도 기업이 스스로 인공지능 기술에 의한 사회적 부작용을 통제하고자 하는 노력의 일환이다. 추가로 인공지능 기업 스스로의 윤리성 제고에는 한계가 있을 수 있으므로 보다 공정하고 편향성 없는 인공지능 기술 개발을 이끌 외부 감사제도도 고려될 수 있으며, 인공지능 파트너쉽과 같은 협회 구성을 통한 공동대응도 하나의 방법이 될 수 있다. 결국 인공지능 윤리에 대한 글로벌 기업들의 대응 동향을 살펴보면 안전성과 같은 발생 시 큰 피해가 예상되는 부문은 관련 원칙을 수립함으로써 미연에 방지하고자 하는 모습을 보이고 있으며, 이후 기술이 활용되면서 이슈가 될 수 있는 부문은 윤리 전문가 채용, 전담부서 설치, 관련 교육 실시 등으로 대응하고 있다고 볼 수 있다.

기업 외에도 학계 등 비영리단체 역시 미래 인공지능 시대에 대비한 광범위한 지침 마련에 앞장서고 있다. 학계의 특성상 기술 활성화 보다는 보다 높은 수준의 포괄적 인공지능 구현을 통한 인간의 삶의 질 향상에 대한 논의가 주를 이루고 있는 모습이다. 예를 들어 아실로마 23대 인공지능 원칙 제정의 배경에는 ‘인공지능을 인류에 이롭게 활용한다’는 전제가 깔려있으며 이러한 이유로 인간의 가치와 공동이익, 공동번영 등을 강조한다. 다른 주요 인공지능 권고안이나 학회의 지침, 가이드라인 역시 인간이 인공지능 기술을 통해 풍요로운 삶을 누리기 위해서는 기술의 부작용을 예측하고 이를 해결해나가는 노력이 필요함을 강조하고 있다. 이렇듯 학계에서는 선입견과 편견을 최소화한 알고리즘 개발을 위해 개인의 다양한 가치가 존중되어야 함을 주장하고 있으며, 기술의 투명성, 안전성, 신뢰성 향상을 위해 설명 가능한 윤리적 블랙박스의 필요성을 강조하는 등 보다 근본적인 논의가 진행 중이다. 결국 학계에서도 인공지능 안전성과 윤리에 대한 논의는 동시에 진행되고 있다고 볼 수 있으며, 특히 알고

리즘에 대한 투명성 및 신뢰성 향상을 위한 사회학적 배경을 제안하는 등 기술 개발 단계에서의 안전성 확보를 위한 이론적 논의가 활발히 진행 중이다.

글로벌 기업과 학계 및 주요 비영리단체들은 인공지능 기술이 가져올 수 있는 위험과 부작용에 대비하고 인공지능에 대한 사회적 불신을 완화하기 위한 목적으로 각자의 인공지능 안전성과 윤리원칙을 제시하고 있다. 글로벌 기업들의 인공지능 기술에 대한 자율적 규제와 협업, 그리고 학계를 중심으로 한 윤리 방향에 대한 논의 등을 통해 인공지능 기술에 대한 사회적 공감대를 확산시키고 사용자들의 접근성을 높일 수 있을 것으로 기대된다.

| 제4장 | 주요국 정부 대응 동향

제1절 주요국 정부 대응 동향

최근 인공지능이 가져다주는 긍정적인 편익과 함께 반대급부로 비윤리적인 활용에 대한 문제가 제기되고 있다. 동시에 인공지능 기술이 내포하고 있는 불완전성과 데이터 부족 등으로 인한 데이터 편향성, 알고리즘 편향성 등의 문제로 인공지능 판단의 부정확성에 대한 우려도 확대되고 있다. 이에 주요국 정부는 인공지능이 향후 사회전반에 빠르게 확산될 것에 대비해 인공지능의 안전성 및 윤리 문제 등을 해결해 신뢰할 수 있는 인공지능을 개발하고 활용하기 위한 기반을 마련하기 위해 노력하고 있다. 예를 들어 미국은 2016년 AI 미래를 위한 준비(Preparing for the future of artificial intelligence, 2016.10.)와 「AI, 자동화, 그리고 경제(Artificial Intelligence, Automation and the Economy, 2016.12.)」등을 발표하며 인공지능 기술의 도입을 위한 안정성과 투명성 이슈에 대한 초기 논의를 시작하였다. EU 역시 지난 2018년 12월에 공개한 AI 윤리가이드 초안을 바탕으로 3개월간 약 500여건 이상의 공개 피드백을 반영해 수정한 문건을 2019년 4월에 공개하였다. 이처럼 각국 정부는 사회적 논의를 통해 인공지능의 윤리적인 문제에 대한 공감대를 형성해가는 한편 정책적으로도 이를 뒷받침하기 위한 노력들을 지속해 나가고 있다. 이는 기존에 기업의 자율성에 의존했던 인공지능 개발 문제에 대해 정부가 정책적 대응을 확대해 나가는 것으로 해석할 수 있다. 동시에 각국 정부는 기술적으로 인공지능의 안정성을 확보하기 위한 연구개발도 지속하고 있다. 특히, 안정성과 관련하여 인공지능 기술의 설명가능성을 위한 투자가 지속되고 있는데 본 절에서는 앞서 언급한 각국의 인공지능 안정성과 투명성 확보를 위한 현황을 논의하고자 한다.

1. 미국

미국은 그간 정부 차원에서 몇 차례에 걸쳐 인공지능 관련 보고서를 발간했다.

2016년 오바마 정부 당시 국가과학엔지니어문회의(National Science and Technology Council on Committee on Technology)의 「AI 미래를 위한 준비(Preparing for the future of artificial intelligence, 2016.10.)」, 「AI, 자동화, 그리고 경제(Artificial Intelligence, Automation and the Economy, 2016.12.)」, 「국가 AI R&D 전략계획(National Artificial Intelligence Research and Development Strategic Plan, 2016.10.)」이 대표적인 사례들이다. 2018년에는 산업계 인공지능 기술 전문가들을 백악관으로 초청해 일종의 민관 간담회인 The 2018 White House Summit on Artificial Intelligence를 개최하였고(미국 백악관 과학 기술정책실, 2018.5.10.), 이어 2019년 2월에는 행정부 명령인 American AI Initiative (‘19.2)를 발표하며 인공지능을 국가 안보 차원의 전략 과제로 선정하고 연구개발, 인력 양성 등에 대한 정부의 의지를 보여 주었다. 그 동안 발표된 미국 정부의 보고서 중에서 인공지능의 윤리적 측면과 관련된 내용은 「AI 미래를 위한 준비(Preparing for the future of artificial intelligence, 2016.10.)」와 「국가 AI R&D 전략계획(National Artificial Intelligence Research and Development Strategic Plan, 2016.10.)」에 상대적으로 상세히 소개되어 있다. 기타 보고서 및 간담회에서는 인공지능으로 인한 일자리 변화, 산업 안보, 혁신 등에 관한 논의가 주를 이루고 있으며 인공지능의 윤리적 문제는 프라이버시와 보호 차원에서 언급되는 수준이다. 이에 본 절에서는 「AI 미래를 위한 준비」와 국가 「국가 AI R&D 전략 계획」에 언급된 인공지능의 윤리 관련 내용과 미국 방위고등연구계획국(DARPA)에서 진행 중인 과제를 살펴보고자 한다.

가. AI 미래를 위한 준비¹⁰⁾

이 보고서에서는 인공지능의 공정성, 안전성, 및 지배구조(fairness, safety, and governance) 이슈를 하나의 챕터로 소개하고 있다. 특히, 엔지니어와 정책 분석가를 중심으로 인공지능이 종종 의도하지 않는 결과를 초래한다는 사실을 지적한다. 다시

10) National Science and Technology Council on Committee on Technology(2016.10.), 「AI 미래를 위한 준비(Preparing for the future of artificial intelligence)」를 포괄 인용하여 작성

말해 사람을 대신해 인공지능이 의사결정을 내리게 될 때 그 결과가 공정하고, 정의로우며, 책임성이 있는 것인가에 의문을 제기하는 것이다. 인공지능이 물리적 장비와 결합될 때는 안전(safety) 문제도 제기될 수 있다. 따라서, 실제 인공지능을 다루는 사람들은 인공지능으로 인한 의도적 차별과 실패를 예방하고, 의도치 않은 결과를 피해야 하며, 이해관계자들에게 예상치 못한 결과가 초래되었을 때 이를 합리적으로 설명할 수 있는 증거를 제공하는 방식을 갖추어야 한다고 본 보고서는 주장한다.

미국에서는 이미 2014년부터 빅데이터 관련 기술이 공정성 문제를 야기할 수 있다는 보고서를 공개하고 관련 논의와 연구를 진행해 왔다. 그리고 관련하여 왜곡된 결과 도출을 방지하기 위한 데이터 품질 제고 및 데이터 부족 해결 방안 모색이 필요함을 정책적으로 제안한 바 있다. 특히, 형사 사법적 목적으로 사용될 경우 데이터에 의한 왜곡, 편견 등이 결과에 반영되지 않도록 ‘좋은’ 데이터를 인공지능에 사용해야만 한다고 권고한다. 실제로 2016년 미국 탐사 보도 매체인 ProPublica는 미국 재판에서 사용하는 인공지능인 COMPAS가 백인보다 흑인을 잠재적 범죄자로 잘못 분류할 확률이 2배 가량 높다는 사실을 보도해 편향적이지 않은 데이터 사용의 중요성을 확인시켰다(테크M, 2018.12.8.). 채용 시스템에서도 인공지능을 활용하는 사례가 늘고 있는데 과거 입사자의 기록에만 의존하여 학습할 경우, 그 동안 선발되어 온 사람들과 큰 차이가 없는 사람들을 선호할 수밖에 없다. 따라서 새로운 역량과 다양성을 요구하는 인사 전략을 수립했을 때 예상치 못하게 인력의 동질성만 강화시키는 결과를 초래할 수 있다.

이러한 우려와 관련해 수차례의 공개 세미나, 워크숍 등이 개최되었고 토론자들 사이에서는 인공지능에 의사결정을 위임하는 것을 제한하는 방안이 논의되었다. 구체적으로 공공의 의사결정 과정에서 인공지능의 역할과 인간 관리자의 역할을 보다 명확히 하고, 인간의 주관과 오류가 개입될 여지가 많은 과정에서만 부분적으로 인공지능을 활용자는 것이다. 아울러, 인공지능 의사결정의 투명성 제고와 관리 감독을 강화해야 한다는 주장도 제기되었다. 여기서, 투명성은 단순히 데이터와 알고리즘의 투명성뿐만 아니라 어떻게 특정 결과가 도출되었는지 설명하는 형태까지를 포함한다. 또한 의사결정능력을 인공지능에게 위임할 때 책임성(accountability)을 유지하기 위한

이론 개발의 필요성도 제기되었다. 하지만, 엔지니어들은 복잡한 기계학습에 의해 추론된 결과를 이해하고 예측하거나, 설명하는 것이 현재로서는 매우 어려운 과제라고 주장한다. 또한 의도적으로 편향적 데이터를 사용하기도 하지만 무의식적으로 사용한 데이터가 편향된 결과를 만들어 내는 문제도 있다고 지적한다. 이러한 경우 엔지니어는 무엇이 문제가 될 수 있는지조차 파악하기 힘들며 따라서 개선의 노력이 미약할 수 있다는 한계를 언급하기도 한다. 즉, 개발자가 편견없이 최선의 인공지능을 개발하려고 해도 인공지능이 만든 결과를 개발자조차 이해하지 못할 수 있는 가능성이 높은 것이 현재 진화를 거듭하고 있는 인공지능의 현실이다.

Moritz Hardt, UC버클리 교수는 엔지니어나 인공지능 알고리즘이 악의를 가지지 않고 의도치 않는 결과를 만들 수 있음을 한 예로 설명하고 있다. 인공지능이 이름 데이터로부터 진짜와 가짜를 구별할 수 있는가하는 문제를 제기한 것이다. 여기서 기계학습 모델은 ‘독특한’ 이름을 ‘가짜’이름으로 구분하는 경향을 보였다. 이 문제를 다양한 인종이 살고 있는 미국 사회에 적용했을 경우 상대적으로 특이한 이름을 가진 소수 민족 그룹의 이름은 가짜 이름으로 분류될 수 있음을 나타낸다. 이것은 엔지니어의 데이터의 왜곡 없이 단순히 통계적으로 충분하지 않은 데이터로 인해 기계학습 모델에 도출한 결과라는 점에서 문제가 될 수 있다. Andrew Moore 카메기멜론대학교 컴퓨터학과 교수는 인공지능의 알고리즘 투명성을 높이기 위해서는 의도치 않은 결과의 유형을 가능 최대로 확보하기 위한 광범위한 실험(extensive testing)을 해야 한다고 한다. 어떤 나쁜 결과들이 도출될 수 있는지 예상해 목록으로 정리하여 각각에 대한 해결책을 찾아가야 한다고 주장한다. 일례로 사진에 자동으로 제목을 달아주는 인공지능 알고리즘이 흑인 사진을 ‘고릴라’로 인식한 오류를 범한 사례가 있다. 이것은 전형적으로 충분한 양의 데이터를 학습하지 못한 것이 문제이며, 이러한 오류를 예방하기 위해서는 광범위한 실험을 통해 모델의 정확도를 높여야 하고, 사람에 의해 결과가 잘못되었는지에 대한 피드백 데이터를 통해 모델을 지속적으로 개선해야 한다.

인공지능 윤리는 인공지능 사용자나 학습자들 모두가 인식해야 할 솔루션 개발의 필수 영역이다. 하지만 윤리 자체로는 충분치 않고 그것이 모든 이해관계자들 사이에 책임성을 제고시킬 때 더욱 의미를 가진다. 또한 윤리적 훈련은 ‘좋은 의도’를 실천으

로 옮기는 기술적 역량을 통해 구현되었을 때 제 빛을 발휘할 수 있다. 개발자들이 인공지능을 시스템을 보다 정의롭고, 공정하고, 책임성 있는 것으로 만들려는 노력을 할수록 그러한 윤리적 요소가 기술 개발의 제약조건이 아니라 기술의 책임성을 강화하는 것으로 나타날 수 있다. 기계학습 결과에 대한 해석력을 높이는 연구가 대표적인 사례인데, 인공지능의 결과를 해석할 수 있는 모델을 개발하게 되면 인간은 인공지능에게 보다 많은 위임을 할 수 있다. 그러나 아직까지 복잡한 알고리즘 결정의 책임성과 견고성을 강화하기 위해서는 한계가 있다. 알고리즘이 부분적으로 공개되어 기능적 취약점을 모두 알 수 없고, 반대로 공개된 알고리즘을 악용하는 문제도 발생할 수 있기 때문이다.

1) 안전과 통제

본 보고서는 인공지능의 확산에 가장 중요한 문제는 ‘안전과 통제’로 보고있다. 구체적으로, 개발자가 시스템의 안정성과 통제 가능성을 확신할 수 없다면 치명적인 결과를 초래할 수 있는 그러한 시스템은 배포할 수도 되어서도 안 된다고 제시한다. 또한, 기술적으로 폐쇄된 실험실 환경에서의 결과가 실제 현장에서 적용되었을 때 예기치 못한 문제를 일으키는 문제가 가장 심각할 것으로 예측한다. 실제 가정 청소용 자율 로봇을 개발하는 어느 업체는 효과적이며 안전한 로봇 개발을 위해 다음과 같은 질문을 한다고 하는데, 요약하면 안전성 확보를 위해 인공지능에게 관련된 상식을 학습시킬 수 있는가 하는 것이 핵심이다.

- 꽃병을 두드려가면서 안전하고 빠르게 청소할 수 있는 로봇이 가능한가?
- 로봇이 청소 완료라는 목표를 달성하기 위해, 사람이 보지 못하는 곳으로 옮겨 놓거나, 자기 눈을 가리는 방식을 채택하지 않게 할 수 있는가?
- 로봇이 어떻게 효율적으로 값비싼 물건을 구분하게 할 수 있을까? 어떻게 특정의 소유물을 따로 두게 할 수 있을까? 혹시 잃어 버린 게 없는지 주인에게 물어보게 할 수 있을까?
- 로봇이 나쁜 결과를 만들 수 있는 행동을 하지 않도록 할 수 있을까? 전기 콘센트에 젖은 걸레를 두지 않게끔 하는 방법은?

2) 공학으로서 인공지능 안전의 성숙화 필요

인공지능 안전에 관한 문제 해결을 위해 보고서에서는 기존의 항공, 발전소, 교량, 자동차 등에서 다뤄진 안전 공학적 접근 방식에 대한 적용부터 검토가 필요하다고 지적한다. 다시 말해, 인공지능 기술에 대한 안전 전략, 위험 관리, 위험 요소 관련 이해 관계자들과의 소통 방식 등에 대해 기존 분야에서의 방식을 어떻게 효과적으로 적용할 수 있을지 검토해야 한다고 제시한다. 특히, 현재 빠르게 성장하는 기계학습 분야는 견고한 이론적 토대보다는 연구자의 직관과 실험에 의존하고 있는데, 이해관계자들은 기계학습을 비롯한 인공지능이 공학적 기반의 학문으로 성숙하기를 원하고 있다.

보고서는 인공지능은 소수의 창의적 연구자들에 의해 ‘do-it-yourself’ 식으로 수행되는 ‘창작(craft)’의 과정을 지나, 숙련가들에 의해 개발된 일반적 원칙(rules-of-thumb)이 작동하고 상용 제품으로 보편적으로 확산되는 단계를 거쳐, 보다 견고한 이론 및 방법론, 교육받은 전문가들이 활동하고 다양한 특화 제품들이 나오는 단계로 발전할 것이라고 예측한다. 대부분의 공학 분야는 인공지능 보다 훨씬 긴 역사를 가지고 있어 이미 완숙된 단계에 이르렀다고 볼 수 있다. 인공지능 공학이 성숙하게 되면 기술 예측성, 신뢰성, 견고성, 안정성, 보안성에서 진보가 이뤄질 것으로 보고 있다.

3) 인공지능 윤리 및 안전 정책 권고


보고서는 연방기관은 증거 기반의 검증 및 타당성 확보를 통한 인공지능의 공정성과 효율성 제고에 특별히 주의를 기울여야 한다고 주장한다. 특히, 인공지능 기반으로 중대한 결정을 하는 주정부와 지방 정부에 보조금을 지원하는 연방기관은 연방 보조금을 통해 구매한 인공지능 기반 제품 및 서비스가 효율성 및 공정성 증거에 의해 충분히 투명성을 보장하는 지를 보조금 지급의 조건으로 검토해야 한다고 주장한다. 학교와 대학은 인공지능, 기계학습, 컴퓨터 과학, 데이터 과학 커리큘럼의 필수 부분으로서 윤리학이나 보안, 프라이버시, 안전 관련 주제를 포함해야 하며, 인공지능, 안전 전문가 및 전문가 단체는 인공지능 안전이 공학으로서 지속으로서 발전해나갈 수 있도록 긴밀히 협력해 나가야 한다고 권고한다.

나. 국가 AI R&D 전략 계획¹¹⁾

2016년 10월에 수립된 미국의 국가 AI R&D 전략 계획은 미국의 인공지능 연구개발 정책에 관한 광범위한 전략을 포함하고 있다. 특히, 인공지능 연구개발을 국가 전략의 우선순위에 두어야 한다고 언급하며 ① 인공지능 분야 장기적·우선적 투자, ② 인간-인공지능 협업 모색, ③ 인공지능의 윤리적·법적·사회적 영향 고려, ④ 인공지능의 안전 및 보안 시스템 마련, ⑤ 인공지능 교육 및 공공 데이터 공유 환경 필요, ⑥ 인공지능의 표준 및 벤치마킹을 통한 기술 측정 및 평가 필요, ⑦ 인력 양성 등 7가지의 추진 전략을 제시하고 있다.

3번째 전략인 ‘인공지능의 윤리적, 법적, 사회적 영향 고려’와 관련해 본 보고서는 사회 질서의 근본적 구동력으로 법과 윤리가 인공지능의 행위 결정에 정보를 제공하고 있다고 가정한다. 따라서 인공지능이 기존 윤리와 법, 사회적 원칙에 부합하도록 설계되어야 하고 동시에 인간의 프라이버시 침해에 대한 대비책도 마련되어야 한다고 보고 있다.

[그림 4-1] 미국 국가 AI R&D 전략계획 ('16.10)



자료: National Science and Technology Council(2016. 10) p.16

11) National Science and Technology Council(2016. 10), 「국가 AI R&D 전략계획(National Artificial Intelligence Research and Development Strategic Plan)」을 요약정리하여 작성

다른 기술과 마찬가지로 인공지능 기술 역시 사회적으로 수용 가능하려면 법과 윤리에 기반을 두어야 하는데, 어떻게 이러한 법, 윤리 체계를 신기술에 적용하느냐가 도전 과제가 될 것으로 전망한다. 한마디로 인공지능이 안정적으로 작동하기 위해서는 각 도메인에 ‘좋은 행동’이 무엇인지 결정해야 하는데 이를 위해서는 컴퓨터 과학, 사회 과학, 행동 과학, 윤리학, 바이오의학, 심리학, 경제학, 법, 정책연구 등 다학제간 관점에서 인공지능 윤리 문제에 접근해야 한다고 주장한다. 보고서에서는 인공지능 윤리와 관련해 다음의 세 가지 방향에 대한 고려가 필요함을 언급하고 있다.

1) 공정성, 투명성, 설계에 의한 책임성

본 계획에는 인공지능 윤리는 데이터 집약적인 알고리즘의 잘못된 사용, 오용과 관련이 있다고 보고있다. 흑인을 고릴라로 인식하거나, 흑인 범죄자의 재범률을 더 높게 예측하는 등 인간의 성별, 나이, 인종, 소득 등의 데이터를 활용해 계층을 분류하는 인공지능 어플리케이션의 오작동은 윤리적인 논쟁을 일으켰고, 이를 해결하기 위한 적절한 양의 데이터 수집과 사용이 중요한 도전 과제가 되고 있다고 언급한다. 그러나 단순히 데이터 관련 문제를 넘어 더 큰 과제는 인공지능을 근본적으로 공정하고 투명하고 책임성 있게 설계하는 것이라고 밝히고 있다. 또한 인공지능의 행위와 의사결정이 투명하고, 쉽게 해석될 수 있도록 연구자들의 노력이 필요하다고 강조한다. 이와 더불어 과학자들은 현재의 제한된 기술 수준에서 어느 정도까지에 인공지능에 공정성과 정의를 적용할 수 있을지 파악하고 개선방안을 찾아야 한다고 언급한다.

2) 윤리적 인공지능 개발

본 계획에 따르면 인공지능이 일반적인 윤리 원칙을 준수할 수 있을지에 대한 우려를 불식시키는 노력도 필요하다. 보고서는 윤리는 내재적으로 철학적 질문이나 인공지능은 공학 기술에 의존적이며 제한을 받을 수 밖에 없다고 지적한다. 따라서 과학자들은 기술적으로 실현가능한 한계 내에서 기존 법, 사회 규범, 윤리와 부합하는 일반적인 알고리즘과 아키텍처를 개발해야 한다고 제시한다. 향후 인공지능이 새로운 형

태의 자율 의사결정 알고리즘을 갖거나, 가치 체계와 부딪히는 도덕적 딜레마에 직면했을 경우 상황은 더욱 복잡해질 것이나, 그럼에도 불구하고 인공지능은 누구나 수용할 수 있는 윤리 참조 프레임워크를 탑재해 의사결정에 활용하고 최종 결과의 근거를 설명할 수 있어야 한다고 지적한다.

3) 윤리적 인공지능을 위한 아키텍처 설계 필요

본 계획은 향후 추가적인 연구는 윤리적 추론을 하는 인공지능을 구현하기 위한 아키텍처 설계에 집중할 필요가 있다고 언급한다. 본 계획에는 이와 관련 다양한 접근법이 제안되고 있는데, 예를 들어 2중(two-tier) 모니터링 아키텍처는 실행 인공지능(operational AI)을 모니터링 에이전트와 분리하는 방식. 즉, 모니터링 에이전트는 어떠한 실행 인공지능의 행위에 대해서 윤리적, 법적 평가를 담당하는 방식이 있다. 본 계획에서 제시된 또 다른 방식은 안정 공학적 접근이다. 인간에 위해를 가하지 않고 안전한 행동을 위한 개념 프레임워크(conceptual framework)를 인공지능 아키텍처에 적용하는 것이다. 세 번째 방식은 집합 이론 원리(set theoretic principles)를 사용해 윤리적 구조를 공식화하고 인공지능이 윤리적 교리에 부합하도록 행동을 제한하는 방식이다. 본 계획은 인공지능이 일반화되면서 내부 아키텍처는 다층적 판단 수준이 작용하는 윤리적 문제를 갖고 있는 다양한 서브시스템들을 포함할 가능성이 높다고 보고 있다. 다층적 판단 수준은 빠른 응답 패턴 매칭 규칙, 행위를 합리화하거나 묘사하는 보다 느린 응답을 위한 심의, 사용자의 신뢰성을 표시하는 사회적 신호, 시스템이 문화적 규범을 준수할 수 있도록 더 긴 시간 규모로 운영되는 사회적 프로세스를 포함한다. 연구자들은 어떻게 AI 시스템이 윤리적, 법적, 사회적 목표에 부합하는 방향으로 종합적으로 설계할 수 있을 지에 집중할 필요가 있다고 강조한다.

다. 미국 방위고등연구계획국(DARPA)¹²⁾


DARPA는 도전적이고 혁신적인 연구를 선도적으로 수행하는 기관으로 많이 언급된

12) 본 주제에 대해서는 소프트웨어정책연구소 추형석 선임연구원의 자문을 받아 작성하였음

다. 특히 실패할 확률이 매우 높은 고위험군의 연구를 많이 수행하고 있는데 인공지능도 예외는 아니다. 최근 DARPA가 수행한 연구 중 상당수가 인공지능¹³⁾과 관련이 있다는 점을 상기시켜 보면 미래 인공지능 역시 미국을 주도로 움직일 것이라는 부분에 이견이 없을 것이다.

DARPA는 지난 2018년 “AI Next Campaign”을 공개하여 2018년부터 2023년까지 20억 달러(약 2조 2000억 원)를 투자한다고 밝혔다. 이 계획의 비전은 인공지능이 도구의 역할을 넘어 인간과 공존하고 협업하는 동반자(partner)로 정착하는 것이다. DARPA는 [그림 4-2]와 같이 인공지능의 물결을 3가지로 구분하여 3차 물결로 나아가기 위한 방향을 제시했다.

[그림 4-2] 인공지능의 3가지 물결



자료 : DARPA 홈페이지.

인공지능의 첫 번째 물결(eescribe)은 규칙 기반의 인공지능이다. 예를 들면, ‘모든 생물은 죽는다. 사람은 생물이다.’라는 규칙을 입력하면, ‘사람은 죽는다.’라는 추론을 할 수 있는 방식이다. 이것은 기호적 인공지능(symbolic AI)으로 전문가 시스템에 주로 활용된 인공지능 기술이었다. IBM 왓슨 역시 대표적인 기호적 인공지능의 예로 볼 수 있다. 두 번째 물결(Categorize)은 현재 심층학습 기반의 인공지능을 말한다. 심층

13) DARPA 그랜드 챌린지로 진행된 자율 주행자동차와 재난 구조 로봇, 애플 Siri의 원천인 CALO 프로젝트, 뉴로모픽칩의 근간이 되는 SyNAPSE 프로젝트 등이 있다.

학습은 데이터를 학습하여 분류하는 것에 가장 큰 성과를 나타내고 있으며, 고도의 사
칙연산을 기반으로 한 경험적 결과를 바탕으로 한다. 마지막으로 세 번째 물결
(Explain)은 이 캠페인이 지향하고자 하는 바를 나타낸다. 세 번째 물결은 궁극적으로
인공지능과 인류가 공존하기 위한 연구를 지향한다. 따라서 대부분의 연구가 안전성과
투명성과 연계되어 있다. 구체적으로 AI Next Campaign에서는 아래 <표 4-1>과 같
이 다섯 가지 주요 분야를 선정하여 연구를 추진할 예정이다.

<표 4-1> DARPA의 AI Next Campaign의 주요 내용


분 야	내 용
새로운 역량 (New capabilities)	국방부 업무의 자동화를 위한 인공지능을 활용하는 방안을 강화하기 위해 도전적 R&D와 연계하고, 그 인공지능 시스템의 조기 도입 추진
강인한 인공지능 (Robust AI)	위성 영상 분석, 사이버 공격, 군수 공급사슬 등의 분야에서 인공지능의 오류를 극복 하고 신뢰성을 확보하기 위한 시스템 개발
적대적 인공지능 (Adversarial AI)	인공지능 시스템을 공격하기 위한 적대적 사례, 인공지능이 하나의 SW로써의 보안 취약점 등을 극복하기 위한 연구
고성능 인공지능 (High performance AI)	인공지능의 효율성을 높이기 위한 주제로, 인공지능 학습 시 소비되는 전력을 최적 화하기 위한 방안, 인공지능 전용 HW개발을 포함하며, 적은 데이터로도 학습할 수 있는 방안을 연구
차세대 인공지능 (Next generation AI)	DARPA는 보다 현실적인 수준의 차세대 인공지능 개발을 추진하여, 설명 가능한 인공지능, 일반 상식(common sense) 추론 등을 수행

자료 : DARPA 홈페이지

DARPA가 인공지능과 관련하여 추진하고 있는 여러 가지 과제 중 안정성이나 투명
성에 연관된 사업은 총 세 가지가 있다. 가장 대표적인 사업은 설명 가능한 인공지능
(XAI)이다. XAI 프로젝트는 2017년부터 2021년까지 진행되며 총 예산은 8천만 달러
(약 910억 원)이다. XAI 프로젝트의 발단은 앞서 심층학습의 한계에서 소개한 인공신
경망의 블랙박스로부터 출발한다. XAI의 일차적인 목표는 블랙박스를 해부하여 의미
를 찾는 다기 보다는 심층학습의 결과가 왜 나왔는지를 설명하는 데 중점을 둔다. 예를
들면, 현재 심층학습은 고양이 사진을 입력 값으로 할 때 출력 값은 고양이일 확률이

가장 높게 산출되어 고양이라고 알려주는 것이다. XAI는 인공지능망이 왜 고양이라고 판단하는지에 대한 설명을 추가하는 것이다. 예를 들면, ‘털과 수염이 있고, 발톱이 있으며 귀가 뾰족한 모양이기 때문에 고양이다’라는 설명을 추가하는 것이다. 이 과정은 [그림 4-3]과 같이 표현할 수 있다.


[그림 4-3] 설명 가능한 인공지능의 목표



자료 : DARPA(2016), p.5

두 번째 연구는 악의적인 공격에 대한 인공지능의 강건성(Guaranteeing AI Robustness and Deception, GARD)이다. 적대적 공격은 기계 학습을 활용한 인공지능 시스템의 판단 착오를 유도하는 기술을 일컫는다. 사람으로 따지면 일종의 착시 현상으로 인공지능을 착시하게 만드는 것이다.

[그림 4-4] 적대적 공격의 예시



자료 : OpenAI 블로그(2017.02.)

[그림 4-4]의 왼쪽에는 판다 이미지가 있고, 이 사진에 ‘솔트 앤 페퍼’¹⁴⁾라는 노이즈를 추가한 것이 오른쪽 이미지다. 사람의 눈으로 판단하기에는 왼쪽이나 오른쪽이나 판다라고 인식하지만, 인공지능경망에서는 왼쪽 사진을 57.7%로 판다라고 예측한 반면 오른쪽 사진은 99.3%의 확률로 긴팔원숭이(gibbon)로 예측한 것이다. 적대적 공격은 현대 인공지능의 취약점을 여실히 보여준다. 가장 큰 문제는 앞서 소개한 블랙박스로부터 시작한다. 인공지능경망은 수많은 가중치를 학습한다. 그러나 각각의 가중치가 어떠한 역할을 하는지 불분명한 상황에서 [그림 4-4]와 같이 판다 사진을 긴팔원숭이로 오인한 것에 대한 원인 규명이 어렵다. 만약, 자율주행차의 인공지능 시스템이 [그림 4-5]의 정지 교통신호판을 오인한다면 대형 참사로 이어질 가능성이 높다. 제대로 된 표지판의 경우라도 날씨나 환경에 의해 오인의 소지가 있다. 이 경우를 방지하기 위한 일차적인 대안은 오인의 여지가 있을 수 있는 데이터를 가능한 한 많이 수집하여 학습시키는 것이다. 하지만 이러한 방법은 비용적인 측면에서 매우 비효율적이다. 소위 가능한 환경이라는 것이 거의 무한대에 가깝기 때문이다. 적대적 공격과 관련된 연구는 적대적 사례(Adversarial example) 생성하는 측과 이를 방어하는 것으로 진행된다(Yuan, Xiaoyong, et al., 2019). 적대적 공격 역시 많은 연구자들이 해결책을 마련하기 위해 노력하고 있기 때문에 향후 전망은 밝은 편이다.

14) 솔트 앤 페퍼는 이미지에 노이즈를 추가하는 대표적인 방법으로, 사진에 소금과 후추를 뿌린 것과 같은 효과를 낸다.

[그림 4-4]에서는 이 ‘솔트 앤 페퍼’ 이미지에 작은 모수 ϵ 를 곱해 그 영향이 더욱 낮아지도록 한다.

[그림 4-5] 적대적 공격의 가능성이 있는 오염된 정지 교통표지판



자료 : Eykholt, Kevin, et al.(2018), p.2

또한 인공지능이 갖는 오픈 사이언스의 특성으로 인해 신경망 구조부터 가중치까지 공개되어 있는 경우가 많다. 만약 이것을 그대로 차용하는 경우 널리 알려진 신경망이 보안적인 측면에서 더욱 취약할 수 있다. 예를 들어, ILSVRC의 2015년 우승 알고리즘인 잔차신경망(Residual Network)이 [그림 4-5]와 같은 적대적 공격에 대해 취약점이 밝혀진다면, 잔차신경망을 활용하는 제품이나 서비스는 즉각적인 개선이 필요할 것이다. 이러한 과정에서 성능의 편차가 발생할 수도 있다는 잠재성이 있기 때문에 적대적 공격을 대비하기 위한 공론화와 기술 개발이 시급한 실정이다.

마지막 주제는 역량을 인지하는 기계학습(Competency-Aware Machine Learning, 이하 CAML)이라는 주제다. CAML의 핵심은 인공지능 시스템이 할 수 있는 일과 할 수 없는 일, 즉 시스템의 역량을 인지하기 위한 것에 있다. 예를 들면 자율주행차가 비가 오는 밤에 주행을 한다면 다음과 같은 역량을 인지하고 사용자에게 알려줄 수 있다.

“비가 오는 밤의 경우 저는 사람과 무생물을 90%의 정확도로 구분할 수 있습니다.
그리고 저는 이러한 환경을 1,000회 경험했습니다.”

인공지능 시스템이 사용자에게 위와 같은 정보를 줄 경우 사용자는 훨씬 안심하고 인공지능을 활용할 수 있다. 비가 오는 밤의 경우, 인공지능 시스템의 경험이 많지 않다면 속도를 제한하거나 사용자가 직접 운전하는 것으로 이어질 수 있기 때문이다. 이렇게 인공지능 시스템이 성공과 실패의 경험을 수치화하여 이를 사용자에게 알려주거

나(Self-knowledge of experience), 행위에 대한 전략을 최적화 하는 등의 접근 (Self-knowledge of task strategies) 등이 CAML 과제다.

2. EU¹⁵⁾

지난 2019년 4월 9일 EU에서는 인공지능 윤리 가이드라인(Ethics Guidelines For Trustworthy AI)을 마련하여 공개하였다(European Commission, 2019.4.8.). 지난 2018년 12월에 공개한 초안을 바탕으로 3개월간 약 500여건 이상의 공개 피드백을 반영해 수정한 결과다. 이번 가이드라인은 그 동안의 인공지능 윤리 관련 논의들이 모두 포함되었다고 해도 과언이 아니다. 특히, 인공지능 개발 현장에서 참조할 수 있는 인공지능 윤리 평가 리스트의 시험 버전을 마련하여 공개하였는데 각계에서 이를 사용해 본 후 피드백을 받아 2020년 개정안을 마련한다는 계획이다. 여기서는 이번 EU의 인공지능 윤리 가이드라인 내용을 중심으로 EU 차원의 인공지능 윤리 문제에 대한 정책을 살펴보고자 한다.

가. 배경

EU는 인공지능이 사회를 현저히 변화시킬 잠재력을 갖고 있다고 믿고 있으며 인간의 번영을 촉진하여 개인과 사회의 복리와 공공선(善)을 강화하고 진보와 혁신을 가져올 수 있는 유망한 수단으로 인식한다. 특히 성평등, 기후변화 해결, 천연 자원의 합리적 사용, 건강 증진, 이동성과 생산 공정 개선 등과 같은 유엔의 지속가능발전목표(Sustainable Development Goals) 달성을 촉진하는 데에 도움을 주고 지속가능성과 사회통합 지표의 진전을 관찰하는 것을 뒷받침해 줄 것이라고도 기대하고 있다.

이를 위해 EU는 인간 중심적이며, 인간의 복리와 자유를 개선하는 것을 목표로 인간과 공공선을 위해 사용되는 인공지능 개발의 필요성에 공감하고 있다. 또한, 인공지능이 가져올 커다란 기회와 위험에 대응하는 방식을 결정해야 중요한 기로에 놓여 있

15) 본 내용은 소프트웨어정책연구소 유재홍 선임연구원의 자문내용과 European Commission(2019.4.8.), "Ethics Guidelines For Trustworthy AI"을 요약·정리하여 작성

다고 판단하고 있는데, 인공지능 개발자들이 제품과 서비스에 신뢰할 수 있는 인공지능(Trustworthy AI)을 적용함으로써 인공지능의 이점을 극대화하는 동시에 위험을 방지하고 최소화해야 한다고 강조하고 있다.

EU는 유럽이 윤리적인 첨단 기술의 본거지이자 선두주자가 되기 위해 인권 존중, 민주주의, 법치라는 기본 자치에 부합하는 방식으로 인공지능의 혜택을 누릴 수 있는 방법을 모색하고 있다. 그 구체적인 행동으로 유럽위원회(European Commission)는 2018년 4월 25일과 12월 7일자 연락문을 통해 "유럽에서 만들어진(Made in Europe) 윤리적이고 안전한 첨단 인공지능"을 지지하는 비전을 선포했다. 위원회의 비전을 뒷받침하는 세 가지 중심축은 1) 인공지능 수용 확대를 위한 공공 및 민간 투자 증대, 2) 사회경제적 변화 대비, 3) 유럽의 가치 강화를 위한 적절한 윤리적, 법적 체계 확보다. 위원회는 이러한 비전의 실현을 뒷받침하기 위해 인공지능에 관한 고위 전문가그룹(High-Level Expert Group on Artificial Intelligence: AI HLEG)을 조직하고 인공지능 윤리 지침과 정책 및 투자 제언 정책 보고서 작성을 위임했다. 본 보고서에 따르면 AI HLEG는 2018년 12월 18일 인공지능 윤리 지침 초안을 공개하고 3개월간의 피드백을 받아 지침서를 마련했다(European Commission, 2019.4.8.). 이후 수개월에 걸쳐 52명의 구성원이 '다양성 속의 일치(united in diversity)'라는 유럽연합의 모토에 따라 토론과 교류를 실시했다. 그 결과 2019년 4월 초 "Ethics Guidelines for Trustworthy AI"라는 이름의 인공지능 윤리 가이드라인이 완성되었다.

나. 기본원칙

1) 신뢰할 수 있는 인공지능

EU가 추구하는 인공지능은 "신뢰할 수 있는 인공지능"으로 축약된다. 신뢰성은 사람과 사회가 인공지능을 개발, 배포, 이용하기 위한 전제조건이다. 인공지능과 그 배후에 있는 사람에 대한 신뢰가 입증되지 않는다면 원치 않는 결과가 발생해 인공지능의 수용이 저해되고 인공지능이 가져다 줄 수 있는 막대한 사회, 경제적 편익의 가능

성을 실현하지 못하게 될 수 있다. EU는 인공지능의 신뢰성은 비단 기술적 품질 뿐만 아니라 전체적인 사회 시스템과 관련이 있다고 보고 있다. 즉, 인공지능의 개발, 배포, 이용에 대한 신뢰는 기술에 내재된 속성뿐만 아니라 인공지능이 응용되는 사회기술적 시스템의 품질과도 관련이 있다고 보는 것이다. 즉, 인공지능의 신뢰 역시 항공, 원자력, 또는 식품 안전의 신뢰 상실 문제와 마찬가지로 단순히 시스템의 구성요소가 아니라 전체적인 시스템의 맥락에서 결정된다는 인식에 기인한다. 따라서 신뢰할 수 있는 인공지능은 시스템의 전체적인 수명주기에 걸쳐 있는 모든 참여자와 과정의 신뢰성을 아우르는 총체적이고 체계적인 접근을 필요로 한다고 보고, 다음의 세 가지 요소를 충족시켜야 한다고 주장한다.

1. 적법해야 한다(lawful). 적용되는 모든 법률과 규정을 준수해야 한다.
2. 윤리적이어야 한다(ethical). 윤리적 원칙과 가치를 지켜야 한다.
3. 견실해야 한다(robust). 선한 의도를 가진 AI 시스템이라 할지라도 기술적, 사회적 관점에서 의도치 않은 피해를 유발할 수 있다.

우선 적법한 인공지능과 관련해, EU의 지침은 인공지능의 개발, 배포 및 이용과 관련된 과정과 활동에 적용되는 모든 법적 권리와 의무가 강제성을 유지하며 반드시 준수해야 하는 것이라는 가정을 바탕으로 하고 있다. 즉, 각 개별국가 및 국제 수준에서 법적 구속력이 있는 여러 규칙들이 오늘날 인공지능의 개발과 배포, 이용에도 유효하게 적용되거나 그와 관련이 있음을 상기시킨다. 인공지능이 따라야 할 법은 EU의 1차적 법원(유럽연합 조약과 기본권 헌장)과 2차적 법원(일반적 정보 보호 규정, 제품 책임 지침, 비개인 정보의 자유로운 흐름에 관한 규정, 비차별 지침, 소비자법, 직장 안전 보건 지침 등), 유엔 인권 조약, 유럽 의회 협약(유럽 인권협약 등), 여러 EU 회원국의 국내법이 해당된다. 또한 수평적으로 적용되는 규칙 외에도 특정 응용 분야에 적용되는 다양한 분야별 규칙까지 포함한다(예. 의료 분야의 의료기기 규정 등). 법률은 긍정적 의무와 부정적 의무를 모두 규정하고 있다. 즉, 해서는 안 되는 것뿐만 아니라 해야 하는 것과 할 수 있는 것에 대한 규정도 포함한다. 법률은 특정한 행위를 금지할

뿐만 아니라 다른 행위를 가능하게 하는 역할도 한다. 이러한 측면에서 EU 헌장에 정보 보호와 차별 금지 등 인공지능의 신뢰성을 담보하고자 할 때 일반인이 익숙하게 떠올리는 영역들에 대한 조항과 함께 '사업 활동의 자유'와 '예술 및 과학의 자유'에 관한 조항이 포함되어 있음을 강조하고 있다. EU의 지침은 신뢰할 수 있는 AI의 첫 번째 요소(적법한 AI)에 대해 명시적으로 다루고 있지 않으며, 그보다는 제2와 제3의 요소(윤리적이고 견실한 AI)를 촉진, 담보하는 것에 관한 길잡이를 제공하는 것을 목표로 하고 있다. 후자의 두 요소는 기존 법률에 이미 어느 정도 반영되어 있는 경우가 많지만, 그러한 요소의 온전한 실현은 기존의 법률적 의무를 넘어설 가능성이 있다. 지침은 기존의 법률 규범 및 요건을 준수할 것을 상기시키는 것으로 어떠한 내용도 제3자에 대한 법적 권리 또는 의무는 없다.

윤리적인 인공지능과 관련해서는, 법률이 기술 발전 속도에 항상 발맞추는 것은 아니며 때로는 윤리적 규범과 어긋나거나 특정 사안을 다루는 데 있어 적합하지 않을 가능성도 있다는 점을 염두에 두고 있다. 따라서 인공지능이 신뢰성을 갖추기 위해서는 윤리적이어야 하고 윤리적 규범에 부합해야 한다고 주장한다.

마지막으로 견실한 인공지능은 윤리적 목적이 담보되었다 하더라도 개인과 사회는 반드시 인공지능이 의도치 않은 해를 끼치지 않으리라는 점을 신뢰할 수 있어야 한다는 점을 지적한다. 인공지능은 안전하고, 확실하며 믿을 수 있는 방식으로 작동되어야 하고, 의도하지 않은 부정적 영향을 방지하기 위해 보호조치를 예견해야 한다. 그러한 점에서 견실성이 중요하며, 이는 기술적 측면(응용 분야 영역 또는 수명주기 단계와 같이 해당 맥락에서 적절한 시스템의 기술적 견실성을 담보하는 것)과 사회적 측면(시스템이 작동되는 맥락과 환경을 충실히 고려하는 것) 모두에서 필요한 사항이다. 따라서 인공지능의 윤리성과 견실성은 상호 연관되어 있으며 상호 보완적이다.

EU 지침은 이러한 세 가지 요소는 각각 신뢰할 수 있는 인공지능을 달성하는 데에 필수적이지만 그 자체만으로는 충분하지 않다고 보고 이상적인 상황은 세 요소가 서로 중첩되어 조화롭게 작용할 것을 주장한다. 그러나 현실에서는 이러한 요소 간에 긴장관계가 형성될 수도 있음을 인정한다(예. 기존 법률의 범위와 내용이 윤리적 규범의 범위를 벗어나는 경우). 이러한 세 요소들이 신뢰할 수 있는 인공지능을 실현할 수

있도록 함께 노력하는 것은 개인과 사회의 책임이라고 말한다. EU의 지침은 기업, 기관, 연구자, 공공기관, 정부 부처, 연구소, 시민사회 조직, 개인, 노동자와 소비자를 비롯해 인공지능을 설계, 개발, 배포, 시행, 사용하거나 그에 의해 영향을 받는 모든 이해관계자들을 위한 것이다. 신뢰할 수 있는 인공지능의 실현을 위해 노력하는 이해관계자들은 그러한 노력의 실천을 위한 방법으로 본 지침을 자발적으로 활용할 수 있으며, 특히 인공지능을 개발, 배포 또는 사용할 때 지침서에 수록된 평가 목록을 활용할 수 있을 것이다. 또한 이러한 평가 목록은 기존 평가 절차를 보완할 수 있으며, 따라서 그러한 절차에 포함될 수 있다.

그러나 상황에 따라 서로 다른 문제가 제기될 수도 있다. 예를 들어 인공지능 음악 추천 시스템과 관련된 윤리적 문제는 핵심적인 의학적 치료를 제안하는 인공지능의 경우와 같지 않다. 마찬가지로 기업 대 고객, 기업 대 기업, 고용주 대 직원, 공공 대 민간 관계의 맥락에서, 또는 보다 일반적으로 서로 다른 분야 또는 용례에서 인공지능으로부터 비롯되는 기회와 문제점들은 서로 다르다. 이렇듯 EU의 지침은 적용 분야의 맥락성을 고려해 적절하게 시행되어야 할 필요가 있다. 뿐만 아니라 본 문서에서 제안하고 있는 일반적인 수평적 체계를 보완하기 위한 추가적인 분야별 접근방식에 대해서도 지속적인 탐색이 필요하다.

다. 신뢰할 수 있는 인공지능 실현을 위한 7가지 요건

본 지침에서는 신뢰성 있는 인공지능의 기본 원칙을 바탕으로 충족해야 하는 7가지 요구사항을 제안하고 있다. 1) 행위자와 감독, 2) 기술적 견실성과 안정성, 3) 개인정보와 데이터 거버넌스, 4) 투명성, 5) 다양성, 차별 금지, 공정성, 6) 사회적, 환경적 웰빙, 7) 책임성이 그것이다.

우선, 행위자와 감독은 인공지능이 인간의 기본적 권리를 침해하지 않으며 인간 행위자와 상호작용하면서 동시에 인간의 감독을 받을 필요가 있다는 내용을 담고 있다. 기술적 견실성과 안정성은 인공지능 시스템이 적대적 공격에 대해 회복 탄력성을 가져야 하고, 보안이 유지되어야 하며, 예기치 않은 상황에 대한 대비 계획, 일반적 안정성, 정확성, 신뢰성, 재현 가능성 등에 관한 내용을 포함한다. 개인정보와 데이터 거버

넌스는 프라이버시, 데이터의 품질과 무결성, 데이터에 대한 접근성에 관한 내용을 담고 있다. 투명성은 인공지능의 결과물에 대해 추적 가능해야 하며, 설명 가능해야 하고, 소통할 수 있어야 한다는 조건이다. 다양성, 차별 금지, 공정성에서는 데이터나 알고리즘의 불공정한 편향의 제거, 보편적 설계와 이해 관계자 참여의 필요성을 강조했고, 사회적, 환경적 웰빙은 인공지능이 지속 가능성과 환경 친화성, 사회적 영향을 고려해야 함을 정리하고 있다. 마지막으로 책임성은 인공지능에 대한 감사가 가능해야 하고 그것의 부정적 영향력을 최소화하며, 손해 배상에 대한 고려사항을 담고 있다. 이러한 요구사항은 개발자, 배포자, 최종 사용자, 전체 사회 등 인공지능의 수명주기에 참여하는 모든 이해 관계자에게 적용된다.

- 개발자는 설계와 개발 과정에서 요구사항을 시행, 적용한다.
- 배포자는 자신이 사용하는 시스템과 제공하는 제품 및 서비스가 요구사항을 충족하도록 한다.
- 최종 사용자와 전체 사회에게는 이러한 요구사항을 대해 알리고 요구사항이 충족될 것을 요청할 수 있도록 해야 한다.

[그림 4-6] 신뢰성 있는 AI의 7가지 요건



자료: European Commission (2019. 4. 8.), p.15

라. 신뢰할 수 있는 인공지능에 대한 평가

EU지침에는 7가지 요구사항을 바탕으로 신뢰할 수 있는 인공지능을 평가하기 위한 비포괄적인 목록(시험 버전)을 규정하고 있다. 이 평가 목록은 특히 사용자와 직접적으로 상호작용하는 인공지능에 적용되며 주로 자체 개발 또는 서드파티로부터 입수한 인공지능의 개발자와 배포자들을 위한 것이다. 이러한 평가 목록은 신뢰할 수 있는 인공지능의 첫 번째 원칙인 ‘적법한 인공지능’의 실현을 다루지 않는다. 즉, 평가 목록에 부합한다는 점이 법률 준수의 증거가 되지 않으며 지침이 적용 가능한 법률의 준수를 담보하는 것도 아니다. 인공지능의 분야별 특정성을 감안할 때, EU 지침의 평가 목록은 구체적인 용례와 시스템이 작동되는 맥락에 맞게 조정할 필요가 있다. EU의 지침은 운영 및 관리 수준에서의 거버넌스 구조를 통해 신뢰할 수 있는 인공지능에 대한 평가 목록을 시행하는 방법에 관한 일반적인 권고를 제공하고 있을 뿐이다.

평가 목록과 거버넌스 구조는 공공 및 민간 분야 이해관계자들과의 긴밀한 협력을 통해 확정되어야 하기 때문에 시범 실시 후 피드백 과정을 걸쳐 2020년 개정될 예정이다. 피드백은 1) 선정된 소수의 기업, 조직, 다양한 분야와 크기의 기관들이 평가 목록과 거버넌스 구조를 시범적으로 실시하고 심층적인 피드백을 제공함으로써 대표성을 담보하는 정성적 과정, 2) 모든 이해관계자들이 평가 목록을 시범적으로 실시하고 열린 논의를 통해 피드백을 제공하는 정량적 과정을 걸쳐 수집될 예정이다. 또한, 신뢰할 수 있는 인공지능의 평가 과정에 최고 경영진의 필수적 참여를 권고한다. 기업, 조직 또는 기관의 모든 이해관계자들의 참여가 새로운 기술적 또는 비기술적 절차 도입의 수용성과 연관성을 높여준다는 연구 결과를 토대로 운영 수준과 최고 경영진 수준의 참여를 독려하는 것이다.

<표 4-2> 조직의 참여 수준과 AI 시스템에 대한 평가 관련 역할

수 준	관련 역할(조직별로 상이함)
경영진, 이사회	최고 경영진은 AI 시스템의 개발, 배포 또는 조달에 대해 논의, 평가하고 심각한 우려 사항이 발견되었을 때 모든 AI 혁신과 이용을 평가하는 상위 기구의 역할을 한다. 여기에는 AI 시스템의 도입에 의해 영향을 받는 사람들과 (예 : 노동자) 정보, 논의, 참여 절차를 통해 이러한 과정 전체에서 그들을 대변하는 대표자들이 포함된다.

수 준	관련 역할(조직별로 상이함)
규제/법을 부서, 기업 책임 부서	책임 부서는 평가 목록의 활용 및 기술 또는 규제 변화에 따른 필수적 진화를 모니터링한다. AI 시스템에 대한 표준 또는 내부 정책을 최신으로 유지하고 그러한 시스템의 이용이 현행 법률 및 규제 체계와 조직의 가치에 부합하는지 확인한다.
제품 서비스 개발 또는 그에 상응하는 부서	제품 서비스 개발 부서는 평가 목록을 활용해 AI 기반의 제품 및 서비스를 평가하고 모든 결과를 기록한다. 경영진 수준에서 이러한 결과에 대해 논의하고 궁극적으로 새롭거나 수정된 AI 기반의 응용 분야를 승인한다.
품질 보증	품질 보증 부서 (또는 그에 상응하는 부서)는 평가 목록의 결과를 확인하고 결과가 만족스럽지 않거나 예상하지 못한 결과가 탐지되는 경우 사안을 상부에 보고하는 조치를 취한다.
인사	인사 부서는 AI 시스템 개발자의 역량과 다양성이 적절히 조화를 이루도록 한다. 조직 내부에서 신뢰할 수 있는 AI에 대해 적절한 수준의 훈련이 제공되도록 한다.
조달	조달 부서는 AI 기반의 제품 또는 서비스 조달을 위한 절차에 신뢰할 수 있는 AI 점검이 포함되도록 한다.
일상적 운영	개발자와 프로젝트 매니저의 일상 업무에 평가 목록을 포함시키고 평가의 결과를 문서화한다.

자료: European Commission(2019. 4. 8.), p.25

마. 신뢰할 수 있는 인공지능 평가 목록의 활용

평가 목록을 실제적으로 활용할 때는 관심 영역뿐만 아니라 쉽게 답을 찾을 수 없는 질문들에 대해서도 주의를 기울일 것을 권장한다. 잠재적인 문제 중 하나는 인공지능을 개발, 시험하는 팀의 기술과 역량의 다양성 부족이며, 따라서 조직 내부 또는 외부의 다른 이해관계자들의 참여가 필요할 수도 있다. 기술적 측면과 관리 측면 모두에서 모든 결과를 기록하여 거버넌스 구조의 모든 수준에서 문제 해결에 대해 이해할 수 있도록 하는 것을 강력히 권장하고 있다. 이러한 평가 목록은 신뢰할 수 있는 인공지능을 달성하기 위한 이해 관계자들의 단순한 지침 역할이 주목적이며 구체적인 용례에 비례하여 평가를 맞춤 조정할 필요가 있다. 시범 실시 단계에서 구체적인 민감 영역이 드러날 가능성이 있고, 그러한 경우 다음 단계에서 추가적인 상세화의 필요성에 대한 평가가 이루어진다. 이러한 평가 목록은 제기된 문제를 해결할 수 있는 구체적인 해답을 제공하지는 않으나 신뢰할 수 있는 인공지능을 운용할 수 있는 방법과 그와 관련하여 취해야 하는 잠재적 조치에 대한 고찰을 촉진한다.

바. 기존 법률 및 절차와의 관련성

특정한 절차를 의무화하거나 특정한 결과를 금지하는 다양한 기존 법률이 존재하며 이것이 평가 목록에 수록된 조치들 중 일부와 중복될 가능성이 있다는 점을 인공지능 관계자들이 인식하는 것도 중요하다. 예를 들어 데이터 보호법에서는 개인 정보의 수집 및 가공에 관여하는 이들이 반드시 충족해야 하는 일련의 법적 요건에 대해 규정하고 있다. 그러나 신뢰할 수 있는 인공지능 또한 데이터의 윤리적 취급을 요구하고 있으므로, 데이터 보호법의 준수를 목표로 하는 내부 절차와 정책은 윤리적 데이터 취급을 촉진하는 데에 이바지하여 결과적으로 기존의 법적 절차를 이행하는 데에 도움을 줄 수 있다. 다만 이러한 평가 목록에 부합한다는 점이 법률 준수의 증거가 되지 않으며, 적용 가능한 법률의 준수를 담보하기 위한 지침의 역할을 할 의도를 갖고 있는 것도 아니다. 뿐만 아니라 인공지능 관계자들이 비법률적 기준의 준수를 담보하기 위한 기존의 평가 도구와 소프트웨어 개발 절차를 시행하고 있는 경우가 많다. 따라서 반드시 단독 평가로 시행할 필요는 없으며 기존의 실무에 포함시킬 수도 있다.

3. 일본

일본은 인공지능 윤리 지침과 관련해 학계, 기업, 비정부 조직 네트워크가 존재하고, 이를 바탕으로 2016년 말부터 인공지능 윤리와 관련된 개발 가이드라인과 사회원칙에 대한 논의를 시작하였다. 일본 정부는 2016년 인공지능 연구개발과 관련하여 「인공지능 R&D 안정성 확보 등 8대 원칙」을 발표하였고, 이어 2017년 4월 G7 장관 회의에서는 일본 총무성 산하의 인공지능 네트워크사회추진회의에서 관련 전문가의 의견수렴을 통해 설계한 「인공지능 연구개발 가이드라인」을 공개하였다(한국정보화진흥원, 2017.9.6.). 가장 최근인 2019년 3월에는 내각부가 인간중심 AI 사회원칙회의를 통해 작성된 「인간중심 AI 사회원칙(안)」을 발표하는데 인공지능의 중장기 연구개발과 활용에 있어 개발자와 사용자 등 다양한 이해관계자의 의견이 반영되었다고 평가받고 있다. 일본 정부가 최근 내놓고 있는 인공지능 가이드라인들의 특징은 '인간 중심의 원칙'을 내세우며 엄격한 개인정보보호와 보안을 강조한다는 점이며, 본 절에서

는 「인공지능 연구개발 가이드라인」과 가장 최근 발표된 「인간중심 AI 사회원칙(안)」에 언급된 내용을 주로 살펴보고자 한다.

가. 인공지능 연구개발 가이드라인¹⁶⁾

2017년 4월 일본 총무성이 G7 정보통신 장관회의에서 공개한 「인공지능 연구개발 가이드라인」은 인공지능이 정보통신 네트워크에 접속해 상호간 또는 이종 시스템과 연결되는 ‘네트워크화(Networked AI System)’를 전망하였다. 본 가이드라인에서는 이러한 네트워크화를 기반으로 인공지능을 통한 다양한 사회문제 해결이 가능해질 것으로 전망했다. 특히 향후 인공지능 네트워크와의 공생으로 데이터와 정보지식을 자유롭고 안전하게 창조, 유통, 연결하는 Wisdom Network Society를 실현하겠다고 언급하며, 1) 이익증진 및 올바른 개발, 2) 위험 완화, 3) 사용자의 수용성 향상 등 3가지 기준 및 9개 연구개발 원칙을 제시하고 있다.

〈표 4-3〉 일본 인공지능 연구개발 가이드라인 주요 내용

분류	원칙	설명
이익 증진 및 올바른 개발	협력성/연계성 (collaboration)	AI 시스템 간의 상호 연결성(inter-connectivity) 및 운용성(inter-operability)에 관한 원칙
위험 완화	투명성 (transparency)	AI 시스템 산출물의 검증(verifiability) 및 산출근거의 설명 가능성에 관한 원칙
	통제가능성 (controllability)	사용자의 AI 시스템 통제 가능성에 관한 원칙
	안전성 (safety)	사용자의 생명, 신체, 자산 등에 미치는 영향에 관한 원칙
	보안성 (security)	AI 시스템이 갖춰야할 신뢰성, 기밀성, 무결성 등의 보안 요소에 관한 원칙
	프라이버시 (privacy)	사용자의 사생활, 개인 정보 등을 침해하지 않음에 관한 원칙
	윤리 (ethics)	AI 시스템 연구개발에서 인간의 존엄성과 자주성 등이 고려되어야 함에 관한 원칙
사용자의 수용성 향상	사용자 지원성 (user assistance)	AI 시스템이 사용자에게 적절한 지원 방법을 제공해야 함에 관한 원칙
	책임성 (accountability)	AI 시스템 연구·개발자의 책임에 관한 원칙

자료: 금융보안원(2018.2.7.), pp1-2.

16) 일본 총무성 ‘AI네트워크 사회 추진회의(AI 네트워크社会推進会議)’(2017.7.28.), 「국제적 논의를 위한 인공지능 연구개발 가이드라인(国際的な議論のためのAI開発ガイドライン案)」을 요약·정리하여 작성

1) 이익 증진 및 올바른 개발

일본이 제시한 이익 증진 관련 연구개발 원칙으로는 연계의 원칙이 있다. 이에 따르면 인공지능 개발자는 자신이 개발하는 인공지능 시스템과 다른 인공지능 시스템 또는 이종 시스템 간의 상호 연결성 및 상호 운용성을 염두에 두어야 한다. 구체적으로, 인공지능 개발 시 다른 인공지능 시스템과의 상호 연결과 상호 운용을 장려하고 이에 따른 위험 요인이 고려되어야 함을 명시하고 있다. 즉, 일본 정부는 인공지능을 단순히 개별 기술의 구성요소가 아닌 전체적인 시스템적 관점에서 접근하고 있는데, 궁극적으로는 인공지능 네트워크화의 심화를 통한 Wisdom Network Society를 지향하고 인공지능 연구개발 역시 이에 부합해야 한다고 인식하고 있는 것이다. 가이드라인에서 제시한 내용을 구체적으로 살펴보면, 1) 개발자는 상호 연결성과 상호 운용성을 확보하기 위해 유효 정보를 공유하도록 노력해야하고, 2) 인공지능 제품 개발 시 존재하는 국제 표준이나 규격을 준용해야 하며, 3) 데이터 형식을 표준화하고 API 등 인터페이스나 프로토콜의 오픈소스화에 대응해야 한다. 마지막으로 4) 자신이 개발한 인공지능 시스템과 다른 시스템이 상호 연결될 때의 위험 요소를 파악해야 한다.

2) 위험 완화

가이드라인은 인공지능 연구 개발로 인한 위험을 제어하기 위한 원칙으로 1) 투명성의 원칙, 2) 통제 가능의 원칙, 3) 안전성의 원칙, 4) 보안성의 원칙, 5) 프라이버시의 원칙, 6) 윤리의 원칙을 제시하고 있다. 첫 번째로 투명성의 원칙부터 살펴보면, 인공지능 개발자는 사용자와 사회의 이해와 신뢰를 얻을 수 있도록 기술의 특성이나 용도에 맞게 데이터 입력과 결과 도출의 검증가능성, 결과의 설명 가능성에 주의하여야 한다. 두 번째 통제 가능의 원칙은 개발자가 인공지능 시스템을 통제할 수 있도록 유의할 것을 강조하고 있다. 이를 위해 통제 가능성과 관련해 사전 검증과 타당성 확인을 실시하도록 장려하고 있으며, 인공지능 통제 가능성을 보장하기 위해 적용 기술의 특성에 따라 인간 또는 신뢰 가능한 인공지능에 의한 모니터링, 인공지능 시스템 정지, 네트워크로부터 차단, 수리 등의 대처가 가능한지에 대해 실효성을 검토해야 한다고 언급하고

있다. 세 번째로 안전성의 원칙은 이용자와 제3자의 생명, 신체, 자산 등에 미치는 영향에 관한 내용을 담고 있다. 개발자는 인공지능이 액추에이터 등을 통해 가동될 때 본질적인 위험 요소를 저감시키고 부가적인 제어장치 등을 통해 안전성을 향상시키도록 개발과정에서 노력해야 한다. 또한 이용자와 제3자의 생명, 신체, 재산의 안전 등과 관련된 인공지능을 개발할 경우 당사자에게 해당 인공지능의 설계 취지와 이유를 설명할 수 있도록 노력해야 한다. 네 번째 보안성의 원칙은 인공지능이 갖춰야 할 신뢰성, 기밀성, 무결성 등의 보안요소에 관한 원칙이다. 정보의 기밀성, 완전성, 가용성 확보가 요구되고, 인공지능의 신뢰성이나 강건성(robust) 확보를 위한 노력도 필요하다. 동시에 개발자는 인공지능 개발 과정에서 시스템에 적용되는 기술의 특성에 맞춰 가능한 범위에서 보안 수준을 높이도록 노력(security by design)해야 한다. 다섯 번째 프라이버시의 원칙은 사용자의 사생활, 개인 정보 등을 침해하지 않는다는 원칙이다. 개발자는 인공지능의 프라이버시 침해 리스크를 평가하기 위해 미리 영향 평가를 실시하도록 노력해야 한다. 또한 인공지능 활용 시의 프라이버시 침해 위험을 최소화하기 위해 개발과정에서 적용 기술의 특징에 맞춰 프라이버시 조치를 강구하도록 노력(privacy by design)해야 한다. 마지막 윤리의 원칙은 인공지능 개발에 있어서 인간의 존엄과 자율을 존중해야 한다는 내용을 담고 있다. 특히, 인간의 뇌나 신체에 연계되는 인공지능을 개발하는 경우에는 생명 윤리에 관한 논의 등을 참고하여 인간의 존엄과 자율성을 침해하지 말아야 한다. 이와 더불어 인공지능 데이터에 포함되는 편견 등으로 부당한 차별이 생기지 않게 필요한 조치를 강구하도록 노력해야 한다.

3) 사용자의 수용성 향상

본 가이드라인에는 인공지능 사용자에 대한 논의도 다루고 있다. 구체적으로, 인공지능 관련 제품 및 서비스 사용자의 수용성을 향상시키기 위한 원칙이 포함되어 있는데, 첫 번째 원칙은 사용자 지원의 원칙이다. 개발자는 인공지능이 사용자의 판단에 필요한 정보와 선택의 기회를 적시에 제공하는 기능을 제공하도록 노력해야 한다. 또한 사용자의 인공지능 이용 편리성을 제고시키기 위해 이해하기 쉬운 선택사항 제시, 피드백 제공, 긴급 시 경고, 에러에 대한 대처 등 조작하기 쉬운 사용자 인터페이스를

제공하도록 노력해야 한다. 두 번째 원칙은 책임의 원칙이다. 개발자는 사용자를 포함한 이해관계자에 대해 책임을 다해야 한다. 개발된 인공지능의 기술적 특성을 사용자에게 충실히 설명하고 다양한 이해관계들로부터 의견을 청취하는 등 적극적으로 피드백을 받도록 노력해야 한다. 또한 개발자는 자신이 개발한 인공지능을 기반으로 제품 및 서비스를 제공하는 주체들과 정보를 공유하고 협력하도록 노력해야 한다.

나. 인간중심 AI 사회원칙(안)¹⁷⁾

「인간중심 AI 사회원칙(안)」은 2019년 3월 인간 중심의 AI 사회원칙 회의를 통해 발표되었다. 본 원칙안은 최우선 원칙으로 ‘인간중심’을 내세웠다. 즉, 인공지능이 인간의 기본적인 존엄과 인권을 침해해선 안된다는 점을 강조한 것이다. 또한 본 원칙안에서도 인공지능을 단독으로 사용되는 기술이 아니라 정보시스템의 일부로서 사용된다는 것을 전제로 원칙안을 제시하였다. 즉 인공지능을 둘러싼 윤리적 쟁점을 고려할 때도 ‘고도로 복잡한 정보시스템’이라는 특징 기반으로 사회에 주는 영향을 논의해야 한다고 주장하였다. 원칙안은 크게 기본 이념과 비전, 인공지능 사회원칙 그리고 인공지능 개발이용원칙으로 구성된다. 기본 이념에는 존엄성(dignity), 다양성과 포용성(diversity & inclusion), 지속 가능성(substantiality) 등 3가지 가치가 포함되어있는데, 첫 번째 가치인 존엄성은 인공지능이 인간을 제약하는데 이용되는 것이 아니라, 인공지능을 도구로 이용함으로써 인간의 창조성이 발현하거나 보다 보람 있는 일에 종사하는 등 인간의 존엄이 존중되는 사회를 구축해야 한다고 강조하고 있다. 두 번째 가치인 다양성과 포용성은 인공지능을 활용하여 다양한 배경과 가치관을 가진 사람들을 유연하게 포용해야 새로운 가치를 창조해 나갈 수 있음을 강조한다. 세 번째 가치인 지속가능성은 글로벌 환경문제와 기후변화, 양극화 등 사회 문제 해결과 지속가능한 ‘AI-Ready’사회를 구현하는데 인공지능이 활용되어야 한다고 언급하고 있다. 특히, 사람, 사회시스템, 산업구조, 혁신시스템, 거버넌스 등 5가지 관점에서 인공지능의 목적을 고려해야 한다고 밝히며, 단순히 인공지능 사용자와 개발자의 관점이 아닌 사회시스템, 산업구조, 혁신시스템 등 총체적인 관점, 사회적 관점에서 인공지능 윤리에

17) 일본 내각부(内閣府)(2019.3.29.), 「인간중심 AI 사회원칙(人間中心の AI 社会原則)」을 요약·정리하여 작성

대한 원칙을 제시하였다.

본 사회원칙(안)은 크게 7가지 원칙으로 구성된다. 그중 첫 번째 원칙은 인간중심원칙이다. 인간중심의 원칙의 내용은 인공지능의 이용 방향에 대한 원칙으로, 인공지능 사용이 인간의 기본권을 침해해서는 안 된다는 내용을 담고 있다. 즉, 인공지능이 인간의 행복 추구를 위해 사용되어야 하며 인간이 일자리를 빼앗기는 것이 아닌 인간의 능력과 창조성이 확대되는 방향으로 활용되어야 한다고 언급하고 있다. 또한 인공지능의 활용 결과에 대해서는 인공지능의 개발, 제공, 이용 등에 참여한 다양한 이해관계자들이 분담하여 책임져야한다고 명시하고 있다. 또한 인공지능의 사용이 정보약자 및 기술약자를 발생시키지 않도록 유의해야 한다고도 언급하고 있다. 두 번째 원칙은 교육, 리터러시(literacy) 원칙이다. 인공지능의 복잡성과 의도적인 악용 발생가능성에 대비해 사회구성원들이 인공지능 기술에 대해 정확히 이해하고 관련된 윤리적 원칙을 습득해야 한다. 구체적으로 누구나 인공지능 개발, 수리, 데이터 사이언스 요소를 습득할 수 있는 교육 시스템이 마련되어야 한다고 명시하며, 특히 리터러시 교육에는 데이터 편향성 등 인공지능의 한계에 관한 내용이 포함되어야 할 필요가 있다고 언급하고 있다. 세 번째 프라이버시 확보 원칙은 개인의 행동 등에 관한 데이터가 개인의 정치적 성향, 경제력, 취미와 기호 등을 내포할 수 있다는 것을 전제로, 개인의 프라이버시가 담긴 데이터가 본인이 원치 않는 형태로 유통되거나 이용되어 개인이 불이익을 받지 않도록 각 이해관계자는 데이터 취급에 있어서 주의를 기울여야 한다고 밝히고 있다. 특히 개인정보 데이터를 이용하는 인공지능 제품 및 서비스는 해당 데이터의 프라이버시와 관련해 정확성과 정당성을 확보하고 개인이 실질적으로 관여할 수 있는 절차를 가지고 있어야 한다. 병력, 범죄이력 등의 데이터를 이용할 경우 개인의 권리와 이익을 크게 침해할 수도 있기 때문에 문화적 배경이나 사회의 공통 이해를 토대로 이용 방안이 세밀하게 검토되어야 한다. 네 번째 원칙은 보안 확보 원칙이다. 이는 인공지능을 통해 사회의 안정성을 강화하고 의도적인 공격 등의 외부 위협에 대비해야 한다는 원칙이다. 구체적으로, 사회는 인공지능 이용에 따른 위협의 올바른 평가 및 위협을 줄이기 위한 연구를 추진하고, 사이버 보안을 포함한 리스크 관리 활동을 해 나가야 한다고 언급하고 있다. 이와 더불어 사회는 항상 인공지능 이

용이 지속가능할지에 대해 고민해야 하며 단일 또는 소수의 인공지능에 전적으로 의존해서는 안 된다고 밝히고 있다. 다섯 번째 원칙은 공정 경쟁 확보 원칙이다. 인공지능 기술을 기반으로 새로운 비즈니스와 서비스가 창출되기 위해서는 공정한 경쟁 환경이 유지되어야 한다는 것인데, 특정 국가나 기업 등에 인공지능 자원이 집중되고 지배적인 위치를 이용한 데이터 수집, 주권침해 등 불공정경쟁이 발생하지 않아야 한다고 명시하고 있다. 또한 부와 사회에 대한 영향력이 일부 이해관계자에게 부당하게 편중되는 사회가 되지 말아야 한다고도 밝혔다. 여섯 번째 원칙은 공평성, 설명 책임, 투명성 원칙이다. 이는 인공지능으로 인해 부당하게 차별을 받거나 인간의 존엄성이 침해당하지 않도록 공평성, 투명한 의사결정, 결과에 대한 설명책임이 적절하게 보장되고 기술에 대한 신뢰성(trust)이 담보되어야 한다는 원칙이다. 구체적으로, 인공지능 설계 단계에서는 인종, 성별, 국적, 연령, 정치적 신념, 종교 등을 이유로 차별을 받지 않아야 하고, 활용되는 데이터의 취득 및 사용 방법, 인공지능 동작 결과의 적절성을 담보하는 시스템 등 사용목적과 상황에 따른 적절한 설명이 이루어져야 한다. 마지막으로 산-관-학-민, 인종, 성별, 국적, 연령, 정치적 신념, 종교 등을 넘어 다양한 지식, 관점, 발상 등에 기반해 인재 양성 및 연구개발을 추진해야 한다고 밝히고 있다. 구체적으로 인재 양성 측면에서 대학, 연구기관, 기업간 대등한 협업/연계 및 유연한 인재의 이동을 촉진해야 하며, 인공지능 관련 품질 및 신뢰성 확인 관련 방법, 활용되는 데이터의 효율적인 수집 및 정비 방법, 인공지능 개발, 테스트, 운영 방법론 등 인공지능 공학을 수립하고, 윤리적 측면, 경제적 측면 등 폭넓은 학문 수립 및 발전이 추진되어야 한다. 데이터 수집에 있어서도 다양한 분야의 데이터가 독점되지 않고 국경을 넘어 효율적으로 이용될 수 있는 환경이 마련되어야 한다고 밝히고 있다. 그리고 마지막으로 이를 위해 정부는 인공지능 발전의 저해 요인이 되고 있는 규제 개혁 등을 추진해야 한다고 명시했다.

4. 중국

중국은 바이두, 알리바바, 텐센트 등의 IT 기업들이 인공지능 연구개발과 상용화를 주도하고 있지만 중국 정부가 국가 정책의 큰 틀을 기업에게 제시해 주기 때문에 인공

지능 안전성 및 윤리성 문제 역시 국가가 관할할 사안이다. 그러나 아직까지 중국 정부는 인공지능 윤리와 규범 제정에 상대적으로 유보적인 입장을 취하고 있으며, 최근 에야 인공지능 윤리 가이드라인 마련을 위한 조직을 구성하는 등 초기 단계에 머물러 있다. 2017년 발표된 「차세대 인공지능 발전계획」에서도 인공지능에 대해 실용주의적 입장을 표하며 기술발전 단계에 따라 인공지능 윤리를 정립하겠다고만 언급하였다. 본 절에서는 「차세대 인공지능 발전계획」과 최근 발표된 「베이징 인공지능 컨센서스」에서 언급된 내용들을 주로 살펴보고자 한다.

가. 차세대 인공지능 발전계획¹⁸⁾

2017년 7월에 수립된 「차세대 인공지능 발전계획」은 인공지능 연구개발, 산업화, 인재 육성, 교육, 표준 설정, 규정, 윤리적 규범 등을 포괄한 전략을 제시하고 있다. 본 계획에서 중국은 2030년까지 인공지능 이론, 기초기술, 응용 등의 전 분야에서 선도국 지위에 도달하겠다는 비전을 가지고 중장기 목표로 1) 2020년까지 인공지능 종합 기술과 응용 기술에서 세계 선진 수준에 도달, 2) 2025년까지 인공지능 기초이론을 실현하고 스마트 사회 건설을 제시하였다. 동시에 기술의 발전 단계에 따른 윤리 규범과 법률 제도 구축을 위한 기본 목표를 제시하였으며, ‘보장조치’의 형태로 국가 차원의 행동방침을 제시하였다. 먼저 본 계획에서 제시한 인공지능 윤리규범과 법제도 마련의 구체적인 전략 단계를 살펴보면, 1) 2020년까지 인공지능 윤리규범과 정책 법규의 토대를 마련하고, 2) 2025년까지 기술적으로 인공지능 안전평가 및 관리통제 능력을 확보하며 제도적으로 인공지능 법규와 윤리규범 정책에 대한 기초를 구축하겠다고 밝혔다. 그리고 마지막으로 3) 2030년 인공지능 법률과 윤리규범정책 등 제도적 정비를 완료하겠다는 목표를 제시하였다. 동시에 본 계획에서는 1) 인공지능 혁신체계 구축, 2) 산업 발전 환경 구축, 3) 안전한 스마트 사회 건설, 4) 스마트 인프라 구축 등 인공지능 선도국이 되기 위한 4가지 중점 임무를 제시하였다. 이중 스마트 인프라 구축의 세부 과업에 인공지능 기초 데이터 및 안전 검사 플랫폼 개발과 인공지능 알고

18) 국무원(国务院) 홈페이지(2017.7.8.). 「국무원 차세대 인공지능 발전계획 통보(「国务院关于印发新一代人工智能发展规划的通知」)」를 요약·정리하여 작성

리즘과 플랫폼의 안정성 평가 기술을 확보하겠다는 내용이 포함되어 있다. 이와 더불어 중점 임무 달성을 위한 ‘6대 보장조치’를 제시하였는데, 인공지능이 초래할 수 있는 위험에 적절히 대응하고 인공지능 기술의 발전에 따라 사회적으로 필요한 제도적 장치 마련에 초점을 맞추고 있다. 인공지능 안정성과 투명성 관점에서 해당조치를 살펴보면, 1) 인공지능 발전 촉진 관련 법률 법규 및 윤리규범 제정, 2) 인공지능 안전감독관리와 평가시스템 구축 등이 직접적으로 연관되어 있음을 알 수 있다.

<표 4-4> 중국 차세대 인공지능 발전계획 6대 보장조치

내 용
(1) 인공지능발전 촉진 관련 법률법규 및 윤리규범 제정
(2) 인공지능발전 지원 관련 중점정책 보완
(3) 인공지능기술표준과 지식재산권 시스템 구축
(4) 인공지능 안전감독관리와 평가시스템 구축
(5) 인공지능 노동력 훈련 대폭 강화
(6) 인공지능 과학보급 활동 추진

자료 : 국무원(国务院) 홈페이지

1) 인공지능발전 촉진 관련 법률법규 및 윤리규범 제정

인공지능발전 촉진관련 법률법규 및 윤리규범 제정과 관련하여 본 계획에서는 1)법률적 기반마련, 2)인공지능 연구개발, 3)인공지능 위험대비, 4)국제협력 등 4가지 방향에서의 제도마련 계획을 제시하고 있다. 먼저, 중국정부는 인공지능과 관련된 법적, 윤리적, 사회적 이슈에 대한 연구를 지속적으로 강화하겠다고 명시하였다. 궁극적으로는 이를 바탕으로 법률을 제정하고 윤리적인 가이드라인을 수립하여 인공지능 기술의 발전을 보장할 것이라고 밝혔다. 이를 위해 중국 정부가 본 계획에서 우선적으로 명시한 법률상 이슈는 1) 인공지능 응용 프로그램과 관련된 민사 및 형사 책임 구분, 2) 개인정보보호, 정보보안 등 활용과 관련된 법적 문제에 대한 조사 수행, 3) 추적가능

하고 책임을 명확화 할 수 있는 법제시스템 구축, 4) 인공지능 관련 권리, 의무 및 책임에 대한 주체 명확화, 5) 자율주행 및 서비스 로봇과 같은 핵심 응용분야의 안전관리 규정 연구 및 개발 가속화와 동시에 신기술의 신속한 상용화를 위한 법적 기반 마련 등이다. 특히, 현재 상용화를 앞두고 있는 자율주행과 서비스 로봇과 같은 응용분야의 안전관리 규정을 우선적으로 제정하여 제도적으로 신기술의 시장 도입을 지원할 것으로 보인다. 두 번째로, 인공지능 연구개발과 관련해서는 1) 윤리이슈에 대한 단계별 판단 체계를 구축하고, 2) 인간-컴퓨터 협업을 위한 기본적인 윤리적 틀을 마련하며, 3) 인공지능 제품의 연구개발을 위한 윤리 및 행동 강령 개발하겠다고 밝혔다. 세 번째로 인공지능의 잠재적 위험에 대해서는 1) 인공지능의 잠재적 위험과 이익에 대한 평가 체계를 강화하고, 2) 인공지능의 복잡한 시나리오에서 예상치 못한 사건 대한 해결방안을 구축하겠다고 밝혔다. 마지막으로 인공지능 윤리 규범 제정에서는 국제적인 협력을 강화하겠다고 밝혔는데, 인공지능의 글로벌 거버넌스에 적극적으로 참여하고 인공지능의 위험과 관련된 공통 문제에 대한 연구를 강화하겠다고 밝혔다. 동시에 인공지능 법규 및 국제규범 등에 관한 국제협력 확대하여 글로벌 과제 해결을 위해 협력하겠다고 언급하였다.

2) 인공지능 안전 감독관리와 평가 시스템 구축

본 계획에서 다루고 있는 인공지능의 전반적인 안전관리와 평가시스템 구축에 대한 가이드라인은 인공지능의 안전성 문제를 직접적으로 다루고 있다. 우선 인공지능이 국가 보안과 기밀자료에 미치는 영향에 대한 연구 및 평가를 강화하겠다고 밝혔는데, 구체적으로 인력, 기술, 자원, 제도를 축으로 하는 안전 관리시스템을 구축·보완할 계획이다. 동시에 인공지능 안전성과 관련한 모니터링 및 조기 경보 시스템을 구축하고 연구개발 방식 측면에서 인공지능 기술 발전 예측 및 추적 연구를 강화하고 문제해결을 지향하는 연구개발을 장려하겠다고 밝혔다. 또한 인공지능 설계, 제품 및 시스템의 복잡성, 위험, 불확실성, 해석가능성, 경제적 영향 등에 대한 체계적인 테스트 방법 및 지표 시스템을 개발해 인공지능 테스트 플랫폼으로 구축하겠다고 밝혔다. 사회적인 측면에서는 인공지능의 위험 인지, 평가, 예방의 중요성을 강조하며 관련 기술의 위험

예방 및 제한 지침을 강화하겠다고 밝혔다. 단기적으로는 인공지능이 고용에 미치는 영향에 중점을 두고 대응하고 장기적으로는 사회에 미치는 전반적인 영향을 고려해 안전하고 제어 가능한 범위의 인공지능 연구개발을 장려하겠다고 밝혔다. 관리시스템 측면에서는 개방적이고 투명한 시스템 구축을 추구하고 있다. 구체적으로, 알고리즘 설계의 책임성과 응용프로그램 감독에 중요성을 부여한 2단계 규제 구조를 구현하겠다고 밝히며 이를 통해 인공지능의 알고리즘 설계, 제품 개발, 결과로 이어지는 전체 프로세스를 감독하겠다고 언급하였다. 상용화와 관련해서는 인공지능 관련 기업의 자체적인 규율을 촉진하여 실질적인 관리를 강화하는 한편, 데이터 악용, 개인 사생활 침해, 도덕 및 윤리 위반에 대한 처벌 수위를 강화하겠다고 언급하였다.

나. 베이징 인공지능 컨센서스 (BEIJING CONSENSUS on AI)¹⁹⁾

2019년 5월 25일 중국 과학기술부와 베이징시 정부가 지원하는 북경지원연구원(北京智源研究院)이 「베이징 인공지능 컨센서스」를 발표하였고, 동시에 연구소 산하의 인공지능 윤리 및 안전 연구센터(伦理与安全研究中心)를 공개하였다(北京智源研究院 홈페이지(2)). 또한 본 원칙안 설계에 북경대학교, 칭화대학교, 중국과학원 자동화연구소, 중국과학원 컴퓨팅기술연구소 등이 공통으로 참여했다고 밝혔다(北京智源研究院 홈페이지(2)). 발표된 문건에는 인공지능 연구개발, 활용, 거버넌스 등 3개 영역에서 15개의 원칙이 포함되어있다. 구체적으로 인류의 이익과 복지를 증진하기 위한 인공지능 연구개발, 잠재적인 인공지능의 윤리적 위험에 대한 책임 등을 다루고 있다. 특히 잠재적인 인공지능의 윤리적 위험에 대한 책임에서는 인간의 사생활, 존엄, 자유, 자율성과 권리 등이 충분히 존중되어야 한다고 설명하고 있는데, 이는 기존에 미국과 EU 등에서 발표한 내용과 부합하는 수준으로 평가받고 있다(MIT Review, 2019.5.31.).

19) 北京智源人工智能研究院 홈페이지(1)(2019.5.25.), 「베이징 인공지능 컨센서스(「人工智能北京共识」)」를 바탕으로 요약 · 정리

1) 인공지능 연구개발

인공지능 연구개발 분야에서는 7가지 원칙이 제시되었다. 첫 번째 원칙은 좋은 의도의 원칙이다. 인공지능은 사회와 인간 문명의 발전, 자연과 사회의 지속 가능한 발전을 촉진하며 모든 인류와 환경에 이익을 주고 사회와 생태계의 안녕을 향상시키기 위해 설계되고 개발되어야 한다는 내용이다. 두 번째 원칙은 인공지능 연구개발은 인류의 전반적인 이익뿐만 아니라 인간의 가치에 부합해야 한다는 것이다. 이에, 인간의 사생활, 존엄성, 자유, 자치권 등의 권리는 충분히 존중되어야 하고 인간을 활용하거나 해를 가하는 데 사용되어서는 안 된다. 세 번째 원칙은 책임이다. 인공지능 개발자는 인공지능 제품 및 서비스가 가져올 잠재적인 윤리적, 법적, 사회적 영향과 위험에 대해 충분히 고려해야 하며 이를 감소하거나 방지하기 위한 구체적인 조치를 마련해야 한다. 네 번째는 위험 통제의 원칙이다. 인공지능의 견고성, 신뢰성, 제어 가능성을 제고하기 위해 데이터 보안, 시스템 안전 및 보안 측면에서 지속적인 노력을 기울여야 한다. 다섯 번째 원칙은 윤리성이며, 사람들이 인공지능을 신뢰할 수 있도록 윤리적 설계 접근 방식을 취해야 한다는 내용이다. 공정한 시스템 만들기, 차별 및 편견 가능성 감소, 투명성, 설명가능성, 예측가능성 향상, 시스템추적 가능성, 감시가능, 책임성 등이 포함된다. 여섯 번째 원칙은 다양성과 포괄성이다. 인공지능 개발 과정에는 다양성과 포괄성이 적용되어야 하고 가능한 많은 사람들, 특히 인공지능 분야에서 소외되는 사람들에게 이익이 되도록 설계되어야 한다. 마지막 원칙은 개방과 공유이다. 데이터와 플랫폼 독점을 경계하고 인공지능 개발의 이점을 최대한 공유하며 각기 다른 지역 및 산업에 대해 동등한 개발 기회를 촉진하기 위해 인공지능 오픈 플랫폼을 구축하는 것을 권장한다.

2) 인공지능 활용

인공지능의 활용과 관련해서는 3가지 원칙이 제시되고 있는데, 첫 번째는 현명하고 올바른 활용이다. 인공지능 시스템을 사용하는 사람은 작동에 필요한 지식과 능력을 갖추고 있어야 할 뿐 만 아니라 오용과 남용의 잠재적 영향을 충분히 이해하여 위험을

회피해야 한다. 두 번째는 정보 제공 동의의 원칙이다. 인공지능 활용 시 자신의 권리와 이익에 미치는 영향에 대해 충분한 정보를 주고 동의를 얻어야 하며, 예상치 못한 상황이 발생하면 사용자의 권리와 이익이 침해당하지 않도록 합당한 데이터 및 서비스 철회 절차를 수립해야 한다. 세 번째는 교육 및 훈련의 원칙이다. 인공지능 관련 이해관계자들은 인공지능 개발이 심리적, 정서적, 기술적 측면에 미치는 영향에 적응하도록 교육과 훈련을 받을 수 있어야 한다.

3) 인공지능 거버넌스

인공지능 거버넌스와 관련해서는 5개의 원칙이 제시되었다. 첫 번째는 고용 최적화이다. 인공지능 거버넌스는 일자리에 대한 인공지능의 잠재적 영향력에 대해 포용적인 태도를 취해야한다고 밝히고 있다. 동시에 인공지능 기술 활용을 통해 인간의 장점과 특성을 충분히 발휘할 수 있도록 인간과 인공지능의 관계에 대한 새로운 형태의 연구가 장려되어야 한다. 두 번째 원칙은 조화와 협력이다. 인공지능 거버넌스는 학제간, 산업간, 지역간, 국가간 등 포괄적인 거버넌스 생태계를 구축하기 위해 협력해야 한다. 세 번째는 정부의 정책 및 규정이 인공지능 개발에 따라 적극적으로 개정되어야 한다. 이에, 인공지능 거버넌스는 인공지능 기술의 적절한 활용을 방해하지 않아야 한다. 네 번째는 인공지능 응용 분야에 대한 구체적이고 세부적인 가이드라인 수립이다. 이는 인공지능 연구개발과 응용의 전체 프로세스를 고려하여 제정되어야 한다. 마지막은 장기적으로 어그멘티드 인텔리전스(Augmented Intelligence)와 초지능(Superintelligence)의 잠재적 위험에 대한 연구를 지속해야 한다.

4) 연구개발 분야

인공지능 윤리 및 안전 연구센터에서는 향후 추진할 연구개발 분야를 공개하였는데, 첫 번째 연구개발 분야는 저위험 기계학습모델 및 플랫폼의 구축, 기계학습모델의 안전평가시스템의 확립, 기타영역과 결합된 검증 플랫폼 구축 등이다. 두 번째 연구개발 분야는 실제 현장에서 검증 가능한 윤리적인 자기 학습 모델 개발이다. 세 번째로

발표한 연구개발 분야는 데이터보안 데모 응용프로그램 시스템 구축이며, 이와 더불어 데이터분류, 권한제어, 데이터 모니터링을 수행 할 수 있는 메커니즘과 컴퓨팅 플랫폼 구축도 제시하였다. 마지막으로 안전성, 공정성, 추적가능성, 데이터, 알고리즘, 인공지능 제품과 애플리케이션의 영향과 범위를 포함하는 보안 샌드박스 플랫폼을 개발하여 포괄적인 위험 및 안전성 테스트 및 평가시스템을 구축하겠다고 밝혔다.

5. OECD AI 권고안²⁰⁾

OECD AI 권고안(Recommendation of the Council on Artificial Intelligence)은 OECD 각료이사회(Ministerial Council Meeting)에서 2019년 5월 공식적으로 선정되었다. 본 권고안은 OECD 36개 회원국과 6개의 비회원국, UN, IMF 등 국제기구의 대표들이 협의를 통해 선정한 인공지능 안전과 윤리 관련 국제간 권고안이라는 점에서 향후 전 세계적으로 미치는 파급력이 상당할 것으로 보인다. OECD는 2016년 인공지능 기술전망포럼(Technology Foresight Forum on AI)과 2017년 인공지능 컨퍼런스(Conference on Artificial Intelligence - AI: Intelligent Machines, Smart Policies) 등 다년간 인공지능 정책 수립을 위한 논의들을 지속해왔다. OECD는 2018년 디지털경제정책위원회(Committee on Digital Economy Policy) 정기 회의에서 OECD 차원의 인공지능 권고안을 수립하기로 결정하였고, 2018년 9월부터 6개월간 4차례의 회의를 통해 의견을 수집하였다. 이후 권고안의 초안 작성을 위해 2019년 OECD 인공지능 전문가 그룹(OECD Expert Group on AI)을 구성하였고, 작성된 권고안 초안이 2019년 5월 OECD 장관급 회의에서 채택되었다. OECD 권고안에 동의한 42개국과 국제기구는 해당 권고안을 따르겠다는 의지를 보여주는 것으로 간주된다.

본 권고안은 AI 시스템, AI 시스템 수명주기, AI 지식, AI 활동주체, 이해관계자 등에 대한 용어정리와 신뢰가능한 AI 구현을 위한 5가지 원칙(Principles for responsible stewardship of trustworthy AI)과 5가지 국가정책 및 국제 협력

20) OECD(2019.5), "Recommendation of the Council on Artificial Intelligence"; 한국정보화진흥원(2019), 「신뢰 가능 AI 구현을 위한 정책 방향」을 포괄 인용하여 작성

(National policies and international co-operation for trustworthy AI)으로 구성되어있다. 특히 본 권고안의 5가지 원칙은 인공지능 분야의 변화 속도를 고려하여 장기적으로 지속될 수 있는 원칙으로 구성되었다.

1) 5가지 원칙

OECD는 첫 번째 원칙으로 ‘인류의 포용성장과 지속가능 발전, 복지 증진(Inclusive growth, sustainable development and well-being)’을 포함한다. 본 원칙은 인공지능과 관련된 이해관계자는 궁극적으로 인류의 포용 성장과 지속 가능한 발전, 인간의 복지 증진을 위한 인공지능 구현을 추구해야한다고 촉구한다. 이를 위해 관련 이해관계자는 소수집단을 포용하고, 인간의 창의성과 능력을 증진시키는 방향으로 인공지능을 구현하도록 노력해야 한다고 언급한다. 또한, 인류의 경제적, 사회적 불평등을 완화하고 자연을 보호하여 궁극적으로 포용적이고 지속가능한 발전 방향으로 인공지능을 구현해야 한다고 밝히고 있다.

두 번째 원칙은 ‘인간중심 가치와 공정성(Human-centred values and fairness)’ 지향이다. 본 권고안은 인공지능 관련 행위주체는 인공지능이 구현되는 전주기(AI system life cycle)에 걸쳐 법률, 인권, 민주적 가치 등을 존중해야 한다고 촉구한다. 이러한 가치는 자유, 존엄성, 개인 데이터(Private data) 보호, 차별 금지, 평등, 다양성, 공정성, 사회 정의, 국제적으로 통용되는 인권 등을 포함한다. 권고안에서는 이를 위해 인공지능 행위자는 인간의 최종적인 결정권 등과 같은 최신 기술을 반영하고 상황에 적합한 안전장치를 설계하고 구현해야고 밝히고 있다.

세 번째 원칙은 투명성과 설명가능성(Transparency and explainability)이다. 본 권고안에 따르면 인공지능 행위자는 투명성을 높이고 인공지능 시스템(AI system)에 대한 이해를 증진시킬 수 있도록 노력해야 한다. 이를 위한 최신의 의미 있는 정보와 전체적인 맥락을 설명할 수 있는 정보를 제공하도록 해야 한다고 제시하고 있다. 구체적으로 인공지능 이해관계자는 인공지능 시스템에 대한 전반적인 이해를 촉진해야 하며, 인공지능 시스템과의 상호작용을 인지할 수 있어야 한다고 언급한다. 이와 더불어 본 권고안은 인공지능 시스템의 결과에 대해 이의를 제기할 수 있어야 하며, 예측과

추천, 결정의 근거가 되는 논리에 대한 설명을 요구할 수 있어야 한다고 밝힌다.

네 번째 원칙은 견고성, 보안과 안전(Robustness, security and safety) 확보이다. 권고안은 인공지능 시스템은 인공지능 시스템의 전주기 사이클에 걸쳐서 견고성과 보안성, 안전성이 확보되어야 한다고 언급한다. 즉 정상적인 사용과 더불어 오용 또는 기타 불리한 조건에서도 적절하게 작동하고 비합리적인 안전 위험을 초래하지 않도록 작동되어야 한다고 제시한다. 이를 위해 인공지능 행위자는 인공지능 시스템 수명주기 동안 이루어진 데이터셋과 프로세스 및 의사결정 등에 추적성(traceability)을 보장하고 인공지능 시스템의 결과와 질의에 대한 응답이 전체 문맥에 적절하고 일관성 있게 유지되고 있는지에 대해 분석이 가능해야 한다고 언급하고 있다. 본 권고안에 따르면 인공지능 행위자는 자신의 역할, 상황, 역량에 따라 인공지능 시스템 수명주기의 각 단계에서 개인정보침해, 보안, 안전 등과 관련된 위험을 처리하기 위해 체계적인 위험 관리 방식을 적용해야 한다.

마지막 원칙은 책임(Accountability)이다. AI 행위자는 인공지능 시스템이 적절히 기능하도록 자신의 역할, 상황, 기술을 최신성 등을 고려하여 위의 원칙을 존중해야 한다고 촉구하고 있다.

2) 국가정책과 국제협력

OECD는 국가정책과 국제협력을 위한 5가지 원칙을 발표하였으며 본 원칙들을 국가정책과 국제협력에서 이행하도록 권고하였다. 첫 번째 원칙은 인공지능 연구개발 투자(Investing in AI research and development)이다. 권고안은 정부는 연구 개발에 장기적인 공공 투자와 학제간 연구를 포함한 민간투자를 장려해야 한다고 밝히고 있다. 이를 통해 사회적, 법적, 윤리적 함의 및 정책에 중점을 둔 신뢰할 수 있는 인공지능 혁신을 촉진해야 한다고 언급한다. 또한 권고안은 정부는 개인정보보호를 준수하는 공개 데이터셋에 대한 민간 투자를 장려해야 한다고 제시한다. 이와 더불어 편견으로부터 자유로운 인공지능 연구 및 개발 환경 조성을 지원하고 상호 운용성과 표준의 사용을 개선해야 한다고 밝히고 있다.

두 번째 원칙은 인공지능 디지털 생태계 조성(Fostering a digital ecosystem for

AI)이다. 권고안은 각국 정부가 신뢰할 수 있는 인공지능 구현을 위한 디지털 생태계의 조성 및 접근을 촉진해야 한다고 밝히고 있다. 이러한 인공지능 디지털 생태계는 디지털 기술과 인프라, 인공지능 지식을 공유하기 위한 메커니즘이 포함된다. 이와 관련하여 정부는 데이터의 안전, 공정하며 합법적이고 윤리적인 데이터의 공유를 지원하기 위해 데이터 트러스트(data-trusts)와 같은 메커니즘을 촉진해야 한다고 언급한다.

세 번째 원칙은 실현 가능한 인공지능 정책 환경 조성(Shaping an enabling policy environment for AI)이다. 권고안은 정부는 연구 개발 단계에서 신뢰할 수 있는 인공지능 시스템의 운영 및 배치 단계로 전환을 지원하는 환경을 조성해야 한다고 제시한다. 이를 위해 인공지능 시스템을 테스트하고 확장(Scale up) 할 수 있는 환경을 제공하도록 고려할 것을 촉구한다. 또한 정부는 신뢰할 수 있는 인공지능의 혁신과 경쟁을 촉진하기 위해 인공지능 시스템에 적용가능한 정책 및 규제, 평가 메커니즘을 검토하고 조정해야 한다고 밝히고 있다.

네 번째 원칙은 인적 역량 구축 및 노동 시장 전환 준비(Building human capacity and preparing for labour market transformation)이다. 권고안은 정부가 관련 이해관계자와 협력하여 노동 시장과 사회의 변화를 준비해야 한다고 언급한다. 구체적으로 향후 필요한 기술을 보완하여 광범위한 응용 프로그램에서 인공지능 시스템을 효과적으로 사용하고 상호 작용할 수 있도록 해야 한다고 언급하고 있다. 예를 들어 정부는 인공지능 적용 시 노동시장변화에 대비하여 훈련 프로그램과 인공지능으로 대체된 인력에 대한 지원 및 노동 시장의 새로운 기회에 대한 접근 보장과 같은 조치를 마련해야 한다고 언급한다. 또한 권고안은 정부가 관련 이해당사자와 긴밀히 협력하여 직장에서의 책임 있는 인공지능의 사용을 촉진해야 한다고 제시한다. 이를 통해 근로자의 안전과 직업의 질, 기업가정신, 생산성 등을 향상시키고 인공지능의 혜택이 광범위하고 공정하게 공유되도록 해야 한다고 밝히고 있다.

다섯 번째 원칙은 신뢰할 수 있는 인공지능 구현을 위한 국제 협력(International co-operation for trustworthy AI)이다. 권고안은 개발도상국과 이해당사자들을 포괄하여 정부는 신뢰할 수 있는 인공지능의 책임 있는 발전을 위해 적극적으로 국제 협력을 해야 한다고 언급한다. 구체적으로 정부는 인공지능 지식 공유를 장려하기 위

해 OECD 및 기타 세계 및 지역 포럼에서 협력하는 것을 장려해야 한다고 밝히고 있다. 또한 권고안은 정부가 장기적인 인공지능 관련 전문 지식을 얻기 위해 국제적이고 개방된 이니셔티브를 장려해야 한다고 언급한다. 이와 더불어 정부는 신뢰가능한 인공지능에 대한 상호 운용성이 뛰어난 글로벌 기술표준 개발을 장려해야 한다고 제시하고 있다. 또한, 정부가 인공지능 연구 개발을 측정하고 원칙의 이행정도를 평가하기 위해 국제적으로 비교 가능한 지표의 개발 및 사용을 장려해야 한다고 언급한다.

6. 시사점

본 절에서는 주요국 정부의 대응 동향을 살펴보았다. 앞서 살펴본 문건들은 공통적으로 인공지능의 확산을 저해하는 안전성 문제를 해결하고 사회적으로 신뢰할 수 있는 인공지능을 개발하고 활용을 위한 지침을 제시하고 있다. 이와 동시에 인공지능이 야기할 수 있는 사생활침해 등의 윤리적 문제에 대해 ‘인간중심’의 원칙을 내세우며 인공지능이 윤리와 사회적 원칙에 부합되게 개발되도록 장려하고 있다. 앞서 살펴본 문건에 따르면 각국이 유사한 정책적 대응 양상을 보이고 있다. 기본적으로 포용성과 지속가능성, 인간가치와 공정성, 투명성과 설명가능성, 강인성과 안전성, 책임성 등을 원칙으로 제시하며 매우 포괄적인 수준에서 가이드라인을 제안하고 있다. Financial Times에 보도에 따르면, 2018년에만 26개국이 국가 AI전략을 수립했다. 인공지능 기술의 빠른 발전에 따라 점차 많은 국가가 인공지능 윤리와 안전성에 대해 언급하고 있지만, 현재까지는 인간의 권리가 보호되어야한다는 일반적인 선언에 불과하다. 대다수의 가이드라인과 원칙에서 언급되는 것처럼 각국정부는 제도적, 법률적 대응이 인공지능 기술의 활용을 억제하는 것을 우려하고 있다. Financial Times는 이를 두고 인공지능 혁신을 위한 경쟁이 기본권 보호를 무색하게 하고 있다고 지적한다 (Financial Times, 2019.4.25.). 특히, EU, 일본이 발표한 가이드라인은 AI 개발자를 비롯해 기업과 사용자 등 이해당사자에 적용하여 인공지능을 규제하기보다는 사회적 투명성을 높여 궁극적으로 인공지능 관련 산업을 강화한다는 것이 핵심이다. 즉, 주요국들은 현재 인공지능 기술이 발전과정에 있는 것을 감안하여 규제도입을 목적으로 가이드라인을 제시하는 것이 적절치 않다는 입장이다.

이처럼 인공지능 관련 규제마련, 법률 개정 등 정책적인 대응에는 소극적인 입장을 보이고 있지만 미국과 중국을 중심으로 안전성 확보를 위한 기술적 대응에는 적극적인 움직임을 보이고 있다. 앞서 살펴보았듯이, 미국 DARPA는 AI Next Campaign 인을 통해 새로운 역량(New capabilities), 강인한 인공지능(Robust AI), 적대적 인공지능(Adversarial AI), 고성능 인공지능(High performance AI), 차세대 인공지능(Next generation AI) 등 5개 분야에서 기존 인공지능의 한계와 안정성 문제를 뛰어넘기 위한 연구개발을 추진하고 있다. 중국 역시 독자적으로 인공지능관련 윤리와 안전 문제를 연구하는 인공지능 윤리 및 안전 연구센터(伦理与安全研究中心)를 개설하고 저위험 기계학습모델 및 플랫폼의 구축, 기계학습모델의 안전평가시스템의 확립, 인공지능 제품과 애플리케이션을 포괄하는 보안 샌드박스 플랫폼 구축을 위한 연구를 진행하고 있다.

제2절 국내 기업·정부·학계 대응 동향²¹⁾

1. 기업 대응 동향

국내 기업의 대응 동향을 살펴보면, 카카오, 삼성전자 등 일부 대기업들은 자율적으로 인공지능 윤리·안전 원칙을 정비하고 있으나, 아직은 구체적인 실행 사항보다는 총론적인 차원에서 준비되고 있다. 인공지능 의료기기 분야 등 인공지능을 적용한 제품의 신뢰성 확보가 판매 허가의 선결과제인 산업에서는 규제 당국과 함께 긴밀하게 협조하면서 인공지능의 안전성 측면에서 구체적 진전을 만들기 시작하고 있다.

가. 카카오

카카오는 자사의 플랫폼을 활용하여 인공지능 서비스를 생활 서비스에 접목하고 있다. 카카오의 인공지능 플랫폼인 카카오는 음성 엔진(음성 인식·합성 기술), 시각 엔

21) 이하 내용은 소프트웨어정책연구소 한상열 선임연구원의 자문을 받아 작성하였음.

진(시각·사물 인식 기술), 대화 엔진(자연어 처리 기술, 챗봇), 추천 엔진(빅데이터 및 머신러닝 기반 추천 기술), 번역 엔진(다국어 번역 처리 기술) 등 다양한 인공지능 기술을 포함하고 있으며, 이 기술들은 카카오의 뉴스, 검색, 내비, 미디어, 인공지능 스피커 등 다양한 서비스에 적용되고 있다. 2017년에는 다양한 인공지능 연구 활동을 지원하기 위해 인공지능 전문 자회사 ‘카카오브레인 인공지능연구소’를 설립하였다.

카카오는 국내 업계 최초로 2018년 1월 31일 개발자들이 알고리즘 설계 시 준수해야 할 사항을 명문화한 “인공지능 알고리즘 윤리 헌장”을 발표하였다(조원영, 2019.4.). 기업의 사회적 책임과 내부 윤리적 기준을 확립하고자 하는 차원에서 내부 직원 의견 수렴하였으며 2017년 9월부터 시작된 연구 및 논의를 거친후에 알고리즘 윤리 관련 주요 논의 과제로 “의도적 차별성”, “데이터 수집 및 관리 측면의 윤리성 부재”, “통제 불가능성”, 그리고 “불투명성”을 도출하였다(표 4-5 참조).

〈표 4-5〉 윤리문제 측면에서 알고리즘과 관련된 주요 논의 주제

논의 주제	내용
1. 의도적 차별성	- 알고리즘의 결과값에 대해 알고리즘의 개발 및 운영 주체가 의도적으로 차별적인 결과가 나오도록 개입을 했는지에 대한 우려가 존재 - 의도적 차별성은 특정 가치 중심으로 편향된 결과값으로 연결될 수 있다는 측면에서 편향성으로도 거론
2. 데이터 수집 및 관리 측면의 윤리성 부재	대개 알고리즘 학습에 쓰이는 학습 데이터는 개인의 일상 기록이거나 그와 관련이 있는 자료이므로 데이터 수집 및 관리 측면에서 높은 윤리 인식 요구
3. 통제 불가능성	- 악의적 의도가 반영된 알고리즘이 인간 통제를 벗어난 상태가 되어 인류에 해를 끼칠 수 있는 개연성에 대한 우려가 존재 - 동일한 맥락에서 AI의 알고리즘 개발 및 운영의 전 과정이 관련 주체에 의해 통제되어야 한다는 의견이 제기 중
4. 불투명성	- 알고리즘의 원리와 작동 방식에 대한 설명의 필요성을 강조하는 차원에서 불투명성이 문제로 제기 중이나, 설명 범위의 타당성에 대해서는 사회적으로 의견이 분분한 상황 - 상황 맥락을 이해할 수 있는 정보의 제공은 상품 혹은 서비스의 이용자에게 제공되어야 한다는 조건으로 거론 중

자료: 카카오(2018.1.), 내용 일부 재정리

이러한 배경에서 제시된 카카오의 알고리즘 윤리 현장은 인공지능을 인류의 편익과 행복을 추구하는데 활용한다는 대원칙 하에 차별에 대한 경계, 학습 데이터 운영, 알고리즘 독립성, 알고리즘에 대한 설명 의무 등의 내용을 담았다<표 4-6 참조>.

<표 4-6> 카카오의 윤리 현장 전문

원칙	내용
1. 카카오 알고리즘의 기본 원칙	카카오는 알고리즘과 관련된 모든 노력을 우리 사회 윤리 안에서 다하며, 이를 통해 인류의 편익과 행복을 추구한다
2. 차별에 대한 경계	알고리즘 결과에서 의도적인 사회적 차별이 일어나지 않도록 경계한다
3. 학습 데이터 운영	알고리즘에 입력되는 학습 데이터를 사회 윤리에 근거하여 수집·분석·활용한다
4. 알고리즘의 독립성	알고리즘이 누군가에 의해 자의적으로 훼손되거나 영향받는 일이 없도록 엄정하게 관리한다
5. 알고리즘에 대한 설명	이용자와의 신뢰 관계를 위해 기업 경쟁력을 훼손하지 않는 범위 내에서 알고리즘에 대해 성실하게 설명한다

자료: 카카오(2018.1.), 내용 일부 재정리

이와 같이 카카오의 윤리현장은 최근 국내외에서 활발히 논의되고 있는 사회적 차별 금지, 데이터 윤리, 알고리즘의 독립성 및 설명 의무 등에 대한 원칙을 포함하고 있다. 즉, 알고리즘 기술이 인간의 도덕적 가치와 윤리 관점에 부합되어야 하고 궁극적으로는 인간의 삶의 효용성을 높일 수 있어야 한다는 점을 강조하고 있다. 실제로 카카오는 2017년 3월에 기업 영업 비밀의 영역으로 간주되어 비공개 되어왔던 뉴스 배열의 알고리즘 일부를 인터넷 기업으로는 최초로 학회 저널에 논문으로 공개한 바 있다(박승택 외, 2017.3.). 또한, 카카오 AI 리포트를 통해 지속적으로 진화된 뉴스 알고리즘을 공개하고 있다(김대원, 2018.1.).

나. 삼성전자

삼성전자는 반도체, 가전, 네트워크 장비 등 다양한 제품 포트폴리오를 보유하고

있으며, 글로벌 시장에서 매년 5억여 개의 제품을 판매하고 있다. 삼성전자는 이러한 다양한 분야의 가전과 IT 제품을 통해 축적된 사용자 이해를 바탕으로 개인화된 인공지능 서비스 제공을 목표하고 있으며, 인공지능 관련 시장이 향후 멀티 디바이스 플랫폼을 활용하여 개인화된 AI로 급속히 발전해 나갈 것으로 전망하고 있다(뉴시스, 2019.1.14.). 예로, 인공지능 스피커를 통해 음성으로 영화 예매를 요청하고, TV나 냉장고의 스크린을 통해 좌석표를 보여줄 수 있다. 이를 추진하기 위해 삼성전자는 “철저하게 개인화된 서비스를 제공하는 유저 센트릭(User Centric)”, “지속적으로 학습해 성능을 높이는 올웨이즈 러닝(Always Learning)”, “멀티 디바이스를 통해 언제 어디서나 사용자를 지원하는 올웨이즈 데어(Always There)”, “사용자의 개입을 최소화하면서 도움이 되는 올웨이즈 헬프풀(Always Helpful)”, “안전과 프라이버시를 보장하는 올웨이즈 세이프(Always Safe)”라는 5가지 인공지능 원칙을 수립하였다(뉴시스, 2019.1.14.). 인공지능의 윤리적 활용 측면에서 삼성전자는 글로벌 업계 관계자들과의 논의가 필수적이라고 보고 2018년 국내기업으로는 최초로 인공지능 국제 컨소시엄인 PAI(Partners on AI)²²⁾에 가입하였다. 인공지능 미래에 대한 범사회적인 논의를 진행 중인 PAI의 주요 연구 분야는 안전성, 공정성·투명성·책임성, AI의 노동·경제, 인간과의 협력, 사회적 영향, 사회적 공익 등이며, 삼성전자는 ‘인간과의 협력’ 분야에서 인간과 AI의 공존 및 협력 방향에 대한 연구에 우선 집중하고, 향후 안전성, 공정성·투명성·책임성, 사회적 영향 등 다양한 분야로 참여를 확대할 예정이다(삼성전자, 2018.11.9.). 또한, 삼성전자는 CES 2019에서 AI 기술을 활용한 제품과 서비스 개발 시 고려해야 할 윤리적 기준으로 공정성(Fairness), 투명성(Transparency), 책임성(Accountability)이라는 인공지능 윤리 핵심 원칙을 공개하였다. 이를 통해 삼성전자는 자사가 구축한 알고리즘이 포용적(Inclusive)이도록 하고, 사용자 정보 및 개인 정보 보호를 최우선 순위로 삼으며, 소비자가 자신의 데이터가 어떻게 사용되는지를 쉽게 이해할 수 있도록 노력을 기울이고 있다고 밝혔다. 삼성전자는 앞으로 인공지능 윤리 원칙을 인공지능 기술이 활용되는 제품과 서비스 개발 관련 의사 결정에 반영

22) PAI는 사람과 사회를 위한 윤리적인 AI 연구와 개발을 통해 사회에 보다 긍정적인 영향을 미치고자 2016년 설립되었으며, 아마존, 구글, MS 등 13개국 90여개 글로벌 기업이 회원사로 가입되어 있다.

하고, AI 윤리에 관한 임직원 가이드라인 마련 및 교육 프로그램도 실시할 계획으로 알려져있다.

다. 네이버

네이버는 2018년 인공지능을 기반으로 한 검색 기술 역량을 확보하기 위해 검색기술의 연구개발 및 운영을 담당하는 조직과 인공지능 기술 플랫폼의 개발 및 운영을 담당하는 조직을 통합한 바 있으며, 사용자 관심도에 따른 다양한 인공지능 기반 추천 시스템을 연구하고 있다(한국경제, 2018.2.5.). 예로, 이용자의 위치정보를 기반으로 시간대, 성별, 연령에 따라 가장 최적화된 장소를 추천해주는 서비스, 개인 취향에 맞는 다양한 재생목록을 제공하는 음악 서비스, 이용자의 개인화 설정 기능에 초점을 맞춘 모바일 검색 서비스 등이 있다.

네이버는 이와 같이 다양한 인공지능 기반 서비스에서 안전한 데이터 활용을 위해 ‘Privacy By Design 원칙’을 적용하여, 서비스 출시 단계에서부터 높은 프라이버시 보호 기준으로 데이터 활용에 있어 법령 위반사항이나 이용자 프라이버시 보호 관점에서 문제가 없는지를 검토하고 있다. 또한, 네이버는 ‘네이버 프라이버시센터’ 홈페이지, 개인정보 보호 블로그 및 SNS를 통해 이용자 프라이버시 보호를 위한 활동과 관련 정보를 공개하고 이용자의 개선제안 등을 받고 있다.

특히, ‘네이버 프라이버시 센터’ 홈페이지에서는 네이버의 개인정보 보호원칙²³⁾, 서비스 운영 관련 정책, 보호 활동, 투명성 보고서, 개인정보 보호와 활용 논의를 위한 Privacy White Paper 등 프라이버시 관련 보고서를 제공하고 있다(표 4-7 참조). 이와 더불어 2018년 5월 유럽연합(EU)의 개인정보보호법(GDPR, General Data Protection Regulation) 내용과 준수 방안 소개도 홈페이지에 추가하였다.

23) 네이버의 개인정보 보호 원칙은 ▲개인정보 보호에 관한 모든 관련 법령과 국제 기준의 준수, ▲회원 개인정보의 처리를 항상 투명한 공개 ▲이용자의 ‘개인정보 자기결정권’ 행사 존중, ▲개인정보를 목적에 맞게 최소한으로 수집 및 보유한 개인정보의 책임 관리, ▲개인정보 보호에 대한 법적 책임과 의무를 넘어 프라이버시 보호까지 최우선 고려 등 5가지로 구분되어 있다.

<표 4-7> 네이버의 프라이버시 관련 보고서

구분	주요 내용	발행주기
투명성 보고서 통계	네이버(주)에서 수사기관에 제공한 이용자 정보 통계	연 2회
개인정보보호 리포트	네이버(주)의 개인정보 보호 활동	연 1회
Privacy White Paper	‘이용자 프라이버시 보호’ 관련 전문 연구 수행 결과	연 1회

자료: 네이버 프라이버시센터 홈페이지

네이버에서 발행한 Privacy White Paper는 외부 필진에 의해서 수행된 ‘인공지능과 개인정보’에 관한 연구(김용대, 2017.12.), ‘인공지능과 차별’에 관한 연구(고학수·정해빈·박도현, 2018.12.) 등을 포함하고 있다. ‘인공지능과 개인정보’ 연구에서는 인공지능 기술의 발전에 따른 부작용으로 인종차별 등 프라이버시와 인권을 침해하는 윤리 문제가 대두되고 있음을 지적하고, 프라이버시 침해를 방지하는 인공지능 기술에 대한 투자, 프라이버시 보호에 대한 사회적 합의 도출을 위한 사회적 공론화 과정, 인공지능 윤리 교육 프로그램, 인공지능 윤리문제 해결을 위한 행정시스템의 구축 등의 필요성을 제기하였다. ‘인공지능과 차별’ 연구에서는 인공지능을 활용하는 과정에서 발생하는 차별은 종래 인공지능이 없던 시기의 차별행위와 비교하여 구체적으로 어떤 차이가 있는지를 알아보고, 인공지능 기술의 활용과 관련한 다양한 법익이나 법정책적 목표 사이의 충돌이 발생할 수 있음을 지적하였다.

두 연구는 공통적으로 높아지는 윤리적 인공지능 기술의 사회적 요구를 고려하여 향후 윤리와 기술발전의 균형을 이룰 수 있는 해결책을 지속적으로 모색할 필요성을 강조하고 있다. 네이버는 내부적으로 인공지능 기술 연구, 빅데이터 분석을 통한 신규 서비스 기획을 진행하면서 경직된 개인정보 관련 법령의 개선 필요성을 느꼈으며, 이러한 연구 결과들이 기술 발전을 저해하지 않으면서도, 데이터 처리 과정에서 정보주체를 실질적으로 보호할 수 있는 방안에 대한 발전적 논의의 계기가 되기를 바라고 있다(네이버, 2018).

라. 뷰노

뷰노는 2014년 12월에 설립된 인공지능 의료솔루션 개발 기업으로, 인공지능 기반 의료영상 진단분야 국내 1호 스타트업이다. 뷰노는 인공지능이 엑스레이 영상을 분석해 뼈 나이를 판독하여 성조숙증이나 저상장 진단을 돕거나, 뇌 자기공명(MR) 영상을 기반으로 알츠하이머성 치매 진단을 돕는 인공지능 기반 진단 보조기기 등을 개발하고 있다. 알츠하이머성 치매 진단의 경우에는 뷰노의 보조기기를 사용하면 기존 최소 10분에서 수 시간이 걸리던 진단 시간을 1분으로 줄일 수 있다(한국경제, 2019.7.15.).

하지만, 의료기기에 인공지능을 활용하기 위해서는 인공지능 신뢰성 확보가 필요하고, 이를 위해 뷰노는 임상검증, 알고리즘 정보 시각화, 규제 당국과 협조의 3가지 방법으로 접근하고 있다(한국정보화진흥원, 2019.4.5.). 우선 여러 병원에서 개발한 인공지능 의료기기의 기능구현 검증을 진행한다. 이를 통해 다양한 데이터셋을 활용한 임상검증 시행을 통해 의료기기의 일반화 및 범용성을 높여 나간다. 두 번째로, 인공지능 진료 결과와 함께 시각화된 알고리즘 처리 과정을 제공하여 서비스의 신뢰성을 높이고 있다. 세 번째, 의료기기는 철저한 인허가 과정이 요구되므로 인공지능 의료기기의 특성을 반영할 수 있는 가이드라인 수립을 위해 규제 당국과 긴밀하게 협조하고 있다. 그 결과 2018년 8월 15일 뷰노의 인공지능 기술이 적용된 의료영상분석장치 소프트웨어 ‘뷰노메드 본에이지(VUNOmed-BoneAge)’가 임상시험을 거쳐 인공지능 기반 의료기기로서는 첫 식품의약품안전처 승인을 획득하였다(식품의약품안전처 보도 자료, 2018.5.16.).

[그림 4-7] VUNO-MED BoneAge(2018)



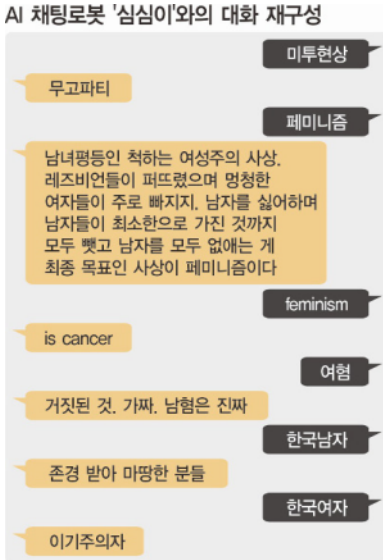
자료: 한국산업기술진흥협회(2018.10.16.), p.22

이는 세계적으로도 미국과 유럽 외에는 규제기관의 승인을 받은 사례가 드물어 상대적으로 빠른 상용화 사례로 볼 수 있다. 하지만, 본격적으로 인공지능 기술이 적용된 의료기기가 임상현장에 도입되어 사용되기 위해서는 신의료기술평가를 통과하여 수가를 인정받아야 하는 과제가 남아있다(한국산업기술진흥협회, 2018.10.16.).

마. 심심이

심심이는 (주)이즈메이커(現 (주)심심이)가 2002년 개발한 인공지능 일상대화 챗봇 서비스이다. 텍스트 기반으로 서비스를 해왔으나, 최근 음성대화 기능도 준비하고 있다(데일리그리드, 2019.8.21.). 미국, 캐나다, 영국, 스웨덴, 인도네시아, 도미니카공화국 등 해외에서도 서비스 이용이 가능하며, 출시이후 다운로드 수는 1억개에 달한다. 심심이는 이용자들이 입력한 질문-대답 세트를 통해 말을 학습하고 그 말을 가공 없이 그대로 사용한다. 하지만, 일부 이용자들은 이러한 특성을 악용해 인종·성별에 따른 혐오발언을 가르치고, 심심이는 학습된 혐오 발언을 다른 사용자들과의 대화에 사용하는 문제가 발생하였다(국민일보, 2019.4.1.).

[그림 4-8] 심심이 대화 중 혐오표현 사례



자료: 국민일보(2019.4.1.)

2016년 마이크로소프트가 개발한 인공지능 챗봇인 '테이(Tay)'도 일부 사용자들이 테이의 언어 습득 능력을 악용하면서 테이가 인종차별적이고 폭력적인 메시지를 발언하는 문제가 발생하였고, 결국 마이크로소프트는 테이 서비스를 중지하였다(TIME, 2016.3.24.). 심심이는 국내 뿐만이 아닌, 태국, 북아일랜드, 브라질 등 해외에서도 비슷한 문제가 일어나 부적절한 대화의 필터링 기능을 강화하고 사용자 신고 제도를 활용하고 있다. 이는 인공지능이 해를 끼칠 때 신속히 대응하기 위한 교정장치 마련의 필요성, 악의적 이용을 방지하기 위한 이용자 윤리 함양 및 인식개선의 필요성을 보여 주고 있다.

바. 한국인공지능협회

한국인공지능협회는 2012년 스타트업 실무자들의 커뮤니티로 시작하여 2017년 사단법인으로 설립되었다. “산업의 지능화”와 “AI 기술의 대중화”를 목표로 인공지능 기술 기업 및 유관기관들을 중심으로 네트워크를 구축하고 있으며, 협회 측에 따르면,

인공지능 유관 150여 기업 대표들이 본 협회가 운영하는 AI 기업인 클러스터에서 활동하고 있다. 본 협회는 인공지능 관련 행사와 세미나를 개최하고 있으며, 2018년과 2019년 국제인공지능대전을 주최한 바 있다(한국인공지능협회 홈페이지). 또한, 인공지능 산업에 필요한 윤리의식과 교육의 필요성을 논의하기 위한 목적으로 2019년 7월 ‘제1회 인공지능 윤리+교육 포럼’을 개최하였으며, 포럼 이후 메니패스토의 일환으로 협회 클러스터 기업 72개 업체가 참여한 2019 인공지능 윤리+교육 포럼 공동선언문을 채택했다(표 4-8 참조).

<표 4-8> 2019 인공지능 윤리+교육 포럼 공동선언문

본 선언문은 대한민국 인공지능 기술의 지속적 성장과 안전한 발전을 위한 윤리적 연구·개발 뿐 아니라, 이와 연계하여 올바른 인공지능 교육을 할 수 있도록 개인과 기업, 국가 그리고 세계기구에 실천적 가이드라인을 제시하는 데 그 목적이 있다.

1. 인공지능 기술은 처음부터 ‘사람 우선’ 원칙으로 인류에게 육체적·정신적·환경적으로 도움을 줄 수 있도록 연구·개발되어야 하고 동시에 설명될 수 있어야 한다. 또한, 우리가 그것을 신뢰하고 공정하게 공유하여 인류 공동의 선을 실현할 수 있도록 해야 한다.
2. 국민 개인은 ‘자기의 기술(The Technology of the Self)’을 학습하여 개인 데이터를 스스로 관리해야 한다. 또 미래 인공지능 기술이 가져올 직업적 변화에 대비하여 자신의 적성과 능력을 파악, 소비자인 동시에 생산자가 될 수 있는 새로운 디지털기술을 습득하고 그것을 발전시켜야 한다.
3. 모든 기업은 시작단계에서부터 ‘안전 우선’을 원칙으로 관계자 교육훈련을 포함한 인공지능 개발과정을 설계하고, 해당 제품의 사람과 사회에 대한 영향을 종합적으로 분석하여 차별과 편견이 없도록 제작해야 한다. 그리고 비상시를 대비하여 위험요소를 즉각 제거할 수 있는 통제기술을 해당 제품에 포함해야 하며, 제품의 전체 제작과정을 표준화시키고, 사후 관리에 책임을 지며, 영업비밀을 훼손하지 않는 범위에서 그것을 설명할 수 있어야 한다.
4. 국가 교육기관은 국민 각자가 국민공동기본교육과정을 통해 생애주기별로 필요한 ‘스마트 라이프(Smart Life)’ 활용기술을 습득하여 일상 생활능력을 확장할 수 있게 하며, 직업적으로 개인의 역량을 최대로 향상시킬 수 있는 ‘자기 계량화(Quantified Self)’ 기술을 포함한 ‘인간공학(Human Engineering)’에 대한 학습기회를 제공해야 한다.
5. 국가는 국민의 인권과 재산, 프라이버시를 보호하기 위해 산업별 인공지능 기술의 긍정적·부정적 영향을 전체적으로 조사·분석·예측하여 그 결과를 공유하고, 관계자에 대한 자각부여 및 교육·훈련을 해야 한다. 특히, 종합적 제품관리를 위해 기업경쟁력을 침해하지 않는 범위에서 산업별 표준화된 평가 매트릭스를 적용하여 투명성과 타당성을 확보하고, 합리적 개입과 감독을 포함한 국가 차원의 가버넌스시스템을 구축해야 한다.

-
6. 인공지능 기술은 그 경계가 없이 세계적으로 확장될 수 있으므로 개인과 기업은 세계시민으로서의 역할교육을 받아야 하며, 한 나라의 국가적 가브너스 시스템은 UN과 같은 세계기구의 글로벌 시스템과 연동시켜 지속해서 발전해 나가야 한다.
 7. UN등 세계기구는 인공지능 기술이 인간의 생리적 진화를 앞지를 수 있는 문명사적 변혁에 대비하여, 인간의 존엄성과 그 존재론적 의미와 가치를 재발견해야 한다. 나아가서는 '사람 우선'의 원칙을 기반으로 인공지능과 인간의 표준화된 기술적 협업 방법을 개발하고 보급하여 상호갈등을 없애고, 세계평화와 질서를 유지할 수 있는 정책을 강구해야 한다.
-

출처: 한국인공지능협회 홈페이지

2. 학계 대응 동향

학계에서는 인공지능을 인간의 존재론적 지위와 연관한 철학적 논의, 인공지능의 범용적인 영향력을 고려한 인문학적 준비 등이 이루어지고 있다. 이러한 논의는 여러 학제간 협력과 논의를 통해 이루어지고 있으며, 향후 인공지능 윤리의 논거 마련, 사회적 합의 도출에 영향을 미칠 것으로 예상된다. 법학계, 정책연구소 등은 인공지능을 적용한 제품·산업의 출현에 대비한 법제도 마련 측면에서 논의를 진행하고 있으며, 인공지능을 적용한 구체적 사례 중심으로 연구를 진행하고 있다.

가. 고등과학원 초학제연구단

고등과학원은 순수이론기초과학 연구기관으로서 학제간 교류와 소통을 통해 기존 연구방법에 구애받지 않고 새로운 연구주제와 방법을 생성하는 초학제 연구프로그램을 2012년부터 진행하고 있다. 이 프로그램의 목표는 과학연구의 지평 확대, 학문간 협력을 통해 새로운 학문적 아젠더 개발, 과학발달의 문화적 배경을 반영한 과학발전의 한국적 모델을 구축하는 것이다. 2017년부터는 초학제 연구프로그램 주제로 인공지능을 정하고, 2017년부터 2018년까지는 〈인공지능: 과학, 역사, 철학〉, 2019년부터는 〈인공지능과 포스트휴머니즘〉 제목으로 인공지능 현장 연구자와 인문학자들이 모여 인공지능과 사회적 영향에 대한 발표와 토론을 진행하는 워크숍을 진행하고 있다(표 4-9 참조).

<표 4-9> 고등과학원 초학제 연구프로그램 워크숍 (2017.11. ~ 2019. 8.)

일정	제목	주요 내용
2017.11.29.	인공지능을 둘러싼 몇몇 철학적 쟁점	- 인공지능 공학의 논리적 바탕 - 역인공지능과 미래의 직업 - 강 인공지능 실현의 조건 - 네트워크 지능의 출현이 초래하는 윤리적, 정치적 문제 - 창의적 교육의 구체적 방안
2017.12.18.	공감하는 인공지능, 낮선 반려자?	- 인공 반려의 조건 - 인공 공감과 인공 감정 - 인공 반려의 유혹
2017.12.19.	법 분야에서의 인공지능	- 인공지능 활용 현황과 발전 방향 - 소송결과 예측의 현실적 모델 - 인공지능 판사의 가능성 타진 - 법 분야에서의 인공지능의 미래
2018.1.30.	인공지능 예술과 창의성	- 뉴로스케이프: 심층 신경망의 멀티모달 커백션 기반 사운드 스케이프 디자인 - 녹음 기술의 등장과 환경 소리의 음악적 활용 - 작품의 구현 - 전후 사이버네틱스와 현대미술 - 인공지능 예술의 현재적 지형 - 인공지능 예술과 미적 경험의 문제
2018.2.27.	철학자 5인 대토론하: 인공지능의 도전, 철학의 응전	- 인공지능과 생명체의 지능의 근본적 차이 - 컴퓨터가 의식을 갖는 상황의 도래 전망 - 인공지능의 발전이 인간의 직업에 미칠 영향 - 교육의 개선 및 혁신 방향 - 인공지능의 발전 제어 필요 여부 및 거버넌스 - 인공지능이 던지는 가장 중요한 철학적 화두
2018.3.29.	도덕적 인공지능: Artificial Moral Agent	- 윤리적 인공지능: 로봇의 필요성 - 도덕적 인공지능위자 - 기술 개발 및 수행 과제
2018.5.3.	자율주행차와 미래사회	- 자율주행이 걸어온 길 - 자율주행 셔틀
2018.6.15.	AI는 정말 우리가 필요없을까? : AI 속 인간 노동과 기술혁신의 정치	- 인간-기계 하이브리드로서의 AI - AI를 위한 인간 노동의 초상 - AI 시대 기술혁신의 정치: 노동의 비가시화와 경계짓기의 정치경제
2018.7.19.	인공지능과 예술 2: 음악	- K-pop과 인공지능 - 인공지능과 음악 - 인공지능과 저작권
2018.9.27.	기술혁신이 미래 직업세계에 미치는 영향	- 기술혁신과 일자리 문제의 역사성 - 산업자동화 인공지능 일자리 영향 - 미래사회 직업세계 변화상

일정	제목	주요 내용
2018.10.18.	로봇윤리의 철학적 기초	- 탈 인간중심 로봇 윤리를 위하여 - 비인간적 인격체 - 인공지능 로봇의 자율성 - 인공지능 로봇의 도덕적 지위와 포스트휴머니즘
2018.11.28.	유럽연합의 GDPR과 개인정보보호법	- EU GDPR의 주요 특징 - GDPR의 영향? 개인정보 비식별화/익명성의 경우
2019.3.29.	설명가능 인공지능의 발전과 그 사회적 함의	- 설명가능 인공지능의 최신 연구동향과 활용전망 - 설명가능 인공지능 : 사회를 위한 도구가 될 것인가?
2019.4.25.	인공지능 대 인간지능	- 인공지능과 인간지능은 얼마나 닮았을까? - 철학적 인간학의 질문 : 인공지능은 왜 인공지능인가?
2019.5.31.	인공지능, 뇌 그리고 학습	- 기억의 뇌 기전과 인간의 지능 - 인공지능 시대의 학습과 교육
2019.6.21.	AI and Post-humanism	- 인공지능의 발전 전망과 한계 - 휴머니즘 및 포스트 휴머니즘에 대한 변화
2019.8.22. (국내연합학술심포지엄)	인공지능의 발전과 사회 패러다임의 변화, 그리고 포스트휴머니즘	- 인공지능 기술의 발전과 산업 전망 - 인공지능 이후의 자본주의 - 포스트휴머니즘의 조건과 지향

자료: 고등과학원 초학제연구단(2018) 내용 재정리

〈인공지능: 과학, 역사, 철학〉 제목으로 진행된 워크숍에서는 인공지능에 대한 철학적 쟁점, 인공지능 예술과 창의성, 자율주행자동차, 인공지능과 예술, 도덕적 인공지능 등 다양한 주제의 발표와 토론이 이루어졌으며, 인공지능 현장 실무자들과 철학자를 비롯한 인문학자간의 인공지능 윤리에 대한 개념과 접근법의 차이를 보여주기도 하였다.

일례로, 2018년 10월 18일에 진행된 〈로봇윤리의 철학적 기초〉 워크숍에서 서울 시립대 이증원 교수는 감정, 도덕성, 자율성 등 인간에게만 고유한 것으로 인식되었던 요소들이 인공지능에서도 구현되어 가고 있으므로 인공지능의 본성을 올바르게 판단하기 위해서는 향후 인공지능을 하나의 인격체로 보는 철학적인 성찰, 탈인간주의의 관점에서 포스트 휴머니즘의 정립이 필요하다고 주장하였다. 이에 대해, 카카오 김대원 정책담당 이사는 현재 논의에서 전제하고 있는 인공지능 수준이 현재 현장에서 연구하고 있는 인공지능 수준과 상당한 차이가 있음을 지적하며 미래의 개연성보다는 현

실의 문제와 함께 논의가 다각화되는 상향식 접근의 필요성을 주장하였다. 또한, 사람을 제어해도 충분히 규제가 가능하다면 별도의 인공지능 윤리가 필요한지에 대해 의문을 제기하였다. 이에 대해 이중원 교수는 인간 친화적인 형태로 개발되는 AI 로봇 등을 예로 들며 자율성을 가진 AI 로봇에 대한 논의가 필요하며, 책임 귀속의 최종 주체는 인간이 될 수 밖에 없지만, 사람들의 집합체가 만들어낸 인공물이 인간에게 영향을 준다면 사회적 차원의 합의가 필요하다고 설명하였다. 또한, 윤리는 기술개발 과정에서 자율적인 자기 규제를 가능하게 하므로 법이 못하는 부정적(negative) 규제 허용 범위를 제시하는 역할을 할 수 있을 것이라고 전망하였다(고등과학원 초학제연구단, 2018).

나. 중앙대학교 인문컨텐츠연구소

중앙대학교 산하 인문컨텐츠 연구소는 2002년 5월 중앙대학교 전략 특성화 사업 연구소로 지정되어 출범하였으며, 2017년 11월부터는 한국연구재단 HK+(인문한국 플러스) 지원 사업에 선정되어 ‘인공지능인문학’ 구축 연구를 수행하고 있다(중앙대학교 인문컨텐츠연구소 홈페이지). 본 연구소는 인공지능 기술 발전이 향후 개인과 사회에 미칠 막대한 영향력을 예상했을 때, 인문학이 총괄적인 방향성을 제시하는 컨트롤 타워의 역할을 해야 하며, 인문학을 중심으로 타 학문을 융합하는 차원이 아닌, 기존 인문학 체계가 지닌 분과 학문의 창발적(통합적) 재구성을 시도하는 새로운 인문학 영역 설계를 위해 ‘인공지능인문학’ 구축이 필요하다고 보았다. 이에 따라, 인공지능인문학을 “자연과학 기술공학·사회과학을 이해하는 통합인문학”이자, “인공지능 전반에 관한 방향성을 관장하는 신설 기초인문학”으로 개념화하였다.

연구 수행을 위해 본 연구소는 인공지능 기술, 인간과 사회의 변화, 인문학 연구성과, 인문학 데이터, 인간 고유성과 인간관계를 연구대상으로 삼아(표 4-10 참조), 자연과학의 엄밀성, 사회과학의 시의성, 기술공학의 효율성을 연결하는 연구방법론을 통해 인공지능인문학의 토대를 구축하고, 연구방법론, 연구결과물, 교육 과정의 연구 및 교육 등의 연구 성과를 목표하고 있다(표 4-11 참조).

<표 4-10> HK+인공지능인문학 세부영역

연구영역	세부영역
인공지능 관계 · 소통학	- 인간과 인공지능과의 소통 문제 - 언어학, 철학, 역사학, 종교학 - 인공지능학, 심리학, 미디어학
인공지능 윤리 · 규범학	- 인공지능이 초래하는 부작용 - 철학, 역사학, 종교학 - 인공지능학, 법학, 뇌과학, 심리학
인공지능 인문데이터 해석학	- 빅데이터와 인간성의 관계 - 언어학, 철학, 역사학, 종교학 - 인공지능학, 정보학(빅데이터)
인공지능 기술비평학	- 인공지능과 인격 - 문학, 철학, 역사학, - 인공지능학, 심리학, 사회학
인공지능 사회 · 문화학	- 인공지능시대 사회문화적 변화의 방향 - 문화인류학, 철학, 역사학, 미학 - 인공지능학, 사회학, 심리학, 정치학, 행정학

자료: 중앙대학교 인문컨텐츠연구소 홈페이지

<표 4-11> HK+인공지능인문학 예상 성과

구분	세부영역
토대 구축 성과	- 인간성 관련 디지털 온톨로지 - 인공지능인문학 연구를 위한 플랫폼 구축 - 인공지능 윤리 규범제정
연구 교육 성과	- 인공지능인문학 연구방법론 - 연구결과물 - 교육과정
연구 내용	- 인공지능 정책제안 - 인공지능인문학 학술지 편찬 - 인공지능인문학 세계화

자료: 중앙대학교 인문컨텐츠연구소 홈페이지

다. 한국인공지능법학회

한국인공지능법학회는 인공지능 기술과 법제도 및 정책의 상호작용에 관한 문제를 종합적인 시각에서 풀어나갈 수 있는 융합학문적인 학술활동 공간 마련을 위하여 2016년 설립되었다(한국인공지능법학회 홈페이지). 설립 이후에는 ‘인공지능과 법인격’, ‘지능정보사회에서의 규제’, ‘자율주행차의 현안과 과제’ 등 4차 산업혁명 기술 관련 입법 이슈를 중심으로 학술 세미나를 개최해오고 있으며, 2019년 3월에는 KAIST 인공지능연구소, 바른미래당 신용현 국회의원과 함께 ‘인공지능의 윤리적 개발 동향과 입법대응 과제’ 세미나를 공동주최한 바 있다.

2019년 3월부터는 인공지능 기술과 법제도, 윤리, 그리고 정책의 상호작용에 관한 문제를 종합적 시각에서 풀어나가고 관련 정책에 대한 사회적 공론의 장을 마련할 취지로서, AI 분야별 정·관·산·학·연 전문가 및 언론사, 시민단체 등 50명 내외로 구성된 AI 정책포럼을 발족하였다.

2019년 2월에는 ‘인공지능과 법’이라는 책을 출간하였으며, 이 책은 인공지능 관련 법 패러다임 변화, 개별법, 정보보호법, 경쟁법, 사회보장법 등 법적 이슈와 자율주행차, 의료, 킬러로봇, 로보어드바이저 등 기술분야에서의 윤리적·법적 쟁점 등을 분석하고 이에 대한 대안을 제시하고자 하였다.

라. 한국인터넷윤리학회

한국인터넷윤리학회는 인터넷의 역기능에 대응하여 문화적으로 더욱 건강한 인터넷 사회를 만들고자 하는 취지로 2011년 창립되었다(한국인터넷윤리학회 홈페이지). 2017년에 ‘인공지능 및 로봇기술의 윤리적 쟁점’ 특별 세미나 등을 개최하는 등 인공지능 분야의 윤리 이슈에 대한 학술 활동을 진행하고 있다. 동년에 논문지 ‘The Digital Ethics’를 발간하여 인공지능 윤리에 대한 다수의 논문을 게재하고 있으며, 정부 부처와 AI 윤리 관련 정책연구도 진행하고 있다. 예로, 2017년에는 지능정보사회 발전을 위한 윤리 원칙 관련 위탁연구 과제(방송통신위원회)를 수행하였고, 2018년에는 전자정부에 인공지능 기술 활용 시 윤리기준 관련 연구(행정안전부)를 수행하

였다(한국로봇산업진흥원, 2019.1.4.).

마. 정보통신정책연구원

정보통신정책연구원은 1985년 설립되어 ICT 전략, 통신전파, 방송미디어, ICT 통계, 국제협력, 경영전략 등 정보통신 및 방송 분야에서 다양한 정책연구를 수행하고 있으며, 인공지능 윤리에 대해서도 연구활동을 진행하고 있다(정보통신정책연구원 홈페이지). 2016년 12월 발간한 ‘지능정보사회의 규범체계 정립을 위한 법·제도 연구’ 보고서는 인공지능이 초래하는 윤리적, 철학적, 법제도적 이슈를 기반으로 지능정보사회 규범의 틀을 제시하였다. 본 연구에 따르면, 우리나라의 현행 법제도는 인공지능만을 독립적으로 규율하는 법률은 아직 찾아보기 어려우며, 인공지능/로봇 분야에 적용될 수 있는 개별법의 경우에도 새로운 기술수준 및 사회적 파급효과를 반영하기에는 미흡하다. 하지만, 지능정보사회의 규범 모델은 ‘약한 인공지능’, ‘강한 인공지능’ 등과 같이 지능정보 기술의 진화 정도에 따라 사회적 수용과 윤리적 대응 수준을 고려한 단계, 중장기의 구상이 필요하다. 또한, 인공지능의 빠른 발전 속도를 고려할 때 인공지능이 초래할 법적 쟁점(책임법리, 사회보장법리, 규율체계 등)에 대한 도전은 신중한 검토와 사회적 합의가 필요하며, 진흥정책적·제도공학적 차원에서만이 아닌, 사회문화적, 인문학적(문명사적) 관점을 포함한 거시적 접근의 필요성을 제기하였다.

2018년 10월 발간한 “4차 산업혁명시대 산업별 인공지능 윤리의 이슈분석 및 정책적 대응방안 연구”는 지능형로봇윤리현장, 지능정보사회윤리가이드라인, 지능정보사회윤리현장 등 일반적/총론적 규범 차원의 논의에 그치고 있는 인공지능 윤리를 인공지능 기술 및 서비스의 구체적 적용 분야의 특성에 따른 윤리이슈 검토 및 대응방안 논의로 구체화해야 할 필요성을 지적하였다. 이에 따라, 본 연구에서는 AI 기술 적용 및 윤리이슈 쟁점 정도를 고려하여 자율주행자동차(제조), AI의료서비스(의료), 로보어드바이저(금융), 킬러로봇/치명적 자율무기체계(LAWS: Lethal Automotive Weapons System)(국방(군사))의 윤리이슈 분석 및 대응방안을 도출하였다(표 4-12, 4-13 참조).

<표 4-12> 개별 산업별 윤리 이슈

	제조분야	금융분야	의료분야	군사 분야
개발 이전		· 시가발 촉진과 규제의 균형 · SI이용 관련 금융종사자 윤리교육	· 인간중심주의 강조 -의료정보 데이터 취급에 유의 · 의료 종사자에 대한 윤리교육	· 인권 존중-국제인권협약 준수 · LAWS 개발의 국방상 필요성 · 국가 안보 수호자로서의 윤리 의식
설계	· 알고리즘의 윤리적 구축-트롤리 딜레마	· 알고리즘의 윤리적 구축-초단타 매매사례		· 알고리즘의 윤리적 구축-전쟁법 등의 준수
개발	· 스마트시티 및 IoT 등 기술과의 연관성 고려		· 의료가 인허가제도 · 기술영향평가제	
시험	· 인허가 단계에서의 윤리적 검증	· 윤리적 자가 검증	· 임상 표준 고려 · 표준 의료정보품질 구축 · 윤리적 자가 검증	· 안전성 보장 · 효용성의 고려 · 테러리스트 등에 대한 보안
소비	· 자율주행차 책임주체성 · 책임보험제도 고려 · 소비자의 자기결정권	· 투자자 보호 · 윤리적 투자	· 유사·불법·자가 의료행위 방지 · 기술 수혜 격차 유의 · 경영자의 의료인의 충돌	· 상대 세력의 전력을 고려한 이용
피드백	· 자동차 사고의 일상성 고려-공동체 차원의 리스크 관리	· 기관 간 정보 공유 · 해킹 대비	· 의료정보 자산화 및 데이터의 공익적 재이용	· 피해 유형의 검토 · 해킹 대비

자료: 정보통신정책연구원(2019.3), p.88

<표 4-13> 윤리 대응 프레임워크 (예시: 제조)

	특수쟁점	개발자/공급자	공적주체	이용자
개발이전 단계	ES ³	윤리 / 리스크 커뮤니케이션을 통한 <자율주행차 윤리 가이드라인 등> 구축		
설계 단계	ES ³	영향평가 자가리스크 진단	영향평가의 요령 제공	영향평가 단계에서 의견 제시
개발 단계	ES ³		스마트시티 구축 등의 지원	
시험 단계	ES ³	윤리 규범 준수	안전 및 윤리 기준 구축	의견 제시
소비 단계	ES ³	책임 주체로서의	논의 플랫폼의 구축 / 민관협력의 사회적 합의체	

	특수쟁점	개발자/공급자	공적주체	이용자
	자율주행차 책임보험제 소비자 자기결정권	피해 구제		리스크에 대한 수용
피드백 단계	자동차 사고의 일상성 고려	공동체 차원의 리스크 관리		

자료: 정보통신정책연구원(2019.3.), p.89

3. 정부 대응 동향

정부는 2007년 로봇윤리헌장을 시작으로 인공지능 윤리에 대한 논의가 형성되어, 2017년부터는 미래 지능정보사회 도래에 따른 순기능과 역기능에 대응하는 총괄적 시각에서 인공지능 윤리와 법제화를 준비하고 있다. 이후 자율주행자동차, 인공지능 의로기기 등 특정 지능정보기술의 제품화가 가시화되면서 제품·산업 특성에 맞춘 구체적인 인공지능 윤리 및 안전, 관련 법제 준비를 위한 정부 계획들이 발표되고 있다.

가. 로봇윤리헌장

한국 정부가 인공지능 윤리 문제에 대응하기 시작한 시점은 2007년 지식경제부 주도로 시작되었던 로봇윤리헌장 제정 활동으로 볼 수 있다(정필운·고인석, 2017; 김윤명·정필운 외, 2017). 2007년 3월에 로봇 관련 산학연 전문가와 사회학, 미래학 분야 등 전문가 13명으로 구성된 실무 위원회가 구성되어 로봇윤리헌장 제정을 위한 활동이 시작되었다. 2007년 4월에는 이탈리아에서 열린 ‘2007 로봇윤리워크숍 ICRA(International Conference on Robotics and Automation)’에서 한국의 로봇윤리헌장 제정에 대해 배경과 계획을 발표하면서 국제적인 관심을 모으기도 하였다.

2007년 8월, 2007 지능형로봇 그랜드워크숍에서 ‘로봇윤리헌장’ 초안이 공개되었다(표 4-14 참조). 로봇윤리헌장제정 실무위는 2100년까지의 미래 로봇사회가 어떻게 진행될 것인지에 대한 5가지 시나리오를 바탕으로 초안을 작성하였다(디지털타임스, 2007.8.30.). 2008년부터는 Jim Dator 교수의 자문에 따라 철학, 윤리, 종교 분야 전문가를 위원으로 추가 선임하여 초안 내용이 검토되었다(정필운·고인석, 2017).

<표 4-14> 2007 로봇윤리헌장 초안

구분	내용
1장(목표)	로봇 윤리 헌장의 목표는 인간과 로봇의 공존 공영을 위해 인간 중심의 윤리 규범을 확립하는데 있다
2장(인간, 로봇의 공동 원칙)	인간과 로봇은 상호간 생명의 존엄성과 정보, 공학적 윤리를 지켜야 한다
3장(인간 윤리)	인간은 로봇을 제조하고 사용할 때 항상 선한 방법으로 판단하고 결정해야 한다
4장(로봇 윤리)	로봇은 인간의 명령에 순종하는 친구·도우미·동반자로서 인간을 다치게 해서는 안된다
5장(제조자 윤리)	로봇 제조자는 인간의 존엄성을 지키는 로봇을 제조하고 로봇 재활용, 정보 보호 의무를 진다
6장(사용자 윤리)	로봇 사용자는 로봇을 인간의 친구로 존중해야 하며, 불법 개조나 로봇 남용은 금한다
7장(실행의 약속)	정부와 지자체는 헌장의 정신을 구현하기 위해 유효한 조치를 시행해야 한다

자료: 로봇신문(2013.12.16.)

2008년에는 「지능형 로봇 개발 및 보급 촉진법」을 통해 로봇윤리헌장 제정에 대한 법적 근거가 마련되었다(표 4-15 참조). 하드웨어인 지능형 로봇을 구동하는 것은 소프트웨어이자 인공지능이기 때문에 지능형 로봇윤리는 인공지능윤리와 별개로 보기 어렵다(김윤명, 2017.1.).

<표 4-15> 지능형 로봇 개발 및 보급 촉진법 중 로봇윤리헌장 관련 내용

구분	내용
제2조(정의)	1. "지능형 로봇"이란 외부환경을 스스로 인식하고 상황을 판단하여 자율적으로 동작하는 기계장치를 말한다. 2. "지능형 로봇윤리헌장"이란 지능형 로봇의 기능과 지능이 발전함에 따라 발생할 수 있는 사회질서의 파괴 등 각종 피해를 방지하여 지능형 로봇이 인간의 삶의 질 향상에 이바지 할 수 있도록 지능형 로봇의 개발·제조 및 사용에 관계하는 자에 대한 행동지침을 정한 것을 말한다.
제5조(기본계획의 수립 등)	① 정부는 지능형 로봇의 개발 및 보급에 관한 이 법의 목적을 효율적으로 달성하기 위하여 5년마다 기본계획(이하 "기본계획"이라 한다)을 수립하여야 한다. ② 기본계획에는 다음 각 호의 사항이 포함되어야 한다. 5. 지능형 로봇윤리헌장의 실행에 관한 사항

구분	내용
제18조(지능형 로봇윤리현장의 제정 등)	① 정부는 지능형 로봇 개발자·제조자 및 사용자가 지켜야 할 윤리 등 대통령령으로 정하는 사항을 포함하는 지능형 로봇윤리현장(이하 "현장"이라 한다)을 제정하여 공표할 수 있다. ② 정부는 대통령령으로 정하는 바에 따라 현장의 보급 및 확산을 위한 필요한 조치를 마련하여야 한다. ③ 관계 중앙행정기관의 장은 현장의 효율적인 운영을 위하여 필요한 경우에는 다른 중앙행정기관의 장에게 관련 자료의 제출이나 그 밖에 필요한 협조를 요청할 수 있다. ④ 현장의 제정·개정에 관한 절차, 홍보, 그 밖에 필요한 사항은 대통령령으로 정한다.
제41조(한국로봇산업진흥원의 설립 등)	① 지능형 로봇산업 진흥을 위한 사업을 효율적이고 체계적으로 추진하고 지능형 로봇산업 관련 정책의 개발을 지원하기 위하여 한국로봇산업진흥원(이하 "진흥원"이라 한다)을 설립한다. ④ 진흥원은 지능형 로봇산업 분야에 관한 다음 각 호의 사업을 수행한다. 4. 지능형 로봇윤리현장의 실행·홍보에 관한 사업

자료: 국가법령정보센터, 「지능형 로봇 개발 및 보급 촉진법」, 법률 제13744호(2016.1.6.)에서 일부 발췌

하지만, 로봇윤리현장 초안은 국가적 차원에서 공식화되지 못하였다. 정필운·고인석(2017)에 따르면, 로봇윤리현장 초안은 “서술 관점의 통일성과 명료성이 결여”되어 있었고, “특히 인공지능이나 인공지능 로봇을 무엇으로 인식할 것인가에 관한 존재론적 관점이 미정립”되어 있었다. 또한, “현장이 선언적 속성을 갖게 되는 것은 자연스럽더라도 그로부터 구체적 실천에 관한 세목들을 도출할 수 있는 기반 및 원천이 될 수 있어야 하는데 이런 기대를 충족하지 못하였고, 로봇윤리현장이 대상으로 삼는 기술의 현황과 사회적 파급효과에 대한 인식에서 전문성과 포괄성이 미흡”하였다.

후속작업으로 2009년 4월에서 8월까지 로봇윤리현장 제정을 위한 연구위원회가 3개 팀으로 구성되어 운영되었으며, 2009년 8월 토론회를 통해 연구결과가 발표되었다. 2009년에는 향후 3개년 계획을 담은 로봇윤리연구 로드맵을 수립하였으나, 이후 2년 이상 사실상의 소강상태에 들어서게 된다. 이후 2010년 이후 로봇윤리는 한국로봇산업진흥원(KIRA) 업무로 이관되었으며, 2011년 10월 한국 로봇산업진흥원 주도로 로봇윤리 공론화 위원회가 구성되어, 2012년 1월 결과보고서를 제출하였다. 이후 2016년 한국로봇산업진흥원이 로봇윤리현장 제정 작업을 속개하였다.

2017년 10월부터 한국로봇산업진흥원이 로봇윤리현장에 대한 개선 연구 용역을 추진하였으며, 한국로봇학회가 본 연구를 수행하여 2018년 3월 ‘로봇윤리 가이드라

인(안)’을 도출하였다(한국로봇산업진흥원, 2019). 본 가이드라인(안)은 행위주체가 준수해야할 3대 기본가치와 5대 실천원칙 및 관련 상세 내용과 사회적 이슈를 담은 해설서로 구성되어 있다(표 4-16 참조). 가이드라인의 적용 범위는 로봇, 인공지능 및 인공지능이 탑재된 로봇이며, 행위주체는 제작자, 서비스 공급자, 사용자 등으로 정의하였다.

〈표 4-16〉 로봇 윤리 가이드라인(안)의 3대 기본가치와 5대 실천원칙

구분	내용				
3대 기본가치	인간 존엄성 보호 (Protection of Human Dignity)		공공선 추구 (Pursuit of Public Good)	행복추구 (Pursuit of Happiness)	
5대 실천원칙	투명성 (Transparency)	제어가능성 (Controllability)	책임성 (Accountability)	안전 (Safety)	정보보호 (Security)

자료: 한국로봇산업진흥원(2019)을 바탕으로 재구성

2017년 7월 더불어민주당 박영선 의원이 발의한 ‘로봇기본법’은 로봇에게 전자적 인력체로서의 지위를 부여하는 내용을 담고있다. 로봇 기본법은 로봇을 ‘전자적 인격체’로 인정하고 책임과 권리, 의무를 부여하고 있다(표 4-17 참조).

〈표 4-17〉 ‘로봇기본법’의 주요 내용

- ‘전자적 인격체’로서 로봇의 지위를 인정하고, 책임과 권리, 의무를 부여
- 로봇에 의해 손해가 발생한 경우, 책임 부여 및 보상 방안과 관련된 정책 마련
- ‘로봇윤리규범’에 관한 사항 및 로봇 설계자·제조자·사용자가 준수해야할 윤리원칙 규정
- 국무총리 소속의 국가로봇윤리·정책위원회 설치하고, 국가로봇정책연구원을 설립하여 로봇공존 사회의 도래에 따른 사회 각 분야의 미래변화를 예측하고 대응할 수 있는 체계 마련
- 사회적 약자들이 로봇과 로봇기술 이용의 기회를 누릴 수 있는 대책 마련
- 로봇의 제조사가 로봇의 결함으로 손해를 입은 자에게 배상해야 하며, 정부는 이용자의 권익보호를 위한 시책 마련
- 로봇등록제 시행

출처: 한국정보화진흥원(2017.12.4.). p.21

나. 지능정보사회 윤리현장

과학기술정보통신부(이하 '과기정통부')는 2017년 11월 '지능정보사회 윤리가이드라인'을 발표하였으며, 2018년 6월에는 가이드라인의 대중적 요약본인 '지능정보사회 윤리현장'을 선포하였다<표 4-18 참조>.

<표 4-18> 지능정보사회 윤리현장

인간의 창의와 혁신을 기반으로 하는 4차 산업혁명과 그에 따른 지능정보사회는 우리 모두에게 불가피한 삶의 환경으로 자리 잡아가고 있다. 인공지능, 로봇 등의 지능정보기술은 사회 모든 분야에서의 융·복합 과정을 통해 경제적 도약과 사회 문제 해결에 새로운 기회를 제공하고 있으나, 의도하지 않은 부작용에 대한 우려도 나타나고 있다. 이에 우리는 지속가능한 공생의 가치를 구현하고, 안전하고 신뢰할 수 있는 지능정보사회로 나아가고자 다음과 같이 결의를 다진다.

1. 지능정보사회는 인간의 존엄과 안전을 지키고 인류의 보편적 가치를 실현하는 방향으로 발전해야 한다.
2. 지능정보사회에서 이루어지는 성과와 혜택은 소수에게 편중되기 보다는 모두에게 공유되어야 한다.
3. 지능정보사회에서 기술, 제품 및 서비스를 개발·공급하는 경우, 오동작과 위험상황에 대한 제어기능을 제공해야 하고 그 사회적 책임을 다해야 한다.
4. 지능정보기술을 활용하여 이루어지는 자동화된 결정과 처리 과정은 필요시 설명가능해야 하고, 사회적 편견과 차별 및 숨겨진 기능이 없어야 한다.
5. 지능정보사회의 가치를 논의하고 문제를 해결하기 위하여 우리는 공론의 장에 참여하여 열린 마음으로 협의하는 문화를 조성해야 한다.
6. 지능정보사회의 지속가능한 발전을 위하여 우리는 사회변화에 따른 디지털 시민성을 갖추고 역량을 강화하도록 노력해야 한다.

자료: 과학기술정보통신부(2018.6). p.23

지능정보사회 윤리가이드라인의 목적은 인간 중심의 지능정보사회를 구현하기 위해 지능정보 기술 및 서비스 개발자의 책임윤리 강화 및 이용자의 오남용 방지를 위한 지침을 제공하기 위한 것이다. 본 가이드라인 준비를 위해 과기정통부는 한국정보화진흥원(NIA)과 함께 민간 전문가로 구성된 '정보문화포럼'을 구성·운영한 바 있다.

본 가이드라인의 기본 방향은 네 가지로 소개되어 있다. 첫 번째는 지능정보기술의 잠재적 위험으로부터 사전에 사회시스템을 보호하는 '사전 예방원칙'이다. 인간의 복지, 권한, 자유의 확대라는 측면에서 지능정보기술로 인한 부작용과 위험요소를 완화할 수 있는 윤리규범을 제시하고자 하였다. 두 번째는 윤리적 규율이 필요한 분야와

관련하여 구체적 행위지침을 제시함으로써 관련 분야의 자율규제 환경 조성에 기여하는 것이다. 본 가이드라인이 관련 연구개발과 산업의 성장을 저해하지 않도록 노력하고, 개발자와 공급자에 대해 부당한 부담을 주지 않는 기준을 제시하는 것이 중요하다고 보았다. 세 번째는 시민 또는 이용자들의 권한 강화와 참여에 기여하고, 이용자의 역량강화에 도움이 되는 방향으로 개발하는 것이다. 마지막으로, 지능정보기술이 인간의 도덕적 가치와 윤리원칙의 관점에서 인간과 조화를 이루어야 하며, 궁극적으로 인간에게 도움이 되어야 하는 원칙을 구현하고자 하였다.

본 윤리가이드라인의 적용대상은 지능정보기술 및 서비스이며, 원칙의 적용범위는 개발자·공급자·이용자로 정의되어 있다(표 4-19 참조). 그리고 이들이 공통적으로 준수해야 할 4대 공통 원칙으로 공공성, 책무성, 통제성, 투명성으로 구성된 'P.A.C.T'가 제시되었으며(표 4-20 참조), 이를 기반으로 적용대상이 지켜야할 세부 지침이 함께 제공되었다(표 4-21 참조). 또한 정책과제로서 “건강한 연구문화 조성 및 국내외 협력 네트워크 구축”, “공공개발 유도 및 위험예방을 위한 법·제도 마련”, 그리고 “오작용 방지 및 이용자 역량강화를 통한 자율적 활용 제고”가 제안되었다.

〈표 4-19〉 지능정보사회 윤리가이드라인의 적용 대상 및 범위

구분	내용
지능정보기술	다음 중 어느 하나에 해당하는 기술 또는 그 결합 및 활용 기술 - 전자적 방법으로 학습·추론·판단 등을 구현하는 기술 - 물건 상호간 또는 사람과 물건 사이에 데이터를 처리하거나 물건을 이용·제어 또는 관리할 수 있도록 하는 기술(사물정보통신) - 클라우드 컴퓨팅 기술 및 데이터의 수집·분석·가공 등 처리기술 - 무선 또는 유무선이 결합된 초연결지능정보통신망 기반 기술
지능정보서비스	다음 중 어느 하나에 해당하는 것 - 「전기통신사업법」 제2조 제6호에 따른 전기통신업무와 이를 이용하여 정보를 제공하거나 정보의 제공을 매개하는 것 - 지능정보기술을 활용한 서비스 - 그밖에 지능정보화를 가능하게 하는 서비스
개발자	지능정보기술을 이용하여 각종 제품 및 서비스를 연구·설계·제작하는 자 * 개발자의 범위는 학술 목적의 연구를 통해 새로운 지능정보기술을 개발하는 연구자와 공급자의 의뢰를 받거나 공급자에게 고용되어 지능정보기술을 개발하고 그 결과를 구체적인 제품에 구현하는 일에 종사하는 전문인력을 포함

구분	내용
공급자	시장에 공급할 목적으로, 혹은 공공서비스의 목적으로 지능정보기술이 적용된 제품이나 서비스를 제공하는 자 * 공급자의 범위에는 해당 기술 및 서비스를 이용·가공하여 제공하는 2차 공급자도 포함
이용자	지능정보기술 기반의 제품 및 서비스를 이용하는 자 * 이용자의 범위에는 업무나 일상생활에 직접 활용하는 자(직접 이용자)와 구체적 인식 없이 지능정보기술이 포함된 서비스를 소비하는 자(간접 이용자), 그리고 지능정보 기술의 영향 속에서 일상생활을 영위하는 일반시민을 모두 포함

자료: 과학기술정보통신부(2018.6). pp.6-7

<표 4-20> 지능정보사회 윤리가이드라인의 공통원칙

구분	내용
공공성 (Publicness)	- 지능정보기술을 가능한 많은 사람들에게 도움을 주어야 하며, 지능정보기술에 의해 창출된 경제적 번영은 모든 인류의 혜택을 위해 광범위하게 공유되어야 한다. * 유관개념: 책임성, 윤리적 절차 이행, 위험 예방
책임성 (Accountability)	- 지능정보기술 및 서비스에 의한 사고 등의 책임 분배를 명확히 하고, 안전과 관련된 정보공유, 이용자 권익보호 등 사회적 의무를 수행해야 한다. * 유관개념: 책임성, 윤리적 절차 이행, 위험 예방
통제성 (Controllability)	- 지능정보기술 및 서비스에 대한 인간의 제어 가능성 및 오작동에 대한 대비책을 미리 마련하고, 이용자의 이용선택권을 최대한 보장하여야 한다. * 유관개념: 제어가능성, 위험관리, 이용자 주도성
투명성 (Transparency)	- 기술개발, 서비스설계, 제품기획 등 의사결정 과정에서 이용자·소비자·시민 등의 의견을 반영하도록 노력해야 하며, 이용 단계에서 예상되는 위험과 관련된 정보를 공개·공유하고, 개인정보 처리의 전 과정은 적절하게 이루어져야 한다. * 유관개념: 설명 가능성, 위험정보 공유, 이용자/시민참여

출처: 과학기술정보통신부(2018.6). p.10

<표 4-21> 지능정보사회 윤리가이드라인의 적용대상별 세부지침

적용대상	적용 단계	세부지침
개발자 (13)	수요분석(2)	지능정보기술의 공공성 확보 노력(P) 책임의 공유(A)
	제품개발(9)	윤리적 절차를 충실히 이행하여 연구·개발(A) 기술 개발 시 사회적 차별요소 배제(P) 사회적 약자 보호를 위한 접근성 보장(P) 품질 인증기준의 충족(A) 기술적 제어장치 마련(C)
		예외적 상황에 대한 종합적 검토(C)

적용대상	적용 단계	세부지침
공급자 (13)		은닉 기능 개발 금지(T)
		위험에 대한 적극적 예측 및 공급자와 공유(T)
		개발자들 간 정보교류와 기술갱신에 지속 참여(A)
	이용자원(2)	지속적 품질관리 실시(C)
		위급상황 시, 필요 데이터 제공(T)
	수요분석(6)	공공의 이익에 부합하는 제품 공급(P)
		상업적 이익과 공공적 기여 사이의 조화(P)
		지능정보서비스의 자율 의사결정 조건 및 범위 확립(A)
		안전성 검증 및 통제 조치의 마련(C)
		이용자의 선택권 보장(C)
		사회적 영향평가 결과의 반영(T)
	제품개발(1)	선한 의도를 가진 발주(P)
	공급·유통(3)	책임 공유 및 책임 보상 원칙의 마련(A)
		이용자 권리보장(A)
		제품 유통과정에서의 위험 통제(C)
	이용자원(3)	위험 관련 정보의 이용자 공유(T)
		이용자 정보의 부당한 이용 금지(T)
		위험 예방을 위한 사회적 공론화에 참여(A)
이용자 (12)	수요분석(1)	지능정보기술 이용역량 강화(C)
	공급·유통(3)	소비자 행동원칙 준수의 일상화(P)
		이용자 윤리책임 속지(A)
		설명을 요구할 권리(T)
	이용자원(8)	악의적 이용금지(P)
		자의적 조작금지(T)
		이용 제품의 교체, 갱신, 폐기 시 지침 준수(A)
		소비자 정보의 공유 의무(T)
		공공의 이익을 위한 제품 개선에 참여(P)
		책임을 제기할 수 있는 권리(A)
		안전 관련 정보공유와 제도화 요구의 권리(A)
		개인정보 활용에 대한 감시자로서의 의무 (T)

주: * 공공성(P), 책무성(A), 통제성(C), 투명성(T)

출처: 과학기술정보통신부(2018.6). p.22

다. 「지능정보사회 기본법(안)」/「지능정보화 기본법(안)」

2017년 2월 강효상 의원이 대표발의한 「지능정보사회 기본법(안)」은 인공지능 개발과 활용 관련 윤리적인 문제들을 포함하고 있다. 본 법안은 “지능정보기술의 자동화 속성으로 인해 국가 전반의 일자리와 분배체계의 혼선, 윤리적 판단기준의 변화, 불확정적인 위험 발생 가능성, 법적 책임 소재 파악의 어려움 등” 기술 변화에 따라 새로운

사회적 문제가 발생할 수 있으므로, 이러한 지능정보기술의 역기능을 최소화할 입법 정책이 필요하다는 취지이다. 이에 따라, 본 법안의 제17조는 정부는 3년마다 지능정보사회 발전기본계획을 수립하고, 기본 계획에 포함되어야 할 사항들에 “지능정보기술로 인한 위험의 방지”, “지능정보기술로 인한 차별의 방지 및 이용자의 권익 보호”, “지능정보기술 관련 윤리의 확립”, “지능정보기술 관련 지식재산권의 보호” 등을 함께 포함하였다.

2018년 2월에는 변재일 의원이 「국가정보화 기본법 전부개정법률안」을 대표발의 하였다. 본 법률안에 따르면 「국가정보화 기본법」을 「지능정보화 기본법」으로 제목을 변경한다. 법률안 제6조에서는 정부는 3년마다 지능정보사회 종합계획을 수립하는데, 지능정보사회의 윤리 확립, 정보보호, 정보격차 해소, 지능정보서비스에 대한 과의존의 예방과 해소를 위한 기본 계획의 수립에 관한 사항 등 역기능 해소, 이용자의 권익 보호 및 지식재산권의 보호 등을 종합계획에 포함할 것을 명시하고 있다. 또한, 법률안 제63조는 “국가기관과 지방자치단체는 지능정보사회 시책을 추진할 때 지능정보기술 및 지능정보서비스 등을 이용하는 이용자의 권익보호를 위한 시책을 마련”하도록 하였다. 구체적으로 본 국가정보화 기본법 전부개정법률안은 “이용자의 생명·신체· 명예 및 재산상의 위해 방지, 이용자의 불만 및 피해에 대한 신속·공정한 구제, 이용자의 권익보호를 위한 조직의 육성 및 활동 지원, 이용자의 권익보호를 위한 교육·홍보 및 연구, 이용자의 안전 보장 및 피해구제” 등 이용자의 권익구제를 위한 손해배상·보험 등 관련 법령 및 제도의 개선 등을 포함하고 있다.

라. 지능정보화시대 이용자 보호 체계

2019년 2월 13일, 방송통신위원회(이하 ‘방통위’)는 통신서비스 이용자보호를 위한 3개년(‘19~’21년) 중장기 정책방안을 담은 「통신 이용자보호 종합계획(이하 ‘종합계획’)」을 수립·시행할 계획이라고 밝혔다. 본 계획은 기술·서비스 동향, 법제도, ICT 환경 변화 등을 고려한 중장기 관점의 종합 대책 필요성에 부응하고, 4차산업혁명 및 지능정보사회 본격화에 따른 새로운 이용자 규범 설정과 체계적인 대책 방안 마련이 필요하다는 판단에 따른 것이다(방송통신위원회, 2019.2.).

본 계획의 주요 추진과제는 “[목표1] 이용자 중심의 보호 체계 확립”, “[목표2] 이용자의 역량 및 권리 강화”, “[목표3] 공정한 생태계 조성으로 이용자 편익제고”, 그리고 “[목표4]지능정보화시대 이용자 보호 체계 정립”의 4가지 목표로 구성되어 있다. 이 중 “[목표4]지능정보화시대 이용자 보호체계 정립”은 인공지능 등 지능정보기술 확산에 따른 알고리즘 차별, 인공지능 오작동 등 신유형의 이용자 피해 발생이 우려됨에 따라 지능정보시대 대비 이용자 보호를 강화하고자 하는 취지로 수립되었다. 본 목표 달성을 위한 하부 전략, 전략별 과제 및 추진 일정은 <표 4-22, 4-23>와 같다.

<표 4-22> “[목표4]지능정보화시대 이용자 보호 체계 정립”의 전략 및 과제

전략	과제별 추진 내용
전략7 4차 산업혁명 등 ICT환경변화에 대응하는 규범 정립	[과제7-1] 지능정보화시대 이용자 보호규범 정립 - (지능정보화시대 이용자보호) 지능정보화시대 이용자보호 원칙과 이용자 권리를 담은 「지능정보사회 방송통신 이용자보호 원칙, 마련·선도 * (보호원칙) 인간중심, 투명성, 책임성, 차별금지, 안전·신뢰 등 - (자율협약체) 지능정보서비스 자율규제를 위한 ‘민관협약체’ 운영 * ‘알고리즘 이용자보호 영향평가’ 방안, 이용자 보호 원칙 및 권리 구현을 위한 개발자·서비스제공자 업무지침서 마련
	[과제 7-2] AI 이용자 보호를 위한 법제도 정비 - (AI 이용자 행태 분석) AI 이용자 행태인식 중심의 패널데이터 구축 및 연구 등을 통해 알고리즘 효과 등을 분석할 수 있는 조사분석방법론 개발 - (AI-데이터윤리혁신센터 설립 추진) 전담연구센터를 구성·운영하여 주요 연구성과를 생산·검증하는 체계를 정립하는 등 연구기반 마련 ※ '19년도 : 센터 설립준비위원회 구성 및 예산 확보 등 연구기반 조성 '20년도 : 센터 인적 구성 및 연구과제 확충 등 사업체계 구축 및 연구추진 본격화 - (AI 연구개발 윤리 가이드라인 마련) AI의 공공성·책임성·통제성·투명성 원칙을 반영한 개발 및 연구 윤리 가이드라인 제정 - (알고리즘 법제도 정립) 인간행위 중심 법체계에서 기계 중심의 법체계를 포괄하는 지능정보사회에 적합한 법제 개선안 마련 ※ 법률적 책임 주체, 알고리즘 설명 책임 등 단계적 해결부터 포괄적 기본법 마련까지 단계적 접근
전략8 이용자보호 법제 정비 및 거버넌스 개선	[과제 8-1] 이용자보호 기본계획 법제화 및 법령 정비 - (기본계획 법제화) 이용자 보호정책의 종합적인 내용을 포함하는 기본계획을 법정 계획(3년 단위)으로 수립할 수 있도록 근거 마련 - (이용자보호 관련 법령 정비) 개별법률에 규정하고 있는 이용자 관련 규정 정비를 통해 규제 불균형을 해소하고 정합성 제고 추진

전략	과제별 추진 내용
	[과제 8-2] 이용자 정책 강화를 위한 조직 효율화 - (조직정비) 불법유험정보 대응, 신속한 통신분쟁 해결, 공정경쟁 질서 확립 및 관리·감독, 조사 강화 등을 위한 방통위 조직 정비 필요 - (조사 전문성 및 역량 강화) 조사절차 개선 및 조사인력 교육 등 전문성 강화, 해외사업자의 불공정행위 조사 및 해외 규제기관과의 업무 협력체계 구축 등 역량 강화 추진

자료: 방송통신위원회(2019.2.), pp.42~45.

<표 4-23> “[목표4]지능정보화시대 이용자 보호 체계 정립” 추진 일정

과제	2019년	2020년	2021년
[과제7-1] 지능정보화시대 이용자 보호규범 정립	이용자보호 원칙 마련 자율협약체 운영	개발자·서비스제공자 업무지침서 마련	-
[과제7-2] AI 이용자 보호를 위한 법제도 정비	新 이용행태 조사 방법론 개발 및 피해현황 분석, AI·데이터윤리혁신센터 설립 기반 조성	AI 연구개발 윤리 가이드라인 마련 법률적 책임·분쟁해결 체계 정립 및 제도 개선, AI·데이터윤리혁신센터 설립 및 연구 추진	알고리즘 법제도 정비
[과제8-1] 이용자보호 기본계획 법제화 및 법령 정비	이용자보호 기본계획 수립(3년)	이용자보호 기본계획의 법적 근거 마련	방송통신 이용자보호 관련 법령 정비
[과제8-2] 이용자 정책 강화를 위한 조직 효율화	조직정비·방통위 직제 개정, 조사심결지원시스템 구축	해외사업자 조사를 위한 전문인력 확충 및 전문성 강화	-

자료: 방송통신위원회(2019.2.), p.48

상기 일정에 따르면, 방통위는 2019년에 AI·데이터윤리혁신센터 설립 기반을 조성하고, 2020년에는 연구소 설립 및 연구를 추진할 계획이다. 2020년에 AI의 공공성, 책임성, 통제성, 투명성 원칙을 반영한 개발 및 연구 윤리 가이드라인을 제정하고, 2021년에는 알고리즘 설명 책임, 법률적 책임 주체 등 단기적 해결부터 포괄적 기본법 마련까지 단계적으로 접근하여 알고리즘 법제도 정비를 추진할 예정이다.

마. 지능형 정부구현을 위한 인공지능 활용 윤리

행정안전부(이하 ‘행안부’)는 4차 산업혁명을 맞아 인공지능, 사물인터넷 등 지능정보기술을 활용한 전자정부 서비스 발전을 추진하고 있다. 행안부는 알파고, 왓슨 등 고성능 인공지능 기술의 출현과 국내 전자정부 추진을 통해 축적한 대량의 디지털 데이터 등을 고려할 때 인공지능·빅데이터 기반의 행정혁신 여건이 성숙했다고 판단하여, 2017년 3월 인공지능과 데이터를 정부 서비스에 적극적으로 도입하는 “지능형 정부 기본계획”을 발표하였다.

지능형 정부는 “지능정보기술을 활용하여 국민 중심으로 정부 서비스를 최적화하고 스스로 일하는 방식을 혁신하며, 국민과 함께 국정운영을 실현함으로써 안전하고 편한 상생의 사회를 만드는 디지털 新정부를 지향”한다. 이를 구현하기 위한 4대 목표로는 “마음을 보살피는 정부”, “사전에 해결하는 정부”, “가치를 공유하는 정부”, “안전을 지켜주는 정부”가 제시되었다. 4대 목표 중 “안전을 지켜주는 정부”는 자기 진화형 사이버 안전 기반 구축 과제를 포함하고 있다. 이는 인공지능 기술을 통해 최신 보안위협 관련 데이터를 스스로 학습하고 이를 통해 체계적으로 대응 및 방어가 가능한 지능형 사이버 안전 체계를 의미하는데 지능형 사이버 공격, AI의 오작동 등 지능형 정부의 이면에 있는 역기능과 위험요소들을 선제적으로 방지할 수 있는 사이버 안전체계가 필요하기 때문이다(행정안전부, 2017.3.).〈표 4-24 참조〉.

〈표 4-24〉 사이버 위협 유형별 대응 방향

구분	사이버 위협	자가 진화형 대응 방향
인공지능 SW	- AI 오작동으로 인한 정책적 오류 - 지능형 사이버 공격 고도화	- 인공지능 SW 안정성 검증체계 마련 - AI 기반 사이버 자가 방어체계 구축
초연결 인프라	- IoT 인프라 보안 위협 - 지능형 네트워크 보안 위협	- IoT 기기 암호화, 통합인증 고도화 - 지능형 보안, 양자암호 체계 도입
빅데이터 등	- 빅데이터에 포함된 개인정보 유출 - 빅데이터 분석 오류	- 데이터 내 개인정보 식별 및 보호강화 - 지능형 분석 검증 체계 마련

자료: 행정안전부(2017.3.), p.13

2017년 10월에는 정부의 AI 서비스가 준수해야 할 윤리 기준 마련을 위해 “지능형 정부 구현을 위한 인공지능 활용 윤리” 연구에 착수하였다. 연구는 한국인터넷윤리학회가 수행하였으며, 인공지능 기반 행정의 투명성, 책임성, 공정성 등 다양한 인공지능 윤리문제 분석을 통해 정부가 준수해야 하는 사항들을 토대로 정부-국민이라는 관계의 특수성을 반영한 “정부가 준수해야 하는 인공지능 활용 윤리”와 항목별 구체적인 이행방안을 마련하는 것이 연구목표이다.

2019년 2월 행정안전부와 한국정보화진흥원은 향후 “지능형 정부를 구현하고 새로운 가치를 창출하는 전자정부 10대 유망기술”을 선정했다(행정안전부 보도자료, 2019.2.7.). 2019년 지능형 정부를 주도할 서비스의 3가지 분야로 “알아서 챙겨주는 지능형(Intelligent) 서비스”, “디지털로 만드는 스마트한(Smart) 업무환경”, “사각지대 없는 촘촘한(Mesh) 보안과 인프라(기반)”를 제시하였다. 각 서비스 분야별 핵심기술로 ‘감성 인공지능’, ‘비정형 데이터’ 등 10대 유망기술을 선정하였으며, 그 중 하나로 ‘인공지능 윤리’를 포함하면서 향후 공공서비스에 인공지능을 도입할 시 준수해야 할 인공지능 윤리 가이드 제시 계획을 재확인하였다.

바. 인공지능 의료기기 규제

식품의약품안전처는 첨단 의료기기 개발 활성화를 지원하기 위해 2017년 11월에 「빅데이터 및 인공지능(AI) 기술이 적용된 의료기기의 허가·심사 가이드라인」을 발표하였다. 본 가이드라인은 빅데이터 및 인공지능 기술이 적용된 의료기기를 “의료용 빅데이터를 분석하여 질병을 진단 또는 예측하는 독립형 소프트웨어 형태의 의료기기”로 정의하였다. 질병을 진단·예측하는 임상결정지원소프트웨어나 의료영상진단보조 소프트웨어 등이 해당된다.

인공지능 의료기기의 판단기준은 “의료기기법 제2조의 정의 규정을 충족하고, 소프트웨어가 의도한 대로 작동하지 않아 환자에게 위해를 끼칠 가능성이 있는지와 의료인의 임상적 판단을 보장하는지” 등을 종합적으로 고려하여 판단한다(정원준, 2018.1.31). 이 외에도 가이드라인은 “허가심사 신청서의 성능 기재 방법, 성능 및 유효성 검증 항목, 임상적 유효성 확인, 제출자료의 범위, 변경 허가·인증 대상, 버전

관리, 학습데이터의 관리, 클라우드 컴퓨팅 기술 적용에 따른 허가 범위”를 규정하고 있다. 본 가이드라인은 인공지능 의료기기 개발 활성화를 위한 구체적 진전이라고 볼 수 있으나, 인공지능 의료기기의 판단기준 및 민형사상 책임문제에 대한 문제점 및 개선 필요성이 제기된 바도 있다(정원준, 2018.1.31.).

사. 혁신성장 확산·가속화 전략

2019년 8월 21일 기획재정부는 「제21차 경제관계장관회의의 겸 제3차 혁신성장전략회의」에서 「혁신성장 확산·가속화 전략」 및 「혁신성장 확산·가속화를 위한 2020 전략투자방향」을 발표하였다. 「혁신성장 확산·가속화 전략」에 따르면, 정부는 ① 산업생태계 전반의 혁신 가속화, ② 혁신의 핵심주체인 기업의 혁신역량 제고, ③ 공공·사회 분야로의 혁신 확산, ④ 인재·규제·노동 등 혁신기반 강화의 4대 전략을 추진할 계획이다. 이 중에서 인재·규제·노동 등 혁신기반 강화 전략은 ‘미래 예측에 기반한 규제정비 및 위험요인 대비’ 측면에서 향후 인공지능 윤리 및 안전 이슈에 대한 정부 계획을 제시하였다.


이 계획의 주요 내용 중 첫 번째는 자율주행차에 시범 실시된 ‘선제적 규제혁파 로드맵’을 수소·전기차, 드론 등 타 분야로 지속적으로 확대하는 것이다. 두 번째는 빅데이터 분석 및 활용의 활성화에 따라 향후 발생할 수 있는 경쟁법적 이슈를 위한 규범 정비를 추진하는 것이다. 구체적으로는 2020년부터 알고리즘 담합과 같은 새로운 경쟁법적 이슈에 대한 대응방안을 마련할 계획이다. 세 번째, 2020년부터 자율주행, 인공지능 등 신기술과 관련된 이용자의 권리 보호와 책임소재의 명확화를 위한 제도와 법적 기준을 마련할 계획이다. 구체적으로 인공지능 오작동, 인공지능·로봇의 전자적 인격부여 여부, 자율주행차 교통사고, AI에 의한 가치판단의 책임소재, 로봇 창작물에 저작권 인정 가능성 등이 대상이 될 수 있다. 네 번째, 2020년에 4차 산업혁명의 진전과 관련하여 발생 가능한 윤리적 문제를 공론화할 계획이다. 국민참여 기반의 지능정보사회 윤리 규범 공론화를 통해 지능정보화 기술의 도입에 따른 역기능 예방과 인간 중심의 윤리시책 마련을 추진한다.

제3절 기업 및 학계/연구계, 주요국 정부 대응 동향 종합

인공지능의 윤리성 및 안전성과 관련해 3장에서 살펴본 기업 및 학계/연구계, 4장의 주요국 정부 대응 동향을 [그림 4-9]의 ‘인공지능 안전성 및 윤리성 측면’을 기준으로 종합해 보면, 인공지능의 안전성 및 윤리 차원과 정책 및 기술적 대응 차원에서 몇 가지 시사점을 도출할 수 있다.

먼저 인공지능의 안전성 및 윤리 차원에서 살펴보면, 기업들은 R&D 및 제품 개발 시 윤리성 및 안전성 확보에 집중하고 있는데 반해, 학계/연구계는 제품/서비스 상용화 및 활용 단계의 윤리성 확보 방안 연구에 치중하고 있음이 확인되었다. 기업 및 학계/연구계와 달리 주요국 정부들은 전 단계에 걸쳐 포괄적으로 윤리성 및 안전성 확보 관련 정책을 수립 중이어서 현재까지 방향성에 큰 문제가 없는 것으로 나타났다. 다만, 기업들은 상용화된 제품/서비스의 오류 및 오용에 대한 대응 방안이 부족한 것으로 조사되었는데, 기업의 사후처리 강화와 정부의 관련 법제도 보완 등 구체적인 대안 마련이 시급하다고 볼 수 있다.


[그림 4-9] 인공지능 안전성 및 윤리성 측면의 대응동향 종합



자료: 연구진 작성

다음으로 정책 및 기술적 대응 차원에서 살펴보면, 기업은 R&D 및 제품/서비스 개발 시 내부 정책과 기술적 대응을 병행하며 인공지능의 윤리성 및 안전성 강화를 추진하는 것과 달리, 학계는 제품/서비스 상용화 및 활용 단계에서 정책적 대응방안을 제시하는데 집중하고, 주요국 정부는 전 단계에 걸친 정책 대응 방안 수립을 진행 중임이 확인되었다. 인공지능의 안전성 및 윤리 차원에서 살펴본 바와 유사하게 정책 및 기술적 대응 차원에서도 상용화된 제품/서비스의 오류 및 오용에 대한 기술적 대응이 상대적으로 부족한 것으로 나타났기 때문에, 제품/서비스 모니터링, 통제 기술 등에 대한 연구개발 강화가 필요하다고 볼 수 있다.

[그림 4-10] 정책 및 기술적 차원의 대응동향 종합



자료: 연구진 작성

| 제5장 | 정책제언

제1절 법제도 개선 방안

1. 법제도적 이슈 정리²⁴⁾

앞서 살펴본 바와 같이 인공지능 알고리즘 오류 및 관련 제품 및 서비스의 오작동에 의한 사건·사고는 끊임없이 발생하고 있다. 2016년 러시아에서 시험 중이던 자율 로봇이 연구실에서 나와 거리를 활보한 사례도 있었고, 같은 해 미국의 한 쇼핑센터에 배치된 보안 로봇이 어린 아이를 공격에 상해를 입히기도 하였다(ZDNet, 2016.7.13.). 2018년 3월에는 미국 애리조나에서 시험 운행 중이던 우버(Uber)의 자율주행차가 무단횡단하던 보행자를 치어 사망에 이르는 사고도 발생했다. 이러한 안전성(safety) 문제와 더불어 윤리성(ethics) 측면에서도 문제가 제기되고 있다. 그 예로, 의도적으로 인공지능을 활용하여 가짜 이미지나 영상, 뉴스, 음성을 생성해 배포하는 사례도 나타나고 있다. 딥페이크(deepfake)라고 불리는 이러한 편집물들은 개인의 평판을 훼손시키고 사회적 구성원 간의 신뢰를 떨어뜨리는 등 부작용이 만만치 않다. 이미 국내외적으로 유명 연예인들의 얼굴이 음란물과 합성돼 인터넷에 무작위로 유포되고 있어 디지털 성범죄에 따른 우려의 목소리가 높아지고 있다.

이미 발생한 사례들 이외에도 아직 발생은 하지 않았지만, 인공지능 기술을 둘러싼 다양한 이슈들이 잠재적 위험요소로 잠복해 있는 상태이다. 이에 대해 제도 보완 등 적절한 대응이 이루어지지 않으면 점차 사회적으로 문제가 증가할 가능성이 농후하다. 본 장에서는 이러한 인공지능의 안전성 및 윤리성 문제 해결을 위한 규제정책 마련 차원에서 우리나라의 관련 법제도 현황과 구체적인 개선방안에 대해 살펴보고자 한다. 구체적으로 주요 인공지능 이슈를 포괄하는 7개 개별법을 살펴보고 안전하고 윤리적인 인공지능 연구개발 및 활용 차원에서 어떤 법제도들이 개선 또는 신설되어야 하는가를 도출하고자 한다.

24) 본 내용은 한국인공지능법학회(2019), 「인공지능과 법」을 포괄 인용하여 작성

가. 민법(계약법, 불법행위법)

인공지능 기술의 발전에 따라 거래에 인공지능 기술이 활용되는 사례가 증가하고 있다. 아마존 알렉사는 음성 명령을 데이터로 저장하고 이 데이터를 바탕으로 상품을 추천하고 주스가 떨어지면 주스를, 생일과 같은 기념일에는 케이크를, 다 써 가는 생필품까지 알아서 주문해준다. 이러한 일상생활의 편의를 위한 거래 뿐만 아니라 전문 분야에서도 인공지능 기술이 활용되고 있다. 특히, 최근에는 주식거래와 펀드에서 알고리즘을 통한 자동매매가 급증하고 있다. 그러면 인공지능을 통해 계약을 체결했을 때 문제가 발생한다면 누가 법적 책임을 지게 되는가에 대한 이슈가 발생한다.

계약관계에서 문제 발생시 누가 계약을 체결했는가에 따라 계약관계를 법적으로 어떻게 파악해야 하는지와 분쟁을 어떻게 해결해야 하는지에 대한 판단이 달라진다. 계약 체결시 원칙적으로 계약의 승낙에 대한 의사표시는 계약당사자가 하게 된다. 그러나 당사자가 체결하지 못하는 상황에서는 대리인이 당사자를 대신해서 계약을 체결하게 된다. 이런 경우 계약이 체결되면 권리와 의무를 취득하는 자는 당사자이지만 계약 승낙의 주체는 대리인이 된다. 대리인은 계약당사자의 의견을 바탕으로 해당 범위에서 계약을 체결할지 결정하고 그 결정을 승낙의 형태로 상대방에게 표시한다. 즉, 계약당사자가 대리인에게 계약체결을 맡기는 것은 계약체결을 위한 대강의 내용은 전달하지만, 일정부분의 자율성을 대리인에게 맡기고 구체적인 상황에 따라 계약을 체결한다는 것을 의미한다.

그러면 인공지능 에이전트를 통한 계약 체결시 해당 인공지능에 법인격을 지닌다고 볼 수 있는가? 이에 대해 다양한 논의가 존재한다. 먼저 사람이 아닌 대상에 대한 법인격 부여에 대한 이슈가 있다. 현행법상 인공지능에 법인격을 부여하지 못하는 필연적인 근거가 존재하는 것은 아니다. 법인(法人)과 같이 사람이 아닌 대상에게도 법인격이 부여되는 사례가 존재하기 때문이다. 따라서 인공지능에 법인격을 부여할 것인가의 문제는 인간의 경제적, 사회적 필요성에 의해 결정이 가능하며, 인공지능이 자율적인 판단을 내릴 수 있다면 법인격을 부여하는 것이 바람직한 방법일 수도 있다. 법인격을 부여하지 않고 인공지능의 작동을 모두 인간의 행위로 환원해서 판단하는 것이 현실적으로 번거로울 수 있기 때문이다.

그러나 실질적으로 법인격을 인정하는 것은 쉽지 않은 문제이다. 사람이 아닌 대상에게 법인격을 인정하는 기준은 법인격을 부여하는 필요성에 달려있기 때문이다. 단순히 대리인으로 취급하기 위해 법인격을 인정할 수 있는 것은 아니다. 인공지능이 형성하는 법률관계를 인공지능을 지배하는 사람과 분리해야 할 사회적 필요성이 인정되는 경우에만 인공지능에게 법인격을 인정할 수 있다. 따라서 인공지능이 체결하는 계약과 관련된 법적 논의는 향후 자율성을 보유한 인공지능에 의한 계약체결이 주요한 사회현상으로 등장하게 되면 진전될 것이다.

계약법과 더불어 인공지능 불법행위법 또한 인공지능 관련 민사법의 주요 이슈로 논의되고 있다. 불법행위란 고의성이나 부주의에 의해 다른 사람에게 손해를 끼친 행위를 의미한다. 불법행위는 특정 행위와 발생한 손해 사이에 인과관계가 있다고 판단되면 인정된다. 이러한 불법행위가 인정되는 경우에는 손해를 끼친 사람이 손해 당사자에게 책임을 갖게 된다. 그렇다면 인공지능의 불법행위로 발생한 손해는 누가 책임을 지어야 하는가? 이에 대해서 사람만이 책임의 주체가 될 수 있다는 관점과 향후 기술발전에 따라 인공지능도 제한된 범위에서 책임 주체가 될 수 있다는 입장이 존재한다. 사람만이 책임의 주체가 될 수 있다는 입장은 현행법이 사람만이 책임의 주체가 될 수 있다는 것을 전제로 한다. 그러나 앞서 언급하였듯이, 현재 법이 정한 목적과 범위 내에서 사람이 아닌 법인 역시 책임주체로 인정한다. 이러한 법인에 대한 이론을 인공지능에 적용하여 인공지능도 책임을 지게 할 수 있다는 주장도 존재한다. 그러나 인공지능이 책임 주체가 될 경우 사람이 책임을 회피하는 수단으로 활용될 수 있다는 지적도 존재한다. 이런 상황을 고려했을 때 현재의 약 인공지능(weak AI/narrow AI) 기술 수준에서는 사람만이 불법행위에 따른 손해배상책임을 지는 것으로 평가해야 한다는 주장이 힘을 얻고 있다.

그러나 향후 인공지능 기술이 발전하여 강 인공지능이 등장한다면 불법행위 관련 법의 개선은 필연적일 것이다. 즉, 어떤 인공지능 기술을 전제로 하는가에 따라서 불법행위로 야기된 손해를 누가 책임져야 하는지가 달라질 수 있다. 향후 인공지능 기술이 빠르게 발전하여 사람과 동등해지거나 또는 사람을 뛰어넘는 단계가 될 경우 인공지능도 불법행위와 관련하여 책임을 질 수 있는 가능성이 생길 수 있다. 이러한 경우

현재 책임의 주체를 사람으로 전제한 법은 변경될 여지가 있다. 즉, 현재 인공지능이 주체가 되어 불법행위를 책임져야 한다는 주장은 현재 수준이 아닌 더 발전된 인공지능 기술 수준을 전제로 한다. 그러나 현재의 인공지능 기술 수준을 전제로 한다면 불법행위법에 있어서 책임 이론이나 책임법과 같은 기존 큰 틀의 변화를 요구하진 않는다는 주장이 대두되고 있다.

나. 지식재산권법

최근 인공지능 기술의 발달로 그동안 인간 고유의 영역이라고 여겨지던 창작활동에서도 저작물을 창출하고 있다. 실제로 구글은 2017년 빈센트 반 고흐(Vincent Van Gogh)의 작품과 화풍을 학습한 인공지능 시스템 ‘딥드림(Deep Dream)’을 공개하였으며, 딥드림이 그린 총 29점의 작품을 9만7천 달러에 판매하기도 하였다(STARTUP TODAY, 2018.9.20.). 이처럼 인공지능이 창출한 창작물이 다양한 분야에서 등장하고 이를 판매하는 사례도 생기면서 인공지능의 저작물의 저작권을 둘러싼 법적 이슈도 제기되고 있다.

저작권법을 둘러싼 구체적인 이슈는 인공지능의 창작물이 ‘저작물’인가에 대한 문제이다. 저작권법 제1조에 의하면 저작권법은 “저작자의 권리와 이에 인접하는 권리를 보호하고 저작물의 공정한 이용을 도모함으로써 문화 및 관련 산업의 향상발전에 이바지함을 목적으로 한다”(저작권법 제1조). 또한, 현행 저작권법은 저작물을 “인간의 사상 또는 감정을 표현한 창작물”로 한정하고 있다(저작권법 제2조 제1호). 즉, 현행법은 인간의 창작 행위에 대해서만 저작물성을 인정하고 있으므로, 인간이 아닌 인공지능이 창작한 저작물에 대해서 저작권을 부여하기는 어렵다. 따라서 현행법상의 법리대로라면 인공지능 로봇이 스스로 창작물을 창작했을 경우에는 창작물을 특정인에게 귀속된 결과물로 보기 어려울 수 있다.

인공지능의 창작물에 저작권이 적용되기 어렵다는 주장은 저작권제도의 취지에서 볼 때 인공지능을 저작물로 인정했을 때 저작물의 보호대상으로 거론되는 프로그래머, 프로그램 사용자, 인공지능, 공동저작자 등이 저작권의 귀속주체가 되기 어렵다는 입장을 취하고 있다. 그러나 이러한 관점에 입각하면 인공지능이 제작한 결과물은 누구

나 마음대로 이용할 수 있다는 결론에 이르게 되는데, 이는 신중한 검토가 필요한 쟁점이다. 이에 인공지능이 창작한 저작물에 대해서 현재 통상적으로 적용되는 보호수준 보다는 낮은 범위의 보호제도가 필요하다는 논의가 진행되고 있다. 즉, 인공지능 창작의 보호는 인간이 창작한 저작물과 동일 수준의 보호를 부여하기 보다는 인공지능 창작을 장려하기 위해 투자를 보호하는 방향으로 논의가 진전되고 있다.

다. 형법

향후 인공지능 기술을 탑재한 로봇이 확대되면 로봇이 범법행위를 통해 인간에게 신체적, 재산적 손해를 입히는 사례도 발생할 것이다. 실제로 2016년 러시아에서 시험 중이던 자율 로봇이 연구실에서 나와 거리를 활보한 사례도 있었고, 같은 해 미국의 한 쇼핑몰에 배치된 보안 로봇이 어린 아이를 공격에 상해를 입히기도 하였다(ZDNet, 2016.7.13.). 이러한 경우 범죄를 저지른 인공지능이 형벌을 받을 수 있는지가 이슈가 되고 있다.

형법상 인공지능을 탑재한 로봇이 형법상 책임을 지기 위해서는 지능형 로봇이 범죄행위를 스스로 행하였어야 한다. 하지만 전통적인 형법은 인간의 범법행위를 기준으로 구성되어 있다. 이에 따르면 로봇 등 기계의 행위는 인간의 행위가 아니기 때문에 형벌을 받을 수 없다. 그러나 이러한 주장에 대해 지능형 로봇의 경우 인간으로부터 독립하여 스스로를 인식하고 판단하여 행동할 수 있다고 보는 시각도 있다. 이러한 논리에 따르면 인공지능을 탑재한 로봇이 인간과 유사한 새로운 주체의 행동으로 해석할 가능성이 열리게 된다. 그러나 실질적으로 현재의 수준에서는 지능형 로봇의 행위를 인간이 행위와 동일하게 보기 어렵다. 현재는 로봇에 탑재된 인공지능의 인식, 판단, 행동 역시 사람의 의도에 따라 구축된 데이터를 이용하여 학습한 결과이기 때문이다. 이와 더불어 지능형 로봇이 인간의 특정 목적을 달성하기 위해 이용된다는 점은 기존의 기계와 크게 다르지 않기 때문이다. 따라서 현재로선 인공지능이 탑재된 로봇이 범법행위를 하였다 하더라도, 로봇에게 형법적 책임을 지우기는 어렵다. 그러나 인공지능 기술이 발전하여 로봇 스스로 의지와 감정을 갖게 된다면 로봇을 형사책임의 대상으로 볼 것인지에 대한 추가적인 논의가 필요할 것이다.

결론적으로 현재 수준의 인공지능 시스템과 지능형 로봇에게 형법상 형벌을 부과하는 어려워 보인다. 그러나 인공지능을 개발하고 이용하는 단계에 따라 악의적 사용이나 과실에 따른 오작동의 경우에 각각 법적 제재가 필요한지 따지고, 필요하지 않은 경우 어떤 제도를 통해 피해자의 손해를 보전할 것인지, 필요할 경우에는 어떤 종류의 제재가 어떠한 정도로 필요한지에 대해 추가적인 논의가 필요하다.

라. 정보보호법

개인정보를 수집, 처리, 분석하는 기술이 확대 될수록 개인정보 오남용에 대한 우려도 확대되고 있다. 과거에는 처리 할 수 있는 정보의 양이 절대적으로 적었고, 데이터를 수집 처리할 수 있는 경로도 제한적이어서 개인정보 오남용에 대한 우려가 상대적으로 적었다. 그러나 정보처리 기술의 발달로 다량의 데이터가 쉽게 처리 될 수 있게 되었고, 데이터의 수집 및 유통 경로도 다양해지면서 기술적으로 다수의 데이터를 결합하여 특정 개인을 식별하는 것이 가능해졌다. 또한 비정형적인 데이터의 경우에도 보다 지능적으로 결합하고 분석하는 것이 가능해지면 점차 특정 개인에 대한 정보 분석, 집계, 추적 등이 용이해졌다.

이처럼 데이터를 처리, 분석하는 인공지능 알고리즘이 고도화 될수록 개인정보보호의 필요성이 점차 증가하고 있다. 현행법상 개인정보는 “생존한 개인에 관한 정보”, “식별가능성”, “결합의 용이성”을 핵심적 요건으로 보고 있다. 개인정보보호법 제2조 제1호에 따르면 “살아있는 개인에 관한 정보로 성명, 주민등록번호, 영상 등을 통해 개인을 알아볼 수 있는 정보(해당 정보만으로는 특정 개인을 알아볼 수 없더라도 다른 정보와 쉽게 결합하여 알아볼 수 있는 것을 포함한다)”로 정의한다. 정의에 따르면 성명이나 주민등록번호와 같이 직접적으로 식별할 수 있는 정보와 더불어 해당 정보만으로는 식별이 불가능하더라도 다른 정보와 결합하여 개인을 식별할 수 있을 경우 개인 정보에 해당된다. 그러나 기존 개인정보보호 법제를 따르면 인공지능 기술을 통한 데이터 분석의 지능화와 자동화는 개인정보보호법상 문제를 발생시킬 수 있다. 기존의 개인정보보호법제는 개인정보자기결정권을 바탕으로 개인정보 처리에 대한 결정권을 정보주체에게 부여하고, 개인정보의 처리단계에 대한 정보주체의 개입을 허용하는 방

식이기 때문이다. 따라서 개인정보처리에 대한 정보주체의 개입권을 법적으로 부여하는 것과 최대한 사람의 개입 여지를 줄여서 지능적이고 자동화된 처리를 하자는 인공지능 사이에서 어떤 방식으로 얼마나 규율할 것인가에 대해서는 가치의 충돌이 불가피하게 발생할 수밖에 없다. 현행법은 인공지능을 고려하여 기준을 정한 것이 아니기 때문에 향후 인공지능을 고려한 합리적인 규율방안 논의가 전개되어야 할 것이다.

마. 공정거래법

독점규제 및 공정거래에 관한 법률 제1조에 의하면 공정거래법은 “사업자의 시장지배적지위의 남용과 과도한 경제력의 집중을 방지하고, 부당한 공동행위 및 불공정거래행위를 규제하여 공정하고 자유로운 경쟁을 촉진”하는 법으로 “시장에서 사업자의 창의적인 기업 활동을 조장하고 소비자를 보호함과 아울러 국민경제의 균형 있는 발전을 도모하는 것을 목적”으로 한다(공정거래법 제1조). 공정거래법은 시장에서 사업자간의 자유롭고 공정한 경쟁이 소비자의 후생을 증대시킨다는 것을 전제로 시장에서 경쟁을 제한하는 시장지배력 남용, 부당한 공동행위, 불공정거래행위 등을 규제하기 때문에 시장 내에서 경쟁구도 변화가 법적용의 주요 요소로서 작용한다.

최근 인공지능 기술이 글로벌 ICT 기업을 중심으로 시장에 빠르게 적용되면서 경쟁 구도와 사업자 간의 역학관계에 중요한 변수로 부상하고 있다. 딥러닝 기술의 발달은 인공지능이 단순히 시장참여자의 결정을 도와주는 수준을 넘어서 직접 결정하는 상황을 발생시켰고 이를 둘러싸고 공정거래법상 우려가 제기되고 있다. 첫 번째 우려는 구매자의 알고리즘 의존 문제이다. 제품 구매를 포함한 다양한 거래에서 알고리즘을 활용하여 의사결정을 할 경우 구매자의 선택이 용이해질 수 있는 장점이 있지만, 구매자가 제공받는 정보가 왜곡되거나 의사결정을 알고리즘에 의존하게 되는 상황이 발생 할 수 있다. 이와 더불어 알고리즘을 통한 가격차별의 문제도 제기되고 있다. 특히 시장 경쟁에서 중요한 결정 요소인 가격의 결정을 알고리즘이 대신하는 상황에서 알고리즘 담합의 가능성이 제기되고 있다. 구체적으로 알고리즘은 구매자의 데이터를 바탕으로 개인의 선호와 특정 상품에 대한 개인의 지급의사를 보다 정확하게 추론 할 수 있기 때문에, 알고리즘이 가격 결정에 적용될 경우 개별 구매자마다 개별화된 가격

책정이 가능해진다. 이러한 구매자별로 개별화된 맞춤형 가격은 경제학 이론상으로는 완벽한 가격차별이 될 가능성이 있다. 이론에 따르면, 구매자별로 선호도와 지급의사에 일치하게 개별 가격이 책정될 경우 소비자 잉여가 판매자에게 모두 귀속되는 결과가 발생할 수 있다.

이처럼 제품 구매자를 차별하는 것과 더불어 판매자를 차별하는 도구로 알고리즘이 이용될 수 있다. 구체적으로 판매자가 제품 판매를 위해 사용하는 플랫폼의 검색 알고리즘과 가격 비교 알고리즘을 판매자가 지급하는 수수료에 따라 차별할 수 있다. 또한 이러한 차별문제는 검색서비스제공자(플랫폼)가 자사 서비스의 경쟁우위를 확보하기 위해 활용할 경우 더 큰 문제가 된다. 실제로 2017년 유럽위원회는 구글이 자사서비스의 검색결과와 경쟁서비스의 검색결과에 적용한 알고리즘이 상이하다는 이유로 이를 구글의 자사서비스 우대로 해석하였으며 이러한 행위가 경쟁법에 위반한다고 판단하였다.

그러나 이처럼 인공지능 알고리즘으로 개별 가격 책정이 가능해지더라도, 판매자간 상이한 알고리즘을 사용하여 경쟁업체의 가격책정에 대응한다면 소비자가 선호하는 가격책정 알고리즘을 선택할 수 있다는 점에서 알고리즘의 가격차별 이슈는 일정부분 해소 될 수 있을 것이다. 그러나 문제는 경쟁자가 동일한 가격결정 알고리즘을 사용하고 해당 알고리즘을 추가로 학습할 때 경쟁자의 가격책정 데이터가 자유롭게 수집되는 경우이다. 만약 경쟁자의 가격책정 데이터가 실시간으로 수집이 가능하다면 해당 데이터를 바탕으로 상대 경쟁자와 동일하게 가격을 결정할 수 있다. 결과적으로 경쟁자 간에 가격결정을 동조한 결과가 발생할 수 있으나 이러한 결과는 상호의 의사전달 없이 알고리즘을 통해 생긴 것이므로 법적으로 카르텔로 단정하기 어려울 수 있다. 이러한 알고리즘 담합이슈에 대해 일부는 담합여부를 판단하는 기준을 ‘합의’로 하는 기존 법리를 확장하여 알고리즘 담합 문제에 대한 규제가 가능하도록 새로운 합의 요건을 재구성해야 한다고 주장한다.

이처럼 인공지능기술이 소비자와 판매자의 의사결정을 자동적으로 수행하는 사례가 발생하면서 시장에서의 경쟁의 개념이 변화하고 있다. 기존에는 시장에서 경쟁 과정을 중점적으로 경쟁법상 위반여부를 살펴보았지만, 경쟁 과정이 명확하지 않아도

소비자의 선택이 줄어들거나 시장의 혁신을 저해하는 경우가 발생 할 수 있다. 이에 따라 혁신과 소비자 선택을 중심으로 재구성된 새로운 경쟁침해이론의 필요성이 증가하고 있다.

바. 도로교통법

도로교통법상 법률 이슈는 크게 1)운전자규제체계의 개편, 2)운전면허제도의 개편, 3)교통규칙의 개편 등 3가지 측면에서 살펴볼 수 있다. 첫 번째 운전자규제체계의 이슈는 크게 두 가지가 있다. 먼저 운전의 개념과 관련된 이슈이다. 도로교통법에 제2조에 따르면 운전은 “도로에서 차마 또는 노면전차를 그 본래의 사용방법에 따라 사용하는 것”을 의미한다(도로교통법 제2조). 이처럼 현행 도로교통법이 운전자 중심으로 구성되어 있기 때문에, 향후 자율주행자동차가 상용화되는 시점에서도 그대로 적용될 수 있는지에 대해 논의가 필요하다. 이와 더불어 행위의 상대방을 사람으로 하여 권리의무관계를 적용하는 기존의 법이론을 자율주행차의 운행과 운전관계에도 적용이 가능한지에 대한 이슈가 존재한다.

두 번째는 운전면허제도의 개편과 관련된 이슈이다. 현행법의 관점에서 보면 자율주행차의 조작 등을 포함한 운전형태는 운전 개념보다는 운행 개념에 좀 더 가깝다고 볼 수 있다. 그러나 기존 운전자면허제도의 목적이 사람의 생명과 재산의 안전성을 보호하기 위한 것이라는 점에서 운전면허제도의 취지 자체를 부인하기는 어려운 것으로 보인다. 또 다른 이슈는 자율주행차의 운행 또는 운전면허는 누구에게 어떤 행위를 대상으로 발행할 것인지에 대한 문제이다. 먼저 면허 발급 대상에 대해 살펴보면 발급 대상은 차량의 소유자와 실제 차량의 운전자로 구분할 수 있다. 소유자의 경우에는 실질적으로 자동차관리법상 차량등록의 의미가 있을 뿐이고, 운전자의 경우 현행 운전면허제도와 다르지 않게 될 것이다. 두 번째로 규제행위 이슈가 있다. 운전 면허의 규제 대상은 차량의 조작행위가 될 것이다. 기존 차량의 조작행위는 차량을 목적지까지 조작하는 행위와 비상시의 차량 통제 등이 이에 포함될 것이다. 그러나 자율주행차는 현재의 차량 운전행위보다는 조작 수준이 단순하다는 점에서 관련 규율이 낮아질 수 있을 것이다. 이에 따라 대부분의 사람들이 자율주행차의 면허를 쉽게 취득하는

방향으로 제도가 마련될 것으로 보인다.

마지막으로 교통규칙 개편을 살펴보면 도로교통법상 교통규칙은 자동차의 운행시 도로에서 일어나는 교통상의 위험과 장애를 방지·제거하여 교통의 원활한 소통과 안전을 확보하기 위하여 필요한 운전자 및 보행자의 행위규범을 말한다. 이 중 운전자의 교통규칙은 모든 차의 운전자가 지켜야할 행위 규범이다. 자율주행차 역시 교통상 위험과 장애를 방지하고 원활한 소통을 확보해야 한다는 점에서 교통규칙은 여전히 필요하다. 이에 따라 자율주행차의 운행에 맞는 교통규칙의 신속한 개편이 요구되고 있다. 관련 쟁점으로는 크게 4가지가 논의되고 있다. 첫 번째는 1)자동차의 운행에 있어서 교통규칙이 필요한지와 2)필요하다면 그 규칙의 준수여부를 차량자체에 부과할 것인지, 운전자에게 부과할 것인지 3)교통규칙 위반에 대한 제재 방법이 타당한지, 4)현행 교통규칙 중에 자율주행자동차의 운행 시 적용될 것은 무엇인지 등이다. 현행법상 교통규칙을 준수하는 의무자는 운전자이다. 그러나 자율주행차는 자동차를 제작할 때 제조과정상 어떤 교통규칙을 준수할 것인지와 윤리적 딜레마가 발생한다면 어떤 선택을 할지에 대해 사전에 제조과정에서 알고리즘으로 설계 되어 있다. 이에 차량 제작사의 의무를 통해 자율주행차 제작과정에서 교통규칙을 알고리즘으로 반영할 의무를 부과하고 법률로 상세하게 규정하는 것으로 제재 대상은 충분하다는 주장이 제기되고 있다. 교통규칙 위반 제재 문제의 경우 현행법상으로 위반행위에 대해 과태료의 행정 제재와 형벌의 형사제재를 하고 있는데 이에 대한 구조를 변경할 필요가 있다는 주장이 제기되고 있다. 우선 자율주행차의 경우 운전자에 대한 규제의 필요성이 저하될 것이므로 현재 운전자 중심 제재구조의 실효성이 감소할 것이라고 예상되고 있다. 또한 앞서 살펴본 것처럼 자율주행차의 경우 차량 제조업체의 규제 필요성이 증가하고 있으므로 제재규정에 대한 전반적인 수정이 필요해 보인다. 구체적인 교통규칙의 개편 내용을 구체적으로 살펴보면 차선이나 신호체계는 기존에 사람이 운전하던 수준보다 엄격하게 적용될 필요가 있다. 또한 현재 운전자를 전제로 하는 음주운전과 같은 교통규칙 위반과 운전석의 개념, 운전석 이탈시 시동정지의무 등에 대한 재검토가 필요해 보인다.

사. 제조물책임법²⁵⁾

인공지능 기술이 산업 전반에 확산됨에 따라 인공지능 기술이 야기하는 예상치 못한 부작용 사례도 증가하고 있다. 중국 선전에서 개최된 전시회에서 지능형 로봇이 기물을 파손하고 사람에게 상해를 입힌 사례(한겨레, 2018.11.5.), 인공지능 비서 알렉사가 가족 간의 대화 내용을 녹음해 회사 동료에게 전송해서 프라이버시를 침해한 사례, 우버가 시범운행하던 자율자동차가 사람을 사망에 이르게 한 사례 등 인공지능 오작동과 오류의 유형이 점차 증가하고 있으며 그중 일부 사건은 심각한 신체 및 재산상 손해를 초래하였다. 이에 따라 인공지능 오류 발생시 책임 소재에 대한 제도 개선 필요성이 확대되고 있지만 오류를 둘러싼 책임소재의 판단이 쉽지 않다는 문제를 가지고 있다.

현재 피해자의 생명이나 신체 또는 재산에 발생한 손해가 제조물의 결함으로 인하여 발생한 경우에 손해배상책임에 대해 제조물책임법을 적용하고 있다. 제조물책임법은 제품의 결함으로 발생한 손해에 대하여 제조업자 등의 책임을 강화함으로써 피해자를 구제하려는 특징을 가지고 있다(이한영·차성민, 2017). 현재 인공지능 소프트웨어 결함으로 인한 손해가 발생한 경우에 제조물책임법상 제조물은 동산(動産)에 국한되어 있고 무체물인 소프트웨어는 제조물에 해당하지 않으므로 소프트웨어 업체를 상대로 제조물책임법상의 책임을 물을 수 없다는 주장이 있다. 그러나 국내 대법원은 소프트웨어 프로그램 자체에 대해서는 제조물성을 인정하지 않고 프로그램이 탑재된 하드웨어를 제조물로 보아 제조물책임을 적용한 바 있어 이를 준용할 수 있을 것이다(법률신문, 2019.8.12.). 다만, 향후 인공지능이 상용화되기 위해서는 하드웨어에 인공지능을 탑재한 '임베디드 소프트웨어(Embedded Software)'에 대해서도 제조물성을 인정하도록 법 개정이 필요하다고 지적되고 있다(법률신문, 2019.8.12.). 소프트웨어는 제조물을 구성하는 핵심으로 제조물의 결함을 이유로 제조사를 상대로 제조물책임법상의 책임을 물을 수 있다고 보아야 한다는 주장이다. 구체적으로 개발자가 결함 있는 소프트웨어를 만들었고, 이로 인해 다수의 인명, 재산 피해가 발생했다고 가정한

25) 한희원(2018), 「인공지능(AI) 법과 공존윤리」 포괄인용

다면 개발자는 사고의 책임에서 자유로울 수 없을 것이다. 결함 있는 소프트웨어를 작성한 당사자가 아무런 처벌도 받지 않는다면 해당 사고로 재산적, 신체적 피해를 본 당사자는 납득이 불가능 할 것이다. 소프트웨어의 행위는 그것을 만든 제작자와 연결되어 있다. 소프트웨어가 인간과 재산에 막대한 해를 끼칠 수 있는 기기를 구동하는 경우에는 더 높은 수준의 기준이 요구된다. 그러나 이와 관련해서도 인공지능 기술의 특성상 알고리즘을 설명할 수 없다면 해당 소프트웨어가 왜 오작동했는지 알 수 없다는 문제도 제기된다. 이 경우 피해자는 '제조물의 결함'인지 증명하기 어려운 현행법상 제약이 존재한다(한국경제, 2019.10.15.).


2. 법제도 개선 우선순위 도출

본 절에서는 국내 인공지능의 안전성 및 윤리성 관련 문제 해결을 위한 규제정책 마련을 위해 법제도 개선의 우선순위를 도출하고자 한다. 구체적으로 앞서 살펴본 주요 인공지능 이슈를 포괄하는 7개 개별법을 기준으로 제도 개선의 우선순위를 도출하였다. 이를 위해 국내 산·학·연의 관련 전문가 20명을 대상으로 설문조사를 수행하였으며, 시급성, 용이성, 파급성을 기준으로 민법, 지식재산권법, 형법, 정보보호법, 공정거래법, 도로교통법, 제조물책임법을 7점 척도로 물어보는 형식을 취하였다.²⁶⁾ 설문은 인공지능 관련 법이나 인공지능 기술 및 적용 분야를 연구하고 있는 정부출연연구소 연구원, 교수 등을 중심으로 진행되었으며, 조사기간은 2019년 8월 30일부터 9월 13일까지 약 2주간 진행되었다. 설문지는 7점 척도 기준(7 = 매우 높음, 1 = 매우 낮음)으로 구성되었다. 이하 설문조사 결과는 인공지능의 안전한 활용을 위해 우선적으로 개선되어야 할 법제도에 대한 전문가들의 의견이 종합된 내용이다.

26) 구체적인 설문 문항은 본 보고서 부록의 '안전하고 윤리적인 인공지능 R&D와 활용을 위한 법제도 개선방안 전문가 설문'을 참고

가. 시급성 평가

[그림 5-1] 인공지능 법제도 개선 시급성 평가




자료: 연구진 작성

인공지능 법제도 개선의 시급성의 평균값은 4.82로 중간값인 4.0을 초과하여 전체적으로 법제도 개선이 시급한 것으로 평가되었다. 분야별로 살펴보면 정보보호법(6.25), 도로교통법(5.5), 제조물책임법(4.88) 순으로 제도 개선이 시급한 것으로 나타났다. 특히, 정보보호법은 7개 분야의 시급성 평균인 4.82보다 약 1.5점 높은 수준으로 가장 신속하게 법제도 개선이 필요한 것으로 평가되었다. 반면 형법(3.38), 민법(4.55), 지식재산권법(4.55)는 상대적으로 다른 분야에 비해 법제도 개선의 시급성이 낮은 것으로 평가되었다. 특히, 형법은 중간값인 4.0이하인 3.38로 가장 시급성이 낮은 분야로 평가되었다.

나. 용이성 평가

[그림 5-2] 인공지능 법제도 개선 용이성 평가




자료: 연구진 작성

인공지능 법제도 개선의 용이성의 분야별로 살펴보면 도로교통법(5.23), 정보보호법(5.2), 제조물책임법(5.1) 순으로 제도 개선이 용이할 것으로 평가되었다. 반면 형법(3.98), 지식재산권법(4.5), 민법(4.6)은 다른 분야에 비해 법제도 개선이 쉽지 않은 것으로 평가되었다. 특히, 형법은 중간값인 4.0이하인 3.98로 향후 관련 법제도 개선을 위해 가장 많은 노력이 필요할 것으로 평가되었다.

다. 파급성 평가

[그림 5-3] 인공지능 법제도 개선 파급성 평가




자료: 연구진 작성

인공지능 법제도 개선의 파급성의 평균값은 4.99로 중간값인 4.0을 초과하여 전체적으로 법제도 개선시 파급력을 지닐 것으로 평가되었다. 분야별로 살펴보면 도로교통법(5.85), 정보보호법(5.7), 제조물책임법(5.45) 순으로 파급력이 클 것으로 평가되었다. 반면 형법(3.9), 공정거래법(4.4), 지식재산권법(4.68)는 상대적으로 다른 분야에 비해 법제도 개선의 파급성이 낮은 것으로 평가되었다. 특히, 형법은 중간값인 4.0 이하인 3.9로 가장 파급성이 낮은 분야로 평가되었다.

라. 평가종합

전문가들이 평가한 인공지능 법제도 개선의 시급성, 용이성, 파급성을 종합적으로 살펴보면 평가를 진행한 7개 개별법 중 형법을 제외한 6개의 평균값이 중간값 4.0을 넘어 향후 제도개선이 필요한 것으로 평가되었다. 특히, 정보보호법(5.72), 도로교통법(5.54), 제조물 책임법(5.14)은 5.0을 넘어 시급성, 용이성, 파급성 면에서 종합적으로 제도 개선이 필요하다는 결과가 도출되었다.

[그림 5-4] 인공지능 법제도 개선 평가 종합



자료: 연구진 작성

3. 법제도 개선 방안²⁷⁾

지금까지 살펴본 것처럼 인공지능의 확산은 판단과 의사결정을 비롯한 인간의 인지적 과업을 수행하는 데 도움을 주면서 많은 이익을 가져다 줄 수 있지만, 그 과정에서 인간의 가치와 권리 및 이익에 상당한 위험을 초래할지 모른다는 우려를 불러일으키기도 한다. 이러한 문제를 해결하는 것은 그 자체로 개인과 공동체의 이익을 지켜내는 것이기도 하지만 동시에 인공지능 기술의 사회적 수용성을 높여 기술 및 산업의 발전의 토대가 되는 것이기도 하다.

법과 제도란 개개의 문제 상황들이 발생할 때마다 즉흥적으로 해결하는 대신에 일반적 원칙과 규율을 미리 만들어두어 보다 합리적이고 효율적인 해결을 꾀하는 한편 부수적으로 바람직한 행동을 이끌어내기 위한 것이다. 따라서 법제도를 마련함에 있어서는 특정한 목표에 치우치기보다는 서로 상충하는 가치들과 관련 당사자들의 이

27) 본 주제에 대해서는 충남대학교 법학전문대학원 이상용 교수의 자문을 받아 작성하였음.

익을 비교 형량하여야 한다. 본 연구가 인공지능과 관련된 안전과 윤리의 문제를 집중적으로 다루고 있기는 하지만, 법제도의 개선방안을 논함에 있어서는 이러한 균형적 시각을 유지하는 것이 필요하다. 각국에서 내놓은 인공지능의 안전 및 윤리에 관한 전략들이 법제도적 해결보다는 기술적 해결에 우선순위를 두고 있다거나, 법제도 개선방안들이 인공지능의 위험만을 다루기보다는 인공지능의 활용을 통한 번영을 추구하면서 그 과정에서 생길 수 있는 부작용을 완화하는 방식으로 구성되고 있다는 것은 바로 이러한 연유에서 비롯된 것이다. 또한 법제도적 개선방안이 헌법 질서와 부합해야 함은 물론인데, 특히 국민의 자유와 권리를 제한하려면 공공복리 등을 위하여 필요한 경우에 한하여 법률로써만 할 수 있다는 비례의 원칙(헌법 §37②)이 강조될 필요가 있다.

인공지능은 이른바 범용 기술로서 우리의 삶에 그 영향이 미치지 않는 부분이 거의 없을 정도이다. 이처럼 광범위한 현상에 대한 법제도적 대응방안을 체계적으로 논의하기 위해서는 기본적인 분석틀을 갖추는 것이 도움이 된다. 인공지능 기술이 가진 특성이 그 출발점이 될 수 있다. 인공지능은 인간의 개입 없이도 과업을 수행한다는 의미에서 자율성이 있고, 그 과업을 인간만큼 또는 인간보다 더 효과적으로 수행한다는 의미에서 합리성이 있으며, 상황에 따라 인간처럼 여겨질 수 있다는 점에서 유사성이 있다. 이들 특성은 생산성 향상의 원천인 동시에 법적·정책적으로 상당한 도전이 되기도 한다(이상용, 2016). 예컨대 자율성은 책임의 회피나 악화의 유인이 되고, 합리성은 인공지능 이용자·비이용자 간의 격차나 다양성의 축소 등의 문제를 일으킬 수 있으며, 유사성은 사기 등의 범죄 수단으로 이용될 위험을 낳는 식이다. 인공지능으로 인한 문제들에 대한 법제도적 대응방안들은 대개 이러한 구도에 의하여 해석될 수 있지만, 각 영역마다의 특수한 고려사항들을 반영하기도 한다.

아래에서는 전문가들에 대한 설문조사를 통하여 인공지능의 확산 과정에서 가장 중요한 과제들로 선정된 세 가지 분야, 즉 정보보호법, 도로교통법, 그리고 제조물책임법 분야에서의 법제도 개선방안을 서술한다. 이를 통하여 인공지능의 안전 및 윤리와 관련된 원칙들, 즉 포용성과 지속가능성, 인간가치와 공정성, 투명성과 설명가능성, 견고성과 안전성, 책임성 등이 구체적인 법제도에 반영되면서 다른 법적 가치들 및

다른 이해관계자들의 이익과 조화를 이루는 모습을 확인할 수 있을 것이다. 당연한 것이지만, 인공지능의 영향이 우리 삶의 곳곳에 미치는 이상 그 법적 과제들은 위 세 가지 분야에 그치지 않으며, 위 분야들은 본 연구의 목적을 위하여 필요한 범위에서 선택된 것일 뿐임을 지적해둔다.

가. 정보보호법

1) 새로운 문제들

오늘날의 세계는 인공지능과 데이터, 그리고 네트워크 기술의 발전에 따라 새로운 차원의 정보화를 맞이하고 있다. 이러한 상황에서 정보 내지 데이터의 보호와 관련된 법제도의 중요성이 점점 더 커지는 것은 당연한 일이다. 정보 보호의 문제는 두 가지 관점에서 바라볼 수 있다. 외부의 공격으로부터 시스템 내부의 정보를 보호하는 문제와 반대로 시스템이 외부의 정보를 침해하는 것과 관련된 문제가 바로 그것이다. 전자를 보안(security)의 문제라고 한다면 후자는 안전(safety)의 문제라고 할 수 있다.

정보화의 심화는 전통적인 문제 상황을 확대하고 복잡하게 만든다. 이제는 단순히 보안만이 아니라 전체 시스템의 신뢰성(trustworthiness) 확보가 중요해진다. 정보 내지 데이터의 보호만이 아니라 새로운 시대의 석유라고도 불리는 데이터의 생산과 활용 역시 함께 고려되어야 한다. 무엇보다 가치 있는 데이터의 대부분을 차지하는 개인정보에 관한 법제도가 이러한 변화에 충분히 대응할 수 있는지 재검토할 필요가 있다.

2) 보안, 안전 그리고 신뢰성

가) 보안성에서 신뢰성으로

정보화가 심화된 오늘날의 세상에서는 5G로 대표되는 고성능 네트워크를 기반으로 수많은 IoT 기기들이 연결되어 실시간으로 데이터가 수집되고 가공되며 나아가 인공지능 알고리즘의 학습과 개선으로 이어진다. 이러한 전체적 시스템은 일종의 사회간

접자본으로 기능하며, 따라서 해킹과 같은 외부의 공격으로부터 시스템을 보호하는 것, 즉 보안성(security)에 주안점이 놓이던 정보보호의 정책과 제도는 이제 안전성(safety), 의존성(reliability), 가용성(availability) 등의 개념을 포괄하는 신뢰성(trustworthiness)의 관점에서 다시 바라볼 필요가 있다.

즉 시스템은 원인 여하를 불문하고 언제나 장애 없이 정상적으로 동작할 수 있어야 하며, 이를 뒷받침할 수 있도록 개발과 검수 등의 과정에서 적절한 절차가 마련되어야 한다. 나아가 많은 IoT 기기들이 적시의 업데이트가 쉽지 않다는 점을 고려하면 보안 내재화 설계를 촉진하기 위한 정책이나 제도가 요구되기도 한다. 예컨대 미국에서는 일찍이 'Military Standard 1785 on System Security Engineering'을 제정하여 군에 도입되는 전산 시스템에 대해 신뢰성과 보안 내재화를 동시에 확보하기 위한 표준 방법론을 확립하였고, 이는 2016년에 'NIST SP 800-160 Systems Security Engineering'이라는 이름으로 연방정부 표준으로 확대된 바 있다(NIST 홈페이지). 특히 인공지능 시스템의 핵심을 이루는 딥러닝 기술의 경우 알고리즘이 갖는 의미를 인간이 이해하기 어렵다는 본질적 한계가 있기 때문에(이른바 '블랙박스'의 문제) 신뢰성 확보를 위한 효과적인 절차를 개발하고 보급하기 위한 제도적 방안이 요구된다고 할 수 있다.

나) 도메인 중심에서 데이터 중심으로

한편 정보 보안을 강화하려는 노력이 데이터 활용을 막는 부작용을 가져오지 않도록 할 필요가 있다. 뒤에서 보는 것처럼 민간 데이터의 활용이 법작제도적으로 용이하지 않은 상황에서 공공 데이터 개방의 중요성이 점차 강조되고 있다. 그러나 종래 공공기관이나 금융기관의 보안 정책이 주로 도메인(domain)을 중심으로 이루지면서 내부 업무용 망과 외부 인터넷 망을 분리하는 등 손쉬운 수단에 의존하여 온 탓에 업무 효율성 저하는 물론 공공 데이터 활용 가능성이 크게 제약되어 왔다. 미국의 경우 보호해야 할 데이터의 중요도에 따라서, 즉, 보호 대상이 기밀 데이터인지 아니면 단순한 중요 데이터(SBU: Sensitive But Unclassified)인지에 따라 기밀 데이터 망과 일반 데이터 망으로 분리하여 후자의 경우 외부 접속을 허용하고 있는 것과 비

교된다. 공공 데이터 활용을 촉진하기 위해서는 보안 정책과 제도가 데이터 중심으로 개편될 필요가 있다.

3) 프라이버시, 개인정보, 데이터

가) 개인정보보호의 법

정보처리 기술이 발달하지 않았던 과거에는 다른 사람에 관한 정보를 입수하여 이용한다는 것 자체로 다른 사람의 권리나 이익이 침해되기는 어려웠으므로 사생활의 비밀과 자유, 즉 프라이버시가 침해되거나 표현의 자유가 침해되는 등의 경우에 한하여 법이 개입하여 구제해주는 것으로 충분하였다. 그런데 해킹으로 수천만 건의 개인정보가 유출되기도 하는 오늘날의 정보화 사회에서는 개인의 자유와 권리에 대한 사전적·예방적 보호의 필요성이 제기되었고, 이는 개인정보 자체에 대한 보호제도인 개인정보보호 법제가 마련되는 계기가 되었다.

1950년 유럽인권협약에서 그 맹아가 나타나기 시작한 개인정보보호 법제는 1995년 유럽개인정보보호지침(Directive 95/46/EC)에 이르러 완성된 모습을 띠게 되었다. 우리나라도 위 지침에 영향을 받아 2011년 개인정보보호법을 제정하면서 동의권, 정정권, 삭제권 등을 비롯한 여러 권리들을 통하여 정보주체의 개인정보에 대한 통제권을 확립하였다. 헌법재판소는 개인정보자기결정권을 사생활의 비밀과 자유 및 행복추구권으로부터 도출되는 독자적 기본권으로 인정하고 있는데,²⁸⁾ 이는 개인정보보호법을 통하여 사인간의 권리로서의 성격도 갖게 되었다.

개인정보에 관한 권리는 인격권의 성질을 갖기 때문에 배타적 효력이 있다. 따라서 그 처리는 법정의 요건을 갖추지 않은 이상 원칙적으로 위법하다고 평가되어 사법상 손해배상청구나 공법상 과태료나 처벌 대상이 된다. 개인정보보호법은 정보주체의 동의나 그 밖의 법정의 정당화 사유가 있는 경우에 한하여 개인정보를 수집할 수 있고, 그 이용은 수집 목적의 범위에 한하는 것으로 규정한다(§15①). 이렇게 수집한 개인정보를 수집 목적 범위 내에서 제3자에게 제공하려면 정보주체의 동의를 비롯한 추가적

28) 헌법재판소 2005. 5. 26.자 99헌마513, 2004헌마190 결정

인 요건이 요구되고(§17①), 목적 외 이용이나 제3자 제공을 위해서도 별도의 동의를 비롯한 추가 요건이 요구된다(§18②). 즉 개인정보보호법은 개인정보의 수집·이용·제공의 전 과정에 걸쳐 목적 제한의 원칙 내에서 정보주체의 동의를 핵심으로 하는 정당화 사유를 요구함으로써 정보주체의 개인정보 통제권을 강력하게 관철하고 있다. 이러한 개인정보보호법의 기본적 틀은 「정보통신망 이용촉진 및 정보보호에 관한 법률」이나 「신용정보의 이용 및 보호에 관한 법률」 등 관련 법률에서도 그대로 채용되었다.

이처럼 프라이버시나 표현의 자유를 보호하기 위한 수단으로서 발전되어 온 개인정보보호 법제는 인공지능 기술의 확산에 따라 새로운 문제 상황을 맞이하고 있다. 먼저 오늘날의 인공지능 기술은 기계학습, 특히 딥러닝 기술이 중심이 되어 있는 까닭에 학습을 위한 대량의 데이터를 필요로 한다. 가치 있는 데이터의 상당 부분은 개인정보에 해당하는데 기존의 개인정보보호법이 개인정보의 보호에 지나치게 치우쳐 있어 그 활용이 쉽지 않다는 점이 문제로 되는 것이다. 인공지능 기술이 인간의 판단과 의사결정을 자동화하는 과정에서 개인정보의 처리도 자동화되고 그 결과 정보주체의 권리나 이익에 영향을 미치는 현상도 새로운 문제로 제기되고 있다. 데이터와 알고리즘의 두 가지 측면에서 나타나는 이러한 현상들은 개인정보보호법의 존재 이유와 역할에 대한 새로운 물음을 제기한다.

나) 데이터로서의 개인정보 - 개인정보의 보호와 활용의 조화

① 개인정보 개념의 명확화

오늘날은 데이터가 중요한 자원이자 재화로서 기능하는 데이터 경제의 시대이다. EU에서는 데이터 경제의 규모가 연간 5.6%의 성장률을 보이면서 2020년 경에는 GDP의 3.17%에 달할 것으로 예측되기도 하였다(EUR-Lex 홈페이지). 데이터는 이제 빅데이터로서 새로운 지식과 영감을 주는 것은 물론 인공지능 알고리즘의 개선을 위한 학습 자료로서 그 중요성이 날이 갈수록 커지고 있다.

그런데 개인정보보호법에 의하면 결합의 용이성과 개인의 식별가능성이 있거나 하면 개인정보에 해당하여 앞서 본 바와 같은 강력한 보호를 받게 된다(§2 i). 그러나

결합의 용이성이라는 기준은 판례(이른바 증권통 앱 사건)²⁹⁾에 의하여 사실상 형해화 되어 있고 식별가능성은 데이터 기술의 발전에 따라 날로 커지고 있다. 결국 현행법상의 개인정보 개념은 그 입법취지를 감안하더라도 지나치게 넓고 모호하다. 최근 국제적으로 영향력을 넓혀가고 있으며 국내의 법개정 논의에도 많은 영향을 미치고 있는 EU GDPR(General Data Protection Regulation) 전문 (26)은 식별 가능성의 판단 기준으로서 ‘개인을 식별하기 위해 사용될 것으로 합리적으로 예상되는 모든 수단’을 고려하도록 하는 한편 이에 해당하는지 여부는 식별을 위해 소요되는 비용과 시간 등을 감안하도록 하고 있는데, 참고할 만하다.

② 개인정보 이용을 위한 제도의 명확화 및 효율화

개인정보 이용을 위한 제도의 명확성과 효율성도 제고될 필요가 있다. 앞서 본 것처럼 개인정보의 수집·이용·제공은 원칙적으로 정보주체의 동의가 있어야 한다. 그러나 개인정보에 관한 권리도 다른 권리와 마찬가지로 비례의 원칙에 따라 공공복리 등을 위하여 법률로 제한할 수 있음은 물론이다(헌법 §37②). 최근에는 개인정보에 관한 권리에 재산권적 성격도 존재한다는 주장이 제기되고 있는데(임건면, 2005; 송오식, 2016), 이를 인정한다면 재산권의 사회적 기속성의 법리에 따라 개인정보에 관한 권리의 내용과 범위는 법률에 의하여 형성되는 것이라는 주장도 가능하다(헌법 §23①, ②; 이상용, 2018). 현행 개인정보보호법상 정보주체의 동의 이외의 다른 적법 요건들은 이러한 관점에서 이해될 수도 있다.

그렇다면 동의 제도는 단순한 위법성 조각사유를 넘어서 일종의 계약으로 이해될 수 있다. 그 경우 종래 공법상 권리로서 자유로운 처분이 제한된다고 여겨져 왔던 개인정보에 관하여도 그 이용관계를 사적자치의 원칙에 따라 자유롭게 설정할 수 있게 된다. 이를 통하여 형식적이고 경직된 동의 제도를 보다 실질적이고 유연한 것으로 만듦으로서 효율적인 거래를 통한 사회적 잉여를 증가시킬 수 있게 된다. 개인정보는 다른 데이터와 마찬가지로 거래를 통한 이익에 비하여 거래비용이 상당히 큰 편인데 이처럼 계약제도를 이용할 수 있도록 하면 대리와 같은 법기술 또는 동의 보조 서비스

29) 서울중앙지방법원 2011. 2. 23. 선고 2010고단5343 판결

(CaaS: Consent as a Service)와 같은 IT 기술을 활용하여 거래비용을 낮추는 것도 가능해진다. 다만 개인정보의 인격권적 성질로 인해 정보주체는 언제나 이용에 대한 동의를 철회할 수 있는데, 그것이 계약위반이 될 수 있는지에 관한 법적 불확실성은 상존한다. 추가적인 연구가 필요한 부분이다.

동의 이외의 개인정보 활용을 위한 제도도 보다 확대되고 명확해질 필요가 있다. EU GDPR 전문(50)에 따르면 목적이 양립 가능한 경우(compatibility) 원래 정보수집을 허용한 법적 근거 이외의 별도의 법적 근거는 불필요하다고 함으로써 목적 제한의 원칙을 다소 완화하고 있는데, 우리 법에도 도입할 필요가 있다. 한편, 개인정보에 대하여 비식별처리 기법을 적용한 결과 개인의 식별가능성이 제거된 익명(anonymous) 정보는 더 이상 개인정보가 아니므로 개인정보보호법이 적용되지 않는다. 그러나 기술의 발달에 따라 비식별처리를 하더라도 개인의 식별가능성이 완전히 제거되지 않는 경우가 많다. 이러한 상태의 개인정보를 가명(pseudonymous) 정보라고 부를 수 있는데, 이 경우에도 일률적으로 엄격한 개인정보보호의 법리를 일관하는 것은 보호와 활용의 균형을 잃은 것이다. 우리 개인정보보호법은 “통계작성 및 학술연구 등의 목적을 위하여 필요한 경우로서 특정 개인을 알아볼 수 없는 형태로 개인정보를 제공하는 경우”에는 정보주체의 동의 없이도 개인정보를 목적 외의 용도로 이용하거나 이를 제3자에게 제공할 수 있도록 하고 있는데(§18② iv), 앞서 본 논지에 따르면 여기서 ‘개인을 알아볼 수 없는 형태’란 익명정보가 아닌 가명정보를 가리키는 것으로 해석되어야 할 것이다. 그러나 이러한 해석에 대하여는 이견이 존재하고 ‘통계작성 및 학술연구’의 개념에도 의견 대립이 존재하므로 결국 입법에 의하여 명확히 할 필요가 있다. EU GDPR은 공익을 위한 유지보존의 목적, 과학이나 역사적 연구나 통계 수집 목적의 개인정보 처리의 경우 개인정보의 가명처리 등 적절한 안전조치를 갖추는 것을 전제로 처리제한권, 삭제권 등의 일부 권리를 배제할 수 있도록 하는 규정(§89)을 두고 있는데, 우리 법의 개정에도 참고할 수 있을 것이다.

③ 데이터 독점과 데이터 이동권

데이터가 주요한 자원으로 기업 경쟁력의 핵심으로 등장하고 있는 현실은 경쟁법적

관점에서도 주의를 끌고 있다. 데이터를 활용하는 대기업들은 상당수가 이른바 플랫폼 기업으로서 네트워크 효과를 누리고 있을 뿐 아니라 데이터 자체도 속성상 한계비용이 거의 없기 때문에 자연 독점으로 이어지기 쉽다. 데이터 중에도 개인정보의 경우에는 앞서 본 것처럼 그 활용이나 유통을 위한 제도적 기반이 취약하기 때문에 처음 이를 수집한 기업 내에 머물러 있기 쉽다(data hoarding). 데이터가 사실상 기업의 주요한 자산으로 기능한다는 사실은 데이터를 독점하는 기업에 경쟁법의 잣대를 적용하려는 시도로 이어질 수 있다(OECD, 2017).

EU GDPR은 개인정보보호법의 관점에서 이러한 문제 해결의 단초를 제공하기 위해 ‘개인정보이동권(right to data portability)’을 도입하였다(§20). 정보주체에게 자신의 개인정보를 기계에서 판독이 가능한 형태로 수령하거나, 외부 정보처리자에게 이전하거나, 가능한 경우 어느 정보처리자에서 다른 정보처리자에게로 직접 이전하게 할 권리를 부여한 것이다. 위 권리는 1차적으로는 자기정보에 대한 통제권을 강화하는 것이지만 부차적으로 데이터의 집중을 해소할 수 있는 경로를 마련하는 것 역시 의도하고 있다. 경쟁법은 시장을 신뢰하는 전제 하에 그 불완전성을 보완하기 위한 것인 만큼 경쟁제한적 효과가 실증된 뒤에야 비로소 동원될 수 있는 장치이다. 경쟁법상의 제재를 논하는 것은 아직은 시기상조이지만, 데이터 이동권은 기업의 현실을 신중히 고려하여 도입을 검토할 필요가 있다.

다) 알고리즘에 의한 개인정보의 처리 - 자동화의 이익과 위험

① 프로파일링

인공지능 기술을 이용한 자동화는 생산성 향상을 비롯한 많은 이익을 가져다 주지만 그에 따른 역효과도 지적되고 있다. 개인정보보호법과 관련하여 문제가 되는 것은 두 가지이다. 첫째는 개인의 식별가능성이 보다 커진다는 점이고, 둘째는 개인정보의 자동화된 처리가 해당 개인에 대한 법적 효과와 연계되어 있는 경우 그 적정성을 담보하기 어렵고 구제가 쉽지 않다는 점이다. EU GDPR은 정보주체에게 그의 동의 등 법정의 사유가 없는 한 자신과 관련된 법적 효과를 야기하거나 자신에게 중대한 영향

을 미치는 프로파일링(profiling)을 포함한 자동화된 처리에만 기초한 의사결정에 종속되지 않을 권리를 인정한다(§22). 인공지능 기술의 발전에 따라 개인정보의 처리에 사람이 개입하여야 한다는 요구와 지능적이고 자동화된 처리를 위하여 사람의 개입을 줄이자는 요구 사이에 가치 충돌이 발생하고 있다(최경진, 2013). 위에서 본 GDPR의 규율은 적절하게 이익형량이 이루어진 것으로 여겨지는데, 우리 법에도 도입을 검토할 필요가 있다.

② 알고리즘 투명성과 설명요구권

인공지능이란 판단과 의사결정의 자동화 도구이므로 개인의 법적 지위와 관련된 판단과 의사결정에도 폭넓게 활용될 수 있고 실제로 많이 활용되고 있다. 그런데 인공지능 알고리즘에 의한 판단의 경우 그 적정성에 대한 신뢰가 아직 형성되어 있지 않다. 이는 생소함에서 비롯된 측면도 있지만 판단과 의사결정의 알고리즘이 알려져 있지 않다는 점과 그 적정성을 담보할 절차가 부재하다는 점에서 비롯된 것이 크다. 이러한 문제의식에서 알고리즘 투명성(transparency)의 요청이 제기되고, 이는 책임성(accountability)과 공정성(fairness)을 확보하는 수단이 되기도 한다. 나아가 딥러닝 기술은 이른바 블랙박스의 속성상 단순히 알고리즘의 공개만이 아니라 인간이 이해할 수 있는 방식으로 설명되어야 한다는 요구로까지 이어진다.

최근에는 EU GDPR에서 규정된 정보주체의 접근권에 관한 조항들(§§12-15)과 프로파일링에 관한 조항(§22)으로부터 설명요구권(right to explanation)을 도출해낼 수 있다는 주장이 제기되어 주목을 끈 바 있고(Goodman and Flaxman, 2017), 국내에도 유사한 주장을 펼치는 견해가 있다(박상돈, 2017). 그러나 이 문제는 비단 개인정보보호법만의 문제는 아니어서 평등 원칙을 비롯하여 알고리즘의 투명성이 요구되는 배후의 근거를 고려하여 별도의 입법을 할 필요가 있다고 생각된다. 특히 영업비밀 등 서로 상충하는 가치와의 이익형량이 이루어질 수 있도록 비례의 원칙에 입각한 입법이 이루어져야 한다. 정보공개에 관한 법률인 독일 연방데이터보호법(BDSG: Bundesdatenschutzgesetz)이 참고가 될 수 있는데, 위 법률은 일반적인 경우에는 출처 등 기본 정보만을 공개하도록 하지만(§34①), 개인에 대한 평가를 수반하는 경우

일반적 용어에 의한 설명을 제공하도록 하고(§34②), 자동화된 결정이 수반된 경우로
직까지 설명하도록 하고 있다(§6a③).

나. 도로교통법

1) 자율주행자동차와 자동차 운행법제

인공지능 기술의 범용성에도 불구하고 우리의 삶에 가장 큰 영향을 미칠 분야를 꼽
자면 역시 자율주행자동차를 들 수밖에 없다. 자동차와 관련된 법제도는 크게 운행법
제와 책임법제로 나눌 수 있다. 운행법제는 다시 자동차 운행의 3요소를 따라 자동차
에 관한 법(자동차관리법), 운전자에 관한 법(도로교통법), 도로에 관한 법(도로법)으로
나뉜다. 책임법제의 경우 민사책임에 관한 법(자동차손해배상보장법, 제조물책임법,
민법), 형사책임에 관한 법(도로교통법, 교통사고처리특례법, 형법) 등으로 나누어볼
수 있다. 책임법제는 다음 장에서 제조물책임 법제의 개선방안을 논의하면서 함께 논
의할 것이며 본 장에서는 도로교통법을 중심으로 운행법제만을 다루기로 한다.

자율주행자동차의 등장은 그 자율성으로 인하여 전통적인 자동차, 운전자, 도로의
개념과 규율방식에 큰 영향을 미친다. 자율주행자동차는 운행법제와 책임법제가 확립
되어 법적 예측가능성이 확보되지 않으면 상용화가 쉽지 않다. 외국의 경우 미국이나
독일처럼 자율주행자동차의 운행법제가 이미 마련된 경우도 있지만,³⁰⁾ 우리나라는
2015. 8. 11. 자동차관리법의 개정으로 자율주행자동차의 개념(§2)과 시험·연구 목적
의 임시운행 근거(§27① 단서)만 마련된 상태이다(NCLS 홈페이지). 다만 2019. 4.
30. 「자율주행자동차 상용화 촉진 및 지원에 관한 법률」(아래에서는 ‘자율주행차촉진
법’이라고만 한다)이 제정되어 2020. 5. 1. 시행을 앞두고 있는 것은 고무적이다. 비
록 위 법률이 운행법제나 책임법제의 기능을 하는 것은 아니지만, 시범운행지구에서
의 규제 완화(§7-14), 자율주행협력시스템(§21)이나 정밀도로지도의 구축(§22), 기
술개발 지원(§24) 및 전문인력 양성(§25) 등 자율주행자동차와 관련된 인프라의 보급
및 생태계 형성을 꾀하고 있다는 점에서 의미가 크다. 특히 사업자의 법적 불명확성

30) 미국의 경우 2019년을 기준으로 자율주행자동차에 관한 법률을 제정한 주(州)는 38에 이른다 (NCLS 홈페이지)

해소를 돕기 위하여 국토부장관에게 규제 법령의 적용 여부 및 해석 등의 확인을 구할 수 있는 ‘규제 확인’ 제도(§14)가 도입된 것은 상당히 합리적이라고 평가된다. 위 법률의 제정을 계기로 자율주행자동차와 관련된 운행법제와 책임법제가 조속히 정비되기를 기대한다.

2) 자동차관리법

가) 자율주행자동차의 개념

자율주행자동차의 경우 기술 발전에 따른 자율성의 정도에 따라 그 법적 규율이 달라지게 되므로 이를 반영하여 개념을 정의할 필요가 있다. 자율성의 정도를 반영한 자율주행의 단계별 구분에 관하여는 미국자동차공학회(SAE International: Society of Automotive Engineers)에서 제시한 기준이 국제적으로 통용되고 있다.

〈표 5-1〉 자율주행 단계별 구분

단계	레벨 0	레벨 1	레벨 2	레벨 3	레벨 4	레벨 5
개념	지원 기능 없음	특정기능 지원	복합기능 지원	부분 자율주행	고도 자율주행	완전 자율주행
자동차 기술협회 (SAE)		Driver Assistance	Partial Automation	Conditional Automation	High Automation	Full Automation
도로교통 연구소 (BAST)		Assisted	Partially Automated	Highly Automated	Fully Automated	
일상 주행	운전자	운전자	시스템	시스템	시스템	시스템
주행 중 상황 인식	운전자	운전자	운전자	시스템	시스템	시스템
비상 제어	운전자	운전자	운전자	운전자	운전자 / 시스템	시스템

자료 : 국회입법조사처(2017), p.23

우리나라의 경우 자동차관리법이 자율주행자동차를 “운전자 또는 승객의 조작 없이 자동차 스스로 운행이 가능한 자동차”(§2 i-3)라고 정의하고 있고, 같은 법 및 시행규칙의 위임을 받아 제정된 국토교통부 고시 「자율주행자동차의 안전운행요건 및 시험 운행 등에 관한 규정」은 조종장치(§10), 시동 시 조종장치의 선택(§11), 표시장치(§12조), 기능고장 자동감지(§13조), 경고장치(§14조), 운전자우선모드 자동전환(§15조), 최고속도제한 및 전방충돌방지 기능(§16조), 운행기록장치 등(§17조), 영상기록장치(§18조) 등의 요소를 나열함으로써 위 정의를 보충하고 있다.

이러한 개념 규정은 자율성의 정도를 고려하지 않은 지나치게 추상적이고 모호한 것이라는 비판을 받는다. 완전자율주행 자동차와 부분자율주행 자동차는 형사책임의 유무에서 차이가 있고, 운전자 없는 자율차와 자율주행시스템에 의한 자율차는 민사책임에서도 구별될 필요가 있다(황창근이중기, 2018). 한편 앞으로의 기술 발전의 가능성을 고려해 볼 때 기술적 장치를 지나치게 구체적으로 규정하는 것은 바람직하지 않다. 최근 제정된 자율주행차촉진법은 자율주행자동차를 운전자 또는 승객의 개입이 필요한 부분자율주행 자동차와 그러한 개입이 필요 없는 완전자율주행 자동차로 대별하면서 국토교통부령으로 그 종류를 세분할 수 있도록 하였는데(§2②), 이로써 향후 운행법제나 책임법제가 보다 정교하게 형성될 수 있는 기틀이 마련된 것으로 평가할 수 있다.

나) 안전기준의 재정립

자율주행자동차의 경우에는 운전자에 의한 운전을 전제로 한 기존의 안전기준 가운데 일부가 부적절하게 되는 한편 새로운 안전기준이 요구될 수 있다. 이를 반영하여 자율주행차촉진법은 조향장치, 제동장치, 좌석 등 자율주행자동차의 특성으로 인하여 통상적인 자동차안전기준이나 부품안전기준을 충족하기 어려운 경우에도 안전 확보 등에 필요한 조건을 붙인 국토교통부장관의 승인 하에 시범운행지구에서 운행할 수 있도록 하고 있다(§11). 반대로 운행기록장치, 사고기록장치, 영상기록장치 등은 자율주행자동차와 관련된 사고가 발생할 경우 책임 소재 규명을 위한 필수적 기술로서 새로이 안전기준에 포함될 필요가 있다.

자율주행자동차의 경우 하드웨어와 소프트웨어가 긴밀하게 결합하면서 지능형교통 시스템이나 다른 차량과 많은 정보교환을 하게 된다. 따라서 사이버보안이나 개인정보보호의 기능을 갖추어야 하고 운행프로그램과 같은 소프트웨어를 포함한 안전기준이 마련될 필요가 있다. 특히 운행프로그램의 경우 업데이트를 통하여 실질적으로 변경될 수 있으므로(NHTSA, 2017) 이에 대비할 수 있도록 하여야 할 것이다.

그 밖에 자율주행자동차의 결합으로 인하여 동일한 유형의 사고가 계속적으로 발생되는 긴급한 상황의 경우 운행제한조치를 할 수 있도록 하자는 주장이 있다. 그리고 현행 자기인증제도(Self-Certification)를 형식승인제도(Type-Approval)로 환원시키자는 주장도 있다. 그러나 이들 문제는 자율주행자동차 운행의 실태나 국제적인 흐름을 살펴며 신중히 결정할 필요가 있다. 특히 형식승인제도로의 환원은 자기인증제도 도입의 배경이 되었던 한미자동차협정 등의 취지를 고려해야 할 것이다(조용혁·장원규, 2017).

3) 도로교통법

가) 운전과 운전자 개념의 변화 가능성

도로교통법은 운전을 “차마를 그 본래의 사용방법에 따라 사용하는 것”이라고 정의함으로써(§2), 운전 및 운전자 개념을 중심으로 안전한 운행을 위한 규율을 펴하고 있다. 자율주행자동차의 경우 자동차의 자율성이 늘어나고 운전자의 역할이 줄어들에 따라 운전자를 중심으로 한 전통적인 접근방법이 여전히 유효할 것인지에 관하여 문제된다. 아래에서는 특히 운전면허 제도와 교통법규와 관련된 문제를 살펴본다.

나) 운전면허 제도의 변화

운전면허 제도와 관련하여 먼저 드는 의문은 과연 자율주행자동차의 경우에 운전면허제도가 필요할 것인지이다. 자율주행자동차에 있어서 운전은 운행의 개념에 가까워지겠지만, 이 경우에도 사람의 생명과 재산을 보호하기 위한 면허제도의 유용성은 인정될 수 있을 것이다.

오히려 문제는 자율주행자동차의 운전면허가 누구의 어떠한 행위를 대상으로 해야 할 것인지를 다. 운행상의 안전 확보라는 취지를 고려해보면 면허의 주체는 소유자가 아니라 운전자(완전자율주행 단계에서는 운행자)라야 할 것이다. 부분자율주행이나 고도자율주행 단계의 경우 운전자가 실제 운전행위를 하는 부분이 있지만 그 정도는 일반적인 자동차의 경우에 비하여 훨씬 덜하고, 완전자율주행 단계에서는 주행 여부 및 목적지나 경로의 결정 외에는 사실상 운전행위라고 할 것이 없다. 따라서 운전면허를 취득하기 위하여 요구되는 능력의 종류나 수준은 현재보다 매우 완화될 것이며, 예컨대 신체적 장애의 중요성은 대폭 줄어들 것이다.

다) 교통법규의 변화

자율주행자동차의 경우 운전자의 조작 없이 차량의 운행이 이루어진다는 점에서 교통상의 위험과 장애를 방지하고 안전하고 원활한 교통을 확보하기 위한 교통법규 역시 변화할 수밖에 없다.

우선 수범자 측면에서 종래 운전자에게 부과되었던 의무의 일부가 차량 제작자의 의무, 즉 자율주행자동차가 교통규칙 준수능력을 갖추도록 할 의무로 전이될 수 있다. 이러한 도로교통법상의 의무는 동시에 자동차관리법상 자율주행자동차의 안전기준이 되는 한편 책임법상 하자 판단의 기준이 될 수 있다. 운전자가 지켜야 할 교통규칙의 내용 역시 자율주행의 단계에 상응하여 변화할 것이다. 예컨대 고도자율주행 단계에서는 전방주시의무를 비롯하여 운전자를 전제로 한 규율의 상당 부분이 덜 중요해지는 반면, 비상제어 준비의무와 같은 새로운 의무들이 중요해질 수 있다. 다만 현재의 자율주행자동차는 부분자율주행 단계에 머무르고 있으므로 아직 운전자들의 주의의무에 변화가 나타나지는 않고 있다. 2018년 샌프란시스코에서 만취 상태에서 자율주행 모드로 Tesla 차량을 운행하던 사람이 음주운전으로 체포된 것은 그 방증이다(Daily News, 2018.11.30.)

4) 도로법

자율주행자동차의 운행을 위해서는 도로와 차량 및 운행시스템이 결합된 지능형 교통시스템(ITS: intelligent transport systems)가 필요하다(강경표, 2016). 자율주행 자동차와 교통시설과의 연계 및 자율주행자동차들 사이의 연계가 중요해짐에 따라 ITS를 포함한 도로시설의 설치 및 안전기준 설정이 요구될 것이다.

5) 개인정보와 정보보안

가) 제4의 운행요소

자율주행자동차의 경우 다른 자율주행자동차 및 교통시설과의 끊임 없는 정보교환과 주위 환경의 인식을 필수적인 전제조건으로 함에 따라 개인정보의 보호 및 정보보안이 운행법제의 중요한 요소가 된다(홍익대 산학협력단, 2017). 이런 점에서 개인정보와 정보보안은 사실상 자율주행자동차의 제4의 운행요소라고 할 수도 있다.

나) 개인정보

자율주행자동차는 운행시 카메라, 레이더, 라이더(LiDAR: Light Detection And Ranging)를 통하여 다른 차량, 보행자, 도로 상의 데이터를 수집하고, GPS, 관성항법장치(INS: Inertial Navigation System), 휠인코더(Wheel Encoder) 등을 통하여 자차의 위치정보를 수집하며, V2V(Vehicle to Vehicle) 통신을 통하여 자차 및 타차에 관한 정보와 도로 및 보행자정보 등을 수집한다. 이러한 데이터의 상당 부분은 개인정보나 개인위치정보에 해당하는데, 현행법상 개인정보의 개념이 식별가능성을 중심으로 설정되어 있고 식별기술이 발달함에 따라 그 범위는 점점 확대되고 있다.

이처럼 자율주행자동차의 운행에 있어서는 개인정보의 수집, 이용과 제3자 제공이 필수적으로 따르게 되는 반면 그 처리가 실시간으로 이루어져야 하는 탓에 정보주체의 사전 동의는 사실상 불가능하다. 현행법상 동의 이외의 방식에 의한 개인정보의 처리에 관한 제도가 불명확하여 자율주행자동차를 개발하는 기업들로서는 감당하기

어려운 법률적 위험부담이 존재하므로 자율주행자동차의 상용화를 위해서는 입법적 개선이 긴요한 상황이다. 그 방식으로는 개인정보보호법제 일반을 개정하기보다는 자율주행자동차의 특성을 반영한 특례 조항을 자동차관리법과 같은 운행법제에 도입하는 것이 합목적적이고 효율적이라고 생각된다. 다만 개인정보의 처리를 수반하는 정책이나 제도의 도입에는 개인정보보호위원회의 개인정보 침해요인 평가를 거쳐야 함을 유의하여야 한다(개인정보보호법 §8의2).

최근 제정된 자율주행차촉진법은 자율주행자동차를 운행하는 과정에서 수집한 개인정보를 추가적으로 개인을 식별할 수 없도록 익명처리하여 활용하는 경우 개인정보보호법 등을 적용하지 않도록 하고 있다(§20). 위 규정으로 인하여 자율주행차의 운행 과정에서 불가피하게 이루어지는 동의 없는 개인정보의 수집행위 자체는 더 이상 위법하지 않다고 볼 여지가 생겼지만 명확한 것은 아니다. 특히 수집 이후의 이용이나 제3자제공 등의 처리를 하려면 여전히 익명화를 필요로 한다는 점에서 현실적으로 그 유용성에는 한계가 있다고 여겨진다. 앞으로 추가적인 입법 논의가 계속될 필요가 있다.

다) 정보보안

자율주행자동차의 경우 해킹 등 사이버 정보보안의 문제는 탑승자와 보행자의 안전 문제와 직결된다. 자동차관리법 시행규칙에서 “자율주행기능을 수행하는 장치에 원격으로 접근침입하는 행위를 방지하거나 대응하기 위한 기술이 적용되어 있을 것”을 규정하는 것은 그 때문이다(§26의2 ① vi). 사이버 보안의 문제에 대처하기 국제적 협력도 활발하다. 자동차 국제안전기준 UN기구는 2016년 말부터 사이버보안 전문가그룹(TFCS)³¹⁾을 구성하여 자율주행차의 보안문제를 다루고 있다. 지난 2018. 4. 서울에서 마지막 회의를 진행하기도 했던 TFCS는 같은 해 9월 권고안 초안³²⁾을 발표하였는데, 이를 바탕으로 향후 UN 차원의 사이버 보안의 기준과 방향이 제시될 것으로 보여 귀추가 주목된다.

31) TFCS는 Task Force on Cyber Security and Over the Air issue의 약자임.

32) Draft Recommendation on Cyber Security of the Task Force on Cyber Security and Over-the-air issues of UNECE WP.29 GRVA (20/09/2018)

다. 제조물책임법

1) 인공지능과 책임법제

가) 과실책임 법리의 완화

인공지능의 도구적 자율성은 인간의 개입 없는 과업의 수행을 가능하게 함으로써 생산성 향상을 가져오지만 그와 동시에 과업 수행의 결과 누군가에게 피해가 발생할 경우 누구도 이에 대한 책임을 지려 하지 않는 책임 회피의 우려도 불러일으킨다. 그러나 책임법의 기본 원리가 손해의 적절한 분담에 있는 이상 인공지능의 자율성에도 불구하고 배후에 있는 개인이나 법인이 책임을 부담하도록 하여야 함은 물론이다. 문제는 이러한 결론을 뒷받침할 수 있는 법원리 내지 법제도가 무엇인지를 따져야 한다.

전통적인 과실책임의 원리에 의하면 고의나 과실에 의한 위법행위를 한 사람이 그로 인한 손해배상의 책임을 부담한다. 그러나 인공지능의 경우 인간의 개입이 제한되어 있으므로 과실책임의 원리에 따라 손해를 배상시키기는 어렵다. 이러한 문제의 해결을 위하여 우선 위험책임의 원리를 검토해볼 수 있다. 위험책임(Gefährdungshaftung)이란 원자력이나 자동차항공기 등과 같이 아무리 주의를 다하여도 손해발생을 완전히 회피할 수 없음에도 불구하고 사회적 유용성 때문에 허용된 위험의 경우에는 위험원을 지배하면서 자신의 이익을 위하여 운영하는 자가 손해를 부담하는 것이 피해자가 손해를 떠안는 것보다 공평하다는 관념에서 인정되는 것이다. 영미법상 비정상적으로 위험한 행위에 대하여 인정되는 엄격책임(strict liability) 역시 같은 취지의 제도이다. 한편, 보상책임의 원리는 “이익을 얻는 과정에서 타인에게 손해를 주었다면 그 손해는 이익 중에서 배상하게 하는 것이 공평하다”는 것으로서 우리 민법상 사용자책임에 관한 규정(§756)에 잘 드러나 있다.

위험책임이나 보상책임의 원리에 따라 법제도를 마련하면 자율성을 지닌 인공지능의 작동에 의하여 생긴 손해도 배후의 개인이나 법인에게 부담시킬 수 있다. 다만 인공지능 기술이 지닌 특성, 즉 과업 수행에 있어서의 합리성이나 학습을 통해 알고리즘을 개선시키는 능력 등을 고려해보면 인공지능 기술이 특별한 위험을 창출한다고 보기는 어렵다는 점에서 위험책임의 원리를 적용하는 것에는 다소 난점이 있다. 보상책

임의 경우 역시 인공지능과 그 이용자의 관계를 피용자와 사용자의 관계로 볼 수는 없다는 문제가 있다. 이러한 문제의식을 바탕으로 인공지능의 활용 과정에서 생긴 손해는 이를 이용하면서 편익을 얻은 자에게 책임을 지워야 한다는 편익책임의 원리를 주장하는 견해가 유력하다(오병철, 2017).

나) 자율주행자동차와 책임법제

현실적으로 인공지능의 작동 과정에서 생긴 손해 발생이 가장 문제되는 분야는 자율주행자동차의 경우이다. 그동안 자동차의 운행으로 인한 손해의 분담은 대부분 자동차손해배상보장법에 따른 운행자책임에 의하여 규율되어 왔다. 위 법에 따르면 자동차의 운행자, 즉 운행자배와 운행이익을 갖는 자는 그 운행으로 타인을 부상하게 하거나 사망하게한 경우 사실상 무과실책임을 부담한다(§3). 즉, 운행자가 책임을 면하려면 승객이 아닌 자가 사상한 경우 운행자와 운전자에게 과실이 없다는 것만으로는 부족하고 자동차의 무결함과 타인의 고의과실까지 증명해야 하고, 승객이 사상한 경우에는 더 나아가 승객의 고의나 자살행위로 인한 것까지 증명해야 하는데, 이는 사실상 불가능한 것이다. 이처럼 인신 손해의 경우 위험책임의 원리가 도입되어 있지만 재산상 손해의 경우에는 여전히 민법에 따른 과실책임의 원리가 적용되어 고의과실이 있는 운전자가 책임을 지게 된다(§750).

이러한 책임 구조는 자율성으로 인하여 인간의 개입이 제한되는 자율주행자동차의 경우에도 타당할 것인가. 먼저 인신 손해의 경우 이미 위험책임의 원리가 도입되어 있는 까닭에 큰 문제는 생기지 않을 것이다. 그동안 사고 피해를 배상받기 어려웠던 공동운행자의 경우에도 자율주행자동차의 자율성이 강화되면서 운행자배 정도가 약화됨에 따라 타인성을 인정받아 손해배상청구권의 주체가 될 수 있게 되는 등 피해자 보호 수준이 높아질 가능성도 있다(권영준·이소은, 2016). 그러나 재산상 손해의 경우에는 자율주행자동차의 자율성 정도가 높아짐에 따라 운전자의 고의과실이 인정되기 어려워 책임의 공백이 생길 수 있다. 따라서 장차 재산상 손해의 경우에도 위험책임의 법리를 확장하는 입법의 필요성이 있다.

그 밖에 자율주행자동차의 자율성에 대응하여 논의되는 책임 근거로는 공작물소유

자의 책임(민법 §758), 사용자책임의 유추적용(§756)이나 동물 점유자책임의 유추적용(§759) 등이 있다. 그러나 공작물 소유자의 책임은 비록 민법이 정하는 유일한 무과실책임이기는 하나 피해자가 공작물의 설치 또는 보존에 하자가 있음을 증명해야 하는 점에서 한계가 있다. 또한 인공지능의 자율성이 도구적인 성격을 갖는 것에 그치는 점을 감안하면 사용자책임이나 동물 점유자책임을 유추적용하는 것도 부적절하다. 결국 자율주행자동차의 경우 자동차손해배상보장법 외에 이들 제도를 활용할 실익은 거의 없다. 오히려 자율주행자동차와 관련하여 실질적 의미를 갖는 것은 제조물책임법에 의한 책임이다. 이에 관하여는 항을 달리하여 살펴본다.

2) 제조물책임법

가) 인공지능과 제조물책임법

인공지능 기술의 활용 과정에서 발생할 수 있는 손해의 분담을 위한 원리로서 공작물 소유자의 책임이나 운전자책임과 같은 위험책임의 법리 못지 않게 중요하게 다루어져야 할 것은 바로 제조물책임이다.

제조물책임은 무과실책임으로 구성되어 있어 인공지능 기술의 도구적 자율성에도 불구하고 책임 귀속이 용이하다. 예방적 관점에서 보더라도 기술에 내재한 위험에 대한 더 많은 정보를 가지면서 위험을 통제할 수 있는 지위에 있는 제조업자가 최소비용 회피자(the cheapest cost avoider)에 해당하므로, 그에게 책임을 부담시키는 것이 보다 효율적으로 위험을 감소시킬 수 있어 사회적으로 이익이 된다(권영준·이소은, 2016). 기술혁신을 촉진하기 위해서는 제조물책임을 축소해야 한다는 견해가 없지는 않으나(Kyle Graham, 2012), 자율주행자동차의 경우 장기적으로 운전자책임보다는 제조물책임에 방점을 두는 한편 이에 대한 책임보험을 장려하거나 강제함으로써 피해자의 제도 접근성을 높이는 것이 바람직하다.

현행 제조물책임법에 따르면 “제조업자는 제조물의 결함으로 생명·신체 또는 재산에 손해를 입은 자에게 그 손해를 배상하여야 한다”(§3①). 인공지능 기술과 관련해서는 제조물의 범위, 결함의 의미, 그리고 면책항변 사유와 관련하여 중요한 쟁점들이 존재한다.

나) 소프트웨어의 제조물 해당 여부

제조물책임법에 따르면 제조물은 “제조되거나 가공된 동산”으로 정의되어 있다(§2 i). 그런데 인공지능 기술이 적용된 도구들은 대체로 소프트웨어의 형태이며, 자율주행자동차와 같이 하드웨어와 결합된 경우에도 그 기능과 가치의 상당 부분은 소프트웨어에 있다. 따라서 인공지능 도구를 동산으로 볼 수 있는지 여부에 따라 제조물책임이 적용될 수 있는지 여부가 달라지게 된다.

민법은 유체물 뿐만 아니라 ‘전기 기타 관리할 수 있는 자연력’도 물건으로 보고 있으므로(§98) 소프트웨어를 동산으로 볼 수 있다는 견해가 없지는 않으나 다수설은 소프트웨어는 동산에 해당하지 않는다고 본다(오병철, 2017). 다만 하드웨어와 결합한 내장형(embedded) 소프트웨어의 경우에는 제조물책임의 대상인 동산에 해당한다고 보는 것이 일반적인데, 소프트웨어와 IT 인프라를 외부 서비스제공자로부터 제공받아 일시적으로 사용할 수 있을 뿐인 소프트웨어(SaaS: Software as a Service)는 이에 해당하지 않는다는 견해도 있다(김진우, 2018). 자율주행자동차에 사용되는 인공지능 도구는 내장형 소프트웨어의 형태를 띠는 경우가 많을 것이므로 대체로 제조물책임법이 적용될 수 있겠지만, 경우에 따라서는 명확하지 않은 경우도 있을 수 있다. 결국 입법적 개선을 통하여 명확히 하는 것이 바람직하다고 하겠다.

다) 결함의 의미

제조물책임법은 결함을 제조상의 결함, 설계상의 결함, 그리고 표시상의 결함으로 유형화하고 있다(§2 ii).

먼저 제조상의 결함이란 제조물이 원래 의도한 설계와 다르게 제조·가공됨으로써 안전하지 못하게 된 경우를 말하며 제조상의 결함이 있는 경우 무과실책임이 인정된다. 그러나 고도의 기술이 집약된 인공지능 도구의 경우 피해자가 제조상의 결함을 증명하기란 매우 어렵다. 판례는 “사고가 제조업자의 배타적 지배하에 있는 영역에서 발생한 것임을 입증하고, 그러한 사고가 어떤 자의 과실 없이는 통상 발생하지 않는다고 하는 사정을 증명”하면 제조업자 측에서 그 사고가 제품의 결함이 아닌 다른 원인

으로 말미암아 발생한 것임을 입증하지 못하는 이상 결합 및 손해와의 인과관계를 추정함으로써 피해자의 입증 부담을 완화하는 ‘기능 이상 법리(결합 추정의 법리)’를 채용하고 있다.³³⁾ 기능 이상 법리의 적용 여부는 제조업자와 피해자가 갖는 정보의 양과 질을 고려하여 판단하여야 하는데, 인공지능과 같은 고도의 기술이 집약된 제조물의 경우 보다 적극적으로 적용되어야 할 것이다. 종래 법원은 급발진 사고에 제조물책임임을 인정하는데 소극적이었는데, 그 이유가 배타적 지배영역에서 발생한 사고임을 증명하기 어려웠기 때문이라면서, 운전자의 개입이 제한된 자율주행자동차의 경우 제조물책임 인정이 더욱 용이해질 것이라는 지적도 있다(오병철, 2017).

국가기술표준원 고시에 따르면 설계상의 결함이란 “제조업자가 합리적인 대체설계를 채용하였더라면 피해나 위험을 줄이거나 피할 수 있었음에도 대체설계를 채용하지 아니하여 해당 제조물이 안전하지 못하게 된 경우”를 말한다. 이는 제조업자의 과실에 상응하는 것으로 볼 수도 있다. 일부 견해는 합리적 대체설계에 같음하여 이른바 제품 분류책임을 주장하기도 한다. 즉 피해자는 제품분류의 핵심적 요소를 유지하는 대체설계에 대한 주장입증을 하는 대신에, 그 제품에 내재하는 ‘극도로 높은 위험성’이 그 제품으로 인한 ‘경미한 사회적 효용성’을 초과한다는 점을 들어 결함의 존재를 주장할 수 있다는 것이다(류창호, 2016). 그러나 이에 대하여는 인공지능 도구는 오히려 ‘경미하게 낮은 위험성’을 내재하면서도 ‘극도로 높은 효용성’을 지니는 것이 일반적이라는 점에서 제품분류책임을 적용할 수 없다는 반론(오병철, 2017)이 있어 그 채용에는 신중을 기할 필요가 있다고 할 것이다.

한편 표시상의 결함이란 제조업자가 합리적인 설명·지시·경고 또는 그 밖의 표시를 하였더라면 해당 제조물에 의하여 발생할 수 있는 피해나 위험을 줄이거나 피할 수 있었음에도 이를 하지 아니한 경우를 말하는데, 인공지능 도구의 경우에는 이용자가 개입할 수 있는 부분이 별로 없어 문제될 여지가 크지 않다.

라) 개발위험의 항변 문제

제조물책임법은 네 가지 면책사유를 규정하고 있는데(§4①), 인공지능 기술과 관련

33) 대법원 2000. 2. 25. 선고 98다15934 판결 등

하여 가장 문제가 되는 것은 이른바 “개발위험의 항변(state-of-the-art defense)”이다. 즉, 제조업자는 해당 제조물을 공급한 시점에서의 과학 및 기술 수준으로는 문제가 되는 결함의 유무를 발견할 수 없었다는 사실을 증명할 경우 제조물책임을 면한다.

이와 관련해서는 먼저 과학기술 수준의 판단 기준이 문제된다. 고도의 기술력이 집약된 인공지능 도구의 경우 제조업자가 정보 면에서 유리한 지위에 있다는 점에서 높은 수준의 과학기술을 기준으로 판단할 필요가 있다(권영준이소은, 2016). 그럼에도 불구하고 특히 딥러닝 알고리즘을 활용하는 경우 설명가능성에 본질적인 한계가 있기 때문에 제조업자의 면책 가능성은 비교적 높을 것으로 예상된다. 혁신의 장려 및 영업의 자유와 개인의 피해 구제 필요성 사이의 신중한 이익형량을 통하여 개발위험의 항변에 대한 입법적 검토를 할 필요가 있다.

과학기술 수준의 판단 시기 역시 문제된다. 인공지능 도구의 경우 지속적인 업데이트나 학습이 매우 중요하고 이를 통하여 제조물이 실질적으로 변경되는 경우도 많을 것으로 예상된다. 그런 점에서 현행법이 ‘공급한 당시’를 기준으로 결함 여부를 판단하는 것은 부적절하다는 비판이 제기될 수 있다(박해선, 2016). 이러한 문제는 ‘제조물관찰의무’를 통하여 어느 정도 해결될 수 있다. 즉, 제조물책임법은 제조업자가 제조물을 공급한 후에 그 제조물에 결함이 존재한다는 사실을 알거나 알 수 있었음에도 그 결함으로 인한 손해의 발생을 방지하기 위한 적절한 조치를 하지 아니한 경우에는 면책을 주장할 수 없도록 하고 있다(§4②). 제조물관찰의무 위반의 판단과정을 거치면서 제조물책임은 과실책임의 성격을 띠게 된다(김진우, 2018).

제2절 결론 및 시사점

1. 인공지능 안전·윤리 R&D의 방향

안전한 인공지능을 개발하기 위한 국제사회의 노력은 그만큼 인공지능이 갖는 잠재력이 크다는 사실을 반증한다. 여기에는 인공지능이 어떤 형태로든 발전하여 우리의 삶을 크게 바꿀 것이라는 믿음이 있다. 그것이 긍정적이든 부정적이든 국제기구를 비

못한 주요국, 그리고 글로벌 IT 기업에 이르기까지 인공지능의 안전성에 대한 관심은 매우 높다. 그러나 이 관심의 전제는 인공지능이 지속적이고도 빠르게 발전할 것이라는 점이다.

과연 미래의 인공지능은 어떠한 형태가 될 것인가? 이것에 대해서는 다양한 갑론을박이 존재하지만, 그간 인공지능의 “성배”로 여겨져 왔던 범용 인공지능이 가장 그럴듯한 후보다. 범용 인공지능은 사람처럼 주변 사물의 상태를 통해 문제를 인식하고, 경험했던 사실을 통해 문제를 해결하는 능력을 구현한다는 개념이다. 분명한 것은 범용 인공지능이 개발될 경우 우리의 삶은 큰 변혁을 맞이할 것이라는 점이다. 범용 인공지능의 개발 가능성이 조금이라도 존재한다면, 이에 대응하기 위한 준비는 빠를수록 좋을 것이다. 다행히도 현재 국제기구와 주요 비영리단체는 범용 인공지능 시대를 대비하기 위한 준비를 이어가고 있다. 지난 2017년 발표된 아실로마 23대 인공지능 원칙 역시 범용 인공지능에 대응하기 위한 것이다. 2019년에는 미래 삶 연구소(FLI)가 전 세계 인공지능 석학들과 함께 이로운 범용 인공지능(Beneficial AGI 2019) 학회를 개최하여 심도 있는 논의를 이어오고 있다.

범용 인공지능에 대한 대비는 그 막대한 파급효과를 고려할 경우 당연히 전 세계적인 관심과 노력이 필요하다. 그러나 범용 인공지능이 구체적으로 무엇인지에 대해서는 아직 명확한 해답이 없다. 결국 범용 인공지능의 실체는 인공지능의 세계적인 석학과 미래학자의 힘을 빌어서 추측할 수밖에 없다. 다행스럽게도 세 번째 황금기를 맞은 인공지능은 그 열기가 아직도 뜨겁다. 2019년 인공지능과 관련된 주요 학회에 접수된 논문의 수는 2년 전에 비해 두 배에 가깝게 성장했다.³⁴⁾ 이러한 연구의 집중과 관심은 인공지능 기술 발전이 다양한 방향으로 발산될 것이라는 점을 암시한다.

사람의 지능적 행동을 대체하는 인공지능은 현 시점에서도 그 안전성에 대한 준비가 진행되고 있다. 범용 인공지능이 다소 먼 미래의 이야기라고 한다면 심층학습의 윤리와 안전성은 현재 화두가 되고 있는 내용이다. 현 시점의 인공지능 패러다임은

34) 인공지능 주요 학회(NeurIPS, ICML, CVPR)의 홈페이지에 따르면 논문투고수가 다음과 같이 증가
NeurIPS 논문 투고(submitted) 수 : 3,240건 (2017년), 6,743건 (2019년) (NeurIPS 홈페이지)
ICML 논문 투고 수 : 1,676건 (2017년), 3,424건 (2019년) (ICML 홈페이지)
CVPR 논문 투고 수 : 2,620건 (2017년), 5,160건 (2019년) (CVPR 홈페이지)

DARPA가 소개했듯이 통계적 학습(statistical learning)에 머물러 있다. 데이터의 절대량이 성능을 좌우할 수 있는 가능성이 큰 심층학습은 데이터와 관련된 위험에서 자유로울 수 없다. 데이터로 발생할 수 있는 문제는 개인정보의 침해, 오염된 데이터의 학습, 데이터를 통한 악의적인 공격 등이 있다. 최근에는 데이터 생성 모델로 인한 인권침해 논란도 이어지고 있다. 딥페이크의 경우 초상권을 침해할 가능성이 매우 높고 가짜 정보를 생성하는 등 사회적으로 악용될 가능성이 높다. 심층학습은 구조적인 측면에서도 안전성이 결여되어 있다. 심층학습의 모태가 되는 인공지능망은 블랙박스 구조다. 블랙박스는 입력에 대한 출력의 상관관계를 설명하기 어렵다는 것을 말한다. 인공지능이 지능적 의사결정에 대한 이유가 설명이 되지 않는다면, 믿고 사용하기에 큰 걸림돌이 될 것이다.

논의의 폭을 좁혀 현 시점의 인공지능이 안전성을 확보할 수 있는 방법은 무엇이 있을까? 가장 쉽게 생각할 수 있는 방법은 기술적 접근이다. 더 적은 데이터로 학습할 수 있고 설명 가능한 심층학습이 개발된다면 일차적인 문제는 해결된 것처럼 보인다. 자율주행차가 급정거를 했을 경우 그 이유를 설명하고, 처음 만나는 환경에서도 스스로 학습하여 최적의 주행을 할 수 있다면 우리는 조금 더 인공지능 시스템을 믿고 서비스를 활용할 수 있을 것이다.

그러나 인공지능으로 발생할 수 있는 많은 문제는 기술적으로 해결하기 어려운 것도 많다. 특히 데이터 생성을 통한 인권 및 저작권 침해는 매우 심각한 문제다. 그러나 이러한 피해를 구제 받기 위한 법·제도적인 측면은 아직 미비하다. 이를 대비하기 위한 방향이 인공지능 개발자의 윤리 의식 함양이다. 인공지능 개발자들이 인공지능을 인류에 이롭게 활용한다는 사명감을 갖게 하는 것이다. 다만 이것은 강제성이 없어 큰 효과를 발휘하기 어려울 수도 있다. 또한 오픈사이언스의 특징을 갖는 인공지능은 도구적인 속성이 강하기 때문에 인공지능 개발자에 대한 범위도 모호할 수 있다. 인공지능 안전성 확보는 개인의 노력도 중요하다. 개인은 무심코 소셜 네트워크에 공유하는 정보들이 악용될 수 있음을 인지하고, 정보 제공 주체로서의 권리와 권한을 정확히 파악해야 한다. 국제기구나 각국의 정부는 개인의 정보 주권 확보를 위한 교육과 의견 수렴 등의 참여를 유도해야 할 것이다.

그렇다면 인공지능 윤리 및 안전성 확보를 위해 우리가 해야 하는 과제는 무엇일까? 본 연구의 결론으로 해당 과제를 크게 두 가지 관점에서 제안하고자 한다. 첫 번째는 인공지능 윤리 확보를 위한 우선순위의 설정이다. 관련해서 국제기구와 국내외 정부가 제시하고 있는 윤리 가이드라인에 대한 실질적인 테스트에 대한 필요성에 대해 논의한다. 두 번째 과제는 인공지능 안전성 확보를 위한 R&D 방향 설정이다. 특히 인공지능 기술이 끊임없이 발전하고 진화하기 때문에 이를 고려한 전략 방향을 찾는 것이 무엇보다 중요하다.

2. 인공지능 윤리 확보를 위한 R&D 방향

인공지능 윤리라는 단어는 우리에게 매우 친숙한 사례를 상기시킨다. 소위 트롤리 문제라고 하는 것인데, 자율주행차가 왼쪽으로 가면 운전자만 사망하고 오른쪽으로 가면 다수의 보행자가 사망하나 운전자는 살 수 있게 될 때의 선택 문제다. 여기서 자율주행차를 브레이크가 파손된 자동차로 가정하고 그것의 방향을 사람이 조정한다고 생각해 보자. 사람이 운전할 경우에는 방향 설정에 대한 다양한 윤리적 논의가 가능하다. 자율주행차 역시 예외는 아닐 것이다. 사람이나 자율주행차나 이 선택에 대해 어느 것이 합당한지를 답하는 것은 매우 어려운 주제다.

이 사례는 인공지능과 인류의 “가치의 정렬” 문제를 상기시킨다. 이 문제는 일차적으로 무엇이 인류의 가치인가에 대한 사회적 합의가 있어야 한다. 만약 인류의 가치가 정해졌다면 이것을 프로그래밍화 할 수 있는가에 대한 논의가 부상한다. 만약 프로그래밍화 할 수 없다면 인공지능 시스템에 인류의 가치를 내재시킬 수 있는 대안을 찾아야 할 것이다.

이러한 차원에서 인공지능 윤리라는 것은 매우 어려운 과제다. 또한 인공지능을 어떠한 지위에서 바라 볼 것인가에 대해서도 의견을 모아야 한다. 인공지능이 인간과 동격이 될 수도 있고, 사물이 될 수도 있다. 이렇게 인공지능은 다양한 존재론적 접근이 있기 때문에 윤리를 논하는 것도 도전적이다.

이렇게 인공지능 윤리의 연구개발과 현실의 간극이 매우 큰 상황에서 인공지능 윤리와 관련된 연구는 추상적인 경우가 많다. 지난 2019년 4월 EU는 인공지능 윤리

가이드라인을 공개했다(European Commission, 2019.4.8.). 인공지능 윤리의 7가지 조건은 그 면면이 합당하다고 여겨지나 실제로 그것을 구현하는 것은 별개의 문제라고 볼 수 있다. 다시 말하자면 인공지능 윤리와 현실의 간극이 크다는 것이다. 그것이 현 시점의 인공지능 기술 수준이든 윤리 가이드의 모호성이든 서로의 간극을 줄여나가는 것이 중요하다. EU의 윤리 가이드라인은 이 간극을 줄이기 위해 파일럿 테스트를 수행한다고 밝혔다. 자국 내외의 인공지능 기업의 자원을 받아 수행되는 이 프로그램은 현실적인 인공지능 윤리 가이드라인 정립에 많은 도움을 줄 것이다. 문제는 기업의 자발적인 참여다. 인공지능 분야는 특히 창업이 가장 활발히 일어나는 분야 중 하나다. 스타트업은 서로 우위를 점하기 위해 치열한 경쟁을 수행하는 과정에서 인공지능 윤리에 큰 가치를 두지 않을 가능성이 높다. 인공지능 윤리라는 것은 상식적으로 생존에 성공한 스타트업의 고려대상이기 때문이다.

그렇다면 우리의 전략은 무엇일까? 우리나라도 2018년 6월 지능정보사회 윤리 현장을 발표했다(과학기술정보통신부, 2018.6). 윤리 현장의 전반적인 내용은 유럽의 윤리 가이드라인의 문맥과 상통한다. 따라서 우리 역시 국내 인공지능 윤리 현장의 고도화를 통해 국제 사회의 인공지능 윤리에 기여할 수 있다고 본다. 윤리 현장의 고도화는 EU의 경우와 마찬가지로 파일럿 테스트를 수행하는 접근이 가장 적절한 방법이다. 국내 인공지능 스타트업은 우리나라의 문화와 법·제도에 익숙하기 때문에 우리에게 필요한 인공지능 윤리가 무엇인지를 파악할 수 있을 것이다. 인공지능 관련 기업이 파일럿 테스트에의 참여를 유도하기 위해 정부가 출연하는 R&D 과제에 윤리와 관련된 예산을 필수적으로 산정하게 하는 방식이 있을 수 있다. 물론 정부 R&D를 수행하는 스타트업의 입장에서는 추가적인 부담이 될 수 있겠지만, 윤리 현장의 고도화와 국제 사회의 방향과 동조할 수 있는 부분에 가치를 두어야 한다고 본다. 또한 어떠한 결과물을 통해 윤리 현장을 고도화할 지에 대한 선행연구도 필요할 것이다. 인공지능과 관련된 윤리 현장이나 가이드라인의 고도화는 긴 호흡을 가지고 추진될 필요가 있다. 그 이유는 인공지능의 기술 트렌드가 변화무쌍하기 때문이다. 이 트렌드에 가장 민첩한 대응이 필요한 주체는 인공지능 스타트업이다. 따라서 인공지능 스타트업을 중심으로 한 인공지능 윤리의 고도화를 장기적인 안목에서 기획하고 추진해야 할 필요

가 있다고 본다.

인공지능 시스템에 인류의 가치를 정렬시키기 위한 윤리적 인공지능은 현 시점에서 추진하기에는 시기상조라고 보여 진다. 인류의 보편적 가치가 어떻게 프로그래밍 될 수 있느냐는 그 자체만으로도 도전적인 연구과제다. 이것이 명확하지 않은 상황에서 개발하는 윤리적 인공지능은 실패할 가능성이 높다. 이러한 연구는 인공지능 최고기술보유국인 미국과 인권을 강조하는 유럽의 역할이 클 것이다. 전 세계에서 10위권 수준의 인공지능 연구역량(소프트웨어정책연구소, 2018)을 보유한 우리나라는 인공지능 R&D에 대한 선택과 집중이 필요하다. 윤리적 인공지능의 개발은 우리가 도전할 수 있는 영역을 구체화하는 노력이 선행될 필요가 있다.

현 시점에서 가장 현실적인 인공지능 윤리 관련 대응은 개발자의 윤리 교육과 정보 제공 주체의 교육 등 인공지능 기술의 공급 측과 수요 측의 인식 개선이다. 먼저 인공지능 개발자는 지속적인 교육을 통해 개발하고자 하는 인공지능 시스템에서 활용되는 데이터가 적법한 절차로 수집된 것인지를 확인하고, 문제 기획 단계에서 편향이 없는 지를 점검하는 등의 노력이 체화되어야 한다. 이러한 프로그램은 윤리 현장에서 파생되어 나온 것으로 연계되어 인공지능 개발자의 윤리 교육 프로그램을 기획할 필요가 있다.

또한 주요 데이터를 생산하는 개인은 자신이 보유하거나 온라인 상에 게시하는 데이터에 대한 주권을 명확히 할 필요가 있다. 현재 웹상에 유통되고 있는 각종 정보는 사전 동의 없이 인공지능의 학습용 데이터로 활용될 소지가 매우 높은데, 개인은 이러한 잠재적인 위협에 대해 충분히 인지해야하고, 인공지능에 활용되는 데이터를 공급할 경우 신중한 약관 동의를 장려하는 문화가 확산되어야 한다.

물론 개인의 정보 주권 강화가 현 시점의 인공지능 발전에는 걸림돌이 될 수 있다. 그러나 딥페이크의 사례에서도 볼 수 있듯이 개인이 생산한 데이터의 공유와 게시는 신중한 선택이 필요하다는 사실을 인지시키는 것이 정부의 역할이라고 볼 수 있다. 인공지능 윤리 확보를 위한 R&D 방향을 요약하면 아래 <표 5-2>과 같다.

<표 5-2> 인공지능 윤리 확보를 위한 R&D 방향

구 분	주 요 내 용
인공지능 윤리 가이드라인의 고도화	- 스타트업이 수행하는 인공지능 관련 정부 R&D 중 일부 예산을 인공지능 윤리 현장의 파일럿 테스트를 위해 배정 - 파일럿 테스트 수행을 위한 기획 연구 필요
윤리적 인공지능 개발	- 윤리적 인공지능 개발은 가치의 정렬 문제를 고려해야하기 때문에 매우 도전적인 과제 - 장기적인 R&D 과제로 추진하되 선택과 집중으로 우리가 투자할 방향을 설정 ※ (예) 평화, 박애, 평등 중 평화와 관련된 윤리적 인공지능 개발
인공지능 윤리 교육 강화	- (개발자) 인공지능 개발 과정상에 있어 고려해야 할 문제의 편향, 데이터의 수집 등 인공지능 윤리 이슈와 관련된 문제 인식 - (정보 제공 주체) 인공지능 시스템에 있어 데이터의 중요성과 그 파급 효과를 지속적으로 인지시키고, 개인의 정보 주권을 확보하기 위한 교육 강화

자료 : 연구진 작성

3. 인공지능 안전성 확보를 위한 R&D 방향

인공지능의 안전성 확보는 우리가 인공지능과 공존하기 위해 매우 중요한 주제다. 그러나 현재의 인공지능, 즉 심층학습의 한계를 고려해보면 안전성 확보라는 주제 자체는 매우 도전적이며 그 범위가 모호하다. 인공지능 윤리와도 투명성, 공정성 등 상당한 부분이 겹친다. 결국 논의의 구분을 위해서 인공지능 안전성 확보를 위한 R&D 방향은 기술적인 부분에 초점을 맞출 필요가 있다. 반면 인공지능 윤리 확보를 위한 R&D 방향은 기술적인 방향 보다는 교육이나 시스템적인 고도화를 지향한다. 인공지능의 안전성 혹은 신뢰성(trustworthiness)을 확보하기 위한 기술적 R&D의 주된 방향은 DARPA의 ‘AI Next Campaign’에서 찾을 수 있다.

우리나라의 인공지능 안전성 확보를 위한 R&D의 가장 큰 방향은 인공지능 기초·원천기술에 대한 지속적인 투자다. 심층학습으로 고도화된 인공지능의 성능은 분명 미래를 혁신할 성장동력임에는 틀림없다. 그러나 현재의 법·제도의 체계는 인공지능을 활용한 다수의 서비스에 원천적인 규제를 걸고 있다. 예를 들어 인공지능이 질병 진단 및 처방을 한다고 가정할 경우 이는 국내 생명윤리법상 불법행위다. 인공지능이

안전한지 여부를 판단하기를 떠나 현재 우리의 법·제도는 상당히 보수적인 것이다. 비단 의료분야 뿐만 아니다. 개인정보의 경우 비식별화 조치를 했음에도 개인이 식별된다면 처벌을 받는다. 이러한 관점에서 우리 사회 시스템이 인공지능을 받아들이기에는 많은 시간이 필요할 것으로 판단된다.

심층학습의 한계를 넘기 위한 기술, 즉 범용 인공지능으로 향하는 R&D를 통해 더 강건한(robust) 인공지능 알고리즘을 개발할 필요가 있다. 이것은 지속적인 관심과 투자가 필요한 영역이다. 현재 인공지능의 한계를 극복하기 위한 노력은 조금씩 전진하고 있다. 물론 인간의 수준에는 현저히 부족하나 심층학습의 한계를 극복하기 위한 여러 방법론들이 부상하고 있다. 예를 들어 메타 학습(meta-learning)은 학습하는 방법을 학습하는 방법이다. 또한 사람처럼 적은 데이터로도 학습하는 원샷, 제로샷 학습, 그리고 치명적 망각(catastrophic forgetting)이라는 단점을 극복하기 위한 지속적인 학습(continual learning), 알파고와 같이 자체 대결(self-play)로 학습하는 방법 등 많은 대안이 부상하고 있다. 이러한 기술들의 면면은 아직 실험실 수준을 벗어나지 못하고 있다. 그러나 이러한 시도들이 가속화하는 인공지능 R&D 생태계는 진화를 거듭하고 있다고 판단해도 무방하다.

2019년 8월 정부는 혁신성장 확산 가속화 전략을 발표했다(관계부처 합동, 2019.9.21). 여기에는 현재 인공지능 기술의 한계를 돌파하기 위한 'NEXT AI R&D'를 추진한다는 내용이 담겼다. 이렇듯 국내 정부가 차세대 인공지능에 대한 필요성을 인지하고 강력한 추진 의지를 보인다는 점은 상당히 고무적이다. 이에 더해 차세대 인공지능 R&D에 안전성과 윤리 확보를 위한 연구 역시 반드시 국가차원에서 추진되어야 한다고 본다.

4. 데이터 이슈를 고려한 인공지능 정책방향³⁵⁾

데이터에 기반을 둔 인공지능 기술은 생산비용을 낮추고 생산성을 증진하여 소비자 효용 증가뿐 아니라 지속가능한 성장과 포용성 증대에도 기여할 수 있다. 하지만 동시에 기계 학습, 딥러닝을 포함한 인공지능 기술이 개인정보를 포함한 빅데이터를 활용

35) 본 주제에 대해서는 대외경제정책연구원 이규엽 부연구위원의 자문을 받아 작성하였음.

하는 까닭으로 이러한 기술을 구동하는 과정에서 발생하는 프라이버시(privacy), 소비자 보호 등과 같은 문제가 데이터 통상이슈로 부상한다. 또한 개인정보가 유통될 때 개인정보를 포함한 데이터가 비식별조치 되더라도 방대한 양의 데이터를 결합하면 개인정보가 기술적으로 재식별될 수 있다는 가능성이 제기될 뿐 아니라, 클라우드 컴퓨팅 서비스 제공자가 활용하는 인공지능 기술 자체가 해킹에도 활용될 수 있어 데이터 보안 이슈에 대한 우려도 존재한다(이규엽, 강민지 2019). 따라서 인공지능 안전성과 윤리 이슈는 개인정보보호를 포함한 데이터 통상이슈와 함께 고려될 필요가 있다.³⁶⁾ 데이터 활용에 관한 국제사회의 논의 동향을 기초로 우리 정부가 인공지능과 관련하여 고려해야 할 정책과제는 크게 ① 데이터 관련법 정비 ② 데이터 보호를 포함한 디지털 윤리 가이드라인 개선 ③ 양자 및 다자 차원의 협력 강화로 볼 수 있다.

2018년 한국은 데이터 활용도를 높이고 개인정보에 대한 안전장치를 강화하는 방향으로 데이터 관련 제도를 정비하기 위한 움직임을 구체화하였다. 가시적으로 나타난 대표적인 사례로 2018년 11월에 제출된 개인정보보호법, 정보통신망법, 신용정보법 등 3개 법률 개정안이 국회에 제출된 점을 꼽을 수 있다(법률신문, 2018.12.7.). 제출된 개정안에는 추가정보 없이는 특정 개인을 식별할 수 없는 가명정보 개념을 도입하고, 보안시설을 갖춘 전문기관을 통해 데이터 결합을 허용하는 내용이 포함되었다. 또한 데이터 활용에 따른 개인정보처리자의 책임을 강화하는 규정도 담고 있다. 그러나 현재 세 개 법률 개정안은 아직까지 국회를 통과하지 못한 상태로 계류되어 있는 상황이다. 이에 데이터 산업, 디지털 혁신 기업, 인공지능 관련 스타트업, 인공지능 기술 사용자 등은 금융, 헬스, 교육 등과 같은 다양한 산업 분야에서 새로운 사업을 영위하기 위한 노력을 기울이고 있으나 보완된 데이터 관련법을 추진력 삼아 앞으로 나아가는데 큰 힘을 얻지 못한다는 비판이 존재한다. 정부가 추진하는 마이데이터(MyData) 사업이나 빅데이터 센터(Big Data Center) 설립과 같은 굵직한 정부 정책은 데이터 관련법이 정비될 때 비로소 성장을 위한 탄력을 받을 수 있을 것이다.

한편 데이터 관련법을 정비하고 개선하기까지는 상당한 시간이 소요될 수 있다. 따

36) 글로벌 시장분석업체인 가트너(Gartner)는 디지털 윤리(digital ethics)와 개인정보보호(privacy)를 2019년에 주목해야 할 10대 전략기술동향 중 하나로 선정하였다.

라서 정부는 개인정보를 포함한 데이터 활용/보호에 관한 내용을 담아 디지털 윤리 가이드라인을 개선하는 방안을 고려해 볼 수 있다. 기존에 작성된 인공지능 관련 가이드라인 중 가장 최신의 것은 과학기술정보통신부가 지난 2018년 6월에 발표한 지능정보사회 윤리 가이드라인이다. 데이터 관련법이 통과되기까지 상당한 시간이 소요될 가능성이 크므로, 해당 가이드라인을 기초로 개인정보를 포함한 데이터 보호의 측면까지 고려하여 보완 작업을 수행한다면, 국내 인공지능 관련 기술의 발전 속도와 법적 대응 속도 사이의 간극을 좁히는 역할을 할 수 있을 것으로 기대된다.

마지막으로 정부는 국가 간 협력을 통해 국경 간 넘나드는 데이터를 활용하여 국내 인공지능 기술발전과 경제효과 증대를 위해 노력할 필요가 있다. 인공지능 경제(AI economy)에서는 국경의 구분 없이 전자상거래(electronic commerce)와 인공지능이 결합하여 상품이나 서비스를 사거나 파는 경제행위가 나타나고 방대한 양의 소비자 정보에 기초한 빅데이터와 이를 활용한 인공지능을 통해 다양한 형태의 서비스가 속속 등장한다. 이러한 추세에서는 개인정보를 포함한 데이터를 중심으로 국경 간 발생할 수 있는 법적인 문제를 완화/해소하거나 이와 관련된 프라이버시, 보안, 안전, 윤리, 인권 등에 관한 이슈가 불거질 경우 이를 다룰 수 있는 양자 또는 다자적 소통 채널을 개설하고 국제협력을 위한 노력이 경주되어야 한다. 실제로 데이터 및 인공지능과 관련하여 파생되는 이슈인 안전, 윤리, 인권 등은 아직 가이드라인을 작성하는 수준에서만 다루어지고 있지만, 양자다자 자유무역협정 차원에서는 프라이버시, 보안의 측면을 염두에 두고 데이터의 국경 간 자유로운 이동, 데이터 지역화 조치 금지, 개인정보보호 보장과 같은 조항을 의무사항으로 명시하는 추세이다. 이에 정부는 APEC, G20, OECD 등 국제기구나 국제회의의 채널을 활용할 수도 있고 양자다자 지역무역협정에서 인공지능 안전성과 윤리적 측면을 강조한 개인정보보호에 대해 협력조항을 삽입하는 방안을 검토해 볼 수 있을 것이다(Meltzer, 2019.5). 국가 간 협력이 원활히 이루어질 때 데이터와 인공지능을 활용하는 기업과 사용자가 주요 선진국뿐 아니라 개발도상국에서도 발생할 수 있는 데이터를 안전하고 효과적으로 수집하고 이를 인공지능 기술 개발에 활용하여 소비자 후생을 높이고 장기적 경제 성장에 이바지할 수 있을 것이다.

참고문헌

제1장 1절 연구 배경

- 관계부처 합동(2016.12.27.), 「제4차 산업혁명에 대응한 지능정보사회 중장기 종합대책」.
- 최병삼·홍성민 외(2018), 「과학기술기반 미래연구사업 X」, 과학기술정책연구원.
- 양희태 외(2018), 「인공지능 기술 전망과 혁신정책 방향 - 국가 인공지능 R&D 정책 개선방안을 중심으로」, 과학기술정책연구원.
- 한국인터넷진흥원(2016.11.). 「미국의 인공지능 보고서의 주요 내용」, 『Power Review』, 한국인터넷진흥원.
- 양희태(2018), 「인공지능의 안전성 이슈와 정책 대응 방안」, 『한국통신학회논문지』, 제43권 제 10호, pp. 1724-1732.
- The Verge(2018.4.4.), "Leading AI researchers threaten Korean university with boycott over its work on 'killer robots'",
<https://www.theverge.com/2018/4/4/17196818/ai-boycot-killer-robots-kaist-university-hanwha>. 2019.4.1. 접속
- Future of Life Institute homepage, <https://futureoflife.org/ai-principles/?cn-reloaded=1>, 2019.4.1. 접속.
- Google blog, <https://www.blog.google/technology/ai/ai-principles/>, 2019.4.1. 접속.

제2장 1절 인공지능 안전성

- 양희태 외(2018), 「인공지능 기술 전망과 혁신정책 방향 - 국가 인공지능 R&D 정책 개선방안을 중심으로」, 과학기술정책연구원.
- 관계부처 합동(2016.12.27.), 「제4차 산업혁명에 대응한 지능정보사회 중장기 종합대책」.
- Roman V. Yampolskiy and M.S. Spellchecker(2016), "Artificial intelligence safety and cybersecurity: A timeline of AI failures", *arXiv preprint arXiv:1610*, pp. 1-12.
- 닉 보스트롬(2017), 『슈퍼 인텔리전스』, 조성진 옮김, 까치글방. [원문: Nick Bostrom(2014), *SUPERINTELLIGENCE: Paths, Dangers, Strategies*, Oxford University Press].
- 중앙일보(2016.3.15.), 「2분 만에 460억 날린 투자AI…사생활 침해 논란 '딥페이스」,

- <https://news.joins.com/article/19723232>, 2019.4.11. 접속
- ZDNet(2016.7.13.), 「자율 로봇, 어린이 공격 '횡당 사건」, http://www.zdnet.co.kr/news/news_view.asp?article_id=20160713092842&lo=zv41, 2019.4.11. 접속
- 최병삼·홍성민 외(2018), 「과학기술기반 미래연구사업 X」, 과학기술정책연구원.
- Bloomberg(2018.5.24.), “Uber Self-Driving Car in Crash Wasn't Programmed to Brake”, <https://www.bloomberg.com/news/articles/2018-05-24/uber-self-driving-system-saw-pedestrian-killed-but-didn-t-stop>. 2019.4.11. 접속
- 로봇신문사(2016.6.16.), 「자유 찾아 연구실 밖으로 탈출한 로봇」, <http://www.irobotnews.com/news/articleView.html?idxno=7842>, 2019.12.17. 접속
- 로봇신문사(2016.7.13.), 「미국 쇼핑몰 경비 로봇, 아이 폭행사건 '일파만파」, <http://www.irobotnews.com/news/articleView.html?idxno=8109>, 2019.12.17. 접속
- New York Times (2018.3.19.), “Self-Driving Uber Car Kills Pedestrian in Arizona, Where Robots Roam”, <https://www.nytimes.com/2018/03/19/technology/uber-driverless-fatality.html>, 2019.12.17. 접속
- 양희태(2018), 「인공지능의 안전성 이슈와 정책 대응 방안」, 『한국통신학회논문지』, 제43권 제 10호, pp. 1724-1732.
- ProPublica(2016.5.23.), “Machine Bias”, <https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing>. 2019.4.11. 접속
- Medium(2018.12.11.), “2018 in Review: 10 AI Failures”, <https://medium.com/syncedreview/2018-in-review-10-ai-failures-c18faadf5983>. 2019.4.11. 접속

제2장 2절 인공지능 윤리

- 한희원(2018), 「인공지능(AI) 법과 공존윤리」, (주)박영사.
- 이유태(2005), 「요나스의 미래윤리와 책임」, 『동서철학연구』, 제36호, pp. 1-15.
- 김효은(2019), 『인공지능과 윤리』, 커뮤니케이션북스.
- Wikipedia, “Three Laws of Robotics”, https://en.wikipedia.org/wiki/Three_Laws_of_Robotics. 2019.4.14. 접속

- 최병삼·홍성민 외(2018), 『과학기술기반 미래연구사업 X』, 과학기술정책연구원.
- 이봉진·김유혁(2018), 「인공지능 기술 등을 적용한 첨단 무기 개발 확대」, 『항공·방위산업 Weekly』, 한화투자증권, p. 1.
- The Guardian(2019.1.10.), “Yemen peace talks at risk after several killed in Houthi drone attack”,
<https://www.theguardian.com/world/2019/jan/10/houthi-drone-attack-on-yemeni-base-kills-several-people-reports>. 2019.4.15. 접속
- The Verge(2018.8.17.), “The Caracas drone attack won’t be the last of its kind”,
<https://www.theverge.com/2018/8/17/17703570/caracas-drone-attack-venezuela-president-nicolas-maduro>. 2019.4.15. 접속
- 연합뉴스(2019.6.13.), 「네가 본 영상을 믿지 마라」...가짜뉴스 이어 ‘딥페이크’ 비상,
<https://www.yna.co.kr/view/AKR20190613121600009>, 2019.12.19. 접속
- BuzzFeed(2018.4.18.), “How To Spot A Deepfake Like The Barack Obama-Jordan Peele Video”, <https://www.buzzfeed.com/craigsilverman/obama-jordan-peelee-deepfake-video-debunk-buzzfeed>. 2019.4.15. 접속
- Mirsky, Yisroel, et al.(2019), "CT-GAN: Malicious Tampering of 3D Medical Imagery using Deep Learning", *arXiv preprint arXiv:1901.03597*, pp. 1-18.

제3장 1절 글로벌 기업 대응 동향

- 조원영(2019.4.), 「인공지능에 대한 사회적 우려와 업계의 대응」, 『월간SW중심사회 9월호』, 소프트웨어정책연구소.
- KPMG(2019.1.), 「Top 5 AI Hires Companies Need to Succeed in 2019」
- Wall Street Journal(2019.1.29.), “Salesforce Ethicist Shares Tips on Working with AI”,
<https://www.wsj.com/articles/reporters-notebook-salesforce-ethicist-shares-tips-on-working-with-ai-11548799201>, 2019.12.19. 접속
- Business Insider(2018.12.16.), “Salesforce is Hiring Its First Chief Ethical and Humane Use Officer to Make Sure Its AI Isn’t Used for Evil”,
<https://www.businessinsider.com/salesforce-hires-paula-goldman-as-chief-ethical-and-humane-use-officer-2018-12>, 2019.12.19. 접속

매일경제(2017.12.17.), 「우버, 세계 도처에서 경쟁사 정보 불법 수집」,

<https://www.mk.co.kr/news/it/view/2017/12/833431/>, 2019.5.17. 접속.

Business Insider (2018.7.10.), “Uber’s Latest Hire is Another Sign the Company is Trying to Grow Up”,

<https://www.businessinsider.com/uber-hired-first-compliance-ethics-officer-2018-7>

CBInsight (2018.9.11.), “Google, Amazon, Facebook, and Apple Are Hiring to Defend Against the Techlash”,

<https://www.cbinsights.com/research/google-amazon-facebook-apple-hiring-techlash/>

New York Times (2018.10.21.), “Who Will Teach Silicon Valley to Be Ethical?”,

<https://www.nytimes.com/2018/10/21/opinion/who-will-teach-silicon-valley-to-be-ethical.html>

Google Blog, <https://blog.google/technology/ai/ai-principles/>, 2019.5.17. 접속.

Google AI 권고사항 홈페이지, <https://ai.google/education/responsible-ai-practices>, 2019.5.17. 접속.

MIT Technology Review (2018. 10.21.), “Establishing an AI Code of Ethics Will Be harder Than People Think”

Microsoft 홈페이지(2018), 「인공지능으로 변화될 미래 : 인공지능, 그리고 그 사회적 역할」

IBM(2018.9.), “Everyday Ethics for Artificial Intelligence : A Practical Guide for Designers & Developers”

IBM Research Trusted AI 홈페이지, “AI Fairness 360 Open Source Toolkit”, <http://aif360.mybluemix.net/>

국민권익위원회(2019.1.), 「카카오-인공지능 윤리현장 발표」, 기업윤리 브리프스

DeepMind 블로그,

<https://deepmind.com/blog/why-we-launched-deepmind-ethics-society/>, 2019.5.19. 접속.

Forbes (2018.5.3.), “Facebook Reportedly Has a Dedicated AI Ethics Team”,

<https://www.forbes.com/sites/samshead/2018/05/03/facebook-reportedly-has-a-dedicated-ai-ethics-team/#b8476ad2e5c0>, 2019.5.17. 접속.

The Guardian (2018.10.19.), “Facebook Has a Fake News ‘War Room’-But Is It Really Working?”,

<https://www.theguardian.com/technology/2018/oct/18/facebook-war-room-social-media-fake-news-politics>, 2019.5.17. 접속.

Google blog(2019.3.26.), “An External Advisory Council to Help Advance the Responsible Development of AI”,
<https://blog.google/technology/ai/external-advisory-council-help-advance-responsible-development-ai/>, 2019.5.17. 접속.

The Guardian (2019.3.29.), “Bias Deep Inside the Code : The Problem with AI Ethics in Silicon valley”,
<https://www.theguardian.com/technology/2019/mar/28/big-tech-ai-ethics-boards-prejudice>, 2019.5.17. 접속.

연합인포맥스 (2019.4.2.), 「구글 직원들, 회사 AI 윤리 자문위 인선에 반발」,
<http://news.einformax.co.kr/news/articleView.html?idxno=4023754>

Bloomberg (2019.4.6.), “The Google AI Ethics Board with Actual Power is Still Around”,
<https://www.bloomberg.com/news/articles/2019-04-06/the-google-ai-ethics-board-with-actual-power-is-still-around>, 2019.5.17. 접속.

Business Insider (2017.7.12.), “Microsoft is Forming a Grand Army of Experts in the AI Wars with Google, Facebook, and Amazon”,
<https://www.businessinsider.com.au/microsoft-research-forms-new-ai-unit-2017-7>, 2019.5.17. 접속.

GeekWire (2018.4.9.), “Microsoft is Turing Down Some Sales Over AI Ethics, Top Researcher Eric Horvitz Says”,
<https://www.geekwire.com/2018/microsoft-cutting-off-sales-ai-ethics-top-researcher-eric-horvitz-says/>, 2019.5.17. 접속.

SAP (2018.9.18.), “SAP Becomes First European Tech Company to Create Ethics Advisory Panel for Artificial Intelligence”,
<https://news.sap.com/2018/09/sap-first-european-tech-company-ai-ethics-advisory-panel/>, 2019.5.17. 접속.

White House Executive Office of the President (2016. 5.), 「Big Data : A Report on Algorithmic Systems, Opportunity, and Civil Right」

Accenture (2018), 「Responsible AI : A Framework for Building Trust in Your AI Solutions」

Wall Street Journal (2019.3.20.), “U.S. Push for AI Supremacy Will Drive Demand for Accountability, Trust”,

<https://www.wsj.com/articles/u-s-push-for-ai-supremacy-will-drive-demand-for-accountability-trust-11553074200>, 2019.5.17. 접속.

Microsoft(2018), 「Human Rights Annual Report : Fiscal Year 2018」

Harvard Business Review (2018.11.28.), 「Why We Need to Audit Algorithms」

Wired (2018.5.9.), “Want to Prove Your Business Is Fair? Audit Your Algorithm”,
<https://www.wired.com/story/want-to-prove-your-business-is-fair-audit-your-algorithm/>, 2019.5.17. 접속.

BBC(2018.9.19.), “IBM Launches Tool Aimed at Detecting AI Bias”,
<https://www.bbc.com/news/technology-45561955>, 2019.5.17. 접속.

MIT Technology Review (2018. 5.25.), 「Microsoft is creating an oracle for catching biased AI algorithms」

Computerworld UK (2018.11.9.), “How Google Is Looking to Ensure AI Development is Ethical and Fair”,
<https://www.cw.com.hk/digital-transformation/how-google-looking-to-ensure-ai-development-ethical-and-fair>, 2019.5.17. 접속.

Google Blog(2018.10.18.), “A New Course to Teach People About Fairness in Machine Learning”,
<https://www.blog.google/technology/ai/new-course-teach-people-about-fairness-machine-learning/>, 2019.5.17. 접속.

Microsoft academy 홈페이지,
<https://academy.microsoft.com/en-us/professional-program/tracks/artificial-intelligence/>, 2019.5.19. 접속.

Google AI For Social Good 홈페이지, <https://ai.google/social-good>, 2019.5.19. 접속.

Intel AI For Social Good 홈페이지, <https://www.intel.ai/ai4socialgood/#gs.c7mh83>,
2019.5.19. 접속.

Data and Society Research Institute (2018), 「Governing Artificial Intelligence : Upholding Human Rights & Dignity」

Facebook Newsroom (2019.1.20.), “Facebook and the Technical University of Munich Announce New Independent TUM Institute for Ethics in AI”,
<https://newsroom.fb.com/news/2019/01/tum-institute-for-ethics-in-ai/>,
2019.5.17. 접속.

- Partnership on AI 홈페이지, <https://www.partnershiponai.org/>, 2019.5.19. 접속.
- Information Technology Industry Council(2017.10.24.), 「AI Policy Principle : Executive Summary」
- Information Technology Industry Council(2019.4.9.), "Global Tech Industry Welcomes EU Ethics Guidelines for AI", <https://www.itic.org/news-events/news-releases/global-tech-industry-welcomes-eu-ethics-guidelines-for-ai>, 2019.5.17. 접속.
- Wikipedia, "Information Technology Industry Council", https://en.wikipedia.org/wiki/Information_Technology_Industry_Council. 2020.1.11. 접속

3장 2절 학계 대응 동향

- 최병삼·홍성민 외(2018), 「과학기술기반 미래연구사업 X」, 과학기술정책연구원.
- Future of Life Institute 홈페이지, <https://futureoflife.org/ai-principles/>, 2019.5.4. 접속.
- 4차산업혁명위원회(2018.10.), 「4차산업혁명시대 산업별 인공지능 윤리의 이슈 분석 및 정책적 대응방안 연구」.
- Future of Life Institute 홈페이지, Beneficial AGI 2019, <https://futureoflife.org/beneficial-agi-2019/>
- CSER 홈페이지, <https://www.cser.ac.uk/>, 2019.5.4. 접속.
- Brundage et al.(2018), "The Malicious Use of Artificial Intelligence: Forecasting, Prevention, and Mitigation".
- 한국정보화진흥원(2018.8.3.), 「인공지능 악용에 따른 위협과 대응 방안」, 『NIA Special Report 2018-12』.
- Bloter(2017.9.20.), 「인공지능, '차별 레이더' 되지 않으려면」, <https://www.bloter.net/archives/290244>, 2019.5.4. 접속.
- Hofheinz, P.(2018), "The Ethics of Artificial Intelligence", The Lisbon Council.
- 로봇신문(2016.9.20.), 「영국표준연구소, 로봇윤리 가이드라인 발표」, <http://www.irobotnews.com/news/articleView.html?idxno=8685>, 2019.5.4. 접속.
- 일본 인공지능학회 윤리연구회 홈페이지, <http://ai-elsi.org/archives/471>, 2019.5.6. 접속.
- 일본 인공지능학회(2017.2.28.), 「인공지능학회 윤리지침(人工知能学会 倫理指針)」,

- https://www.nibp.kr:5002/xe/?module=file&act=procFileDownload&file_srl=81820&sid=32d3e58cbf008a2f981c2d1258388c67&module_srl=182, 2019.5.6. 접속.
- 연합뉴스(2017.3.1.), 「“인공지능(AI), 인간과 동등한 윤리지침 지켜라”...日 첫 제정」,
<https://www.yna.co.kr/view/AKR20170301051200073>, 2019.5.6. 접속.
- Berkman Klein Center 홈페이지, <https://cyber.harvard.edu/projects-tools>, 2019.5.4. 접속.
- Princeton University 홈페이지, <https://aiethics.princeton.edu/>, 2019.5.4. 접속.
- 이원태(2016), 「EU의 알고리즘 규제 이슈와 정책적 시사점」, 『KISDI Premium Report』,
정보통신정책연구원.
- NewsPeppermint(2016.7.4.), 「어떻게 인공지능으로 하여금 정의를 판단하게 만들 것인가」,
<https://newspeppermint.com/2016/07/03/m-sitl/>, 2019.5.17. 접속.
- Bengani, P.(2018.4.), "Controlling the Conversation: The Ethics of Social Platforms and Content Moderation", University of Southern California Annenberg.
- 로봇신문(2017.8.7.), 「AI 특이점, “로봇 투명성”과 ‘윤리적 블랙박스’로 대비」,
<http://www.irobotnews.com/news/articleView.html?idxno=11350>, 2019.5.4. 접속.
- The Science Monitor(2018.8.18.), 「[AI컨퍼런스②]폴 메이슨 ‘AI시대 탈자본주의’, 윈필드 교수
‘로봇윤리’ ‘로봇세’ 조명」, <https://bit.ly/2J1cjLg>, 2019.5.4. 접속.
- New York Times (2018.11.2.), “Colleges Grapple With Teaching the Technology and Ethics of AI”,
<https://www.nytimes.com/2018/11/02/education/learning/colleges-grapple-with-teaching-ai.html>, 2019.5.17. 접속.
- MIT AI Ethics Reading Group (2018.11.7.), “Building AI Ethics Education into Computer Science Classes”, <https://mitaiethics.github.io/2018/11/07/ethics-education/>,
2019.5.17. 접속.
- IEEE Educational Activities 홈페이지, https://innovationatwork.ieee.org/AI_Ethics/,
2019.5.19. 접속.

제4장 1절 주요국 대응 동향

- National Science and Technology Council on Committee on Technology(2016.10.), 「AI 미래를 위한 준비(Preparing for the future of artificial intelligence)」
- Executive Office of the President(2016.12.), 「AI, 자동화, 그리고 경제(Artificial Intelligence,

Automation and the Economy)」

National Science and Technology Council(2016. 10.), 「국가 AI R&D 전략계획(National Artificial Intelligence Research And Development Strategic Plan)」

미국 백악관 과학기술정책실 (2018. 5. 10), “Summary of the 2018 White House Summit on Artificial Intelligence for American Industry”

테크M(2018.12.8.), 「AI 판단, 다시 고려해 봐야 하는 이유...다양한 AI 편향성 논란」,
http://techm.kr/bbs/board.php?bo_table=article&wr_id=5403, 2019.6.19. 접속.

DARPA 홈페이지, <https://www.darpa.mil/work-with-us/ai-next-campaign>, 2019.6.19. 접속.

DARPA(2016), “Explainable Artificial Intelligence (XAI)”, David Gunning.

OpenAI 블로그(2017.02.), “Attacking Machine Learning with Adversarial Examples”.

Yuan, Xiaoyong, et al.(2019), “Adversarial examples: Attacks and defenses for deep learning.”, IEEE transactions on neural networks and learning systems

Eykholt, Kevin, et al.(2018), “Robust physical-world attacks on deep learning visual classification”, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition.

European Commission (2019. 4. 8.), “Ethics Guidelines For Trustworthy AI”.

한국정보화진흥원(2017.9.6.), 「AI 연구개발과 활용 촉진을 위한 AI 개발 가이드라인(안)(国際的な議論のためのAI開発ガイドライン案)」, 『NIA Special Report』.

일본 총무성 ‘AI네트워크 사회 추진회의(AI 네트워크社会推進会議)(2017.7.28.)」, 「국제적 논의를 위한 인공지능 연구개발 가이드라인(国際的な議論のためのAI開発ガイドライン案)」.

금융보안원(2018.2.7.), 「일본 총무성, AI 연구개발 가이드라인 주요 내용」, 금융보안원

일본 내각부(内閣府)(2019.3.29.), 「인간중심 AI 사회원칙(人間中心の AI 社会原則)」.

국무원(国务院) 홈페이지(2017.7.8.). 「国务院关于印发新一代人工智能发展规划的通知」.
http://www.gov.cn/zhengce/content/2017-07/20/content_5211996.htm, 2019.6.5. 접속.

北京智源人工智能研究院 홈페이지(1)(2019.5.25.), 「人工智能北京共识」.
<https://www.baai.ac.cn/blog/f4d28928ef4>, 2019.6.5. 접속.

北京智源人工智能研究院 홈페이지(2)(2019.5.25.),
 「『人工智能北京共识』发布, 智源研究院成立伦理与安全研究中心」.
<https://www.baai.ac.cn/blog/1127498a4d1>, 2019.6.5. 접속.

MIT Review(2019.5.31.). "Why does Beijing suddenly care about AI ethics?",
<https://www.technologyreview.com/s/613610/why-does-china-suddenly-care-about-ai-ethics-and-privacy/>, 2019.6.19. 접속.

OECD(2019.5) "Recommendation of the Council on Artificial Intelligence".

한국정보화진흥원(2019), 「신뢰 가능 AI 구현을 위한 정책 방향」.

Financial Times(2019.4.25.). "EU backs AI regulation while China and US favour technology",
<https://www.ft.com/content/4fd088a4-021b-11e9-bf0f-53b8511afd73>, 2019.6.19. 접속.

제4장 2절 국내 대응 동향

조원영(2019.4.), 「인공지능에 대한 사회적 우려와 업계의 대응」, 『월간SW중심사회 9월호』, 소프트웨어정책연구소.

카카오(2018.1), 「KAKAO AI Report」, vol 10.

박승택 외 5인(2017.3.), 「기계학습 기반의 뉴스 추천 서비스 구조와 그 효과에 대한 고찰: 카카오의 루빅스를 중심으로」, 사이버커뮤니케이션학보, 통권 제34권 1호

김대원(2018.1.), 「카카오 알고리즘 윤리 현장의 해제로봇윤리 규범화 본격 시동」, KAKAO AI Report, vol 10.

뉴시스(2019.1.14.), 「삼성전자의 미래 AI 서비스는... "다양한 기기들로 진정한 개인화 이룰 것"」,
http://www.newsis.com/view/?id=NISX20190114_0000529015, 2019.8.14. 접속.

삼성전자(2018.11.9.), 「삼성전자, 인공지능 국제협력단체 'PAI' 가입」,
<https://news.samsung.com/kr/삼성전자-인공지능-국제협력단체-pai-가입>, 2019.8.14. 접속.

한국경제(2018.2.5.), 「네이버 "검색 AI 조직 합친다」,
<https://www.hankyung.com/it/article/2018020574941>, 2019.8.14. 접속.

네이버 프라이버시센터 홈페이지, <https://privacy.naver.com/>, 2020.1.11. 접속.

김용대(2017.12.), 「인공지능과 개인정보에 관한 연구」, 김용대, NAVER Privacy White Paper

고학수·정해빈·박도현(2018.12.), 「인공지능과 차별」, NAVER Privacy White Paper

네이버(2018), 「네이버 개인정보보호 리포트」

한국경제(2019.7.15.), 「AI기반 의료영상 진단 '국내 1호'...부노, 치매·암 등 빠른 진단 지원」,

- <https://www.hankyung.com/economy/article/2019071538521>, 2019.8.14. 접속.
- 한국정보화진흥원(2019.4.5.), 「지속 가능한 인공지능(AI) 발전을 위한 OECD 논의 동향 <한-OECD AI 컨퍼런스 현장 보고서>」, Special Report
- 식품의약품안전처 보도자료(2018.5.16.), 「국내에서 개발한 인공지능(AI) 기반 의료기기 첫 허가」
- 한국산업기술진흥협회(2018.10.16.), 「의료 인공지능 개발 및 사업화 사례」, 『기술과혁신 10월호』
- 데일리그리드(2019.8.21), 「일상대화 AI 챗봇 심심이, 음성대화 무료체험 기간 운영」,
<http://www.dailygrid.net/news/articleView.html?idxno=270343>, 2019.8.14. 접속.
- 국민일보(2019.4.1.), 「미투=무고파티, 페미니즘=암... 여혐 쏟아내는 챗봇 ‘심심이」,
<http://news.kmib.co.kr/article/view.asp?arcid=0924070317>, 2019.8.14. 접속.
- TIME(2016.3.24.), “Microsoft Takes Chatbot Offline After It Starts Tweeting Racist Messages”,
<https://time.com/4270684/microsoft-tay-chatbot-racism/>, 2019.8.14. 접속.
- 한국인공지능협회 홈페이지, 「2019 인공지능 윤리+교육 포럼 공동선언문」,
<https://koraia.org/board/index.html?id=bizalim&no=28>, 2020.1.11. 접속.
- 고등과학원 초학제연구단(2018), 「인공지능: 과학, 역사, 철학」, 초학제 연구프로그램 워크숍 발표집
- 중앙대학교 인문컨텐츠연구소 홈페이지, <http://aihumanities.org/ko/>, 2020.1.11. 접속.
- 한국인공지능법학회 홈페이지, <http://kaail.or.kr/>, 2020.1.11. 접속.
- 한국인터넷윤리학회 홈페이지, <http://ksie.kr/>, 2020.1.11. 접속.
- 한국로봇산업진흥원(2019.1.4.), 「국내·외 인공지능, 로봇윤리 연구 동향 분석」, KIRIA ISSUE REPORT, 2018-4호
- 정보통신정책연구원 홈페이지, <http://www.kisdi.re.kr/kisdi/jsp/fp/kr/main.jsp>, 2020.1.11. 접속.
- 정보통신정책연구원(2019.3), 「4차 산업혁명시대 산업별 윤리의 이슈 분석 및 정책적 대응방안 연구」,
 한국인공지능법학회 세미나 발표자료
- 정필운·고인석(2017), 「인공지능윤리 가이드라인의 필요성과 제정 방향」, 인공지능 윤리 가이드라인,
 그 필요성과 내용 토론회 발표자료
- 김운명·정필운 외(2017), 『지능정보사회를 위한 법제도 조사연구』, 소프트웨어정책연구소
- 디지털타임스(2007.8.30.), 「로봇과 인간의 공생 ‘로봇윤리현장’ 나온다」,
http://www.dt.co.kr/contents.html?article_no=2007083002010332614001,
 2019.8.14. 접속.

로봇신문(2013.12.16.), 로봇 윤리 현장,

<http://www.irobotnews.com/news/articleView.html?idxno=1606>, 2019. 11. 12. 접속.

김윤명(2017.1.), 「제4차 산업혁명의 선구적 법률, ‘지능형로봇 개발 및 보급 촉진법’」,

『월간SW중심사회 1월호』, 소프트웨어정책연구소

국가법령정보센터, 「지능형 로봇 개발 및 보급 촉진법」, 법률 제13744호(2016.1.6.)

한국로봇산업진흥원(2019), 「로봇윤리 가이드라인(안)」.

한국정보화진흥원(2017.12.4.). 「AI, 윤리로 들여다 보기」

과학기술정보통신부(2018.6). 「지능정보사회 윤리 가이드라인」

방송통신위원회(2019.2.), 「통신 이용자보호 종합계획(‘19~’21)」

행정안전부(2017.3.), 「지능형 정부 기본계획」

행정안전부 보도자료(2019.2.7.), 「2019년 지능형 정부를 주도할 핵심기술 선정」

정원준(2018.1.31.), 「국내 인공지능(AI) 의료기기 현황 및 규제 이슈」, 『주간기술동향 1831호』,

정보통신기술진흥센터

제5장 1절 법제도 개선 방안

한국인공지능법학회(2019), 「인공지능과 법」, 박영사

ZDNet(2016.7.13.), 「자율 로봇, 어린이 공격 ‘황당 사건」, http://www.zdnet.co.kr/news/news_view.asp?article_id=20160713092842&lo=zv41, 2019.4.11. 접속

STARTUP TODAY(2018.9.20.), 「인공지능, 창작의 영역으로 들어오다」,

<http://www.startuptoday.kr/news/articleView.html?idxno=10970>, 2020.1.11. 접속

한희원(2018), 「인공지능(AI) 법과 공존윤리」, (주)박영사.

한겨레(2018.11.5.). 「인공지능 오류에 대한 대비는 완벽한가」,

<http://www.hani.co.kr/arti/opinion/because/868930.html#csidxc826539cb928cdfa96b962ad7ed9d5f>, 2020.1.11. 접속

이한영·차성민(2017), 「인공지능과 제조물 책임」, Asia-Pacific Journal of Multimedia Services Convergent with Art, Humanities, and Sociology, Vol.7, No.3, pp. 321-328

법률신문(2019.8.12.). 「자율운행선박 상용화를 위한 해상법적 쟁점」,

<https://m.lawtimes.co.kr/Content/Info?serial=155023>, 2020.1.11. 접속

한국경제(2019.10.15.). 「자율주행차 사고시 법적 책임은 누가?...AI알고리즘 설명할 수 있어야」,

- <https://www.hankyung.com/it/article/201910156351g>, 2020.1.11. 접속
- 이상용(2016), 「인공지능과 계약법 - 인공지능에이전트에 의한 계약 체결과 사적자치의 원칙」, 『비교사법』, 제23권 제4호
- NIST 홈페이지,
<https://csrc.nist.gov/publications/detail/sp/800-160/archive/2016-11-14>, 2019.11.14. 접속
- EUR-Lex 홈페이지,
<https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=COM:2017:9:FIN>, 2020.1.11. 접속
- 임건면(2005), 「개인정보의 의의와 귀속관계」, 『중앙법학』, 제7집 제4호
- 송오식(2016), 「개인정보침해에 대한 합리적 구제방안」, 『법학논총』, 제36권 제1호, 전남대학교 법학연구소
- 이상용(2018), 「데이터 거래의 법적 기초」, 『법조』, 제67권 제2호, 법조협회
- OECD(2017), "Algorithms and collusion: Competition policy in the digital age"
- 최경진(2013), 「빅데이터와 개인정보」, 『성균관법학』, 제25권 제2호
- Goodman, B. and Flaxman, S. (2017), "European Union regulations on algorithmic decision-making and a right to explanation," AI Magazine vol.38 no.3
- 박상돈(2017), 「헌법상 자동의사결정 알고리즘 설명요구권에 관한 개괄적 고찰」, 『헌법학연구』, 제23호
- NCLS 홈페이지, <http://www.ncsl.org/research/transportation/ncsl-p3-update.aspx>. 2019. 9. 29. 접속
- 국회입법조사처(2017), 「자율주행자동차 관련 국내외 입법·정책 동향과 과제」
- 황창근이중기(2018), 「자율주행자동차 운행을 위한 자동차관리법의 개정 방향」, 『중앙법학』, 제20집 제2호
- NHTSA(2017), "Federal Automated Vehicles Policy"
- 조용혁·장원규(2017), 「자율주행자동차 상용화에 따른 자동차관리법 개선방안」, 한국법제연구원
- Daily News(2018.11.30.), "Drunk driver caught sleeping behind wheel of Tesla sedan driving 70 mph on freeway, California cops allege",
<https://www.nydailynews.com/news/ny-news-california-man-arrested-dui-autopilot-tesla-20181130-story.html>, 2020.1.11. 접속
- 강경표(2016), 「자율주행시스템과 스마트 도로인프라기술의 진화」, 『한국도로학회지』, 제18권 제3호

- 홍익대 산학협력단(2017), 「자율주행자동차의 개인정보 보호체계 및 규제방식에 관한 연구」, 『연구보고서』, 개인정보보호위원회
- 오병철(2017), 「인공지능 로봇에 의한 손해의 불법행위책임」, 『법학연구』, 제27권 제4호, 연세대학교 법학연구원
- 권영준·이소은(2016), 「자율주행자동차 사고와 민사책임」, 『민사법학』, 제75권
- Kyle Graham(2012), "Of Frightened Horses and Autonomous Vehicles: Tort Law and its Assimilation of Innovations", 52 Santa Clara L. Rev. 1241.
- 김진우(2018), 「자율주행에서의 제조물책임에 관한 몇 가지 법률문제」, 『소비자문제연구』, 제49권 제2호
- 류창호(2016), 「자율주행자동차에 대한 제조물책임의 적용에 관한 연구」, 『아주법학』, 제10권 제1호
- 박해선(2016), 「스마트사회와 민사책임」, 『법학논총』, 제23집 제2호, 조선대학교

5장 2절 결론 및 시사점

- NeurIPS 홈페이지, <https://neurips.cc/Conferences/2019/Schedule?type=Poster>, 2020.1.11. 접속
- ICML 홈페이지, <https://icml.cc/Conferences/2019/Schedule?type=Poster>, 2020.1.11. 접속
- CVPR 홈페이지, <http://cvpr2019.thecvf.com/>, 2020.1.11. 접속
- European Commission (2019. 4. 8.), 「Ethics Guidelines For Trustworthy AI」.
- 과학기술정보통신부(2018.6). 「지능정보사회 윤리 가이드라인」.
- 소프트웨어정책연구소(2018), 「인공지능 연구역량 국제비교 및 시사점」, 소프트웨어정책연구소
- 관계부처 합동(2019.9.21.). 「혁신성장 확산·가속화 전략」
- 이규엽·강민지(2019), 「디지털 무역규범의 국제 논의 동향: WTO 전자상거래 협상과 미 개인정보보호법 입법안을 중심으로」, 『오늘의 세계경제』, 대외경제정책연구원
- 법률신문(2018.12.7.). 「「개인정보 보호법」, 「정보통신망의 이용촉진 및 정보보호 등에 관한 법률」 및 「신용정보의 이용 및 보호에 관한 법률」 개정 법률안들 발의」, <https://m.lawtimes.co.kr/Content/LawFirm-NewsLetter?serial=149066>, 2019.12.19. 접속
- Meltzer, J. P. (2019.5.), "Artificial intelligence primer: What is needed to maximize AI's economic, social and trade opportunities", Global Economy and Development at Brookings

부 록

안전하고 윤리적인 인공지능 R&D와 활용을 위한 법제도 개선방안 전문가 설문

안녕하십니까? 과학기술정책연구원은 올해 ‘인공지능 기술 전망과 혁신정책 방향(2차 년도)’이라는 과제를 진행하고 있습니다. 관련하여, “안전하고 윤리적인 인공지능 R&D와 활용을 위한 법제도 개선방안”에 대한 전문가들의 의견을 청취하고자 합니다.

설문 문항은 인공지능 R&D와 활용을 위한 법제도 개선방안을 시급성, 파급성, 용이성으로 평가하는 것입니다.

구분	평가표준	내용
시급성	우선성	다른 법제도 대비 우선 개선이 필요한가?
	국내외 수준 차이	주요국에 비해 법제도 개선이 뒤처지고 있는가?
파급성	경제성	법제도 개선시, 국내외 시장 성장 및 이로 인한 경제적 파급효과(GDP, 투자, 고용 등)가 기대되는가?
	안전성	법제도 개선시, 사회적 위험이 개선될 수 있는가? ※ 오류, 오작동에 의한 사건, 사고 등
용이성	비용/절차	기존 제도의 미세 조정으로 해결 가능한가? ※ 시행령, 시행규칙 개정 등
	민감도	신규생태계와 기존 산업 간의 갈등이 많은가?

- 빠진 문항없이 모두 답변해주시기 바랍니다.
- 시급성, 파급성, 용이성 등 3항목으로 구성되어 있으며, 7점 척도 기준입니다.
(7점: 매우 높음, 1점: 매우 낮음)

1. 인공지능 법제도 개선 시급성

1.1 우선성

관련 법제도	안전/윤리 관련 주요 이슈	시급성 정도						
민법(계약법, 불법행위법 등)	인공지능과의 계약 후 문제 발생 또는 불법행위의 책임 소재 불분명	1	2	3	4	5	6	7
지식재산권법	인공지능이 창작한 저작물은 보호 범위 불분명	1	2	3	4	5	6	7
형법	범죄를 저지른 인공지능이 형벌 기준모호	1	2	3	4	5	6	7
정보보호법	개인정보보호와 정보 활용의 충돌	1	2	3	4	5	6	7
공정거래법	알고리즘 담합, 가격 차별 등 인공지능 관련 불공정거래 행위 확산	1	2	3	4	5	6	7
도로교통법	자율주행 운행사 운전자 규제, 면허, 교통규칙 미정립	1	2	3	4	5	6	7
제조물책임법	S/W 성격을 가진 인공지능에 오류 발생 시 제조물책임법 적용 모호	1	2	3	4	5	6	7

1.2 국내외 수준차이

관련 법제도	안전/윤리 관련 주요 이슈	시급성 정도						
민법(계약법, 불법행위법 등)	인공지능과의 계약 후 문제 발생 또는 불법행위의 책임 소재 불분명	1	2	3	4	5	6	7
지식재산권법	인공지능이 창작한 저작물은 보호 범위 불분명	1	2	3	4	5	6	7
형법	범죄를 저지른 인공지능이 형벌 기준모호	1	2	3	4	5	6	7
정보보호법	개인정보보호와 정보 활용의 충돌	1	2	3	4	5	6	7
공정거래법	알고리즘 담합, 가격 차별 등 인공지능 관련 불공정거래 행위 확산	1	2	3	4	5	6	7
도로교통법	자율주행 운행사 운전자 규제, 면허, 교통규칙 미정립	1	2	3	4	5	6	7
제조물책임법	S/W 성격을 가진 인공지능에 오류 발생 시 제조물책임법 적용 모호	1	2	3	4	5	6	7

2. 인공지능 법제도 개선 파급성

2.1 경제성

관련 법제도	안전/윤리 관련 주요 이슈	파급성 정도						
민법(계약법, 불법행위법 등)	인공지능과의 계약 후 문제 발생 또는 불법행위의 책임 소재 불분명	1	2	3	4	5	6	7
지식재산권법	인공지능이 창작한 저작물은 보호 범위 불분명	1	2	3	4	5	6	7
형법	범죄를 저지른 인공지능이 형벌 기준모호	1	2	3	4	5	6	7
정보보호법	개인정보보호와 정보 활용의 충돌	1	2	3	4	5	6	7
공정거래법	알고리즘 담합, 가격 차별 등 인공지능 관련 불공정거래 행위 확산	1	2	3	4	5	6	7
도로교통법	자율주행 운행시 운전자 규제, 면허, 교통규칙 미정립	1	2	3	4	5	6	7
제조물책임법	S/W 성격을 가진 인공지능에 오류 발생 시 제조물책임법 적용 모호	1	2	3	4	5	6	7

2.2 안전성

관련 법제도	안전/윤리 관련 주요 이슈	파급성 정도						
민법(계약법, 불법행위법 등)	인공지능과의 계약 후 문제 발생 또는 불법행위의 책임 소재 불분명	1	2	3	4	5	6	7
지식재산권법	인공지능이 창작한 저작물은 보호 범위 불분명	1	2	3	4	5	6	7
형법	범죄를 저지른 인공지능이 형벌 기준모호	1	2	3	4	5	6	7
정보보호법	개인정보보호와 정보 활용의 충돌	1	2	3	4	5	6	7
공정거래법	알고리즘 담합, 가격 차별 등 인공지능 관련 불공정거래 행위 확산	1	2	3	4	5	6	7
도로교통법	자율주행 운행시 운전자 규제, 면허, 교통규칙 미정립	1	2	3	4	5	6	7
제조물책임법	S/W 성격을 가진 인공지능에 오류 발생 시 제조물책임법 적용 모호	1	2	3	4	5	6	7

3. 인공지능 법제도 개선 용이성

3.1 비용/절차

관련 법제도	안전/윤리 관련 주요 이슈	용이성 정도						
민법(계약법, 불법행위법 등)	인공지능과의 계약 후 문제 발생 또는 불법행위의 책임 소재 불분명	1	2	3	4	5	6	7
지식재산권법	인공지능이 창작한 저작물은 보호 범위 불분명	1	2	3	4	5	6	7
형법	범죄를 저지른 인공지능이 형벌 기준모호	1	2	3	4	5	6	7
정보보호법	개인정보보호와 정보 활용의 충돌	1	2	3	4	5	6	7
공정거래법	알고리즘 담합, 가격 차별 등 인공지능 관련 불공정거래 행위 확산	1	2	3	4	5	6	7
도로교통법	자율주행 운행시 운전자 규제, 면허, 교통규칙 미정립	1	2	3	4	5	6	7
제조물책임법	S/W 성격을 가진 인공지능에 오류 발생 시 제조물책임법 적용 모호	1	2	3	4	5	6	7

3.2 민감도

관련 법제도	안전/윤리 관련 주요 이슈	용이성 정도						
민법(계약법, 불법행위법 등)	인공지능과의 계약 후 문제 발생 또는 불법행위의 책임 소재 불분명	1	2	3	4	5	6	7
지식재산권법	인공지능이 창작한 저작물은 보호 범위 불분명	1	2	3	4	5	6	7
형법	범죄를 저지른 인공지능이 형벌 기준모호	1	2	3	4	5	6	7
정보보호법	개인정보보호와 정보 활용의 충돌	1	2	3	4	5	6	7
공정거래법	알고리즘 담합, 가격 차별 등 인공지능 관련 불공정거래 행위 확산	1	2	3	4	5	6	7
도로교통법	자율주행 운행시 운전자 규제, 면허, 교통규칙 미정립	1	2	3	4	5	6	7
제조물책임법	S/W 성격을 가진 인공지능에 오류 발생 시 제조물책임법 적용 모호	1	2	3	4	5	6	7

설문에 응해주셔서 감사합니다.

Summary

A Prospective Analysis of Artificial Intelligence(AI) Technology and Innovation Policies: Focused on Improving a System for Safe and Ethical AI R&D and Utilization

- **Project Leader: Jei Young Lee**
- **Participants: Danbi Kim · Heetae Yang**

As artificial intelligence(AI) is undergoing a renaissance in the 2010s, competitions among countries is intensifying beyond companies, and issues related to safety and ethics are also emerging in earnest. One of the major issues regarding safety is the damage caused by malfunctions occurring during the test or use of AI-based self-driving cars, robo-advisors, robots and intelligent personal assistant devices. There has been a lot of concern and criticism in ethical terms about using AI for military purposes and developing autonomous weapons of destruction. This study started with the notion that securing the safety of AI and solving ethical issues are prerequisites for sustainable AI R&D and market revitalization. Thus, our research aims to examine safety and ethical issues of AI in advance and present effective countermeasures so that AI can continue the current pace of technological development and be commercialized as expected to provide a breakthrough in human life.

In this study, AI safety is defined as "concepts and areas to prepare for unintended risks that may arise due to the technical and structural limitations and characteristics of AI". Unlike social consensus, guidelines and regulatory-oriented AI ethics, AI safety is therefore at the core of the discussion for R&D to overcome technological limitations of AI. We also defines the scope of AI ethics as "universal social norms and related technologies that AI-related stakeholders should comply with". The main difference of AI ethics from the AI safety is

whether it is "intentional" or not. In other words, the abuse of AI by developers with bad intentions, or by the seller of related products and services, goes against the value of AI ethics. Thus, social confusion caused by unethical AI can be prevented through stakeholder agreements, guidelines and legislative regulations.

By hiring AI ethics experts, global major companies want to actively address security issues such as personal information protection and privacy as well as social problems that can arise in the course of technology development. Besides companies, non-profit organizations such as academia are also taking the lead in developing a wide range of guidelines for the future AI era. In particular, theoretical discussions are underway to secure safety in the technology development stage by proposing a sociological background for improving transparency and reliability of algorithms. The major AI developed countries are also striving to establish a foundation for developing and utilizing reliable AI in preparation for the rapid spread of AI across society in the future. Governments are encouraging AI to be developed in accordance with ethics and social principles by presenting guidelines.

In this trend, Korea also needs to improve the current status of relevant legal systems and concrete efforts to prepare regulatory policies to solve the safety and ethical issues of AI. In particular, the seven individual laws (i.e., civil law, intellectual property law, criminal law, information protection law, fair trade law, road traffic law and product liability law) that cover major AI issues need to be improved to promote AI R&D and technology. In addition, overhauling data-related laws including privacy protection and improving digital ethics guidelines for data protection need to be considered to activate data-based AI ecosystem in the near future.

Contents

Summary	i
Chapter 1. Introduction: Objectives of the Study	1
1. Background of the Study	1
2. Objectives of the Study and Research Framework	4
Chapter 2. Concepts of AI Safety and Ethics	6
1. AI Safety	6
2. AI Ethics	12
3. Conceptual Scope of AI Safety and Ethics	19
Chapter 3. Companies and Academic Research Trends	20
1. Responding Trends of Global Companies	21
2. Responding Trends of Academic and Research Institutions	36
2. Implications	47
Chapter 4. Responding Trends of Governments in Major Countries	50
1. Responding Trends of Governments in Major Countries	50
2. Responding Trends of Domestic Companies, Government and Academia	90
3. Comprehensive Review	122
Chapter 5. Policy Suggestions	124
1. Measures to Improve the Legal System	124
2. Conclusions and Implications	161
References	171

Appendix 185

Summary 189

Contents 191