

2018 STEPI Fellowship

인공지능 알고리즘과 차별

A.I. Algorithm and Discrimination

홍성욱

연 구 진

연구책임자

홍성욱 (Sungook Hong)¹⁾ | 서울대학교 교수

1) comenius@snu.ac.kr

| 목 차 |

요 약	i
1. 문제제기	1
2. 인공지능 알고리즘, 빅데이터의 속성과 공정성 문제	5
3. 사법 영역에서의 알고리즘 공정성 논쟁: 컴파스(COMPAS) 알고리즘은 흑백을 차별하는가?	16
4. 치안 영역에서의 알고리즘 차별: 예측적 치안유지는 편향적인가?	23
5. 알고리즘 공정성 문제에 대한 접근 방안	31
6. 한국의 인공지능 알고리즘의 공정성 문제	37
참고문헌	43

| 표 목 차 |

〈표 1〉 백인에 비해 흑인에게 불리하게 분류된 위험점수	17
〈표 2〉 백인과 흑인의 위험점수의 유불리가 뚜렷하게 구별되지 않는 경우	18
〈표 3〉 통계적 공정성을 가리는 방식들	20

| 그 림 목 차 |

[그림 1] “인공지능”에 대한 구글 트렌드의 검색 결과	37
---------------------------------------	----

| 요 약 |

빅데이터에 근거하여 자동적인 의사결정을 내리는 알고리즘이 사회의 각종 영역에서 점차 널리 사용되고 있는 저변에는 알고리즘의 의사결정이 사회의 자원을 보다 효율적으로 분배하리라는 기대뿐만 아니라 그 결정이 인간의 선입견, 편향, 자의적 판단 등이 개입된 의사결정보다 더 공정한 결과를 낳으리라는 희망 또한 자리 잡고 있다. 하지만 알고리즘 의사결정이 그 결정에 의해 영향 받는 이들을 공정하게 다루지 않는다는 사례들이 거듭 나타나면서, 의사결정이 어떻게 절차화 되었는지, 또한 특정한 의사결정을 공정하다고 판단하는 데에 어떤 요인이 고려되는지에 대한 근본적인 질문들이 새롭게 제기되고 있다. 본 연구는 주로 사법, 치안의 영역에서 활용되는 알고리즘과 관련해서 차별의 문제가 제기되는 상황을 구체적으로 분석한 연구들을 검토함으로써, 인공지능 알고리즘이 과연 특정 집단의 인간을 차별하는지, 그리고 공정한 의사결정을 분별하는 기준은 무엇인지 살펴보고자 한다. 본격적인 검토에 앞서 데이터 마이닝 각 단계에서 의도적으로 그리고 비의도적으로 편향적인 결과가 산출될 수 있는 원인에는 무엇이 있는지를 살필 것이다. 결론에서는 이러한 이론적이고 실질적인 검토가 현대 한국 사회에 시사하는 바가 무엇인지 간추려 제시할 것이다.

주제어: 인공지능, 알고리즘, 빅데이터, 차별, 컴퍼스 알고리즘, 프레드폴 알고리즘, 국경 통제 알고리즘

1. 문제제기

2017년 12월, 미국 뉴욕시의 시의원 제임스 바카(James Vacca)와 동료들은 소위 “알고리즘의 설명책임 법안”(algorithmic accountability bill)²⁾이라고 불리는 법안을 발의했다(Kirchner, 2017). 이 법안은 시에서 구성한 특별위원회가 뉴욕시에서 사용되는 알고리즘(algorithm)³⁾이 뉴욕 시민의 삶에 어떤 영향을 미치는지, 그리고 이런 알고리즘이 연령, 인종, 종교, 성별, 성적 지향, 시민권의 여부에 따라서 시민들을 차별하는지를 조사하는 것을 의무화했다. 법안을 발의한 바카는 이 법안의 목표가 알고리즘의 “투명성(transparency)과 설명책임(accountability)”을 확립하는 데에 있다고 강조했다.⁴⁾ 뉴욕시는 치안이나 사법 같은 영역만이 아니라, 금융, 행정, 교육, 채용과 같은 영역에서도 인공지능 알고리즘을 광범위하게 사용해 왔는데, 올해 1월부터 시행된 이 법안에 따라서 뉴욕시는 5월에 공무원, 학계, 법조계, 과학기술계의 전문가로 구성된 태스크포스를 발족시켰다. 이들은 뉴욕시가 학교 배정, 치안, 사회보장제도 등에 사용하는 알고리즘에서 차별적인 요소는 있는지를 검토해서 2019년 말에 보고서를 발간하는 계획을 확정하고 활동에 들어갔다. 다른 도시나 자치단체에서는 뉴욕시의 이 법안을 예의 주시하면서 비슷한 법안을 만들어야 하는지를 논의하고 있는 중이다.⁵⁾

2) 법안의 정식 타이틀은 “기관에 의해 사용되는 자동화된 결정 시스템과 관련된 지역 법안”(NYC Local Law No. 49 of 2018). 이 법안과 법안을 논의하는 과정의 기록은 <https://legistar.council.nyc.gov/LegislationDetail.aspx?ID=3137815&GUID=437A6A6D-62E1-47E2-9C42-461253F9C6D0>에서 볼 수 있다.

3) 이 연구에서 필자는 알고리즘을 “특화된 계산에 근거해서 인풋 데이터를 바라는 아웃풋으로 변환시키는 코드화된 절차”로 정의한 Gillespie(2014, p. 167)의 규정을 따른다. 여기서 보듯이 데이터와 알고리즘은 뗄 수 없는 관계이다(Constantiou and Kallinikos, 2015). 현대사회에서 알고리즘은 우리가 일상적으로 세상을 접하고, 경험하고, 물화시키며, 우리에게 편견을 강화하거나 선택지를 제한하는 방식으로 작동한다(Wilson, 2017).

4) 알고리즘의 투명성은 말 그대로 사람이 이를 들여다 볼 수 있다는 것을 의미하며, 설명책임은 그 알고리즘에 문제가 있을 때 이를 만든 사람이 문제의 원인을 설명할 책임을 진다는 것을 의미한다. 개인이 기업에게 알고리즘의 공개를 요구할 때 기업은 자신의 지적 재산권을 주장하면서 이를 공개하지 않을 수 있기 때문에, 투명성을 보장하는 방법으로 제 3의 감독기관에 의한 조사 방법을 주로 사용한다. 달리 말해 설명책임은 알고리즘의 개발자가 그 작동에 대해서 설명할 의무를 포함해서 윤리적이고 책임성있는 방식으로 이를 개발하고, 그 결과에 책임을 지는 것을 의미한다 (SearchEnterpriseAI, 2015; SearchEnterpriseAI, 2017).

5) 태스크 포스 발족과 활동에 대해서는 Sidney Fussell, “NYC Launches Task Force to Study How Government Algorithms Impact Your Life,” *Gizmodo* (2018. 5. 16) at

법안이 명시한 알고리즘은 “자동화된 결정 시스템”(automated decision system)이다. 이것은 “결정을 내리거나 도움을 주는 데 사용되는 머신러닝(machine learning), 데이터 프로세싱(data processing), 혹은 인공지능(artificial intelligence)의 기술에서 유래된 알고리즘을 포함하는 알고리즘들의 컴퓨터화된 구현”으로 정의된다.⁶⁾ 인공지능을 인간을 대신하여 자동적으로 결정을 내리거나, 혹은 인간의 결정을 도와주는 알고리즘으로 잠정적으로 정의한다면, 뉴욕시의 법안은 인공지능 알고리즘을 투명하고 설명책임 있는 것으로 만들기 위한 법안이라고 볼 수 있다. 투명성과 설명책임은 기업의 거버넌스를 지탱하는 가장 중요한 원칙으로 간주되는 것인데,⁷⁾ 이것이 기업 활동을 넘어서 개별 기술분야, 특히 인공지능 알고리즘의 영역에도 그대로 도입된 것이다.

사람들은 인공지능이 퀴즈쇼나 바둑의 세계 챔피언을 이길 정도로 고도로 발전했다는 것만 생각하고 있었는데, 인공지능의 차별이라는 문제가 사회적인 문제로 제기된 것이었다. 2017년에 MIT에서 열린 인공지능학회에서는 인공지능의 편향성에 대한 논의가 이루어지지 않는다는 질타가 등장했고⁸⁾, 비슷한 시기에 구글의 인공지능 총책임자인 존 기아난드리아(John Giannandrea)는 MIT Technology Review와의 인터뷰에서 인공지능의 편향성을 우려했다. 이 인터뷰가 실린 기사의 제목은 “킬러 로봇은 잊어버려라. 편견이 AI의 진짜 위협이다”는 제목이 달렸다(Knight, 2017). 2017년이 되면 점점 더 많은 사람들이 AI의 편향성의 문제, 그리고 이런 편향성이 낳을 수 있는 차별의 문제에 주목하게 되었다. 그 하나의 결과가 2017년 12월에 뉴욕시에서 입안된 법안이었다.

본 연구는 인공지능 알고리즘이 불러일으킨 공정성과 차별에 관한 논란을 소개하면

<https://gizmodo.com/nyc-launches-task-force-to-study-how-government-algorit-1826087643> 참조.

6) 각주 1번의 법안 참조.

7) 기업 거버넌스에서 투명성에 대한 관심이 높아지게 된 계기는 2002년 Enron의 도산한 이후 WorldCom, Typo, Qwest, 회계법인 Arthur Anderson 등의 미국 대기업들이 회계부정사건에 휘말리면서 기업에 대한 신뢰 저하와 추가 하락으로 이어진 데에서 찾을 수 있다. 안중호, 양지윤(2006: 100) 참조.

8)

<https://www.technologyreview.com/s/608248/biased-algorithms-are-everywhere-and-no-one-seems-to-care/>

서 이를 학술적으로 분석하는 데 목적이 있다. 보다 효율적인 논의를 위해 본 연구에서 다룰 “인공지능 알고리즘”은 사회 현상으로부터 수집된 빅데이터 바탕의 예측 모델에 기반한 알고리즘 및 소프트웨어를 부르는 것에 한정할 것이다. 분석을 위해 본 연구는 과학기술학(STS)에서 많이 사용되는 논쟁연구의 방법론을 사용해서 상반되는 주장을 공평하고 대칭적으로 분석한 뒤에, 이런 논쟁을 통해 서로 다른 주장들 중에 어떤 입장이 더 설득력이 있는지, 그리고 정책적인 대안이 어떻게 제시되는지를 보여줄 것이다.⁹⁾ 더불어 사회기술적 현장에서 기술이 개발되고 사용되는 맥락에 대한 컴퓨터 과학자들과 문화/비판 연구자들의 연구도 함께 검토할 것이다.

본 연구의 2절은 인공지능 알고리즘에 사용되는 데이터, 특히 빅데이터의 속성과 이런 데이터가 편파적으로 사용될 가능성을 논할 것이다. 이를 바탕으로 이어지는 두 개의 절에서는 사법, 치안의 영역에서 알고리즘 차별 문제를 구체적으로 분석한다. 각 영역들은 국가 권력의 동작 기제에 어떻게 인공지능 기술이 접목되고 있는지를 세부적으로 드러내어 보여주는 동시에 인공지능 기술이 어떻게 개인과 시공간을 추적과 예측의 대상으로 변환하는지를 보여줄 수 있을 것이다. 구체적으로 3절은 사법의 영역에서 사용되는 알고리즘이 개개인을 평가할 때 인종이나 빈부에 따라서 개인을 차별하는가의 문제를 다룰 것인데, 최근에 크게 논란이 되었던 노스포인트(Northpointe) 사의 위험 판정 알고리즘 컴파스(COMPAS)를 주로 분석할 것이다. 4절은 미국의 여러 도시에서 경찰이 치안 영역에서 사용하는 프레드폴(PredPol) 같은 알고리즘이 범죄가 일어나는 시간이나 공간을 예측할 때 역시 인종과 빈부를 차별하는가의 문제를 다룰 것이다. 이런 사례를 분석한 뒤에 5절은 알고리즘의 공정성 문제를 해결할 수 있는 몇 가지 가능성을 짚어볼 것이다. 6절에서는 이런 논의가 우리 사회에 가지는 함의를 모색하면서 알고리즘을 통한 차별이라는 주제와 관련된 한국 사회의 현황을 분석하고 가까운 미래에 우리가 직면할 문제와 해법의 가능성을 가늠해 볼 것이다. 다만 한국사회의 경우, 아직 사법이나 치안의 영역에서 법원이나 정부기관에 의한 인공지능 알고리즘의 사용이 미국처럼 활발하지 않다. 많은 기관들이 ‘4차 산업혁명’의

9) 다만 여러 논쟁이 지금(2018년 10월)도 진행 중인 경우가 많아서 논쟁이 어떻게 종결되는지를 보이는 것은 본 연구의 범위를 넘어선다. 이는 추후의 연구 주제가 될 것이다.

4 인공지능 알고리즘과 차별

일환으로 이런 인공지능 알고리즘을 도입하기 위해 연구 프로젝트를 진행중이거나 알고리즘을 개발하는 중이다. 따라서 본 연구는 미국의 사례를 깊게 분석해서 이를 바탕으로 가까운 미래에 닥칠 수 있는 국내 상황에 대한 좌표의 역할은 하는 것에 만족할 수밖에 없다. 국내에서 사용되는 인공지능 알고리즘의 차별 가능성에 대한 분석은 1-2년 후의 후속 연구에서 진행될 수 있을 것이다.

2. 인공지능 알고리즘, 빅데이터의 속성과 공정성 문제

인공지능을 지능정보 기술과 관련된 넓은 의미의 과학기술 영역을 포괄한다. 인공지능을 분류하는 데에는 여러 방법이 있는데, 철학자 존 쉘(John Searle)은 인공지능을 강한 인공지능(Strong AI)과 약한 인공지능(Weak AI)로 분류한다. 강한 인공지능은 인간처럼 생각하고 판단하는 수준의 인공지능이며, 약한 인공지능은 인간에 의해서 프로그램 된 대로 사고하면서 인간을 보조하는 수준의 인공지능을 의미한다(Searle, 1980). 쉘이 이렇게 인공지능을 분류한 것은 당시 인공지능 연구자들이 마치 인공지능이 인간처럼 의식을 가진 존재라고 얘기하는 것을 논박하기 위한 것이었다. 중국어를 모르면서 영어를 중국어로 번역해주는 사람이 존재할 수 있듯이, 자기가 뭘 하는지 모르면서 마치 지능을 가진 존재처럼 활동하는 인공지능이 얼마든지 가능하다는 것이었다. 이런 인공지능은 모두 약한 인공지능이었다. 쉘은 강한 인공지능이 불가능하다고 주장했다.

반면에 인공지능 연구자들은 다른 분류 기준을 사용하기도 한다. 최근에 미국의 인공지능 연구자 아렌드 힌체(Arend Hintze)는 인공지능을 1) 미래를 예측해서 판단을 내리는 Reactive Machine AI 유형, 2) 과거의 경험을 잠깐 저장해서 판단을 내리는 Limited Memory AI 유형, 3) 타인의 마음의 상태를 알아내서 상호작용할 수 있는 “Theory of Mind” AI 유형, 4) 자신이 무엇을 하는지를 아는 “자기인식” AI 유형으로 나누었다(Hintze, 2016). 체스를 두는 딥블루(Deep Blue)나 알파고 같은 인공지능이 1)의 유형이고, 자율주행 자동차가 2)의 유형, 아직 충분치는 않지만 최근에 개발되는 다양한 사회적 로봇(Social Robots)이 3)의 유형이다. 4)는 아직도 가까운 미래에 개발되지는 않을 것으로 예측된다. 본 연구에서 다루는 인공지능은 거의 대부분 약한 인공지능이며, 힌체의 분류에 의하면 1)부터 3)까지의 인공지능에 국한될 것이다. 최근 인간의 지능을 훨씬 뛰어넘어 인간보다 1,000배 똑똑하거나, 심지어 I.Q. 6,000인 초지능(Superintelligence)에 대한 논의가 철학자와 인공지능 연구자 일각에서 이루어지고 있다(보스트롬 2017). 그렇지만 킬러 로봇과 마찬가지로 초지능에 대한 우려는 과장된 부분이 있고, 또 지금 당장 우리에게 시급한 문제도 아니다.¹⁰⁾

여기에서 간단히 지난 10여년 간의 인공지능의 역사를 간단히 살펴볼 필요가 있다. 잘 알려져 있듯이 2000년대 이후에 기존의 신경망 네트워크(neural network), 머신러닝 등의 성능을 획기적으로 개선한 딥러닝(deep learning) 등의 방법이 인공지능 분야에 도입되면서, 인공지능의 효율성과 정확성은 놀라울 정도로 높아졌고, 응용되는 영역도 넓어졌다. IBM의 인공지능 왓슨은 2011년 2월에 퀴즈 프로그램 <Jeopardy!>의 챔피언을 이긴 뒤에 암 진단과 금융 상품의 선택에 응용되기 시작했다. 우리나라의 길병원도 IBM의 왓슨을 도입해서 암 진단을 하는 것으로 화제를 불러 모았다.¹¹⁾ 2016년 3월에 구글 답마인드의 알파고는 이세돌 국수에 승리를 거뒀다. 구글에서 만든 자율주행자동차는 2012년 5월에 미국 네바다주에서 최초로 운전면허를 획득했다. 지난 2-3년 동안에 법률 분야에 도입된 인공지능은 한 사안에 대해서 여러 복잡한 법안들을 뒤져서 자료를 만드는 일을 초급 변호사보다 더 잘 수행하기 시작했고, 인공지능에 의한 구글이나 네이버의 번역 서비스도 과거에 비하면 월등히 개선되었으며, 얼굴 인식과 사물 인식 분야에서 인공지능은 거의 사람이 수준에 도달했다. 그 사이에 인공지능의 응용 분야는 더 확대되어 인공지능 알고리즘은 기존의 의료, 법률, 금융 등의 분야에서 만이 아니라, 채용, 치안, 사법, 교육, 공공행정, 감사, 국경 관리, 이민 및 난민 관리 등의 분야에서도 인간의 판단을 보조하거나 대체하기 시작했다. 인공지능이 직장의 소멸을 가지고 온다는 우려가 커지면서, 인공지능에 대한 사회적 관심도 매우 커졌다.¹²⁾ 두 번의 겨울을 거치고, 인공지능의 세 번째 르네상스가 찾아온 것이었다(브린올프슨, 맥아피, 2014; 테그마크, 2017).

그렇지만 2015년 이후에 인공지능 알고리즘이 예상치 못했던 방식으로 편파적인 판단을 내린다는 소식이 잇달아 전해지기 시작했다. 대표적인 사례는 2015년에 구글

10) 초지능에 대한 비판적 논의가 홍성욱(2018)에 있다.

11) 조선일보(2017. 6. 22) 「길병원 인공지능 '왓슨' 암환자 진료현장 취재, 10개 항목 입력, 10초 만에 진단 끝」 http://health.chosun.com/site/data/html_dir/2017/06/20/2017062002175.html

12) 이 연구에서는 다루지 않지만 인공지능을 사용한 자동화가 직장, 직업의 급격한 변화를 가져오리라는 예측은 2013년에 출판된 소위 “옥스퍼드 보고서”에서 시작했다. 이후 많은 경제학자와 각국의 싱크탱크들은 이 문제를 연구해서 이에 대한 논문과 보고서를 출판했다. 옥스퍼드 연구에 대해서는 Frey and Osborne(2013)를 참고할 것. 최근에 출판된 한 연구(Vermeulen et al., 2018)는 지금까지 이 주제에 대해서 출판된 연구와 데이터를 종합적으로 분석해서, 지금 인공지능과 로봇이 불러 일으키는 직장, 직업의 변화가 “노동의 종말”과 같은 과격하고 급진적인 변화가 아니라 산업화 이후에 인류가 여러 번 경험했던 “구조적인 변화”임을 주장한다.

의 사물 인식 프로그램으로 출시한 “구글 포토”(Google Photo)라는 카메라 앱(app)이 흑인 커플의 얼굴을 ‘고릴라’라는 카테고리로 분류한 것이었다.¹³⁾ 이는 큰 사회적 논란을 불러 일으켰고, 구글은 이에 대해 바로 사과하고 시정을 약속했다.¹⁴⁾ 또 같은 해에 미국에 거주하는 아시아인들이 백인에 비해서 과외 튜터링 서비스에 2배 가까운 돈을 내고 있다는 사실이 폭로되었다(Angwin and Larson, 2015). 회사가 튜터링 서비스의 가격을 결정하기 위해 알고리즘에 도입한 여러 변수들이 그런 결과를 낳았던 것이었다. 또 구글의 광고가 여성에 비해 남성들에게 더 높은 보수의 자문, 관리 직종 등의 상대적으로 고급 취업 광고를 내보낸다는 사실도 드러났다(Gibbs, 2015). 일찍이 같은 해 1월 출간되어 평판, 인터넷 검색, 신용 평점의 영역에 활용되는 알고리즘들의 비가시적 영향력과 문제점을 널리 알린 프랭크 파스칼레(Frank Pasquale)의 대중서 『블랙박스 사회 *The Black Box Society*』가 공공롭게도 뒤이을 소식들의 전조 역할을 한 셈이었다(파스칼레, 2016).

이듬해 2016년에는 마이크로소프트사의 인공지능 챗봇(chat-bot) 테이(Tay)가 인간의 혐오 표현을 따라 하기 시작해서 큰 충격을 주었다. 테이는 출시 전에 사람이 사용하는 언어 중에서도 정제되고 고급스러운 언어만을 이용해서 훈련을 받았지만 출시된 뒤에 하루가 지나지 않아서 매춘부(whore) 같은 여성혐오적인 단어를 사용하고 “홀로코스트는 다 조작된 것이다”는 식의 정치적으로 올바르지 않은 표현을 발설해서 충격을 주었다(Liu, 2017). 같은 해에 미국 법원과 교도소에서 형량, 가석방, 보석 등의 판결에 널리 사용되던 컴파스(COMPAS) 알고리즘이 흑인들에게 편파적인 판결을 냈다는 <프로퍼블리카 *ProPublica*>지의 폭로가 이어졌다(Angwin, Larson, Mattu, and Kirchner, 2016). 이 폭로는 알고리즘 연구자, 사회과학자, 정책 결정자들 사이에 큰 논쟁을 불러 일으켰다. 뉴욕시의 2017년 법안을 발의한 제임스 바카도 이 논란을 겪으면서 법안의 필요성을 절감했다고 회고했을 정도였다(Kirchner, 2017). 보다 최근에는 전자상거래 기업 아마존이 구직자의 이력서를 평가하기 위한 알고리즘을 만들기 위해 알고리즘을 훈련시켜 왔었으나 젠더 편향 등의 문제로 결국 2017년에 개발

13) “Google Photos, ...” <https://twitter.com/jackyalcine/status/615329515909156865>

14) 구글은 이 문제를 해결할 장기적인 해법을 모색하겠다고 했지만, 2018년에 발표된 해결책은 “고릴라”를 검색 인덱스에서 지우는 것이었다. Simonite(2018) 참조.

을 중단했다는 보도가 나왔다(Dastin, 2018). 이 알고리즘은 “여성 체스 클럽” 등 “여성”이 언급된 지원서를 채용대상에서 배제하거나 두 곳의 여성대학을 졸업한 이들을 감점 매기는 등, 성별 편향적인 결과를 보였기 때문이다.¹⁵⁾

같은 시기에 이런 문제가 여러 저서와 연구들을 통해서 널리 알려지게 되었다. 2017년에는 알고리즘의 불평등한 결과 및 편향 문제를 분석한 수학자 캐시 오닐(Kathy O’Neil)의 대중서 『대량살상수학무기 *Weapons of Math Destruction*』이 출판되어 베스트셀러가 되었다(오닐, 2017). 오닐은 하버드 대학교의 수학과에서 박사학위를 받은 뒤에 월스트리트의 금융회사에서 인공지능 금융 모델을 만들던 개발자였다. 그렇지만 그녀는 2008년의 금융위기를 경험하면서 자신과 같은 개발자들이 만든 알고리즘 때문에 수많은 사람들이 큰 고통을 겪는 것을 목격하고, 회사를 그만두고 월스트리트에 저항하는 대항운동의 대열에 합류했다. 이후 그녀는 자신이 잘 알고 있는 알고리즘의 문제를 분석해서 책을 낸 것이었다. 오닐의 책은 알고리즘에 의한 차별의 문제를 쉬운 언어로 대중들이 이해할 수 있는 형태로 드러냈으며, 이후 여러 연구들의 전형이 되었다. 같은 해에 와쳐-보처(Sara Wachter-Boettcher)는 『기술적으로 잘못되었다 : 성차별주의 앱, 편향된 알고리즘, 그리고 유독한 기술의 다른 위협들』(*Technically Wrong: Sexist Apps, Biased Algorithms, and Other Threats of Toxic Tech*)이라는 자극적인 제목의 책을 냈고(Wachter-Boettcher, 2017), 법학자 퍼거슨(A.G. Ferguson)은 인공지능에 의존한 치안유지를 분석한 『빅데이터 경찰의 등장』(*The Rise of Big Data Policing*)이라는 책을 출판했다(Ferguson, 2017). 2018년에는 유뱅크스(Virginia Eubanks)가 『불평등을 자동화하기』(*Automating Inequality*)라는 책을(Eubanks, 2018), 노블(Safiya Noble)이 『억압의 알고리즘』(*Algorithms of Oppression*)이라는 책을 출판했다(Noble, 2018). 이런 과정을 통해 인공지능 알고리즘의 편향성이라는 문제점, 그리고 이런 편향성이 낳을 수 있는

15) 이력서 평가 알고리즘의 개발 과정에서 영국 소재 아마존 에든버러 엔지니어링팀은 저마다 상이한 직무 능력을 평가하는 500개의 모델을 만들어 과거 지원자의 이력서 데이터에 등장하는 5만개의 전문용어를 추출하도록 했다. 하지만 결과적으로 알고리즘은 젠더 편향 이외에도 여러 문제점을 보였다. 알고리즘들은 다양한 컴퓨터 코드 작성 능력 등과 같이 IT 분야에서 흔한 역량에 낮은 가중치를 부여했고, “실행했다”(executed)와 “포착했다”(captured) 등과 같이 남성 엔지니어의 이력서에 더 빈번하게 사용되는 동사들로 자신을 묘사한 지원자들을 선호했다(Dastin, 2018).

차별의 문제가 학자들의 연구주제에서 사회적으로 중요한 문제로 부상했던 것이다.

본 연구에서도 논의하겠지만 이런 인공지능과 뗄 수 없는 것이 ‘빅데이터’(Big Data)이다. 1993년에 인터넷이 일반 시민들에게 공개되면서 수 많은 데이터가 만들어지기 시작했다. 웹사이트를 운영하는 기업은 쿠키와 같은 기술을 사용해서 사람들의 방문 성향을 분석했고, 멤버십 가입을 통해서 자신들의 고객의 데이터와 소비 습관을 분석했다. 병원도 기존의 데이터를 디지털화하고 새로운 데이터와 병합함으로써 엄청난 양의 데이터를 확보했으며, 학교, 경찰, 정부, 법원 등도 비슷한 작업을 수행했다. 2005년에 오라일리 미디어 그룹(O'Reilly Media)의 무갈라스(Roger Mougala)는 최초로 ‘빅데이터’(Big Data)라는 단어를 만들어서 공표했다. 기업과 정부는 빅데이터 프로젝트를 출범시켰는데, 인도 정부는 2009년에 12억 국민 모두의 홍채, 지문, 사진을 스캔해서 디지털화한다는 엄청난 계획에 착수했다. 2010년에 구글의 회장 에릭 슈미트(Eric Schmidt)은 인류가 문명을 탄생시키고 2003년까지 5 엑사바이트(exabytes: 10^{18})의 정보를 만들었지만, 2003년 이후에는 이런 양의 정보가 2년마다 만들어진다고 하면서 빅데이터의 시대의 도래를 알렸다. 2011년에 경영 컨설팅 회사인 맥킨지사는 “빅데이터 보고서”에서 가까운 미래에 데이터 산업이 미국의 핵심 산업이 될 것이라고 예측했다.¹⁶⁾

빅데이터는 인터넷 검색 및 사용 기록, 인터넷을 통한 개인정보의 수합, 페이스북, 트위터, 인스타그램 같은 SNS에 올린 포스팅과 좋아요(like) 기록들, SNS의 친구 관계, 다양한 전자 센서들을 사용해서 수집하는 데이터, 인공위성 등의 전통적인 기기를 통해서 수합되는 데이터 등 다양한 방식으로 수집되고 구성된다. 이런 빅데이터에는 우리가 전혀 모르는 채로 수집되는 것들이 많은데, 예를 들자면 전 세계 병원에서 만들어진 디지털 정보는 하루에 수백 테라바이트를 넘고 있으며, 한 대의 비행기가 운행할 때마다 센서를 통해 수집되는 데이터는 0.5 테라바이트에 이른다. 매일 25,000대의 비행기가 운항하기 때문에 이를 다 합치면 엔진 결함이나 난기류 등을

16) McKinsey Global Institute, *Big Data: The Next Frontier for Innovation, Competition, and Productivity* (2011) at

<https://www.mckinsey.com/business-functions/digital-mckinsey/our-insights/big-data-the-next-frontier-for-innovation>

예측하는 데 유용한 데이터가 된다. 수많은 택배 배송 차량의 통신 센서는 엔진 성능을 추적하고, 라우팅을 개선하여 연료를 절약하고 최적의 동선을 운전자에게 제공하고 있다.¹⁷⁾ 구글은 사람들이 검색엔진을 이용하는 것을 분석해서 독감의 전파를 분석했는데, 이는 각 국의 질병관리본부가 분석한 것보다 더 빠르고 더 정확했다고 평가되었다(정하웅 외, 2013).

모든 정보가 그렇지만 빅데이터 역시 명암이 있다. 특히 우리 생활을 편리하게 해 줄 목적으로 수집된 데이터가 개인정보를 침해하거나 시민의 삶에 예상치 않은 피해를 줄 경우가 빅데이터의 어두운 면이다. 해양 연구자들은 파도, 해류, 기타 데이터 등을 모니터링하기 위해 데이터 분석 및 해양 센서를 사용하는데, 이를 이용해서 쓰나미와 같은 자연재해를 예측하기 시작했다.¹⁸⁾ 그런데 이 과정에서 특정 지역의 해수면이 상승하고 있다는 데이터가 공개되었고, 그 결과로 지역에 사는 많은 주민들의 집값이 급격하게 하락했다(Zook et al., 2017: 2). 이런 극단적인 경우가 있지만, 실제 대부분의 문제는 개인정보의 이용과 유출에 의한 프라이버시의 침해이다. Facebook에 무심코 찍은 좋아요(like) 버튼이 모이면 사용자의 쇼핑, 친구, 여행 취향 등이 분석될 수 있고, 이런 결과는 광고회사에 판매된다. 비슷한 병을 앓고 있는 환자들이 인터넷 포럼을 통해서 나눈 감정적인 얘기들이 소셜 미디어 회사에 의해서 수집되어 제약 회사와 병원에 판매된다. 오래 전에 올린 포스팅 내용이 문제가 되어 고용 거부를 당하는 사례도 있다.¹⁹⁾ 따라서 데이터 과학의 사회적 영향을 연구하는 연구자들 중에는

17) Software Alliance BSA에서 나온 2015년도 보고서 「데이터는 왜 중요한가?」

https://data.bsa.org/wp-content/uploads/2015/12/BSADataStudy_ko.pdf를 참조.

18) "Big Data to Predict Offshore Accidents, Tsunamis and Other Natural Disasters." *Predictive Analytics Today*. (2013)

<http://www.predictiveanalyticstoday.com/big-data-predict-shore-accidents-tsunamis-naturaldisasters/>

19) 2013년에는 10명 중 1명이 SNS 포스팅 때문에 취직이 거절되었다는 보도가 있었지만, 2016년에는 이 비율이 30%로 증가했다. 취직을 한 뒤에 SNS포스팅 때문에 해고당한 사례도 많이 있다. "1 in 10 Young People Denied Jobs Due to Social Media Use," *Daily Caller* (2013. 5. 30) at <https://dailycaller.com/2013/05/30/1-in-10-young-people-denied-jobs-due-to-social-media-use/>; "Beware what you post on social media: Study reveals a third of job applicants are rejected after web checks by employers," *Mail Online* (2016. 9. 10) at <https://www.dailymail.co.uk/news/article-3783488/Beware-post-social-media-job-applicants-rejected-web-checks-employers.html>.

“모든 데이터가 사람이다”는 원칙을 고수해야 한다고 주장하는 사람들이 있다(Zook et al., 2017).

빅데이터가 낳는 가장 심각하고, 또 상대적으로 명백한 문제 중 하나는 프라이버시의 침해이다. 2012년에 미국의 슈퍼마켓 타겟(Target)이 가족에게까지 임신 사실을 감춘 한 10대 여성에게 임신부 전용 광고지를 발송한 사건은 잘 알려져 있다. 타겟은 (실제로는 타겟의 인공지능 알고리즘은) 이 여성의 구매 패턴으로부터 여성이 임신부라는 사실을 추정하고, 크레딧 카드에서 집 주소 정보를 찾아내서 집으로 광고지를 발송할 수 있었다.²⁰⁾ 데이터 기업은 이메일 하나에서 이름, 나이, 성별은 물론 집 주소, 그리고 집을 살 때 얻은 담보 등의 정보를 쉽게 알아낼 수 있다. 사실 개인이 자신의 개인정보를 줄 때, 대부분의 사람들은 자신이 주는 정보에서 얼마나 많은 정보가 추출될 수 있는지를 알기 힘들다. 이는 많은 정보들이 연동되어 있기 때문에 가능하다. 최근에 유럽이나 캘리포니아 주에서 프라이버시를 보호하는 강력한 개인정보보호법들이 입안 되어서 이런 문제가 기업과 개인의 이해관계가 충돌하는 매우 중요한 문제가 되고 있다. 그렇지만 편향성과 차별의 문제에 주목하는 본 연구에서는 이에 대한 본격적인 분석은 하지 않을 것이다.

그렇다면 인공지능에 의한 차별이라는 문제를 생각할 때 우리가 주목해야 하는 빅데이터의 특성은 어떤 것인가? 가장 중요한 특성은 빅데이터에 수많은 상관관계(correlations)가 존재한다는 것이다. 이런 상관관계의 가장 극적인 사례가 2004년에 보도된 월마트의 스트로베리 팝타르트²¹⁾ 판매와 관련된 것이다. 허리케인 태풍이 잦은 플로리다주의 월마트는 태풍이 오기 전에 사람들이 맥주를 많이 찾는다고 생각하고 맥주를 구매하기 쉬운 곳에 진열하곤 했다. 그런데 2004년에 월마트의 정보분석팀은 태풍이 오기 전에 플로리다주 주민들이 맥주가 아니라 스트로베리 팝타르트를 무려 7배 이상 구매한다는 것을 밝혀냈고, 이후 이를 계산대 옆에 진열해서 더 큰 수익을 올릴 수 있었다. 허리케인 태풍과 아무런 관계가 없어 보이는 스트로베리 팝타르트

20) 2012년에 일어난 이 사건에 대해서는 Kashmir Hill, “How Target Figured Out A Teen Girl Was Pregnant Before Her Father Did” *Forbes* (2012. 2. 16) at <https://www.forbes.com/sites/kashmirhill/2012/02/16/how-target-figured-out-a-teen-girl-was-pregnant-before-her-father-did/#d2c8d7e66686>를 참조.

21) 팝타르트(Pop-tart)는 과자 비슷한 음식이다. 속에 딸기 잼이 들어있는 것이 스트로베리 팝타르트이다.

의 연관, 혹은 상관관계가 빅데이터를 이용해서 드러났던 것이다.²²⁾

비슷하게 내 위치 정보, 소비 패턴, 학습 패턴, 인터넷 검색 패턴, 병원 방문 패턴, 전화 이용 패턴, GPS 정보 등이 종합되면, 나에 대해서 많은 상관관계가 생길 수 있다. 내 인터넷 검색기록에서 내가 겨울에 홍콩 여행을 계획하고 있다는 것을 쉽게 알 수 있고, 적절한 호텔과 항공편에 대한 광고를 내 페이스북에 게시할 수 있다. 그런데 빅데이터는 여기에서 멈추지 않는다. 이런 데이터가 나에 대해서만이 아니라 다른 사람에 대해서도 수집이 되고, 횡적으로 비교가 되면 훨씬 더 많은 상관관계가 생기게 된다. 나에 대한 수많은 데이터, 그리고 나와 나이, 성별, 취향, 직업이 비슷한 사람들에게 대한 데이터의 상관관계를 패턴으로부터 스스로 배우는 머신러닝 알고리즘에 결합시키면, 다음과 같은 세 가지 결과가 도출된다(Williams et al., 2018).

첫 번째는 내 행동에 대한 예측이 가능해진다. 내가 병원에 간 다음 날 무엇을 할 것인가라는 것은, 나와 비슷한 상태에서 병원에 간 사람들이 그 다음날 무엇을 하는가를 분석하면 어느 정도 예측할 수 있다. 나와 비슷한 사람들이 병원에 간 다음날 체육관을 많이 방문했다고 하면, 병원을 방문한 내게 체육시설에 대한 광고가 효과가 있을 수 있다. 극단적인 경우지만 나와 비슷한 카테고리의 사람들을 분석했을 때 장마철에 범죄를 저지르는 사람이 많다면, 나에 대해서도 그럴 가능성이 높다는 예측이 나올 수 있다. 경찰은 이렇게 예측된 사람들을 집중적으로 감시함으로써 범죄를 사전에 예방해서 줄일 수 있는 것이다.

두 번째로 머신러닝을 통해 빠진 데이터를 채우는 대체(imputation)가 용이해진다. 예를 들어, 나에 대한 데이터 중에서 내 신용도에 대한 데이터가 없어도, 비슷한 사람들을 분석해서 나의 빈 데이터를 채워 넣을 수 있다. 그리고 마지막으로 직접적으로 획득이 곤란한 민감한 데이터를 대리변수(proxy variable)를 이용해서 획득하는 것이 가능해진다(Williams et al., 2018). 특히 대리변수를 사용하면 직접적으로 물어보는 것이 금지되어 있는 민감 정보에 대한 추정이 가능해진다. 예를 들어, 취업 면접자에 대해서 부모의 직업과 소득을 물어보는 것이 불법이라고 해도, 거주지 정보, 소

22) Constance L. Hays, "What Wal-Mart Knows about Customer's Habits," *New York Times* (2004. 11. 14).

비 패턴, 취미 활동 등에 대한 정보를 결합하면 이를 어렵지 않게 추정할 수 있는 것이다. 성별과 인종에 대해서도 데이터를 결합, 비교하거나 이를 가능케 하는 몇 가지 질문을 던지면 이를 쉽게 추정할 수 있다.²³⁾ 이렇게 빅데이터와 인공지능 알고리즘이 결합하면 차별적인 결과를 낳을 수 있다.

이런 차별에는 의도적인 차별과 그렇지 않은 차별이 있다. 위에서 언급한 대로 면접 알고리즘을 사용하는 회사가 여성이나 특정 지역 출신의 응모자들을 뽑지 않기 위해서 의도적으로 이런 정보를 추출할 수 있는 질문 통해 원하는 정보를 얻어내는 것이 의도적인 차별의 사례이다. 그렇지만 이런 의도적 추정 이외에도 알고리즘이 의도와 무관하게 차별적인 결정을 내리는 결과를 낳을 수도 있다(Barocas & Selbst, 2016: 677-694; Kroll, et al., 2017: 679-682). 예컨대 경력직 구직자를 평가할 때 이들이 이전 직장에서 받은 연간 업무 평가 점수보다 재직 기간을 평가하는 방식으로 알고리즘을 만든다면, 이는 상대적으로 재직 기간이 짧은 여성에게 불리하다는 식이다. 후자가 전자에 비해 구직자끼리 쉽게 비교 가능하기 때문이라는 것이다. 문제는 재직 기간이 업무 성과를 예측할 수 있는 요인으로 중립적이지 않다는 점이다. 여성의 경우에 육아에 의한 경력 단절 등의 이유 때문에 상대적으로 재직 기간이 짧다. 따라서 재직 기간에 대한 예측을 바탕으로 좋은 직원을 결정한다면 이는 결과적으로 여성에게 적은 채용 기회를 제공하게 될 수 있다.

이 외에도 특정 계층의 정보가 부정확하게 수집되거나, 통계적으로 상응하는 인구 비율과 차이 나게 수집된 경우가 있을 수 있다. 한 예로 보스턴 시는 “스트리트 범프”(Street Bump) 라는 스마트폰 앱을 활용하여 도로의 구멍 위치를 파악하고 이 결과를 도로 보수에 활용하고자 했다. 하지만 스마트 폰 보유율이 계층별로 차이가 있고 서로 다른 계층이 주로 이용하는 도로가 다르다는 점을 감안하면, 앱에서 자동으로 수집된 정보를 바탕으로 도로 보수 지점을 결정하는 것은 시의 자원을 특정한 계층에

23) 데이터 마이닝 기법이 편향적인 결과를 산출하도록 의도적으로 유도하는 또 다른 경우로 마스킹(masking) 기법이 있다. 이 기법의 하위 분류로는 특정 계층에게 불리한 추론이 가능하도록 일부러 편향적인 데이터를 수집하기, 기존의 편향적인 데이터가 신빙성 있고 공평하다고 주장함으로써 기존 데이터에 배태된 편향을 보존하기, 보다 세부적인 속성들이 아니라 조악하게 분류된 수준의 속성을 사용함으로써 특정 계층들에게 불리한 결과를 피할 수 없게 만들기 등이 있다(Barocas & Selbst, 2016: 692-693).

보다 유리하게 배정하는 결과를 낼 수 있는 것이다(Crawford, 2010; Barocas & Selbst, 2016: 685에서 재인용).

그렇다면 인공지능에 의한 차별을 방지하기 위해서는 객관적이고 중립적인 데이터만 확보되면 되는 것인가? 이는 다음의 이유 때문에 쉽지가 않다. 우선 객관적이고 중립적인 데이터가 무엇을 의미하는지가 분명치 않다. 미국에서 인종별 범죄자의 데이터를 인공지능에 입력한다고 할 때, 인종별로 지금 교도소에 있는 사람들의 비율을 넣으면 될 것인가? 이는 누가 계산을 해도 비슷한 결과가 나온다는 의미에서 객관적일 수는 있지만, 중립적이거나 공평하다고 보기는 힘들다. 왜냐하면 많은 사회과학 연구들은 더 많은 흑인이 교도소에 있는 이유가 기존의 인종차별적인 경찰과 법원의 문제 때문이라고 보기 때문이다. 따라서 현재의 재소자의 비율이라는 데이터를 이용하면, 이런 편견이 고스란히 반영된다고 볼 수 있다. 그런데 이런 데이터에 문제가 있다는 것을 인정해도, 어떤 데이터가 객관적이고 중립적인 데이터가 될 수 있는지는 분명치 않다. 범죄자의 비율은 인종에 따라서 동일하다고 보는 것이 객관적이고 중립적인 데이터인가? 아마 많은 백인들은 그렇지 않다고 생각할 것이기 때문이다.

계다가 알고리즘이 공평한 결과를 낳는 방식으로 설계되었는가를 알기도 힘들다. 요즘 사용하는 많은 알고리즘의 경우, 기존의 데이터에 대해서 편향된 결과를 낳는다고 해서 중립적인 데이터를 넣었을 때 중립적인 결과를 낳을 것이라는 보장이 없다. 최근의 머신러닝 시스템은 그 알고리즘이 잘 알려져 있다고 하더라도 모든 상황에서의 행동을 예측하긴 어렵다. 머신러닝 시스템의 동작은 데이터 세트의 패턴과 상관관계에 의하여 이루어지는데, 그 상관관계의 속성상 결과를 미리 알기 어렵기 때문이다. 알파고 프로그래머들이 알파고의 다음 수를 예측할 수 없는 것과 비슷하다. 이런 측면 때문에, 인공지능이 둔 바둑의 한 수에 “창의적”이라는 평가를 붙일 수도 있다. 인공지능이 갖는 이러한 창의적 특성이 긍정적 결과를 낳을 수도 있지만, 예측이 곤란하기 때문에 부정적 결과를 낳을 수도 있다. 특히 사람에게 위해가 되는 결과가 생겼을 때, 법적 책임과 관련하여서 여러 가지 문제를 일으킬 수 있다(Buri, 2016; Scherer, 2016; 양종모, 2016).

실제 세상에서 객관적인 데이터, 투명한 알고리즘을 가진다는 것은 말처럼 쉽지 않

다. 이는 다음 절에서 다루는 두 사례에 의해서 분명해 질 것이다.

3. 사법 영역에서의 알고리즘 공정성 논쟁: 컴파스(COMPAS)²⁴⁾ 알고리즘은 흑백을 차별하는가?

알고리즘 공정성의 문제가 정확성의 문제와 상충 관계를 가진다면 알고리즘 공정성의 문제를 개선하는 데에는 불가피한 한계가 있음을 인정하지 않을 수 없게 된다. 하지만 알고리즘 공정성 문제를 개선하기 어려운 또 다른 주요한 이유는 보다 근원적인 긴장 관계에서 기인한다. 바로 알고리즘 공정성(fairness) 자체를 정의하는 지표들과 척도들이 다양하며 공정성에 대해 서로 다른 결론을 도출할 수 있기 때문이다. 대표적인 사례가 재범 확률을 예측하는 노스포인트(Northpointe)사가 개발한 알고리즘 컴파스가 형사 재판을 받는 개인의 위험성을 예측할 때 백인과 흑인에 대해 차별적인 판단을 내린다는 주장과 관련된 논쟁이다.

이 주장은 2016년에 탐사보도매체인 ProPublica에 의해서 제기되었고(Angwin, Larson, Mattu, and Kirchner, 2016), 이후 New York Times 같은 권위있는 매체들에 의해서 보도되어 세상에 널리 알려졌다. 컴파스는 피고인의 일반범죄 재범률과 강력범죄 재범률을 추정하여 피고인의 리스크 스코어(risk score)를 1(최저위험 군)에서 10(최고위험 군)까지의 숫자로 결정해서 판사에게 제공함으로써, 판사가 형량을 선고하거나 가석방을 결정하는 보조 자료로서 널리 사용되는 알고리즘이다. ProPublica의 기자들은 플로리다 주 브라워드(Broward) 카운티 법원에서 선고받은 7,000명 이상의 피의자를 대상으로 컴파스의 예측결과와 실제 재범여부를 입수하여 조사했다. 이 기자들은 특히 두 가지 통계를 보고 컴파스가 흑인과 백인을 차별하는 결과를 냈다고 주장했다. 그 중 하나는 백인의 경우에는 리스크 스코어 1에 해당되는 사람이 가장 많고, 이후 10까지 그 비율이 계속 감소했음에 반해, 흑인들의 경우는 1부터 10까지 비슷한 비율로 판정을 받았다는 것이었다. 즉, 흑인의 경우 재범 확률이 높다고 판정을 받은 사람들이 백인의 경우보다 훨씬 더 많았던 것이다.

두 번째는 재범률이 높은 것으로 예측되었지만 실제로 2년간 범죄를 저지르지 않은

24) COMPAS는 Correctional Offender Management Profiling for Alternative Sanctions의 머리글자를 따서 만든 약어이다.

것으로 드러난 경우가 흑인의 45%로 백인의 23%에 두 배에 달한다는 점, 그리고 재범률이 낮은 것으로 예측되었지만 실제로 2년간 범죄를 저지른 경우가 백인이 48%로 흑인 28%보다 훨씬 높다는 사실이었다(표 1). 즉 흑인의 경우 위양성(false positive)이 백인에 비해서 거의 두 배, 위음성(false negative)은 백인의 절반 보다 조금 더 높은 정도였다는 것이다. 이 두 증거를 종합하면 흑인은 더 많은 수가 편파적으로 고위험 군으로 분류되었고, 백인은 더 많은 수가 부당하게 저위험 군으로 분류되었다고 할 수 있다. 이를 토대로 ProPublica는 컴파스 알고리즘이 인종차별적인 결정을 내리고 있다고 주장했다.

〈표 1〉 백인에 비해 흑인에게 불리하게 분류된 위험점수

	백인	아프리카계 미국인
위험 점수가 높다고 분류되었으나, 실제로는 2년 안에 재범하지 않은 확률(false positive)	23.5%	44.9%
위험 점수가 낮다고 분류되었으나, 실제로는 2년 안에 재범한 확률(false negative)	47.7%	28.0%

자료: ProPublica(2016)

반면 이를 반박하는 기술문서에서 노스포인트사는 앞선 통계적 사실들이 알고리즘의 의사결정이 인종 차별적이라는 주장을 뒷받침하지 않는다고 반박했다(Dieterich et al., 2016). 회사는 우선 컴파스 소프트웨어의 목적은 재범자를 예측하는 것에 있으며, 이에 있어 백인과 흑인에 차별적인 결과는 나타나지 않았다고 주장했다. 위험 점수가 높다고 분류되었고 실제로 재범한 이의 경우(진양성, true positive)는 백인 59%, 흑인 63%로 유의미한 차이가 나타나지 않았고, 위험 점수가 낮다고 분류되었고 실제로 2년 안에 재범하지 않은 이의 경우(진음성, true negative) 역시 백인 71%, 흑인 65%로 크게 차이 나지 않았다는 것이다(표 2).

<표 2> 백인과 흑인의 위험점수의 유효리가 뚜렷하게 구별되지 않는 경우

	백인	아프리카계 미국인
위험 점수가 높다고 분류되었고, 실제로 2년 안에 재범한 확률 (true positive)	59%	63%
위험 점수가 낮다고 분류되었고, 실제로 2년 안에 재범하지 않은 확률 (true negative)	71%	65%

자료: Dieterich et al.(2016), 김기태, 정재관(2016)의 정리를 참조함.

또한 노스포인트사는 *ProPublica*의 주장의 근거 지표 중 하나이기도 한 위양성에 대해 이 지표가 기본구성비율(base rate)의 영향을 받으며 정(正)의 상관관계를 띠는 연구 결과(Leeang et al., 2013)를 인용하며, 기본구성비율 자체에 있어 흑인의 재범률과 백인의 재범률이 차이를 보임을 지적했다. 흑인의 일반범죄 재범률은 51%로 백인의 39%에 비해 높으며, 흑인의 강력범죄 재범률 역시 14%로 백인의 9%에 비해 높다는 것이다. 회사가 배포한 기술문서에 따르면, 높은 값의 위양성 값은 백인에 비해 높은 흑인의 재범률이라는 기본구성비율 자체의 차이에서 기인한 것일 뿐, 컴파스 알고리즘의 판정이 인종차별적이라는 증거가 아니라는 것이다.

*ProPublica*의 주장을 보면 컴파스가 공정하지 못한 것 같지만, 노스포인트사의 주장을 보면 컴파스가 충분히 공정하다. 왜 이런 차이가 생긴 것일까? 우선 노스포인트사가 주목하는 공정성은 어떤 사람이 흑인이건 백인이건 인종에 관계없이 그를 평가한 항목들의 점수를 더한 값이 같다면 동일한 최종 리스크 스코어를 얻는다는 것을 의미한다. 이는 “캘리브레이션”(calibration)이라고 알려진 공정성의 기준이다. 그리고 회사는 컴파스가 고위험 군으로 평가된 사람들 중 실제로 재범을 저지르는 사람들의 비율(진양성) 역시 흑백과 무관하게 비슷한 값을 냈음을 강조했는데, 이는 예측적 공정성(predictive parity)이라는 기준을 만족한 것이었다(Dieterich et al., 2016).

원래 *ProPublica*는 흑인/백인의 리스크 스코어 분포가 크게 차이가 난다는 것을 불공정의 한 요소로 강조했지만, 이후 논의에서는 이를 다시 언급하지 않았다. 위험 분포가 같아야 한다는 것은 “통계적 공정성”(statistical parity)이라는 기준인데, 인종에 따른 범죄율과 재범률이 차이가 나는 세상에서 이는 달성하기 힘든 기준이기 때문

이다. 그렇지만 이어진 반론에서 *ProPublica*는 “‘예측적 공정성’이라는 것은 실로 ‘최적의 차별’(optimal discrimination)이다”라고 평가한 시카고 대학교의 통계학자 네이튼 스레브로(Nathan Srebro)의 논평을 인용하면서, 노스포인트사가 강조한 예측적 공정성이라는 것이 결국 흑인에 대해 허위 고위험 군을 더 많이 만들어낸 결과를 낳는다고 다시 비판했다(Angwin and Larson, 2016). *ProPublica*는 공정한 알고리즘이라면 위양성/위음성의 비율이 흑백에 상관없이 비슷한 점수가 나와야 한다고 강조했는데, 이런 “오류 비율의 공정성”(error-rate parity)은 스레브로 그룹의 결론이기도 했다(Hardt et al., 2016).

이런 기준들을 모두 만족시키는 방식으로 공정성의 기준을 정할 수는 없을까? 2016년에 컴파스에 대한 논쟁이 시작되면서 여러 통계예측 분야의 전문가들이 이 문제를 분석했지만, 이들의 답은 부정적이었다. 일례로 클라인버그와 동료들은 캘리브레이션과 오류 비율의 공정성이라는 두 개의 기준이 아주 특정한 경우를 제외하고는 양립할 수 없는 기준임을 보여주었다(Kleinberg et al., 2016). 클라인버그의 분석에 의하면 이 중 하나의 기준을 더 잘 만족시키려고 하면, 다른 기준에서는 벗어나는 결과를 낳았던 것이다. 더 나아가 버크와 그의 동료들은 통계적으로 공정성을 가늠하는 방식이 적어도 5개는 존재한다고 지적했다(표3). 이들은 이런 5가지 조건을 동시에 만족시키는 “완전한 공정성”(total fairness)은 가능하지 않다고 하면서, 이 각각이 소수 그룹의 보호에 대해서 서로 다른 함의를 가지는 방식으로 서로 상충되며, 이중 어느 하나를 온전히 만족시키려고 하면 통계적인 정확성을 잃는 결과가 생긴다고 지적했다(Berk et al., 2018). 반면에 또 다른 통계학자는 예측적 공정성을 조금 희생하더라도 위양성과 위음성의 값을 같게 하는 것이 더 공정한 방식이라고 주장했다(Chouldechova, 2017).

<표 3> 통계적 공정성을 가리는 방식들

정의들	성립 조건	계층마다 동일해야 하는 값
전반적 정확성 균등 (Overall accuracy equality)	집단의 각 계층에 (예: 백인과 흑인) 대해 전반적 절차적 정확성이 동일	$(a+d)/(a+b+c+d)$
통계적 동등성 (Statistical parity)	각 계층에 대해 주변 분포들(marginal distributions)이 동일	$(a+c)/(a+b+c+d)$ $(b+d)/(a+b+c+d)$
조건부 절차적 정확성 균등 (Conditional procedure accuracy equality)	각 계층마다 조건부 절차 정확성(Conditional procedure accuracy)이 동일	$a/(a+b)$ $d/(c+d)$
조건부 사용 정확성 균등 (Conditional use accuracy equality)	각 계층마다 조건부 사용 정확성(Conditional use accuracy)가 동일	$a/(a+c)$ $d/(b+d)$
처리 균등 (Treatment equality)	계층마다 위음성 (false negatives)과 위양성(false positives) 간의 비율이 동일	c/b or b/c
종합적 공정성 (Total fairness)	앞선 다섯 가지 공평성 조건을 모두 만족	

a: 진양성, b: 위음성, c: 위양성, d: 진음성
자료: Berk et al. (2018: 13-15)

컴파스의 공정성에 대한 논쟁이 생기면서 이를 법정에서 사용하는 것을 대법원에 탄원한 경우도 있었다. 총격전에 사용된 차를 운전하면서 경찰의 추격을 따돌리려 한 죄로 2013년 기소된 루미스(Eric Loomis)는 성범죄 전력이 있었고, 컴파스의 알고리즘에 의해서 고위험으로 분류되었다. 그는 위스컨신 법원에 의해 징역 6년을 선고받았는데, 자신이 컴퍼스 알고리즘의 과학적 타당성을 검증할 수 없으며, 이것이 여성보다 자신과 같은 남성을 더 위험하다고 판단하는 불공정성을 내포하기 때문에 공정하게 재판받을 권리를 침해당했다고 항소했다(그는 흑백 차별을 문제 삼지는 않았다). 위스컨신 고등법원은 이 판단을 대법원에 넘겼고,²⁵⁾ 위스컨신 주 대법원은 2017년 6월 이를 기각했다.²⁶⁾ 대법원은 피고가 컴퍼스 알고리즘을 이해하지는 못하지만 설문 문

25) 위스컨신 고등법원 재판부는 항소 기각 사유로 COMPAS의 분석보고서가 유일한(sole) 근거는 아니며, 6년형을 선고한 재판부가 분석 결과에 동의하지 않을 재량과 정보를 갖는다는 점을 들었다. 유영무 (2017. 7. 17) 「인공지능 분석에 근거한 형사재판의 문제점」, 법률신문.

함에 직접 답을 하면서 이것이 어떤 정보를 이용하는지 충분히 이해했고, 만약에 이 때 정보를 잘못 제공했다면 재판 과정에서 이견을 제시할 기회가 있었기 때문에 이것이 재판의 공정성을 침해했다고 볼 수 없다고 판결했다. 남성을 차별했기 때문에 공정하지 못하다는 주장에 대해서 대법원은 남성이 여성보다 강력범죄를 저지르는 비율이 높은 것이 사실이고 컴파스의 리스크 스코어 산출에는 이런 비율이 반영되어 있었을 뿐이며, 이렇게 나온 리스크 스코어는 판사가 판결에서 고려한 여러 요소 중 하나일 뿐이라고 반박했다.²⁷⁾ 대법원의 이런 판결은 컴파스가 판사의 판결을 도와주는 알고리즘으로 미국의 법정에서 정당하게 계속 사용될 수 있다는 인가를 내준 셈이나 마찬가지였다.

대법원의 판결에서도 나타났지만 통계적 예측 프로그램의 공정성을 염려하는 사람들이 가장 어려워하는 문제는 기본구성비율이다. 우리는 강력범죄의 대다수가 젊은 남성들에 의해서 저질러진다는 것을 알고 있다.²⁸⁾ 그렇다면 강력범죄에 대한 리스크 스코어를 산정한다고 했을 때 성별과 나이가 중요한 변수로 포함될 것이며, 젊은 남성의 경우 성별과 나이라는 속성 때문에 리스크 스코어가 높아질 것이다. 그런데 처음 범죄를 저질러서 재판을 받는 20대 남성의 경우에는 자신과 나이가 비슷한 다른 남성들이 저지른 범죄 때문에 자신의 리스크 스코어가 높아지는 것을 부당하다고 생각할 수 있다. 인종의 경우도 마찬가지다. 노스포인트사가 강조하듯이 미국의 경우에 지금까지의 강력범죄를 저지른 사람 중 백인보다 흑인의 비율이 높다. 기존 데이터에 기반한 리스크 스코어 산정 방식에 따라, 형량 선고를 앞둔 흑인 피의자들은 백인에 비해 더 높은 리스크 스코어를 부여받는다. 그러면 이들의 형량이 늘어나고, 백인에 비해

26) "Loomis v. Wisconsin - SCOTUSblog" in *SCOTUSblog - Supreme Court of the United States Blog*, <http://www.scotusblog.com/case-files/cases/loomis-v-wisconsin/>

27) "Brief for the United States as Amicus Curiae" (Eric L. Loomis v. State of Wisconsin, May 2017) at <http://www.scotusblog.com/wp-content/uploads/2017/05/16-6387-CVSG-Loomis-AC-Pet.pdf>

28) 대검찰청이 발행한 2016년 발생 범죄 통계에 따르면 살인, 강도, 방화, 성폭력 등 "강력범죄(총약)" 범죄자의 남녀 비율은 96.6%:3.4%이며, 가장 많은 범죄자 연령대는 19세~30세 (27.0%), 31세~40세 (21.4%), 51세~60세(15.0%), 18세 이하(8.7%) 순이었다. 또 다른 강력범죄 유형으로는 폭행, 상해, 공갈, 약취와 유인, 체포와 감금, 폭력 행위 등의 "강력범죄(폭력)"가 있다. 해당 분류 범죄의 2015년 통계에 따르면 남녀비율은 83.7%:16.3%이며, 범죄자 연령대 비율은 41세~50세(24.1%) 51세~60세 (21.1%), 19세~30세(20.7%), 31세~40세(19.5%) 순이었다. 대검찰청, (2017). 『2017 범죄분석』, <http://www.spo.go.kr/spo/info/stats/stats02.jsp>

가석방될 가능성도 줄어든다. 이들은 더 오랜 기간 동안 교도소에 있게 되고, 이는 다시 향후 재판받을 흑인들의 리스크 스코어를 높이는 결과를 가져온다. 양의 피드백이 작동하는 이러한 “피드백 효과”는 결국 더 많은 흑인을 교도소에 가두는 결과로 이어진다. 과학철학자 이언 해킹(Ian Hacking)이 다중인격의 구성을 논하면서 제시한 “루핑 효과”(looping effect)²⁹⁾처럼, 알고리즘이 ‘교도소에 수감된 흑인 재소자’라는 범주의 인간을 더 많이 만들어 내는 것이다. 미국의 많은 민권운동가들은 흑인이 강력범죄의 비율이 높았던 것은 흑백 인종차별의 결과였다고 항변하면서 이런 차별을 고착화하는 컴파스의 사용을 반대한다. 이런 피드백 효과라는 문제는 컴파스를 지지하는 사람들조차 우려하고 있는 부분이다.

29) 루핑 효과는 특정한 정신의학적 개념이 이에 해당하는 사람들을 만들어 내며, 이것이 다시 이런 정신의학 개념을 정당화하는 루프(loop) 형태의 과정을 지칭한 것이다. Hacking(1995) 참조.

4. 치안 영역에서의 알고리즘 차별: 예측적 치안유지는 편향적인가?

영화로도 만들어져서 더 유명해진 필립 K. 딕의 SF 소설 「마이너리티 리포트」를 보면 범죄가 일어날 시간과 장소를 미리 예측해서 경찰이 범죄가 일어나기 전에 현장에 출동하는 장면이 나온다. 이렇게 범죄가 예측되어 예방되는 미래 사회는 ‘범죄율 제로’ 사회이다. 아마 끊임없이 발생하는 크고 작은 범죄에 시달리는 치안 담당자들은 이런 미래사회가 다름 아닌 ‘유토피아’라고 생각할 것이다.

2013년의 랜드 연구소(RAND Corporation)에서 출간한 보고서에 의하면 “예측적 치안유지”(predictive policing)에는 범죄를 예측하는 것, 범인을 예측하는 것, (과거 범죄로부터) 범인의 신원을 예견하는 것, 그리고 희생자를 예측하는 것의 네 가지 유형이 있다(Perry et al., 2013). 이러한 예측적 치안유지는 보통 4단계로 구성되는데, 첫 번째는 경찰이 데이터를 수집하는 것이며, 두 번째는 이를 분석해서 예측을 하는 것, 세 번째는 경찰 인력을 이용해서 작전을 짜는 것, 그리고 마지막은 범죄자의 반응에 대응하는 단계이다. 이 마지막 단계는 작전에 대한 평가를 낚으면서 다시 새로운 첫 번째 단계, 즉 데이터 수집 단계와 연결되어 있다.

여기에서는 이런 네 가지 예측 중에서 첫 번째 범주인 “범죄의 예측”을 주로 다룰 것인데, 이 첫 번째 유형의 예측은 기본적으로 범죄가 일어날 법한 시간과 장소를 예측하는 것을 의미한다. 랜드 보고서가 나오기 몇 년 전인 2008년에 미국의 범죄학자 데이비드 와이스버드(David Weisburd)는 범죄의 패러다임이 사람 중심의 패러다임(people-centric paradigm)에서 장소 중심의 패러다임(place-centric paradigm)으로 바뀌어야 한다고 주장했다. 즉, 범죄자를 프로파일링 하던 과거의 방식에서 범죄가 빈번히 일어나는 “범죄 핫스팟”(crime hotspots)을 찾아내고 이를 감시하는 방법으로의 변환을 주장했던 것이다(Weisburd, 2008). 얼마 뒤에 제미슨 톨(Jameson L. Toole)과 동료들은 수학과 물리학 공식을 사용해서 유형 별로 범죄 사건의 시/공간적 특성을 찾아내어 필라델피아의 10년간 범죄 발생을 분석했고, 와이스버드의 말처럼 범죄가 빈번히 일어나는 핫스팟이 존재한다는 것을 발견했다(Toole et al., 2011).

그렇지만 더 급진적인 시도는 캘리포니아에서 일어났다. 수학자 조지 몰러(George O. Mohler)와 동료들은 큰 지진이 일어난 뒤에 여진이 생긴다는 지진의 원리와 비슷하게 하나의 범죄가 생긴 뒤에 이를 뒤따르는 범죄들이 비슷한 지역에서 뒤이어 발생한다고 추론하고, 여진을 예측하는 프로그램을 변형해서 범죄 예측 프로그램을 만들었다. 여기에 몰러의 동료인 쇼트(Martin B. Short)는 범죄자의 심리를 포함시켜서, 어느 지역이 범죄를 저지르기에 “만만해” 보이는가의 변수를 포함시켰다. 이들은 LA의 한 지역에서 1년 동안 일어난 범죄 데이터를 가지고 알고리즘을 완성했고(Molher et al., 2011), 성공적인 테스트를 거쳤다. 이 테스트에서 인간 분석가가 형사 범죄가 일어날 지역 중 3% 만을 예측한 반면, 알고리즘은 6%를 예측한 것이다.³⁰⁾ 이후 몰러와 동료들은 개인투자자 및 UCLA 벤처스 투자회사로부터 총 370만 달러 규모의 투자를 받아³¹⁾ 프레드폴(PredPol)이라는 회사를 2012년 창업하여 이 기술을 상업화했다.³²⁾ 이 회사의 범죄 예측 알고리즘 프레드폴은 출시부터 언론의 큰 주목을 받았다. 영국 경제지 Economist에 따르면, 영국 켄트 카운티(Kent County) 북부에서 2013년 4월부터 4달간 진행한 시험에 따르면, 모든 시내 형사 범죄의 8.5%가 프레드폴이 예측한 구역 안에서 일어났으며, 더 많은 수의 범죄가 그 구역과 바로 인접한 지역에서 일어났다. 이에 비해 경찰 분석가의 예측은 5%에 머물렀다.³³⁾ 실제로 4달 실험 전후로 시내 범죄는 6% 감소하기도 했다.³⁴⁾ 이후 프레드폴사의 예측 프로그램이 LA, 아틀란타, 시애틀, 산타 크루즈 같은 도시의 치안 유지에 도입되기 시작했다.³⁵⁾ 산타 크루즈 시는 이 프로그램을 도입하고 1년 동안 절도가 11%, 강도가 27% 감소했다고

30) *The Economist* (2013. 7. 20), “Don’t even think about it – Predictive policing”

31) CrunchBase (n.a.), “PredPol” <https://www.crunchbase.com/organization/predpol>

32) PredPol은 Predictive Policing의 머리글자들을 따서 만든 명칭이다. 몰러는 현재 PredPol 회사의 최고 데이터 과학자(Chief Data Scientist)로 재직중이다. <http://www.predpol.com/about/company/>

33) *The Economist* (2013. 7. 20)

34) An Internet Archive page of Kent Police (2013. 12. 3) “Predictive Policing day of action targets burglars,” archived on May 2nd, 2014. [https://web.archive.org/web/20140502001827/http://www.kent.police.uk/news/latest_news/131203_predpol_day_a.html]. Kent 카운티 경찰국의 원본 페이지는 2018년 11월 현재 열리지 않는다 [https://www.kent.police.uk/news/latest_news/131203_predpol_day_a.html].

35) *Los Angeles Times*(2010. 8. 21), “Stopping Crime Before It Starts”; *Santa Cruz Sentinel*(2012. 2. 26), “Modest Gains in First Six Months of Santa Cruz’s Predictive Police Program.”; *NPR*(2011. 11. 26), “At LAPD, Predicting Crimes Before They Happen,” <http://www.npr.org/2011/11/26/142758000/at-lapd-predictingcrimes-before-they-happen>

발표했다.³⁶⁾

경찰이 이 프로그램을 열성적으로 도입한 데에는 몇 가지 이유가 있다. 우선 지난 몇 십 년 동안 도시의 인구가 늘고, 따라서 절도, 강도 등 도시형 범죄가 급증했다. 반면에 여러 가지 이유로 경찰 인력은 축소되어 치안 유지에 애로점이 증가했다. 여기에 백인 경찰이 인종을 차별한다는 비판이 지속적으로 제기되었다. 미국의 여러 도시에서 백인 경찰이 흑인을 무자비하게 폭행하거나 사살하는 사건이 일어났고, 이런 사건이 일어날 때마다 경찰의 인종차별은 여론의 도마에 올랐다. 이런 상황에서 일견 중립적으로 보이면서 범죄를 예측하는 알고리즘은 경찰의 입장에서 봐도 경찰이 직면한 모든 문제를 한 번에 해결할 수 있는 매력적인 해법이었던 것이다. 초기에는 이런 알고리즘에 대해서 미래를 확실하게 알 수 있다거나, 범죄를 확연히 줄일 수 있다는 식으로 과장된 평가가 많았지만(Perry et al., 2013: 11-12), 시간이 지나면서 이런 과장은 수그러들고 현실적인 평가가 이를 대체했다.

범죄를 100% 정확히 예측하지는 못해도 예측적 알고리즘은 여러 이점이 있는 것으로 평가되었다. 우선 알고리즘은 특정한 지역이나 상황에 경찰의 순찰력을 집중할 수 있게 했고, 또 어떤 환경에서 범죄가 더 잘 일어나는지를 분석할 자료를 제공했다. 더 효과적으로 범죄를 예방하는 조치를 계획할 수 있게 했으며, 경찰이 특정한 전략을 사용할 수 있게 도와줄 수도 있었다. 이 프로그램에 비추어서 경찰이 세운 가설을 테스트해 볼 수도 있었고, 범죄들을 관통하는 패턴이나 경향을 분석할 수도 있었으며, 어떤 범죄 데이터가 분석적으로 유용한지에 대한 기준을 제공해 주기도 했다. 다른 빅데이터가 그렇듯이, 이 경우에도 범죄와 관련된 여러 데이터들이 알고리즘에 의해서 상대적으로 쉽게 상관관계로 이어질 수 있었다. 예를 들어 범죄 시간, 장소, 유형, 재산 손실, 희생자 유형 등의 상관관계를 얻어내면, 경찰이 이런저런 경우에 어떤 작전을 세워야 하는지 더 분명해졌다(Schlehahn et al., 2015).

그렇지만 프레드폴 알고리즘의 문제점도 곧 드러났다(Perry et al., 2013: 12-13).

36) *San Francisco Weekly*(2013. 10. 30), "All Tomorrow's Crime: The Future of Policing Looks a Lot Like Good Branding."; *Santa Cruz Sentinel*(2012.02.26), "Modest Gains in First Six Months of Santa Cruz's Predictive Police Program".

무엇보다 알고리즘에서 사용하는 데이터의 질이 낮다는 것이 문제가 제기될 수 있었다. 예를 들어 가게 주인들이 아침 8시에 절도를 신고했다면, 이것만으로는 8시에 절도가 일어난 것인지 아니면 그 때 가게 문을 열다가 절도를 발견한 것인지 불분명했다. 경찰의 입장에서도 알고리즘이 핫스팟을 적시했다고 해도 적시된 핫스팟에서 대체 무엇에 주목해야 하는지 이해하기 힘들었고, 따라서 자신이 사용하는 알고리즘의 효력을 평가하기 쉽지 않았다. 그렇지만 가장 심각한 문제로 지적된 것은 이런 프로그램이 시민권, 특히 미국 수정헌법 제 4조(The Fourth Amendment)에 명시된 프라이버시의 권리를 침해한다는 비판이었다. 실제로 몇 년이 지나지 않아서 이런 비판이 학계, 법조계, 인권단체에서 쏟아졌다.

『대량살상 수학무기』의 저자 캐시 오닐은 프레드폴 알고리즘을 만들 때 경범죄를 데이터에 포함시킨 것부터 잘못이라고 비판했다(오닐, 2017). 보통 경범죄는 거리에서 술을 마시면서 소란을 피우거나 대마초를 흡입하는 행위 등을 포함하는데, 중산층 이상의 백인들이 많이 사는 지역에서는 이런 행위가 집 안에서 일어나고 따라서 경찰의 순찰에 의해 적발되지 않는 반면에, 흑인들이 많이 거주하는 빈민가에서는 이런 행위가 거리에서 주로 일어나고 따라서 경찰에 의해 쉽게 적발되었다는 것이다(Ferguson, 2015: 402). 경범죄의 데이터가 포함되면서 처음부터 흑인들이 많이 거주하는 더 많은 지역이 범죄의 핫스팟으로 분류되었고, 경찰은 이런 지역을 순찰하다가 의심스럽게 보이는 사람들을 세워서 검문하게 되고, 이 중에 마약이나 수상한 물건을 가진 사람들을 검거하게 되는 식이었다. 이런 검거는 프레드폴 알고리즘의 성공률을 높이면서 다시 이 알고리즘에 입력되고 데이터로 기능하며, 이는 다시 경찰로 하여금 흑인들이 사는 지역을 집중 순찰하도록 이끈다(오닐, 2017).

또 다른 연구자인 젤프스트(Selbst, 2018)는 프레드폴의 예측이 네 가지 점에서 문제가 있다고 지적했다. 첫 번째 문제는 범죄를 컴퓨터 코드화하는 데에서 발생한다. 범죄는 다양한 방식으로 이루어지며 그 유형도 다양지만, 예측 프로그램은 이 중에서 컴퓨터가 쉽게 인지할 수 있는 범죄에 초점을 맞춘다. 그 중 대표적인 것은 절도를 포함한 재산범죄(property crime)이다. 이런 범죄는 지리학적으로 분석이 가능하기 때문에 알고리즘이 선호한다. 예를 들어 프레드폴 알고리즘은 지역을 500피트x500피

트(약 150미터x150미터)의 격자로 나눠서 분석한다. 재산범죄의 발생비율이 높은 지역을 순찰하는 경찰은 이 지역에서 살인이나 방화와 같은 다른 범죄도 더 많이 일어날 것이라고 가정한다. 그렇지만 이런 재산범죄의 발생비율이 다른 범죄의 발생비율과 항상 동일한 것은 아니다. 따라서 쉽게 지역화 되는(territorialized) 재산범죄를 기준으로 순찰을 하면 재산범죄의 발생비율이 낮은 지역은 경찰 순찰에서 과소평가되는 결과가 생기고, 이는 지역 간의 차별을 불러올 수 있다. 이런 지역이 흑·백 인종의 거주 지역으로 나뉘어 있다면, 이는 인종에 대한 차별로 이어진다(ibid.: 131-133).

두 번째 편향은 빅데이터를 “훈련”시키는 과정에서 발생할 수 있다. 새로운 데이터를 처리하기 위해서는 “기준 값”(ground truth)을 정하고, 이를 기준으로 이후의 데이터를 평가해야 한다. 범죄 예측 알고리즘에서는 무엇을 기준 값으로 사용했을까? 앞서 나왔지만, 순찰을 하는 지역의 과거의 범죄 발생 데이터가 기준 값이 되었다. 그런데 이 과거 범죄 데이터에 문제가 있다. 우선 경찰이 가진 데이터가 모든 범죄에 대한 데이터가 아니다. 신고된 범죄, 혹은 경찰이 기록한 범죄는 전체 범죄의 일부분에 불과하다. 이는 가벼운 절도 사건일 경우에는 더더욱 그러하다. 또 범인에 대한 경찰의 기록은 주로 체포에 국한된다. 경찰에 의해 체포된 수상한 인물이 나중에 무죄로 방면되었어도 경찰에는 체포 기록이 남게 되고, 이것이 범죄 예측 프로그램에 입력된다. 그런데 경찰에 의한 체포가 인종적으로 편향되었다는 것은 여러 연구에 의해서 확인된 사실이다(Beckett, et al., 2006; Gelman, et al., 2007). 즉, 프레드폴 같은 알고리즘은 인종적으로 편향된 기준 값을 사용했으며, 처음부터 흑인이나 히스패닉이 많이 사는 지역을 범죄의 핫스팟으로 판별하고 이에 순찰력을 집중했을 가능성이 매우 큰 것이다(Selbst, 2018: 133-135).

세 번째 편향은 데이터의 특정한 특징을 선택하는 데에서 일어난다. 경찰은 모든 범죄를 다룰 수 없듯이, 프레드폴에도 모든 변수를 입력할 수 없다. 예를 들어 경찰은 지역, 범죄 유형, 시간에 집중할지, 아니면 날씨, 휴일, 알려진 범죄자의 거주지에 집중할지를 선택해야 한다. LA 경찰이 사용하는 프레드폴은 전자를 선택했고, 시카고 경찰이 사용하는 헌치랩(Hunchlab)이라는 알고리즘은 후자를 선택했다. 한 쪽을 선택하면 다른 쪽이 희생되며, 따라서 그 결과는 원칙적으로 편향될 수밖에 없다. 특히

이 과정은 경찰이 데이터 브로커(data broker)로부터 데이터를 구매해서 사용할 때 더 커진다. 대부분의 데이터 브로커는 구매력을 파악하려 하는 기업들 위해 데이터를 수집하는데, 범죄가 아닌 구매력에 맞춰져 있는 데이터를 범죄 예측에 사용할 때 오류의 확률은 더 커진다(ibid.: 136). 마지막 편향은 “정확도”와 “공정성”의 불균형이다. 알고리즘은 정확한 예측을 위해서 구역을 정하고, 우편번호나 주소 정보를 사용한다. 이렇게 더 정확하게 범죄의 발생을 예측하려고 하면, 어떤 사람들은 본인의 의지와 무관하게 그 지역 근처에 거주하는 것 때문에 불이익을 받게 된다. 예측은 더 정확해질 수 있지만, 공정성은 더 손상되는 것이다(ibid.: 137).

이런 알고리즘을 사용하면 다음과 같은 상황을 쉽게 예상할 수 있을 것이다. 프레드 폴은 오늘 오후 4시에 특정 지역을 절도 핫스팟으로 예측했고, 이곳을 순찰하던 경찰은 주차장에서 두 명의 흑인 젊은이가 차의 내부를 들여다보면서 얘기를 나누고 있는 것을 발견했다. 경찰은 이들에게 검문을 요청해서 몸을 수색했고, 이 중 한 명에게서 대마초를, 다른 한 명에게서 드라이버를 발견하고 이들을 체포했다. 그런데 이런 경우 경찰의 검문, 몸수색은 공권력에 의한 부당한 사생활침해를 금지한 미국 수정헌법 제 4조에 위배되는가? 아마 ‘스몰 데이터’(small data) 시대였던 과거에는 이런 검문은 불법이라고 간주되었을 것이다. 체포된 사람들이 범죄로 간주될 수 있는 의심스러운 행동을 하지 않았기 때문이다. 미국의 경우 지금까지 법원은 경찰이 “상당한 이유”(probable cause)나 “합리적 의심”(reasonable suspicion)이 있을 경우에만 미국 수정헌법 제 4조를 어길 수 있다고, 즉 수상하다고 생각하는 사람들을 불러 세워서 수색을 할 수 있다고 판결했다. “합리적 의심”의 기준이 너무 낮다는 비판도 있지만 경찰이 “합리적 의심”을 했다는 것을 증명해야 하는 상황이 되면 그는 자신이 수상하다고 생각한 사람의 행동이 범죄와 연루되었다고 판단한 여러 가지 데이터 포인트(data point)를 제시해야 했다. 경찰이 제시한 데이터 포인트가 충분하지 않다고 해서 법원은 종종 경찰의 체포를 무효화하기도 했다. 그렇지만 빅데이터를 이용한 예측 프로그램들은 전반적으로 경찰이 “합리적 의심”을 했음을 지지하는 엄청난 데이터를 제공해 줄 수 있다. 과거에는 정당화되기 힘들었던 경찰의 검문과 수색이 충분히 정당화될 수 있다는 얘기다. 따라서 법학자들은 빅데이터와 예측 알고리즘이 그렇지 않아도

인종차별 같은 차별에 무력했던 미국 수정헌법 4조를 더 약화시키는 결과를 낳고 있다고 판단하고 있다(Ferguson, 2015).³⁷⁾

미국 수정헌법 4조를 약화하면서 법적으로 제재를 받지 않고, 그렇지만 차별적인 결과를 낼 것이 거의 확실한 프레드폴 같은 알고리즘의 사용을 어떻게 저지할 수 있을까? 경찰이 이런 차별적인 알고리즘을 사용하는 것의 위법성을 따지기 힘들고, 또 여러 가지 내적, 외적 이유에서 이를 계속 사용한다면(Ferguson 2017), 이 차별적 체포를 줄이거나 무력화할 수 있는 방법 중 하나는 법원의 판결이다. 즉 빅데이터와 예측 알고리즘에 입각한 체포를 “합리적 의심”의 기준을 만족하지 못한 위법으로 판정하는 것인데, 퍼거슨(Ferguson, 2015)은 이를 위해 판사가 알고리즘이 예측한 수치를 요구하고, 역시 예측한 정확한 시간, 장소를 공개하라는 요청을 하는 것이 중요하다고 주장한다. 예를 들자면, ‘알고리즘이 예측했기 때문에 체포할 수 있었다’는 경찰의 진술과 ‘알고리즘이 절도 가능성을 2.06%로 예측했다’는 보고는 큰 차이가 나기 때문이다. 마찬가지로 정확한 핫스팟의 위치와 시간 정보를 경찰이 법원에 제공하는 것도 중요하다. 이렇게 되면 판사는 빅데이터라는 신탁의 예언 뒤에 가려진 충족되지 않은 이론상의 가정들, 속성들 사이의 상충적 관계(trade-off), 개인의 자결권 문제들을 비로소 볼 수 있게 되고, 이에 근거해서 경찰의 체포가 합리적 의심에 근거한 것이었는지를 더 종합적으로 판단할 수 있다.

반면에 젤프스트(Selbst, 2018)는 경찰의 사용을 제한하는 방안을 제시했다. 미국 정부는 1970년에 제정된 국가환경정책법(National Environmental Policy Act: NEPA)에 개별사업(project)뿐만 아니라 정책, 계획, 프로그램까지 환경영향평가를 하게 규정했고, 사업의 주관 기관이 사업과 관련된 의사결정이 어떻게 내려지는지를 이해한다는 것을 보이는 환경영향평가서(Environmental Impacts Statement, EIS)를 제출하는 것을 의무화했다. 이와 비슷하게 젤프스트는 범죄 예측 알고리즘을 사용하는 경찰이 “알고리즘영향평가서”(Algorithm Impact Statements, AIS)를 만들어

37) 또 다른 선례로 미국 대법원이 “우범”(high-crime) 지역에서 경찰이 합리적 의심의 기준은 완화할 수 있다고 판결한 것을 들 수 있다. 예측 프로그램이 핫스팟으로 지정한 지역은 우범 지역으로 충분히 해석될 수 있고, 이럴 경우에 이 지역에서는 경찰이 의심스러운 사람은 불러 세워서 몸수색을 할 수 있다(Perry et al., 2013: 13).

서 제출해야 한다고 주장했다. 그에 의하면 이 평가서에는 경찰과 같은 기관이 자신이 사용하는 알고리즘에 차별적 요소가 포함되어 있음을 인지한다는 사실과, 시민사회의 요청이 있을 때 이 사용에 대한 자료를 투명하게 공개하겠다는 선언이 담겨야 한다. 마치 환경영향평가가 산업 발전을 위해서 오염과 건강 침해는 어쩔 수 없다는 과거의 인식을 바꾸었듯이, 알고리즘영향평가 역시 데이터 산업의 발전을 위해서는 소수의 인권침해는 어쩔 수 없다는 현재의 인식을 바꿀 수 있다는 것이다.

판사에게 정량적 데이터를 요청하게 하지는 퍼거슨의 제안이나 알고리즘영향평가서를 작성하도록 하지는 젤프스트의 제안은 알고리즘이 계속 사용된다는 가정 하에 만들어진 제안이다. 이러한 가정은 인공지능 알고리즘이 인간의 판단보다 더 나은 판단을 할 것이라는 또 다른 가정에 근거하고 있다. 그런데 인공지능이 인간보다 더 나은 판단을 하는가? 인공지능 알고리즘이 사법이나 치안에서의 업무를 해결하는 가장 좋고 공평한 해결책인가? 아니면 가장 값싸고 효율적인 해결책인가? 알고리즘이 문제를 해결하는 방식이 가장 (혹은 얼마나) 좋고 공평한지, 혹은 가장 (혹은 얼마나) 값싸고 효율적인지 판단하기 위한 조건은 무엇이며 그 조건은 누가 어떻게 정할 수 있는가? 이 문제에 대해서는 아직 충분한 연구가 부족하기 때문에 이를 본 연구에서 깊게 다루기 힘들다. 그렇지만 필자는 다음 절에서 이런 문제에 접근할 수 있는 원칙적인 방법을 간략히 논의해 볼 것이다.

5. 알고리즘 공정성 문제에 대한 접근 방안들

지금까지 본 연구는 사법과 치안의 영역에서의 인공지능 알고리즘이 어떻게 민감한 그룹에 대한 차별적으로 보이는 판단을 내고, 이를 재생산하는 데에 기여하는지를 논한 연구들을 분석했다. 사실 인공지능 알고리즘이 낳는 차별은 이런 영역에 그치는 것이 아니다. 오히려 이런 분야보다 더 일상적으로 경험하는 것은 구글의 검색에서 사용되는 ‘단어 끼어 넣기’(word embedding), 네이버가 뉴스를 보여주는 알고리즘에서 보인 편향, 차별이다. 또한 구글 이미지 검색, 번역 서비스에서도 남/녀 차별이 존재한다는 사실이 지적되었다(Noble, 2018). 미국에서는 학생을 학교에 배정하는 알고리즘, 입사 서류를 평가하는 알고리즘, 면접을 수행하는 인공지능도 차별적이라는 주장이 제기되었고, 의료 알고리즘에도 비슷한 문제가 있을 수 있다는 지적도 나왔다.³⁸⁾ 인공지능이 우리의 일상생활에 더 많이 사용되면서, 알고리즘 속에 숨겨진 차별이 속속 드러나고 있는 것이다.

문제는 이런 빅데이터 인공지능 알고리즘이 우리 사회에 만연한 차별을 반영하는데 그치지 않고 이를 영속시키고 증폭시킨다는 것이다. 차별적인 사회가 낳은 데이터를 가지고 인공지능 알고리즘은 차별적인 결과를 만들어 낸다. 그렇지만 우리는 인공지능의 내부를 들여다볼 수 없다. 즉 우리는 왜 알고리즘이 특정한 판단을 내린 것인지 그 내부 기제나 작동 원리를 볼 수 있는 허가를 받지 못하거나, 매우 개략적인 수준의 설명만 제공되어 어렵게 추정하는 정도만 가능하거나, 상세한 방식이 공개되더라도 알고리즘을 동작시키는 패턴 인식이나 통계적 방법론 등을 전문적으로 이해하기 어렵다. 설명 이에 대한 전문가들의 분석이 있어도 알고리즘이 자동적으로 생성해 낸 분류 기준들이 때때로 인간의 판단 기준이나 직관에 배치되기도 한다(Burrell, 2016), 이런 여러 이유 때문에 우리는 인간의 머리로는 도저히 분석할 수 없는 빅데이터를 순식간에 분석해 내는 인공지능 알고리즘에 의해서 산출되는 결과물들을 인간이 낳은 결과물보다 더 낫고, 더 공평하다고 생각한다.

38) 의료 알고리즘에 대해서는 많은 논의가 있다. 이를 간략하게 정리한 글로 Hart(2017)을 참조하면 좋다.

알고리즘이 인간의 판단보다 더 나은 판단을 제공하는가? 컴파스 알고리즘은 재범률을 따가지 위해서 137개의 문항에 대한 답을 검토한다고 알려져 있다(Angwin et al., 2016). 반면에 사람은 보통 10개 내외의 항목을 검토해서 판단을 내린다고 알려져 있다. 사람들은 137개의 데이터 포인트를 연결하고 분석하고 종합해서 내린 결론이 10개의 데이터를 검토해서 얻어진 결론보다 더 낫다고 생각할 것이다. 그렇지만 2018년에 Science Advances 지에 출판된 연구는 컴파스의 판단이 법률 비전문가 인간의 판단보다 더 나은 것은 아니라는 점을 보여준다.³⁹⁾ 재범 확률 예측의 정확도에 있어서도 인간의 판단이 (흑인 피의자: 68.2%, 백인 피의자: 67.6%) 알고리즘의 판단보다 (흑인 피의자: 64.9%, 백인 피의자: 65.7%) 미세하게 더 정확했고, 인간이 내린 판단에서 흑인에 대한 위양성의 비율도 (흑인 피의자: 37.1%, 백인 피의자: 27.2%) 알고리즘의 판단에 비해 (흑인 피의자: 40.4%, 백인 피의자: 25.4%) 약간 줄어들었고, 흑인/백인의 위양성율의 차이도 줄어들었다. 인간의 판단에서 백인에 대한 위음성도 (흑인 피의자: 29.2%, 백인 피의자: 40.3%) 알고리즘의 판단에 비해 (흑인 피의자: 30.9%, 백인 피의자: 47.9%) 줄어들었고, 백인/흑인의 위음성율의 차이도 줄었다. 모든 경우에 인간의 판단이 아주 조금이나마 더 바람직한 결과를 낳았던 것이다 (Dressel and Farid, 2018). 이런 연구가 다른 영역으로도 확장된다면 우리 사회가 빅데이터, 인공지능에 대한 과학주의적 환상을 걷어냄으로써 그 가능성과 역력에 대해 보다 현실적인 기대치를 설정하고 그 목표를 꾸준히 달성해 가는 데 일조할 수 있을 것이다.

인공지능 알고리즘의 문제가 드러난 뒤에 여러 인권단체들은 인공지능에 의한 차별을 비판하고 알고리즘에 대한 감사(auditing)를 주장해 왔다. 인공지능을 감사하는 방법으로는 알고리즘 자체를 들여다보는 방법이 있을 수 있는데, 이는 알고리즘에 대한 화이트박스 테스트링(white-box testing)이라고 알려진 방법이다. 그렇지만 기업이 지

39) 인간 참여집단과 알고리즘은 모두 2013-2014년 플로리다 주의 브로워드(Broward) 카운티의 데이터베이스에 대해 판단을 내렸다. 알고리즘은 7214 명의 피의자 전원에게 판정했고, 인간 참여자들은 랜덤하게 구성되어 전체 모집단 데이터와 유사한 통계 특성을 갖는 1000건의 피의자 사안에 대해 판단했다. 총 2회차의 실험 중 피의자의 인종을 고려하지 않은 1차 실험에 참여한 462명 중 400명의 답변이 유효답변으로 연구에 활용되었고, 피의자의 인종을 고려한 2차 실험의 449명의 참여자 중 400 명의 답변이 유효하게 연구에 활용되었다(Dressel and Farid, 2018).

적 재산권을 주장하는 알고리즘을 공개하지 않는 경우가 많기 때문에, 이런 방법이 불가능한 경우가 많이 있다. 또한 공개가 가능하다고 가정하더라도, 설명하기 쉽도록 만든 예측 모델을 실제에 적용할 수 있는 수준으로 유연하게 개선시켜 가다보면 불가피하게 모델의 복잡성이 증가한다. 일례로 분류 알고리즘이 훈련 데이터에 지나치게 최적화되는 것을 피하고, 학습 과정에서 관찰되지 않았던 새로운 패턴에 적응하기 위해서 최적화 수준을 의도적으로 제한하는 정규화(regularization), 그리고 훈련 데이터를 소집단으로 쪼개거나 데이터의 속성을 소집단으로 쪼개어 랜덤화(randomization)하는 과정이 필요하다. 하지만 이들 과정이 분류 알고리즘 단계부터 관여하므로, 결국 유연성을 얻은 대가로 모델에 대한 해석가능성이 희생되게 된다. 다시 말해 투명성을 일정 수준 달성하기 위해서는 어느 정도 모델의 효과성을 희생시켜야 하는 상충관계가 있고, 그 역도 역시 성립한다. 이런 이유 때문에 잘 작동하는 인공지능의 경우에는 만족할 만한 검사가 가능한 정도의 투명성을 확보하기가 힘들게 된다(김도훈, 2018: 17-22).

따라서 알고리즘 검사를 주장하는 인권단체는 인공지능 알고리즘에 대한 블랙박스 테스트(black-box testing)에 의존하는 경우가 많다. 이는 중립적인 데이터를 확보해서 이를 알고리즘을 통해 처리하게 한 뒤에, 그 결과가 중립적으로 나왔는지를 보는 것이다. 이 때 사용하는 중립적인 데이터는 연구자들이 활용할 수 있도록 자신의 메타정보, 데이터, 알고리즘의 출력 데이터를 자발적으로 제공하는 사용자들을 모집하는 방식 등을 통해서 얻어질 수 있다(Sandvig et al., 2016). 하지만 이런 방법으로 중립적인 데이터를 얻는다는 게 현실적으로 쉽지 않은 경우가 많기 때문에, 이 역시 손쉬운 방법은 아니다. 게다가 중립적인 데이터를 얻어서 인공지능을 훈련시켰다고 해도, 이것만 가지고는 이런 인공지능이 새로운 데이터에 대해서 중립적으로 공정하게 예측할 수 있는가를 보장할 수 없다(Zhang et al., 2018).

따라서 알고리즘에 대한 검사는 사법권을 가진 정부기관이나 위원회에 의해서 이루어지는 것이 현실적으로 가능한 방법이다. 서론에서 언급했듯이 알고리즘의 투명성을 요구하는 뉴욕시의 법안 같은 조치가 이런 검사를 실질적으로 효과적인 것으로 만들어 준다. 비슷한 문제의식을 가지고 유럽연합이 2017년에 제정한 개인정보보호법

(General Data Protection Regulation, GDPR)은 개인이 자동화된 프로파일링의 결정 대상이 되지 않을 권리를 보장하고 있으며, 인공지능 알고리즘이 내린 결정에 대해서 개인이 설명을 요구할 권리를 명시하고 있다. 덧붙여 알고리즘뿐만 아니라 공공 데이터가 공개되는 것도 알고리즘 설명 문제를 개선하는 데에 도움이 될 수 있다. 뉴욕시는 2012년 3월 세계 최초로 기술 정책이나 행정 명령보다 상위 수준에서 오픈 데이터 법(Open Data Law)을 지방법으로 제정하여⁴⁰⁾ 2018년 말까지 단일 웹 포털에서 모든 공공 데이터가 접근 가능해야 한다고 명시했다.⁴¹⁾ 그 결과물인 뉴욕시의 공공 데이터 포털에서는 비단 보건, 위생, 교통 등의 일상 데이터뿐만 아니라 경찰국의 시내 범죄, 공원 범죄, 범죄 진압 활동 등의 다양한 데이터가 공개되어 있다(Poirier, et al., 2018).⁴²⁾ 한국의 경우 행정안전부 주도로 범정부 공공데이터 개방 창구인 공공데이터포털(data.go.kr), 그리고 정부 및 민간 사이의 데이터 활용 관련 협의단체인 “공공데이터 기반 사회혁신을 위한 오픈데이터포럼” (odf.or.kr) 등이 유사한 역할을 수행하고 있다.⁴³⁾ 이러한 데이터 공개의 범위와 수가 늘어날수록 향후 치안, 사법 등에 관련한 알고리즘의 판단 결과를 두고 논쟁이 불거졌을 때 알고리즘의 판단 결과를 설명하는 것을 도울 수 있는 참고자료가 많아질 수 있다.

사회적 압력이 거세지면 문제의 해결에 시장의 논리가 긍정적으로 기능할 수도 있다. 최근에 인공지능에 대한 차별의 문제가 인공지능의 사회적 확산에 가장 장애가 되는 심각한 문제로 부상함에 따라서 이를 극복하려는 노력이 실리콘 밸리의 거대 기업과 스타트업에 의해서 이루어지고 있다. 알고리즘의 설명가능성(explainability)⁴⁴⁾ 및 해석가능성(interpretability)을 담보하려는 노력, 모델 구축, 추론, 예측, 의사 결

40) 전자신문(2013. 4. 24), 「금융의 중심 뉴욕, IT 메카까지 넘본다」.

41) City of New York (n.a.) “Laws and Reports” <https://opendata.cityofnewyork.us/open-data-law/>

42) City of New York (n.a.) “NYC Open Data” <https://opendata.cityofnewyork.us/> ; City of New York (n.a.) “Results matching of Policy Department (NYPD) | NYC Open Data” https://data.cityofnewyork.us/browse?Dataset=Information_Agency=Police+Department+%28NYPD%29

43) 연합뉴스(2017. 7. 27), 「행안부, 오픈데이터포럼 발족」.

44) “알고리즘 설명가능성” 연구는 비단 기업뿐만 아니라 자동화된 의사결정이 인명 살상 등의 치명적 결과로 이어질 수 있는 DARPA 같은 미국 국방부의 기관에서 선도적으로 수행되고 있다. 설명가능한 인공지능 프로젝트를 공모한 Gunning(2016)을 보면 그 목적이 “미래의 전쟁전사들이 새롭게 출현하는 인공지능 기계 파트너의 세대를 이해하고, 적절하게 신뢰하고, 효과적으로 다루기 위해서 필수적”이라고 하고 있다.

정에서 상대적으로 보다 통합적인 프레임워크를 제공하는 베이지안 추론(Bayesian reasoning) 등의 분야에서부터 알고리즘 해석가능성의 실질적인 개선을 이루어가려는 노력(Chakraborty et al., 2017: 5), 더 공정한 알고리즘을 만들려는 노력, 차별 같은 문제가 드러나면 이를 고칠 수 있게 만들려는 노력이 가시화되는 것이다. 타 경쟁사로 핵심 정보가 유출되지 않는 한도 내에서 기업이 알고리즘 설명 활동을 적극적으로 한다던가(Michael and Lupton, 2016; 오요한, 2018), 학술단체의 윤리 위원회에서 “자율 지능 시스템의 윤리에 대한 국제 이니셔티브”⁴⁵⁾와 “알고리즘 투명성 및 설명책임에 대한 성명서”⁴⁶⁾ 등의 활동을 통해 학계와 산업계를 향한 권고사항을 제안한다거나, 연구자들이 자생적으로 머신러닝의 공정성, 설명책임, 투명성(Fairness, Accountability, and Transparency in Machine Learning, FAT/ML)을 추구하는 공동체를⁴⁷⁾ 만든 사례도 이러한 맥락에서 이해될 수 있다.⁴⁸⁾

그렇지만 이런 노력이 계속된다고 해도 절대적으로 공정한 알고리즘을 만들 수 없는 경우가 있음을 염두에 두어야 한다. 설명가능한 인공지능이 자신이 왜 그런 결론을 내렸는지를 인간에게 이해할 수 있는 언어로 설명하던지 혹은 그 중간의 과정들을 시각화해서 보여준다고 해도, 사람은 그것이 설명인지 변명인지 알 수가 없다. 이것을 설명으로 받아들이기 위해서는 비슷한 경우에 인공지능이 어떤 결정을 내렸는지를 알아야 한다. 즉, 인공지능을 들여다보는 것보다, 이것이 일관적인지 아닌지를, 즉 얼마나 공정한지를 이해하는 것이 인공지능에 대한 신뢰를 형성하는 데 더 중요하다는 것이다. 사람들은 “왜 P인가”에 대한 설명보다 “왜 Q가 아니라 P인가”에 대한 설명을

45) The IEEE Global Initiative on Ethics of Autonomous and Intelligent Systems (2017).

46) ACM U.S. Public Policy Council and ACM Europe Policy Committee (2017).

47) www.fatml.org/

48) 한편 컴퓨터 과학 전문가들이 머신 러닝, 인공 지능의 공정성을 위해 조직한 학술단체 뿐만 아니라 기술 기업들이 사회·윤리적 문제에 공동대응하고자 결성한 연합체인 The Partnership on AI to Benefit People and Society, 혹은 그러한 목적으로 설립된 회사 OpenAI 등의 활동들이 공통적으로 전제된 가정에 대해 비판적인 견해도 존재한다. 대니얼 그린 (Daniel Greene) 등의 저자들의 지적에 따르면, 이러한 활동을 벌이는 전문가 단체들 및 기술기업들은 윤리와 가치들이 기술 및 디자인 전문가에 의해 다루지는 것이 최선이라는 기술 결정론적 시각을 전제로 하고 있다. 또한 이 전문가 단체들은 과학기술학에서의 비판적 방법론으로부터 차용한 절차적 요소들과 맥락적 프레임워크를 공유하면서도 정작 과학기술학자들의 궁극적 목표 중의 하나인 사회 정의와 균등성에 대한 추구를 논외로 두고, 사업 윤리(business ethics)를 “도덕적 배경”(moral background)으로 삼고 있다고 볼 수 있다 (Greene, Hoffmann & Stark, 2019).


업을 때 만족하기 때문이다(Miller, 2018).

공정한 알고리즘을 만들려고 할 때, 우리가 컴파스의 경우에 보았듯이 알고리즘 공정성에 일종의 상충적 관계(trade-off)가 있음을 감안해야 한다. 즉 완벽한 공정성이란 존재하지 않는다는 얘기다. 그렇다면 결국 그때그때 맥락과 적용 분야에 맞게 공정성을 찾아가야 한다는 게 중요해 진다. 이 알고리즘이 어떤 목표를 가지고 있는지, 그 목표를 달성하기 위해서 어떤 기준을 정했는지, 사용하는 데이터가 비교적 공정하게 얻어진 것인지, 사회적으로 시급한 정의(justice)가 어느 영역에서 찾아져야 하는지, 특정하게 정의된 정의를 실현하기 위해 손쉽게 수치화될 수 있는 요인들은 무엇이며 이 요인들에 답지 되지 못하는 정의의 포괄적인 사례가 무엇인지와 같은 문제를 고려해야 한다는 것이다. 알고리즘은 보편적이고 중립적인 것이 아니라 상황지어지고(situated), 사회기술적 맥락에 의해서 구성된(configured) 것임을 고려하면서 문제에 접근해야 한다.

6. 한국의 인공지능 알고리즘의 공정성 문제

외국에서는 1950년대 이후에 인공지능이 발전하면서, 이에 대한 인문학적, 사회과학적 논의가 많이 있었다. 물론 인공지능 연구자들이 이런 논의에 크게 영향을 받은 것은 아니다. 예를 들어 많은 인공지능 연구자들은 컴퓨터가 사람처럼 생각할 수 없다는 휴버트 드레이퍼스(Dreyfus, 1972)의 주장이나, 강한 인공지능이 불가능하다는 존 설의 주장이 인공지능을 모르고 하는 얘기라고 평가했다(Searle, 1980). 그렇지만 이들이 이런 평가를 했다는 것은, 적어도 인공지능에 대한 이런 비판이 존재한다는 것을 알고 있었다는 사실을 증명한다. 드레이퍼스나 설의 주장은 초기에 많은 비판을 받았지만, 지금은 엔지니어들 중에서도 인간처럼 생각하고 의식을 가진 기계를 만드는 것은 먼 미래의 일이고, 어쩌면 불가능할 수도 있는 일이라고 생각하는 사람들이 있다. 인공지능의 사회적, 경제적 영향에 대해서도 많은 논의들이 있어왔고, 지금 진행되는 논의들은 이런 축적된 논의를 바탕으로 하고 있다.

[그림 1] “인공지능”에 대한 구글 트렌드의 검색 결과



이세돌-알파고의 대국이 있던 3월 13~19일에 인공지능에 대한 검색이 피크가 되었고, 그 이후로 증가세를 유지했음을 알 수 있다.

자료: 구글 트렌드

그렇지만 우리나라에서 인공지능에 대한 관심이 폭발했던 시점은 2016년이였다.

2016년 3월에 있었던 이세돌-알파고의 대국에서 현존하는 바둑 최강자인 이세돌 국수가 인공지능에게 패한 것에 대한 문화적 충격이 지금의 인공지능 연구에 대한 지원으로 이어지고 있는 것이다. 같은 시기에 다보스 포럼에서 제창한 “4차 산업혁명”이 상륙했고, 인공지능의 충격과 4차 산업혁명이 결합한 파고 속에서 대통령 선거를 맞았다. 각 후보는 모두 제각각 4차 산업혁명을 강조했고, 현 문재인 정부는 4차 산업혁명을 국가적 어젠더로 설정하고 있다. 정부는 인공지능을 4차 산업혁명의 핵심 기술이라고 판단하고 뒤늦게 인공지능 연구에 많은 연구비를 지원하고 있다. 과학기술정보통신부는 올해 2018년 예산으로 인공지능 국가전략프로젝트에 244억, 인공지능 원천기술개발 사업에 48억을 배정했다. 인공지능 국가 전략프로젝트는 알파고의 쇼크가 있던 2016년에 처음 신설되어 2017년 예산부터 실행되었던 것인데, 2017년에는 90억이 책정되었었다. 1년 만에 250% 증가세를 보였고, 이런 증가세는 앞으로도 당분간 계속 될 전망이다.⁴⁹⁾

우리가 지난 20-30년 동안 인공지능에 대한 연구와 그와 관련된 인문학적 성찰을 꾸준히 발전시켜왔던 것이 아니기 때문에, 우리 사회의 인공지능에 대한 연구와 담론에는 균형이 깨져 있는 부분이 존재한다. 외국의 경우에 인공지능 연구와 이에 대한 철학적 성찰이 서로를 견제하고 긴장을 유지하는 형태의 상호작용을 하면서 발전했다. 최근에 등장한 인공지능에 의한 차별에 대한 많은 사회과학적, 인문학적 논의는 이런 전통을 기반으로 한 것이다. 반면에, 우리나라의 경우는 서로에게 소원한 과학과 철학의 간극이 이 경우에도 그대로 드러난다. 인공지능을 연구하는 과학기술자들과 인공지능에 대해 인문사회과학적 논의를 하는 연구자들 사이에 의미 있는 접점이 거의 없는 것이다. 따라서 이런 문제 때문에 한국의 인공지능에 대한 사회적 담론은 양극화된다. 과학기술자들을 대상으로 한 설문조사는 90%가 4차 산업혁명의 결과에 대해서 낙관적이라는 사실을 보여준다(홍성욱 외, 2017). 여기서 보듯이 과학기술자들은 인공지능의 발전이 새로운 산업기술을 낳고, 새로운 일자리를 만들 것이라는 낙관론을 주로 피력한다. 이들은 기술의 발전이 일자리를 없앨 수 있다는 경제학자들의 주장이 인공지능 기술에 대한 무지에서 비롯되었다고 평가한다.

49) 이런 조급한 정책결정에 대한 비판으로는 홍성욱 외(2017)을 보라.

반면에 인문학자들 중에는 비관적인 사람들이 많다. 이들은 기술과 인간성은 서로 양립할 수 없는 것이기 때문에, 인공지능의 발전은 인간성을 황폐하게 만드는 결과를 낳을 것이라고 주장한다. 이들의 입장은 뛰어난 인공지능이 처음에는 우리를 도와주지만 곧 우리의 현 직장을 소멸시킬 것이며, 더 나아가서 초지능으로 발전한 인공지능이 인간을 지배하고 쓸모없는 존재로 만들며 결국 인간을 전부 말살시킬 거라는 식의 극단적으로 비관적인 형태를 취한다(이진우, 2017).

인공지능의 사회적 영향에 대한 논의가 양 극단을 달리는 이유는 여러 가지가 있다. 첫 번째로, 위에서 지적했듯이, 우리가 그 동안 인공지능과 같은 기술의 발전에 대해서 성찰하지 못했기 때문이다. 두 번째로는, 인공지능에 대한 우리의 관심이 알파고 이후에 급속도로 증가했기 때문이다. 우리는 서양의 체스는 컴퓨터가 마스터할 수 있지만, 동양의 바둑은 그럴 수 없다고 생각했다. 서양의 체스나 동양의 바둑 모두 컴퓨터가 잘 할 수 있는 게임이라는 생각을 하지 못하고, 바둑에는 기계가 접근할 수 없는 직관, 창의성, 심지어 어떤 혼(魂)이 존재한다고 생각했다. 이렇게 생각되던 바둑이 컴퓨터에게 패한 것을 목도한 이후에, 우리 사회에는 인공지능에 대한 두려움이 증폭되었다. “인공지능이 바둑 챔피언을 이기는 데, 못할 일이 무엇인가”라는 근거 없는 두려움이 팽배하게 되었다는 것이다. 가까운 미래에 판사, 의사, 기자, 교수, 교사, 공무원, 외교관, 심지어 예술가 같은 전문직업의 대부분이 인공지능에 의해서 대체될 것이라는 불안감이 만연했다. 사람들의 불안과 위험 체감도는 소위 전문 지식을 가진 사람들의 견해가 일치하지 않을 때 증가하는데, 인공지능에 대한 과학기술자들의 낙관론과 인문학자들의 비관론의 극단적 견해의 공존은 시민들의 불안감을 증폭시켰으면 증폭시켰지 해소하지 못했다.

따라서 이런 시점에 우리에게 요구되는 것은, 미래에 다가오는 인공지능의 영향을 좀 분석적인 틀로 나누어 생각해 보는 것이다. 그 중에는 지금 당장 문제가 되는 것이 있고, 가까운 미래에 문제가 될 수 있는 것들이 있으며, 먼 미래에 일어날지 아닐지 확실치 않은 얘기기 때문에 지금 이에 대해서 논하거나 준비하는 것이 의미가 없는 것이 있다. 이런 식으로 문제를 분리해서 생각하면, 비관론이나 낙관론의 한 극단 대신에 그 두 극단을 이어주는 넓은 스펙트럼을 볼 수 있으며, 대부분의 문제들에 대한

답은 이런 넓은 스펙트럼의 “회색 지대”에 존재함을 알 수 있다. 이런 문제들에도 불확실성은 남아 있지만, 그래도 우리는 바람직한 해답의 방향이 무엇인지를 어느 정도는 이해하고 그 쪽으로 기술 발전과 사회적 대응의 방향을 유도할 수 있다.

우리나라에서는 아직 편향적인 인공지능 알고리즘에 의한 차별이 큰 사회적 문제가 되지 않았다. 본 보고서에서 논의한 사법, 치안 영역의 알고리즘은 현재 검찰청, 경찰청 등에서 인공지능 연구자들과 함께 개발 중에 있다. 이런 알고리즘이 공정한지, 이런 알고리즘에 의한 성별, 인종별, 계층별 차별은 없는지에 대한 본격적인 논의는 이런 알고리즘이 어느 정도 완성되고 실험을 거치면서야 가능할 것이다.⁵⁰⁾ 그렇지만 이런 알고리즘이 사용이 안 되는 것은 아니다. 잘 드러나지 않지만 정부 규제기관이나 금융기관에서는 여러 종류의 자동화된 결정 알고리즘을 쓰고 있다. 이중 대표적인 것이 의심거래를 보고하거나, 이상금융거래를 탐지하고, 부당청구 등을 감시하는 데 사용되는 Fraud Detection System(FDS)이다. 이 시스템은 사람이 감시하기 힘든 부당청구를 알고리즘을 사용해서 추출하는 것인데, 국민건강보험공단은 이를 이용해서 2015년 1년 동안 장기요양기관 중에서 부당청구를 한 기관을 11,327개를 판별했다. 그런데 2016년에 이루어진 상위 150기관에 대한 감사에서 절반이 부당청구를 하지 않았음이 밝혀졌다. FDS가 의심스럽다고 판단한 기관 중 총 0.66%만이 부당청구를 했고, 75위를 한 기관의 부당청구액은 1,000원에 불과했다. 기관의 서비스 제공이 많을 경우에 부당청구 가능성을 높게 평가한 FDS의 알고리즘이 이런 문제를 불러 일으킨 것이었다. 이는 2016년 국정감사를 통해 밝혀졌고 건강보험공단은 이 시스템을 개선하겠다고 보고했다.⁵¹⁾

정부가 4차 산업혁명을 추진하고 스타트업을 장려하면서 사법과 치안 분야에서 법

50) 필자는 본 연구 프로젝트를 진행하면서 현재 사법, 치안 영역에서 인공지능 알고리즘을 개발한다고 알려진 연구자들을 접촉해서 현재 진행 상황에 대한 정보 요청을 했지만, 긍정적인 답을 얻지 못했다. 인공지능 알고리즘을 개발하는 인공지능 연구자이거나 이를 지원하는 회사, 단체는 사회과학자 개인에게 자신의 연구를 공개할 의무도, 이유도 없는 것이 현실이다. 이런 상황은 뉴욕시의 “알고리즘의 설명책임 법안”(algorithmic accountability bill)과 비슷한 법안이 우리에게도 필요한 이유를 보여준다고 할 수 있다.

51) 국제뉴스(2016.7.4.) 「무차별적 장기요양기관 현지조사 개선 …“FDS 재설계 필요”」

관이나 경찰의 판단을 돕는 알고리즘 역시 개발 중에 있으며, 이것이 낳는 여러 문제가 표면 위로 부상할 것임이 확실하다. 국내에서는 PredPol 같은 복잡한 모델은 아니지만 대검찰청에서 공개한 빅데이터를 기반으로 표준편차 타원체 및 공간밀도 분석과 같은 공간통계분석을 이용한 범죄발생확률 예측 알고리즘을 개발한 연구팀이 있다(차경현 외, 2014). 대검찰청과 경찰청에서는 각각 사법 알고리즘과 범죄 예측 알고리즘을 개발하기 시작했다.⁵²⁾ 미국과 유럽에서 인공지능 알고리즘이 불러일으키는 차별에 대한 사회적 논란을 분석한 본 연구는 가까운 미래에 이런 문제가 우리에게 닥치기 전에 우리가 이를 어떻게 사전 대응할 수 있는지에 대한 여러 가지 정책적 시사점을 제공한다. 남녀간, 연령간, 지역간, 자산 및 소득 계층간의 갈등, 편견, 혐오의 뿌리가 깊고 그 가지가 넓게 퍼져있고, 점차 다문화사회로 변하면서 인종간의 갈등도 표면화되는 한국 사회에서 인공지능 알고리즘의 확산은 사회적 차별을 반영하고 증폭시킬 수 있다. 알고리즘의 차별 가능성에 대해서 적극적으로 개입하고 알고리즘의 반민주주의적 사용을 반대하고 저지하는 “알고리즘 시민권”(algorithmic citizenship)의 형성이 어느 때보다도 더 절실하다.

52) 전자신문(2016. 8. 9), 「인공지능으로 범죄 막을 수 있을까…대검, 범죄예방체계 컨설팅 착수」; 매일경제(2016. 12. 29), 「범죄 용의자 시가 찾는다」.

참고문헌

- 강준만 (2014), 「왜 흑인이 사는 빈곤층 거주 지역에 붉은 줄을 긋는가? - redlining」, 『인문학은 언어에서 태어났다』, 서울 : 인물과사상사, 288-290쪽.
- 김기태·정재관 (2018), 「알고리즘이 이용자에게 미친 영향과 방법론적 쟁점: 알고리즘 편향(bias)과 개인정보 보호(privacy protection)를 중심으로」, 정보통신정책연구원, 『사이버 커뮤니케이션학회 공동주최 지능정보화 이용자 보호 학술 세미나 ‘알고리즘 시대 이용자 연구 어떻게 할 것인가’ 자료집(2018.6.14)』, 17-35쪽.
- 김도훈 (2018), 「알고리즘 책임성 논의와 알고리즘에 대한 이해」, 정보통신기술진흥센터 (IITP), 『주간기술동향』, 제16권, 제1호, 제1848호 (2018. 5. 30). 14-28쪽.
[<http://www.itfind.or.kr/WZIN/jugidong/1848/file4136408682380886323-184802.pdf>]
- 닉 보스트롬 (2017) 『슈퍼인텔리전스: 경로, 위험, 전략』 서울 : 까치글방. [Bostrom, Nick (2014), Superintelligence: Paths, Dangers, Strategies, Oxford: Oxford University Press.]
- 맥스 테그마크, 백우진 번역 (2017) 『맥스 테그마크의 라이프 3.0 - 인공지능이 열어갈 인류와 생명의 미래』 서울 : 동아사이 [Tegmark, M. (2017), Life 3.0: Being Human in the Age of Artificial Intelligence, New York, NY: Knopf.]
- 안중호·양지윤 (2006), 「기업 거버넌스 측면에서의 IT 거버넌스」, 『경영정보논총』, 제16권, 제1호, 97-119쪽.
- 양종모 (2016), 「인공지능의 위험의 특성과 법적 규제방안」, 『홍익법학』, 제17권 제4호, 537-565쪽.
- 에릭 브린올프슨, 앤드루 맥아피, 이한음 번역 (2014), 『제2의 기계 시대 - 인간과 기계의 공생이 시작된다』, 서울 : 청림출판. [Brynjolfsson, E., and A. McAfee (2016), The Second Machine Age: Work, Progress, and Prosperity in a Time of Brilliant Technologies, New York, NY: W. W. Norton & Company.]
- 오요한 (2018), 「알고리즘 조사 활동과 그 제약사항의 설정: 네이버 실시간급상승검색어 알고리즘에 대한 검증 논쟁을 중심으로」, 서울대학교 대학원 석사학위논문.
- 이진우 (2017), 「인공지능, 인간을 넘어서다」 한국철학회 춘계 학술대회 (이화여자 대학교, 2017. 3. 17).

- 정하웅 외 (2013), 『구글 신은 모든 것을 알고 있다』 서울 : 사이언스북스
- 차경현 외 (2014), 「빅 데이터를 이용한 범죄패턴 분석 알고리즘의 구현」 『통신위성우주산업연구회 논문지』 제 9권 제 4호, 57-62쪽.
- 캐시 오닐, 김정혜 번역 (2017), 『대량살상 수학무기: 어떻게 빅데이터는 불평등을 확산하고 민주주의를 위협하는가』, 서울 : 흐름출판. [O'Neil, C. (2016), Weapons of Math Destruction: How Big Data Increases Inequality and Threatens Democracy, New York, NY: Crown.]
- 프랭크 파스칼레, (2016), 『블랙박스 사회: 당신의 모든 것이 수집되고 있다』, 안양 : 안티고네. [Pasquale, F. (2015), The Black Box Society: The Secret Algorithms that Control Money and Information. Cambridge, MA: Harvard University Press.]
- 필립 K. 딕, 조호근 번역 (2015), 『마이너리티 리포트』, 서울 : 폴라북스 [Dick, P. K. and Triptree Jr., J. (2002), The Minority Report and Other Classic Stories, New York, NY: Citadel.]
- 홍성욱 외 (2017), 『4차 산업혁명이라는 유령 - 우리는 왜 4차 산업혁명에 열광하는가』 서울 : 휴머니스트.
- 홍성욱 (2018), 「이타적 인공지능은 가능할까? 인간과 호혜적인 인공지능」 이상수 외 저, 『이타주의자들』 제 7장. 서울 : 사회평론.
- ACM (Association for Computing Machinery) U.S. Public Policy Council and ACM Europe Policy Committee (2017), "Statement on Algorithmic Transparency and Accountability", Accessed on: Oct. 14, 2018. [Online]. Available: https://www.acm.org/binaries/content/assets/public-policy/2017_joint_statement_algorithms.pdf
- Angwin, J. and Larson, J. (2015), "The Tiger Mom Tax: Asians Are Nearly Twice as Likely to Get a Higher Price from Princeton Review", ProPublica. [<https://www.propublica.org/article/asians-nearly-twice-as-likely-to-get-higher-price-from-princeton-review>]
- Angwin, J. and Larwon, J. (2016), "Bias in Criminal Risk Scores is Mathematically Inevitable, Researchers Say", ProPublica. [<https://www.propublica.org/article/bias-in-criminal-risk-scores-is-mathematic>

- ally-inevitable-researchers-say]
- Angwin, J., Larson, J., Mattu, S. and Kirchner, L. (2016.05.23.), "Machine Bias There's software used across the country to predict future criminals. And it's biased against blacks", ProPublica. [<https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing>]
- Angwin, J., and Larson, J. (2016.07.29), "ProPublica Responds to Company's Critique of Machine Bias Story", ProPublica. [<https://www.propublica.org/article/propublica-responds-to-companys-critique-of-machine-bias-story>]
- Aradau, C. and Blanke, T. (2016), "Politics of Prediction: Security and the Time/Space of Governmentality in the age of Big Data", *European Journal of Social Theory*, 20(3), pp. 373-391.
- Asaro, P. M. (2013), "The Labor of Surveillance and Bureaucratized Killing: New Subjectivities of Military Drone Operators", *Social Semiotics*, 23(2), pp. 196-224.
- Barocas, S. and Selbst, A. D. (2016), "Big Data's Disparate Impact", *California Law Review*, 104(3), pp. 671-732.
- Beckett, K., Nyrop, K., & Pfingst, L. (2006), "Race, drugs, and policing: Understanding disparities in drug delivery arrests." *Criminology*, 44(1), pp. 105-137.
- Berk, R., Hoda, H. Shahin, J. Michael K. and Aaron R, (2018), "Fairness in Criminal Justice Risk Assessments: The State of the Art", *Sociological Methods & Research*, 20(10), pp. 1-42.
- Buri, Thomas. (2016), "Machine Learning and the Law: Five Theses", Paper read at NIPS Symposium, Barcelona (2016. 12. 8).
- Burrell, J. (2016), "How the machine 'thinks': Understanding opacity in machine learning algorithms" *Big Data & Society*, 3(1), pp. 1-12.
- Chakraborty, S., Tomsett, R., Raghavendra, R., Harborne, D., Alzantot, M., Cerutti, F., Srivastavaz, M., Preecey, A., Julieryy, S., Rao, R. M., Kelley, T. D., Brainesx, D., Sensoyk, M., Willis, C. J., & Gurram, P. (2017), "Interpretability of deep learning

- models: a survey of results.” In IEEE Smart World Congress 2017 Workshop: DAIS.
- Constantiou, I. D. and Kallinikos, J. (2015), “New Games, New Rules: Big Data and the Changing Context of Strategy”, *Journal of Information Technology*, 30(1), pp. 44-57.
- Corbett-Davies, S. Pierson, E. Feller, A. Goel, S. and Hug, A. (2017), “Algorithmic Decision Making and Cost of Fairness”, *KDD '17 (Knowledge Discovery and Data Mining)*. [<https://arxiv.org/abs/1701.08230>]
- Crawford, K. (2013.05.10), “Think Again: Big Data - Why the Rise of Machines isn't All it's Cracked Up to Be”, *Foreign Policy*. [<https://foreignpolicy.com/2013/05/10/think-again-big-data>]
- Curtis, N. (2016), “The Explication of the Social: Algorithms, Drones and(counter-) Terror”, *Journal of Sociology*, 52(3), pp. 522-536.
- d'Alessandro, B., O'Neil, C., & LaGatta, T. (2017), “Conscientious Classification: A Data Scientist's Guide to Discrimination-Aware Classification.” *Big data*, 5(2), pp. 120-134.
- Dastin, J. (2018), “Amazon scraps secret AI recruiting tool that showed bias against women,” *Reuters*, (2018. 10. 9) <https://www.reuters.com/article/us-amazon-com-jobs-automation-insight/amazon-scraps-secret-ai-recruiting-tool-that-showed-bias-against-women-idUSKCN1MK08G>
- Dennis, B. (2007), “The New Digital Borders of Europe: EU Databases and the Surveillance of Irregular Migrants”, *International Sociology*, 22(1), pp. 71-92.
- Der Derian, J. (2009), *Virtuous war: Mapping the military-industrial-media-entertainment-network*. Routledge.
- Dieterich, W., Mendoza, C., and Brennan, T. (2016), “COMPAS Risk Scales: Demonstrating Accuracy Equity and Predictive Parity”, Northpointe Inc. Research Department. Published by Northpointe (2016. 7. 8.). [<http://www.northpointeinc.com/northpointe-analysis>]

- Dourish, P. (2016), "Algorithms and Their Others: Algorithmic Culture in Context", *Big Data & Society*, Vol 3, No. 2, pp. 1-11.
- Dressel, J. and H. Farid. (2018), "The Accuracy, Fairness, and Limits of Predicting Recidivism", *Science Advances*, 4(1), [DOI: 10.1126/sciadv.aao5580].
- Dreyfus, H. (1972), *What Computers can't Do: A Critique of Artificial Reason*. New York : Harper & Row Publishers.
- Eubanks, V. (2018), *Automating Inequality: How High-Tech Tools Profile, Police, and Punish the Poor*, New York : St. Martin's Press.
- Ferguson, A. G. (2015), "Big Data and Predictive Reasonable Suspicion", *University of Pennsylvania Law Review*, 163(2), pp. 327-410.
- Ferguson, A. G. (2017), *The Rise of Big Data Policing: Surveillance, Race, and the Future of Law Enforcement*. NYU Press.
- Frey, C. B. and M. A. Osborne (2013), "The Future of Employment: How Susceptible are Jobs to Computerisation?" Oxford Martin School Working Paper. [https://www.oxfordmartin.ox.ac.uk/downloads/academic/The_Future_of_Employment.pdf]
- Friedler, S., Scheidegger, C., and Venkatasubramanian, S. (2016), "On the (im)possibility of Fairness", [<https://arxiv.org/abs/1609.07236>]
- Gelman, A., Fagan, J., & Kiss, A. (2007), "An analysis of the New York City police department's 'stop-and-frisk' policy in the context of claims of racial bias." *Journal of the American Statistical Association*, 102(479), pp. 813-823.
- Gibbs, S. (2015.07.08), "Women less likely to be Shown Ads for High-paid Jobs on Google, Study Shows", *The Guardian*. [<https://www.theguardian.com/technology/2015/jul/08/women-less-likely-ads-high-paid-jobs-google-study>]
- Gillespie, T. (2014), "The Relevance of Algorithms", in T. Gillespie, Boczkowski, P.J., and Foot, K.A. eds., *Media Technologies: Essays on Communication, Materiality, and Society*, pp. 167-193, MIT Press.
- Greene, D., Hoffmann, A. L., and Stark, L. (2019), "Better, Nicer, Clearer, Fairer: A

- Critical Assessment of the Movement for Ethical Artificial Intelligence and Machine Learning”, The 52nd Annual Hawaii International Conference on System Sciences (HICSS), Maui, HI.
- Gunning, David. (2016), “Explainable Artificial Intelligence (XAI)”, DARPA-BAA-16-53 (2016. 8. 10).
- Hacking I. (1995), “The looping effect of human kinds”, In Sperber. D. Premack, D ., and Premack, A. J. eds., Causal cognition: a multidisciplinary debate, Oxford: Oxford University Press, pp. 351-83.
- Hand, D. J. (2006), “Classifier Technology and the Illusion of Progress”, Statistical science, 21(1), pp. 1-14.
- Hardt, M., Price, E., and Srebro, N. (2016), “Equality of Opportunity in Supervised Learning”, Advances in Neural Information Processing Systems 29 (NIPS 2016), [https://arxiv.org/abs/1610.02413]
- Hart, R.D. (2017), “If you’re not a white male, artificial intelligence’s use in healthcare could be dangerous”, Quartz (2017. 7. 10) at https://qz.com/1023448/if-youre-not-a-white-male-artificial-intelligences-use-in-healthcare-could-be-dangerous/
- Hintze, A. (2016), “Understanding the four types of AI, from reactive robots to self-aware beings” https://theconversation.com/understanding-the-four-types-of-ai-from-reactive-robots-to-self-aware-beings-67616
- The IEEE (Institute of Electrical and Electronics Engineers) Global Initiative on Ethics of Autonomous and Intelligent Systems (2017), “Ethically aligned design: A vision for prioritizing human well-being with autonomous and intelligent systems”, version 2. Accessed on: Oct. 14, 2018. [http://standards.ieee.org/develop/indconn/ec/ead_v2.pdf]
- Jeandesboz, J. (2014), “EU Border Control: Violence, Capture and Apparatus”, In Jansen, Y., Celikates, R., and De Bloois, J. eds., The Irregularization of Migration in Europe, London: Rowman & Littlefield International. pp. 87-103,

- Kahn, C. (2011.11.26.), "At LAPD, Predicting Crimes Before They Happen", National Public Radio.
[<https://www.npr.org/2011/11/26/142758000/at-lapd-predicting-crimes-before-they-happen>]
- Kirchner, L. (2017.12.18), "New York City Moves to Create Accountability for Algorithms", Propublica
[<https://www.propublica.org/article/new-york-city-moves-to-create-accountability-for-algorithms>]
- Kleinberg, J., Mullainathan, S., and Raghavan, M. (2016.09.11), "Inherent Trade-Offs in the Fair Determination of Risk Scores", in Proc. 8th Conf. on Innovations in Theoretical Computer Science (ITCS), 2017. [<https://arxiv.org/abs/1609.05807>]
- Knight, Will. (2017), "Forget Killer Robots—Bias Is the Real AI Danger: John Giannandrea, who leads AI at Google, is worried about intelligent systems learning human prejudices," MIT Technology Review (3 October).
<https://www.technologyreview.com/s/608986/forget-killer-robotsbias-is-the-real-ai-danger/>
- Kroll, J., Huey, J., Barocas, S., Felten, E., Reidenberg, J., Robinson, D., and Yu, H. (2017), "Accountable algorithms", University of Pennsylvania Law Review, 165(3), pp. 633-705.
- Kuhn, T. (1962), The Structure of Scientific Revolutions, Chicago: University of Chicago Press.
- Larson, J. and Angwin, L. (2016.07.29), "Technical Response to Northpointe", ProPublica.
[<https://www.propublica.org/article/technical-response-to-northpointe>]
- Leeang, M. M., Rutjes, A. W., Reitsma, J. B., Hooft, L., and Bossuyt, P. M. (2013), "Variation of a Test's Sensitivity and Specicity with Disease Prevalence", Canadian Medical Association Journal, 185(11), pp. 537-544.
- Leslie, S. W. (1993), The Cold War and American science: The military-industrial-academic complex at MIT and Stanford. Columbia University

Press;

- Liu, H. and Motoda., H. (2012), Feature selection for knowledge discovery and data mining. Springer Science & Business Media.
- Liu, Y. (2017.01.17), "The Accountability of AI — Case Study: Microsoft's Tay Experiment", Medium.
[<https://chatbotlife.com/the-accountability-of-ai-case-study-microsofts-tay-experiment-ad577015181f>]
- Michael, M., & Lupton, D. (2016), "Toward a manifesto for the 'public understanding of big data'." Public Understanding of Science, 25(1), pp. 104-116.
- Miller, Tim. (2018), "Explanation in Artificial Intelligence: Insights from the Social Sciences", [arXiv:1706.07269v2 [cs.AI] 24 May 2018].
- Mohler, G. O., Short, M. B., Brantingham, P. J., Schoenberg, F. P., and Tita. G. E. (2011), "Self-exciting Point Process Modeling of Crime", Journal of the American Statistical Association, 106(Issue 493), pp. 100-108.
- Murphy, E. and Maguire, M. (2015), "Speed, Time and Security: Anthropological Perspectives on Automated Border Control", Etnofoor, 27(2), pp. 157-177.
- Noble, S. U. (2018), Algorithms of Oppression: How search engines reinforce racism. New York: NYU Press.
- Perry, W. L., McInnis, B., Price, C. C., Smith, S. C., and Hollywood, J. S. (2013), Predictive policing: The Role of Crime Forecasting in Law Enforcement Operations, Rand Corporation.
- Poirier, L., Hidalgo, N., & Goldman, E. (2018), "Data Design Challenges and Opportunities for NYC Community Boards." BetaNYC.
[<https://beta.nyc/publications/data-design-challenges-and-opportunities-for-nyc-community-boards/>]
- Potzsch, H. (2015), "The emergence of Border: Bordering Bodies, Networks, and Machines", Environment and Planning D: Society and Space, 33(1), pp. 101-118.
- Sandvig, C., Hamilton, K., Karahalios, K., & Langbort, C. (2014), "Auditing Algorithms: Research Methods for Detecting Discrimination on Internet Platforms", In Data

- and Discrimination: Converting Critical Concerns into Productive: A preconference at the 64th Annual Meeting of the International Communication Association. Seattle, WA, 2014.
- Scherer, Matthew U. (2016), "Regulating Artificial Intelligence System: Risks Challenges, Competencies, And Strategies", *Harvard Journal of Law & Technology* 29(2), pp. 353-400.
- Schlehahn, E., Aichroth, P., Mann, S., Schreiner, R., Lang, U., Shepherd, I. D. H., and Wong, B. L. W. (2015), "Benefits and Pitfalls of Predictive Policing", *Proceedings of 2015 European Intelligence and Security Informatics Conference (EISIC 2015)*. [<https://ieeexplore.ieee.org/document/7379738>]
- SearchEnterpriseAI (2015), "algorithmic transparency", by Matthew Haughn. <https://searchenterpriseai.techtarget.com/definition/algorithmic-transparency>
- SearchEnterpriseAI (2017), "algorithmic accountability", by Matthew Haughn. <https://searchenterpriseai.techtarget.com/definition/algorithmic-accountability>
- Searle, John. (1980), "Minds, Brains, and Programs", *Behavioral and Brain Sciences* 3, pp. 417-424.
- Selbst, A. D. (2018), "Disparate Impact in Big Data Policing", *Georgia Law Review*, 52, pp. 109-195.
- Simonite, T. (2018.11.01), "When It Comes to Gorillas, Google Photos Remains Blind", *Wired*. [<https://www.wired.com/story/when-it-comes-to-gorillas-google-photos-remains-blind>]
- Toole, J. L., Eagle, N., and Plotkin, J. B. (2011), "Spatiotemporal correlations in Criminal Oense Records." *ACM Transactions on Intelligent Systems and Technology*, 2(4), pp. 1-38.
- Rubin, J. (2010.08.21.), "Stopping Crime Before It Starts", *Los Angeles Times*. [<http://articles.latimes.com/2010/aug/21/local/la-me-predictcrime-20100427-1>]
- Ulbricht, L. (2018), "When Big Data Meet Securitization. Algorithmic Regulation with Passenger Name Records", *European Journal for Security Research*, 3(2), pp.

1-23.

- Vermeulen, Ben, et al., (2018), "The Impact of Automation on Employment: Just the Usual Structural Change?" *Sustainability* 10, pp. 1-27.
- Wachter-Boettcher, S. (2017), *Technically Wrong: Sexist Apps, Biased Algorithms, and Other Threats of Toxic Tech*, New York : W.W. Norton and Co.
- Weisburd, D. (2008), "Place-based policing", *Ideas in American policing*, 9 (January 2008), pp. 1-15.
- Wilke, C. (2017), "Seeing and Unmaking Civilians in Afghanistan: Visual Technologies and Contested Professional Visions", *Science, Technology, & Human Values*, 42(6), pp. 1031-1060.
- Williams, B. A., Brooks, C. F., and Shmargad, Y. (2018), "How Algorithms Discriminate Based on Data They Lack", *Journal of Information Policy*, 8(1), pp. 78-115.
- Wilson, M. (2017), "Algorithms(and the) Everyday", *Information, Communication & Society*, 20(1), pp. 137-150.
- Wirth, N. (1975), *Algorithms + Data Structures = Programs*. Englewood Cliffs, Prentice-Hall.
- Zhanghizi, L. et al. (2018), "Achieving Non-Discrimination in Prediction," [arXiv:1703.00060v2 [cs.LG] 28 Mar 2018].